

# Revisão do Pré-projeto

**Disciplina: Trabalho de Conclusão de Curso I – BCC**

Caro, orientando,

segue abaixo o Termo de Compromisso, as DUAS revisões do seu pré-projeto contendo a avaliação do professor “avaliador” e professor “TCC1”, junto com as avaliações da defesa na banca de qualificação. É muito importante que revise com cuidado e discuta possíveis dúvidas decorrente das revisões com o seu professor orientador, e com o professor de TCC1. Sempre procure fazer todos os ajustes solicitados, até mesmo os menores detalhes, pois todos são importantes e irão refletir na sua nota nesta disciplina. Lembre de abrir localmente em um visualizador PDF para poder ver as anotações que foram feitas. E, aparecendo uma anotação feita por mim (prof. De TCC1) que inicie com “TF-...” (ex. “TF-ALÍNEA”) se refere a ajustes de formatação indicando que deve usar o estilo do Word correto do modelo do projeto.

Mas, caso o professor orientador julgue que algumas anotações das revisões não devam ser feitas, ou mesmo que sejam feitas de forma diferente a solicitada pelo revisor, anexe ao final do seu projeto a ficha “Projeto: Observações – Professor Orientador” disponível no material da disciplina, e justifique o motivo.

Lembrem que agora o limite de páginas do projeto é no máximo 12 (doze) páginas. E que a seção de “Revisão Bibliográfica” deve ser complementada (ampliada) usando subseções para cada assunto apresentado.

Atenciosamente,

---

**TERMO DE COMPROMISSO - BCC**

|   |   |
|---|---|
| <b>I – IDENTIFICAÇÃO DO ALUNO</b>   |   |
| Nome:   | CHRSTIAN TRISOTTO ALEGRI                          |
| Telefone:   | 47 992211463                                      |
| <b>II – IDENTIFICAÇÃO DO TRABALHO</b>   |   |
| Título:   | SISTEMAS MULTIAGENTES APLICADO A FUTEBOL DE ROBÔS |
|   |   |
| Orientador:   | AURÉLIO FAUSTINO HOPPE                            |
| Coorientador (se houver):   |   |
| <b>III – COMPROMISSO DE REALIZAÇÃO DO TCC</b>   |   |
| Eu (aluno),   | CHRSTIAN TRISOTTO ALEGRI                          |
| comprometo-me a realizar o trabalho proposto no semestre <u>2023/2</u> , de acordo com as normas e os prazos determinados pela FURB, conforme previsto na resolução nº.20/2016. |   |
| <b>IV – COMPROMISSO DE ORIENTAÇÃO</b>   |   |
| Eu (orientador),  | AURÉLIO FAUSTINO HOPPE                            |
| comprometo-me a orientar o trabalho proposto no semestre <u>2023/2</u> , de acordo com as normas e os prazos determinados pela FURB, conforme previsto na resolução nº.20/2016. |   |

|                                      |             |                      |
|--------------------------------------|-------------|----------------------|
| CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC |             |                      |
| ( X ) PRÉ-PROJETO                    | ( ) PROJETO | ANO/SEMESTRE: 2023/1 |

## SISTEMAS MULTIAGENTES APLICADO AO FUTEBOL DE ROBÔS

Christian Trisotto Alegri

Prof. Aurélio Faustino Hoppe – Orientador

### 1 INTRODUÇÃO

A robótica tem evoluído significativamente desde sua criação, há mais de 60 anos. Inicialmente, as máquinas eram projetadas para executar tarefas simples e repetitivas na indústria, mas hoje em dia, robôs são utilizados em uma variedade de áreas, incluindo saúde, segurança, exploração espacial, entre outras. Segundo Gupta (2013), as tecnologias de robótica têm avançado rapidamente nas últimas décadas, com o surgimento de novas técnicas de fabricação, sensores, atuadores, sistemas de controle e algoritmos de inteligência artificial, permitindo que robôs se tornem cada vez mais sofisticados e autônomos. A robótica tem o potencial de transformar radicalmente a maneira como as pessoas vivem e trabalham, e sua evolução continuará a impulsionar novas possibilidades e aplicações no futuro.

Dentro do campo interdisciplinar da robótica, uma área em rápido crescimento é a dos sistemas multiagentes, que são compostos por vários agentes autônomos que cooperam ou competem uns com os outros para atingir um objetivo comum. Um exemplo particularmente interessante de aplicação de sistemas multiagentes é o futebol de robôs, que tem o potencial de ser um desafio altamente complexo e desafiador para a inteligência artificial e a robótica. Segundo Huang *et al.* (2021), o futebol de robôs é uma das aplicações mais ambiciosas de sistemas multiagentes, que exige a integração de diversas habilidades e estratégias de tomada de decisão em um ambiente altamente dinâmico e imprevisível. O uso de sistemas multiagentes no futebol de robôs pode ajudar a resolver alguns dos principais desafios enfrentados pelos robôs individuais, como a limitação de sua percepção do ambiente e a dificuldade de tomada de decisões em tempo real.

Wooldridge (2009) destaca que um dos campos de aplicação mais fascinantes dessa tecnologia é o esporte. É nesse contexto que surge o futebol de robôs, uma competição que coloca em jogo a criatividade e a engenhosidade dos pesquisadores e entusiastas da robótica. O futebol de robôs é uma competição que envolve equipes de robôs jogando futebol em um campo especialmente projetado. Essa competição tem como objetivo incentivar o desenvolvimento de sistemas robóticos capazes de jogar futebol de forma autônoma. Para alcançar esse objetivo, os pesquisadores utilizam técnicas avançadas de inteligência artificial, como a visão computacional e os sistemas multiagentes.

De acordo com Chen *et al.* (2020), os Sistemas Multiagentes (SMA) são particularmente importantes no futebol de robôs, pois permitem que os robôs se comuniquem entre si e com o ambiente, coordenando suas ações para alcançar os objetivos do jogo. Esses sistemas são compostos por vários agentes autônomos que interagem entre si e com o ambiente em busca de alcançar os objetivos específicos do jogo. No entanto, a aplicação de sistemas multiagentes no futebol de robôs ainda enfrenta vários desafios, como a dinamicidade e imprevisibilidade do jogo, além das situações de conflito que podem ocorrer entre os robôs durante a partida. Por isso, é importante avaliar se os sistemas multiagentes podem ser utilizados de forma eficiente no futebol de robôs.

Tisue e Wilensky (2004) afirma que o desenvolvimento de simuladores é uma das principais ferramentas utilizadas para avaliar o desempenho de sistemas robóticos em diversas áreas de aplicação. No futebol de robôs, os simuladores são particularmente importantes para testar e avaliar novas estratégias e abordagens de forma segura e controlada. Dentre os simuladores utilizados para essa finalidade, destaca-se o NetLogo, uma plataforma de modelagem e simulação de sistemas complexos baseada em agentes. O NetLogo permite modelar e simular sistemas multiagentes de forma intuitiva e visual, além de possuir uma ampla variedade de ferramentas de análise.

Diante desse contexto, a pergunta de pesquisa deste trabalho é: sistemas multiagentes podem ser utilizados de forma eficiente no futebol de robôs, considerando as características dinâmicas e imprevisíveis do jogo e as situações de conflito que podem ocorrer entre os robôs?

#### 1.1 OBJETIVOS

O objetivo deste trabalho é utilizar a plataforma NetLogo para simular futebol de robôs a partir de sistemas multiagentes, com o propósito de avaliar diferentes estratégias de jogo e estudar o comportamento dos agentes em um ambiente controlado.

Os objetivos específicos são:

- modelar cada um dos elementos do jogo de futebol como um agente, definindo seu conhecimento,

- funções, comportamento e modos de interação no NetLogo;
- b) analisar o comportamento dos agentes em diferentes situações de jogo, como jogadas de ataque, defesa, cobranças de falta, entre outras;
- c) avaliar o desempenho do modelo em simulações e testes reais, utilizando métricas relevantes para futebol de robôs, como a taxa de sucesso em marcar gols, a precisão na tomada de decisão e a eficiência na coordenação de múltiplos robôs.

## 2 TRABALHOS CORRELATOS


Nesta seção são apresentados trabalhos com características semelhantes aos principais objetivos do estudo proposto. A subseção 2.1 apresenta um modelo para predição do comportamento dos jogadores (OMIDSHAFEI *et al.*, 2022). Na subseção 2.2 é descrito um método para treinar times de agentes virtuais a jogar futebol em alto nível (LIN *et al.*, 2023). Por fim, a subseção 2.3 apresenta uma abordagem para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente (HUANG *et al.*, 2021).

### 2.1 MULTIAGENT OFF-SCREEN BEHAVIOR PREDICTION IN FOOTBALL

Omidshafei *et al.* (2022) abordam o problema de imputação de séries temporais multiagente no contexto do futebol, onde subconjuntos de jogadores podem entrar e sair do campo de visão das imagens de vídeo transmitidas, enquanto os jogadores não observados continuam a interagir fora da tela. O objetivo dos autores era desenvolver um método de aprendizado de máquina que pudesse usar observações passadas e futuras de subconjuntos de jogadores de futebol para estimar as observações ausentes dos jogadores fora da tela.

A abordagem de Omidshafei *et al.* (2022), chamada de Graph Imputer, é um método de aprendizado de máquina que combina redes de grafo e autoencoders variacionais para permitir a aprendizagem de uma distribuição de trajetórias imputadas para jogadores de futebol fora da tela. O método envolve várias etapas. Primeiro, os autores constroem um grafo que representa as interações entre jogadores observados fora da tela. Os nós no grafo representam os jogadores e as arestas representam as interações entre eles. Em seguida, os autores treinam um AutoEncoder Variacional (AEV) nas trajetórias observadas dos jogadores para aprender uma representação de baixa dimensão do comportamento dos jogadores. O AEV é treinado para reconstruir as trajetórias observadas e gerar novas trajetórias que são semelhantes às observadas. Por fim, os autores usam a representação aprendida pelo AEV para codificar as trajetórias observadas dos jogadores e gerar trajetórias imputadas para os jogadores fora da tela. As trajetórias imputadas são geradas demonstrando a distribuição de comportamento dos jogadores aprendida condicionada às trajetórias observadas. A Figura 1 apresenta uma sequência de trajetórias geradas a partir do AEV.

Figura 1 – Visualização das trajetórias



Fonte: Omidshafei *et al.* (2022).

Para testar a eficácia de sua abordagem proposta, Omidshafei *et al.* (2022) realizaram experimentos a partir de jogos de futebol do mundo real. Eles utilizaram o módulo de câmera para simular a estimativa do estado dos jogadores fora da tela. Os autores avaliaram o método usando o *framework* de controle de campo (*pitch control*), ao qual depende de dados totalmente observados. Segundo Omidshafei *et al.* (2022), o controle de campo é um método para avaliar a habilidade de uma equipe em controlar o espaço no campo e restringir os movimentos da equipe adversária. Além disso, os autores também compararam o método com várias abordagens de ponta, incluindo aquelas feitas manualmente para o futebol, e mostraram que o método superou todas as outras abordagens em todas as métricas consideradas, conforme pode ser visto na Figura 2.

Figura 2 – Comparação com outros métodos

|            | Model                      | Pitch control MAE |
|------------|----------------------------|-------------------|
| Restricted | Role-Invariant VRNN        | 0.0447 ± 0.0204   |
|            | Bidir. Role-Invariant VRNN | 0.0209 ± 0.0096   |
| General    | LSTM                       | 0.0592 ± 0.0274   |
|            | Bidir. LSTM                | 0.0296 ± 0.0139   |
|            | Social LSTM <sup>†</sup>   | 0.0474 ± 0.0216   |
|            | Bidir. Social LSTM         | 0.0219 ± 0.0098   |
|            | GVRNN <sup>‡</sup>         | 0.0418 ± 0.0189   |
|            | Graph Imputer (Ours)       | 0.0207 ± 0.0094   |

Fonte: Omidshafei *et al.* (2022).

Omidshafei *et al.* (2022) concluem que a abordagem é eficaz na previsão do comportamento de jogadores fora da tela em jogos de futebol. Os autores também demonstraram que o método supera várias abordagens de ponta, incluindo aquelas feitas exclusivamente para o futebol. Porém, ressaltam que o método depende de dados das trajetórias verdadeiras, que nem sempre estão disponíveis na prática. Omidshafei *et al.* (2022) sugerem avaliar a eficácia do método em configurações mais realistas, onde apenas observações parciais do comportamento dos jogadores estão disponíveis. Como possíveis expansões do método, apontam a necessidade de incorporação de fontes adicionais de informação, como atributos de jogadores ou formações de equipe, para melhorar a precisão das previsões. Os autores também sugeriram que o método poderia ser aplicado a outros domínios, como dinâmica de multidões ou robótica, onde sistemas multiagentes são comuns.

## 2.2 TIZERO: MASTERING MULTI-AGENT FOOTBALL WITH CURRICULUM LEARNING AND SELF-PLAY

Lin *et al.* (2023) desenvolveram um método para treinar times de agentes virtuais a jogar futebol em alto nível. Os autores combinaram duas técnicas de aprendizado de máquina: aprendizado de currículo e autajogo. O aprendizado de currículo envolve aumentar gradualmente a dificuldade das tarefas que os agentes devem executar, enquanto o autajogo envolve fazê-los jogar uns contra os outros para melhorar suas estratégias ao longo do tempo. Ao utilizar essas técnicas, os autores esperavam desenvolver agentes que pudessem cooperar e competir efetivamente como um time, melhorando o desempenho geral do jogo de futebol.

Segundo Lin *et al.* (2023), na abordagem de aprendizado de currículo aumentou-se gradualmente a dificuldade das tarefas aos quais os agentes foram solicitados a executar, começando com tarefas mais simples, como passar e driblar, e progredindo para cenários mais complexos que exigiam coordenação e trabalho em equipe. De acordo com os autores, ao usar tal técnica, os agentes foram capazes de construir sobre suas experiências anteriores e melhorar gradualmente seu desempenho geral.

Lin *et al.* (2023) também utilizaram o autajogo para treinar seus agentes, onde cada agente jogava contra uma cópia de si mesmo com uma política ligeiramente modificada. Essa abordagem permitiu que os agentes aprendessem com suas próprias experiências e ajustassem suas políticas para melhorar seu desempenho ao longo do tempo. Neste caso, os autores utilizaram uma variante do algoritmo de Otimização de Política Próxima de Múltiplos Agentes (OPMA) para treinar seus agentes por meio do autajogo. Esse algoritmo permitiu que os agentes aprendessem com as experiências uns dos outros e ajustassem suas políticas com base em suas observações.

Além disso, Lin *et al.* (2023) introduziram uma abordagem inovadora para o autajogo que envolveu emparelhar os agentes de uma maneira que encorajava a cooperação em vez da competição. Essa abordagem, segundo os autores, resultou no desenvolvimento de agentes que poderiam trabalhar juntos efetivamente como um time, melhorando o desempenho do jogo de futebol. Em termos de resultados, Figura 3 apresenta a comparação do desempenho do TiZero em relação a vários baselines, incluindo TiKick, WeKick, JiDi\_3rd, Built-in, Hard Rule-Based-1 e Rule-Based-2.

Figura 3 – Comparação TiZero em relação a outros métodos baselines

| Metric          | TiZero (Ours)     | TiKick     | WeKick      | JiDi_3rd    | Built-in Hard | Rule-Based-1 | Rule-Based-2 |
|-----------------|-------------------|------------|-------------|-------------|---------------|--------------|--------------|
| Assist          | <b>1.30(1.02)</b> | 0.61(0.79) | 0.20(0.47)  | 0.35(0.62)  | 0.20(0.55)    | 0.28(0.59)   | 0.22(0.53)   |
| Pass            | <b>19.2(3.44)</b> | 6.99(2.71) | 5.33(2.44)  | 3.96(2.33)  | 11.5(4.63)    | 7.28(2.77)   | 7.50(3.12)   |
| Pass Rate       | <b>0.73(0.07)</b> | 0.65(0.17) | 0.53(0.18)  | 0.44(0.19)  | 0.66(0.12)    | 0.64(0.17)   | 0.63(0.19)   |
| Goal            | <b>3.42(1.69)</b> | 1.79(1.41) | 0.88(0.88)  | 1.43(1.34)  | 0.52(0.91)    | 0.73(0.69)   | 0.64(0.82)   |
| Goal Difference | <b>2.27(1.93)</b> | 0.71(2.08) | -0.47(1.68) | -0.02(2.14) | -1.06(1.93)   | -0.60(1.03)  | -0.71(1.45)  |
| Draw Rate (%)   | <b>8.50</b>       | 22.2       | 29.0        | 23.2        | 24.8          | 28.7         | 27.8         |
| Lose Rate (%)   | <b>6.50</b>       | 23.5       | 44.2        | 33.8        | 59.6          | 48.2         | 49.5         |
| Win Rate (%)    | <b>85.0</b>       | 54.3       | 26.8        | 43.0        | 15.6          | 23.1         | 22.7         |
| TrueSkill       | <b>45.2</b>       | 37.2       | 30.9        | 35.0        | 24.9          | 28.2         | 27.1         |

Fonte: Lin *et al.* (2023).

Segundo Lin *et al.* (2023), o TiZero superou todos os outros métodos em termos de assistência, passe, taxa de passe, gol, diferença de gol, taxa de empate, taxa de derrota, taxa de vitória e TrueSkill. O TiZero apresentou uma média de assistências de 1,30, uma média de passes de 19,2 e uma taxa de passe média de 0,73. Em termos de gols, TiZero marcou uma média de 3,42, com a segunda melhor pontuação de TiKick sendo apenas 1,79. Além disso, também teve a maior diferença de gols, com uma média de 2,27.


Lin *et al.* (2023) acrescentaram várias inovações em técnicas existentes para treinar agentes fortes para o modo de jogo GFootball 11 vs. 11 a partir do zero. Os autores concluem que o TiZero consegue superar todos os sistemas, por uma grande margem, em termos de taxa de vitória e diferença de gols, utilizando comportamentos de coordenação mais complexos do que seus anteriores. Por fim, os autores sugerem a aplicação do sistema para outros domínios e ambientes com cenários mais desafiadores.

### 2.3 TIKICK: TOWARDS PLAYING MULTI-AGENT FOOTBALL FULL GAMES FROM SINGLE-AGENT DEMONSTRATIONS

Huang *et al.* (2021) propuseram uma abordagem para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente. Eles buscavam resolver o desafio de treinar múltiplos agentes para jogar juntos como uma equipe em um ambiente dinâmico e complexo. Os autores combinaram técnicas de aprendizado por imitação e aprendizado por reforço, utilizando uma rede neural para modelar a política do agente e um ambiente de simulação para testar a eficácia da abordagem.

Huang *et al.* (2021) também elaboraram uma abordagem baseada em hierarquia para lidar com o problema da coordenação entre os agentes. Segundo os autores, tal abordagem treina uma política global que define a estratégia da equipe e políticas individuais para cada agente levando em consideração a interação entre eles. A média da diferença de gols em todos os cenários acadêmicos para o MAPPO (esquerda) e TiKick (direita). Os resultados mostram que o método proposto alcança pontuações melhores em todos os cenários, conforme pode ser visto na Figura 4.

Figura 4 – Comparação do MAPPO em relação ao TiKick



Fonte: Huang *et al.* (2021).

Segundo Huang *et al.* (2021), o método possui seis *baselines*, cada uma aprimorando a etapa anterior:

- CQL: CQL (Kumar *et al.*, 2020) é um algoritmo de aprendizado por reforço offline que tenta aprender valores Q conservadores adicionando penalidades nas funções Q;
- MABC: O algoritmo de clonagem de comportamento multiagente e usa uma perda supervisionada ingênua;
- $\alpha$ -Balance: Adiciona um peso de equilíbrio  $\alpha$  à baseline MABC para aliviar o problema do desequilíbrio de classes;
- Min Build-in: Adiciona uma perda de minimização de ação embutida à baseline anterior para forçar o jogador designado a escolher a ação não embutida;
- Buffer Ranking: Adiciona o truque de classificação de buffer para aproveitar as boas experiências passadas;
- Advantage Weight: Adiciona uma perda ponderada por vantagem à baseline anterior e obtém a perda final. Consiste no método utilizado no modelo final do TiKick.

De acordo com Huang *et al.* (2021), os resultados dos experimentos mostraram que a abordagem proposta é capaz de treinar múltiplos agentes para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente. A abordagem hierárquica proposta pelos autores também se mostrou eficaz para lidar com o problema da coordenação entre os agentes. Huang *et al.* (2021) também apresentaram uma análise mais detalhada dos resultados, incluindo uma análise de sensibilidade dos hiperparâmetros e uma análise da robustez da abordagem em relação a diferentes cenários de jogo. Segundo os autores, os resultados mostram que a abordagem proposta é capaz de lidar com diferentes configurações do ambiente e é robusta em relação a variações na densidade do agente e na complexidade do ambiente.

Huang *et al.* (2021) ressaltam que a abordagem hierárquica se mostrou eficaz para lidar com o problema da coordenação entre os agentes. No entanto, os autores também apontam algumas limitações em sua abordagem. Em particular, a abordagem requer que o agente aprenda com um único demonstrador, o que pode limitar a variedade de estratégias aprendidas pelos agentes. Além disso, a abordagem é específica para o ambiente de futebol multiagentes e pode não ser diretamente aplicável a outros ambientes multiagentes.

Por fim, Huang *et al.* (2021) sugerem como extensão a incorporação de mais fontes de informação, como informações de vídeo, e a exploração de técnicas de aprendizado por reforço com curadoria, que podem ajudar a melhorar a diversidade de estratégias aprendidas pelos agentes.

### 3 PROPOSTA DE MODELO

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo simular futebol de robôs no ambiente NetLogo utilizando sistemas multiagentes. A metodologia adotada para o desenvolvimento do modelo será detalhada, bem como os requisitos necessários para a sua implementação, além disso, serão apresentados os principais assuntos e fontes bibliográficas que irão fundamentar o estudo proposto.

#### 3.1 JUSTIFICATIVA

No Quadro 1 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas são cada trabalho e as linhas as características, com elas podemos entender como será solucionado os problemas propostos por este trabalho.

Quadro 1 – Comparativo dos trabalhos correlatos

| Características                        | Omidshafei <i>et al.</i> (2022)                                   | Lin <i>et al.</i> (2023)   | Huang <i>et al.</i> (2021)                    |
|--|---|--|---|
| Objetivo                               | Aprimorar o comportamento dos multiagentes fora do campo de visão | Desenvolver um algoritmo estado-da-arte voltado ao futebol de multiagentes | Aplicar AWR ao futebol de multiagentes        |
| Arquitetura de modelagem dos SMAs      | Graph Imputer   | JRPO   | MAPPO   |
| Linguagem de programação               | Não informou  | Python   | Python  |
| Cenários testados                      | Comparação com dados reais utilizando Pitch Control               | Partidas 11 vs 11, 5 minutos   | 1, 2 e 3 vs goleiro Escanteios, Contra-ataque |
| Forma de interação dos agentes         | LSTM bidirecional<br>Graph Network, VRNN                          | Recompensa   | Recompensa                                    |
| Quantidade de repetições por simulação | Não informou  | 3000   | 3000  |

Fonte: elaborado pelo autor.

A partir do Quadro 1 pode-se observar que Huang *et al.* (2021) propuseram uma abordagem mais simples e com menor complexidade computacional em comparação com TiZero. Eles apresentam um sistema de aprendizado por demonstração em que um único agente aprende a jogar futebol multiagente por meio de demonstrações de um jogador experiente. Os autores destacam que os resultados são promissores, embora ainda haja espaço para melhorias em termos de desempenho.

Em relação ao trabalho de Lin *et al.* (2023), é importante destacar que ele apresenta uma abordagem inovadora para treinamento de agentes em ambientes complexos de futebol multiagente, utilizando técnicas de aprendizado por reforço distribuído e autojogo. Os resultados obtidos mostraram que o TiZero superou amplamente os sistemas anteriores em termos de taxa de vitórias e diferença de gols, além de utilizar comportamentos de coordenação mais complexos.

Por fim, Omidshafei *et al.* (2022) apresentam uma abordagem diferente dos dois primeiros trabalhos, focando na predição de comportamentos fora da tela em jogos de futebol multiagente. Os autores propõem um modelo de aprendizado profundo que utiliza informações de rastreamento de jogadores para prever o comportamento de um jogador fora da tela, com resultados positivos. Em resumo, os três trabalhos apresentam abordagens diferentes para lidar com desafios em ambientes de futebol multiagente, cada um com suas vantagens e limitações. TiZero apresenta um alto desempenho, TiKick propõe uma abordagem mais simples e com menor complexidade computacional, enquanto o terceiro artigo foca na predição de comportamentos fora da tela.

Diante deste contexto, este trabalho é relevante por sua contribuição ao avanço da pesquisa em Sistemas Multiagentes (SMA) aplicado à robótica, especialmente em jogos de futebol de robôs. A implementação de uma arquitetura de SMA para coordenação das ações dos robôs em um jogo de futebol pode levar a uma melhoria significativa no desempenho do jogo, possibilitando a participação de equipes mais eficientes e com maior

capacidade de adaptação em competições de robótica. O estudo também pode contribuir para o desenvolvimento de sistemas robóticos mais flexíveis, adaptativos e autônomos, capazes de lidar com incertezas e ambientes dinâmicos. Além disso, a aplicação de SMA em jogos de futebol de robôs pode contribuir quanto a coordenação de múltiplos agentes em outros domínios, como em sistemas de transporte inteligente, logística e redes de sensores distribuídos.

### 3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O trabalho proposto deverá contemplar os seguintes Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF):

- a) permitir que o ambiente de jogo seja configurável, permitindo a definição de diferentes tipos de campo, tamanho, obstáculos, entre outros fatores que podem influenciar o desempenho dos robôs (RF);
- i) permitir a criação de equipes de robôs, com diferentes características, tais como velocidade, agilidade, habilidade de passe, etc (RF);
- j) permitir que os robôs sejam capazes de se comunicar entre si, trocando informações sobre a posição da bola, posição dos adversários, etc (RF);
- k) permitir a implementação de diferentes estratégias de jogo, tais como táticas de defesa, ataque, marcação, etc (RF);
- l) ter uma interface com o usuário intuitiva e amigável, permitindo a fácil configuração dos parâmetros do jogo, controle da partida e visualização das estatísticas (RF);
- m) ser capaz de simular partidas em tempo real, garantindo a fluidez da experiência do usuário (RNF);
- n) utilizar o paradigma de programação orientada a agentes (RNF);
- o) ser desenvolvido na linguagem de programação Python e na ferramenta NetLogo (RNF).

### 3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: escolher trabalhos correlatos e entender os assuntos relacionados à futebol de robôs e SMAs;
- b) definição do cenário de simulação: identificar os aspectos relevantes (estado global, dinâmicas globais/ entidades locais) que representem o ambiente dos agentes;
- c) definição de parâmetros iniciais: determinar as informações do ambiente, as quais devem ser fornecidas aos agentes para que estes possam selecionar as ações a serem praticadas;
- d) modelagem dos agentes: determinar as ações básicas dos agentes, e suas reações às entidades do ambiente;
- e) definição e escolha da arquitetura de agentes: pesquisar as principais arquiteturas que possibilitem explorar a conexão entre o comportamento ao nível micro dos indivíduos e os padrões ao nível macro, escolhendo o mais adequado para o desenvolvimento do trabalho;
- f) implementação: desenvolver o artefato computacional de simulação multiagente a partir dos itens (b) até (e), considerando inicialmente a arquitetura BDI, utilizando a linguagem de programação Python e a ferramenta NetLogo;
- g) validação e calibragem: avaliar o comportamento e capacidade dos agentes em se adaptar a diferentes situações e estratégias de jogo. Para isso, serão utilizadas métricas relevantes para futebol de robôs, como a taxa de sucesso em marcar gols, a precisão na tomada de decisão e a eficiência na coordenação de múltiplos robôs.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem realizadas

| etapas / quinzenas                            | 2023 |   |      |   |      |   |      |   |      |   |
|---|------|---|------|---|------|---|------|---|------|---|
|   | jul. |   | ago. |   | set. |   | out. |   | nov. |   |
|   | 1    | 2 | 1    | 2 | 1    | 2 | 1    | 2 | 1    | 2 |
| levantamento bibliográfico                    |      |   |      |   |      |   |      |   |      |   |
| definição do cenário de simulação             |      |   |      |   |      |   |      |   |      |   |
| definição de parâmetros iniciais              |      |   |      |   |      |   |      |   |      |   |
| modelagem do agente                           |      |   |      |   |      |   |      |   |      |   |
| definição e escolha da arquitetura de agentes |      |   |      |   |      |   |      |   |      |   |
| implementação                                 |      |   |      |   |      |   |      |   |      |   |
| validação e calibragem                        |      |   |      |   |      |   |      |   |      |   |

Fonte: elaborado pelo autor.



#### 4 REVISÃO BIBLIOGRÁFICA

Nesta seção serão abordados brevemente os principais assuntos que fundamentarão o estudo a ser realizado: Futebol de robôs e Sistemas Multiagentes.

Segundo Kitano (1999), o futebol de robôs é uma das áreas mais importantes no campo da robótica, sendo amplamente estudado e pesquisado nos últimos anos. Trata-se de um esporte em que robôs jogam futebol em um campo especial, geralmente seguindo regras semelhantes às do futebol humano. Um dos primeiros trabalhos sobre futebol de robôs foi realizado por Hiroaki Kitano em 1993, que criou a primeira liga de futebol de robôs, a RoboCup. Desde então, essa competição tem sido realizada anualmente em todo o mundo e se tornou uma plataforma importante para o desenvolvimento e aprimoramento de técnicas em robótica.

De acordo com Kitano (1999), existem diversas abordagens para a implementação de um time de futebol de robôs, que variam desde técnicas baseadas em visão computacional até técnicas baseadas em aprendizado de máquina. Entre as técnicas de visão computacional, é possível citar o uso de câmeras para a identificação da bola e dos jogadores, enquanto que as técnicas baseadas em aprendizado de máquina geralmente envolvem a criação de modelos que podem aprender a jogar futebol com base em exemplos. Algumas das principais áreas de pesquisa em futebol de robôs incluem o desenvolvimento de técnicas de percepção, como a detecção e rastreamento da bola e dos jogadores, o desenvolvimento de técnicas de planejamento de trajetória, o desenvolvimento de técnicas de controle de robôs e o desenvolvimento de técnicas de tomada de decisão.

Para SichMan (1995), nos últimos anos, a aplicação de técnicas de inteligência artificial, como o aprendizado por reforço, aprendizado profundo e sistemas multiagentes, tem sido cada vez mais explorada na área de futebol de robôs. A ideia por trás de sistemas multiagentes é definir agentes que consigam resolver serviços complexos. Agentes podem definir seus próprios objetivos e planos, assim como podem realizar interações complexas com os demais agentes. Os agentes são independentes de uma organização de solução de problema única, tanto que eles podem definir ou até mesmo mudar essa organização conforme a resolução do problema for acontecendo. De qualquer forma, para que isso ocorra, os agentes precisam ser capazes de perceber as mudanças e agir no ambiente no qual eles estão inseridos. Eles também têm a capacidade de levar em conta os objetivos e as habilidades de outros agentes, para assim resolver o problema de forma cooperativa.

De acordo com Juchem e Bastos (2001), a estrutura e a arquitetura de modelagem de agentes podem variar de acordo com os objetivos desse agente. A primeira coisa a se fazer para definir qual arquitetura utilizar está baseada em entender qual o tipo de agente do qual se está tratando. Os agentes podem ser cognitivos, que podem ser considerados racionais e tem a capacidade de escolher as ações a executar, dentre as existentes em seu repertório, para chegar em seu objetivo, bem como podem ser reativos, que não necessariamente são agentes racionais, pois eles podem ter seu comportamento definido através de um padrão estímulo-resposta (JUCHEM; BASTOS, 2001). A partir dos dois tipos de agentes descritos, é possível desenvolver uma arquitetura cognitiva (ou deliberativa), que adota o princípio de que agentes são racionais, definindo assim que os agentes cognitivos têm suas deliberações feitas por meio de um processo baseado em raciocínio lógico, escolhendo sua ação por meio da representação simbólica do mundo, um plano e uma função utilizada para a ação. Também pode-se desenvolver uma arquitetura funcional, na qual o agente é composto por módulos que representam cada uma das funcionalidades necessárias para sua operação. Outra arquitetura tradicional muito comum é a arquitetura BDI, que considera três estados mentais do agente: Crença, Desejo e Interação (*Belief, Desire and Intention*). A arquitetura BDI permite que o agente possa decidir, momento a momento, qual ação desempenhar na direção de seus objetivos (JUCHEM; BASTOS, 2001).

#### REFERÊNCIAS

- CHEN, Liang *et al.* **Survey of Multi-Agent Strategy Based on Reinforcement Learning**. Chinese Control And Decision Conference (CCDC), Hefei, China, p. 604-609, 2020. Disponível em: <<https://ieeexplore.ieee.org/document/9164559>>. Acesso em: 28 abr. 2023.
- GUPTA, Sen *et al.* **Recent Advances in Robotics and Automation**. 2013. Disponível em: <[https://www.researchgate.net/publication/321613321\\_Recent\\_Advances\\_in\\_Robotics\\_and\\_Automation](https://www.researchgate.net/publication/321613321_Recent_Advances_in_Robotics_and_Automation)>. Acesso em: 01 maio 2023.
- HUANG, Shiyu *et al.* **TiKick: Toward Playing Multi-agent Football Full Games from Single-agent Demonstrations**. 2021. Disponível em: <<https://arxiv.org/abs/2110.04507>>. Acesso em: 16 abr. 2023.
- JUCHEM, Murilo; BASTOS, Ricardo Melo. **Arquitetura de Agentes**. Relatório Técnico, n. 013 arquivado na Pró-Reitoria de Pesquisa, Faculdade de Informática PUCRS, Porto Alegre. 2001. Disponível em: <<https://www.pucrs.br/facin-prov/wp-content/uploads/sites/19/2016/03/tr013.pdf>>. Acesso em: 12 maio 2013.
- LIN, Fanqi *et al.* **TiZero: Mastering Multi-Agent Football with Curriculum Learning and Self-Play**. 2023. Disponível em: <<https://arxiv.org/abs/2302.07515>>. Acesso em 16 abr. 2023.
- KITANO, Hiroaki *et al.* **RoboCup: Today and tomorrow—What we have learned**. Artificial Intelligence, Volume 110, Issue 2. 1999. Disponível em <<https://www.cs.cmu.edu/~mmv/papers/AIJ99-robocup.pdf>>. Acesso em: 16 maio 2023.

KUMAR, Aviral *et al.* **Conservative q-learning for offline reinforcement learning**. 2020. Disponível em: <<https://arxiv.org/abs/2006.04779>>. Acesso em: 15 maio 2023.

OMIDSHAFIEI, Shayegan *et al.* **Multiagent off-screen behavior prediction in football**. Sci Rep 12, 8638 (2022). . Disponível em: <https://doi.org/10.1038/s41598-022-12547-0> Acesso em: 15 maio 2023.

SICHMAN, Jaime S. **Exploiting Social Reasoning to Enhance Adaption in Open-Multi-Agent Systems**, São Paulo, SP, 1995. Disponível em <[https://www.researchgate.net/publication/220974703\\_Exploiting\\_Social\\_Reasoning\\_to\\_Enhance\\_Adaption\\_in\\_Open-Multi-Agent\\_Systems](https://www.researchgate.net/publication/220974703_Exploiting_Social_Reasoning_to_Enhance_Adaption_in_Open-Multi-Agent_Systems)>. Acesso em: 09 maio 2023.

TISUE, Seth; WILENSKY, Uri. **NetLogo: A simple environment for modeling complexity**. International Conference on Complex Systems. In: Agent 2004 Conference on Social Dynamics: Interaction, Reflexivity and Emergence. 2004. Disponível em <[https://www.researchgate.net/publication/230818221\\_NetLogo\\_A\\_simple\\_environment\\_for\\_modeling\\_complexity](https://www.researchgate.net/publication/230818221_NetLogo_A_simple_environment_for_modeling_complexity)>. Acesso em 14 maio 2013

WOOLDRIDGE, Michael. **An Introduction to MultiAgent Systems**. 2 ed. Estados Unidos: Wiley, 2009.

## FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR AVALIADOR – PRÉ-PROJETO

Avaliador(a): **Miguel Alexandre Wisintainer**

Atenção: quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

| ASPECTOS AVALIADOS     |  | Atende | atende parcialmente | não atende |
|------------------------|--|--------|---------------------|------------|
| ASPECTOS TÉCNICOS      | 1. INTRODUÇÃO<br>O tema de pesquisa está devidamente contextualizado/delimitado?   | x      |                     |            |
|                        | O problema está claramente formulado?  | x      |                     |            |
|                        | 2. OBJETIVOS<br>O objetivo principal está claramente definido e é passível de ser alcançado?   | x      |                     |            |
|                        | Os objetivos específicos são coerentes com o objetivo principal?   | x      |                     |            |
|                        | 3. TRABALHOS CORRELATOS<br>São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?              | x      |                     |            |
|                        | 4. JUSTIFICATIVA<br>Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada? | x      |                     |            |
|                        | São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?  | x      |                     |            |
|                        | São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?   | x      |                     |            |
|                        | 5. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO<br>Os requisitos funcionais e não funcionais foram claramente descritos?                               | x      |                     |            |
|                        | 6. METODOLOGIA<br>Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?  | x      |                     |            |
| ASPECTOS METODOLÓGICOS | Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?   | x      |                     |            |
|                        | 7. REVISÃO BIBLIOGRÁFICA<br>Os assuntos apresentados são suficientes e têm relação com o tema do TCC?  | x      |                     |            |
|                        | As referências contemplam adequadamente os assuntos abordados (são indicadas obras atualizadas e as mais importantes da área)?                               | x      |                     |            |
|                        | 8. LINGUAGEM USADA (redação)<br>O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?                | x      |                     |            |
|                        | A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?  | x      |                     |            |

|                                      |             |                      |
|--------------------------------------|-------------|----------------------|
| CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC |             |                      |
| ( X ) PRÉ-PROJETO                    | ( ) PROJETO | ANO/SEMESTRE: 2023/1 |

## SISTEMAS MULTIAGENTES APLICADO AO FUTEBOL DE ROBÔS

Christian Trisotto Alegri

Prof. Aurélio Faustino Hoppe – Orientador

### 1 INTRODUÇÃO

A robótica tem evoluído significativamente desde sua criação, há mais de 60 anos. Inicialmente, as máquinas eram projetadas para executar tarefas simples e repetitivas na indústria, mas hoje em dia, robôs são utilizados em uma variedade de áreas, incluindo saúde, segurança, exploração espacial, entre outras. Segundo Gupta (2013), as tecnologias de robótica têm avançado rapidamente nas últimas décadas, com o surgimento de novas técnicas de fabricação, sensores, atuadores, sistemas de controle e algoritmos de inteligência artificial, permitindo que robôs se tornem cada vez mais sofisticados e autônomos. A robótica tem o potencial de transformar radicalmente a maneira como as pessoas vivem e trabalham, e sua evolução continuará a impulsionar novas possibilidades e aplicações no futuro.

Dentro do campo interdisciplinar da robótica, uma área em rápido crescimento é a dos sistemas multiagentes, que são compostos por vários agentes autônomos que cooperam ou competem uns com os outros para atingir um objetivo comum. Um exemplo particularmente interessante de aplicação de sistemas multiagentes é o futebol de robôs, que tem o potencial de ser um desafio altamente complexo e desafiador para a inteligência artificial e a robótica. Segundo Huang *et al.* (2021), o futebol de robôs é uma das aplicações mais ambiciosas de sistemas multiagentes, que exige a integração de diversas habilidades e estratégias de tomada de decisão em um ambiente altamente dinâmico e imprevisível. O uso de sistemas multiagentes no futebol de robôs pode ajudar a resolver alguns dos principais desafios enfrentados pelos robôs individuais, como a limitação de sua percepção do ambiente e a dificuldade de tomada de decisões em tempo real.

Wooldridge (2009) destaca que um dos campos de aplicação mais fascinantes dessa tecnologia é o esporte. É nesse contexto que surge o futebol de robôs, uma competição que coloca em jogo a criatividade e a engenhosidade dos pesquisadores e entusiastas da robótica. O futebol de robôs é uma competição que envolve equipes de robôs jogando futebol em um campo especialmente projetado. Essa competição tem como objetivo incentivar o desenvolvimento de sistemas robóticos capazes de jogar futebol de forma autônoma. Para alcançar esse objetivo, os pesquisadores utilizam técnicas avançadas de inteligência artificial, como a visão computacional e os sistemas multiagentes.

De acordo com Chen *et al.* (2020), os Sistemas Multiagentes (SMA) são particularmente importantes no futebol de robôs, pois permitem que os robôs se comuniquem entre si e com o ambiente, coordenando suas ações para alcançar os objetivos do jogo. Esses sistemas são compostos por vários agentes autônomos que interagem entre si e com o ambiente em busca de alcançar os objetivos específicos do jogo. No entanto, a aplicação de sistemas multiagentes no futebol de robôs ainda enfrenta vários desafios, como a dinamicidade e imprevisibilidade do jogo, além das situações de conflito que podem ocorrer entre os robôs durante a partida. Por isso, é importante avaliar se os sistemas multiagentes podem ser utilizados de forma eficiente no futebol de robôs.

Tisue e Wilensky (2004) afirma que o desenvolvimento de simuladores é uma das principais ferramentas utilizadas para avaliar o desempenho de sistemas robóticos em diversas áreas de aplicação. No futebol de robôs, os simuladores são particularmente importantes para testar e avaliar novas estratégias e abordagens de forma segura e controlada. Dentre os simuladores utilizados para essa finalidade, destaca-se o NetLogo, uma plataforma de modelagem e simulação de sistemas complexos baseada em agentes. O NetLogo permite modelar e simular sistemas multiagentes de forma intuitiva e visual, além de possuir uma ampla variedade de ferramentas de análise.

Diante desse contexto, a pergunta de pesquisa deste trabalho é: sistemas multiagentes podem ser utilizados de forma eficiente no futebol de robôs, considerando as características dinâmicas e imprevisíveis do jogo e as situações de conflito que podem ocorrer entre os robôs?

#### 1.1 OBJETIVOS

O objetivo deste trabalho é utilizar a plataforma NetLogo para simular futebol de robôs a partir de sistemas multiagentes, com o propósito de avaliar diferentes estratégias de jogo e estudar o comportamento dos agentes em um ambiente controlado.

Os objetivos específicos são:

- modelar cada um dos elementos do jogo de futebol como um agente, definindo seu conhecimento,

- funções, comportamento e modos de interação no NetLogo;
- b) analisar o comportamento dos agentes em diferentes situações de jogo, como jogadas de ataque, defesa, cobranças de falta, entre outras;
- c) avaliar o desempenho do modelo em simulações e testes reais, utilizando métricas relevantes para futebol de robôs, como a taxa de sucesso em marcar gols, a precisão na tomada de decisão e a eficiência na coordenação de múltiplos robôs.

## 2 TRABALHOS CORRELATOS

Nesta seção são apresentados trabalhos com características semelhantes aos principais objetivos do estudo proposto. A subseção 2.1 apresenta um modelo para predição do comportamento dos jogadores (OMIDSHAFEI *et al.*, 2022). Na subseção 2.2 é descrito um método para treinar times de agentes virtuais a jogar futebol em alto nível (LIN *et al.*, 2023). Por fim, a subseção 2.3 apresenta uma abordagem para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente (HUANG *et al.*, 2021).

### 2.1 MULTIAGENT OFF-SCREEN BEHAVIOR PREDICTION IN FOOTBALL

Omidshafei *et al.* (2022) abordam o problema de imputação de séries temporais multiagente no contexto do futebol, onde subconjuntos de jogadores podem entrar e sair do campo de visão das imagens de vídeo transmitidas, enquanto os jogadores não observados continuam a interagir fora da tela. O objetivo dos autores era desenvolver um método de aprendizado de máquina que pudesse usar observações passadas e futuras de subconjuntos de jogadores de futebol para estimar as observações ausentes dos jogadores fora da tela.

A abordagem de Omidshafei *et al.* (2022), chamada de Graph Imputer, é um método de aprendizado de máquina que combina redes de grafo e *autoencoders* variacionais para permitir a aprendizagem de uma distribuição de trajetórias imputadas para jogadores de futebol fora da tela. O método envolve várias etapas. Primeiro, os autores constroem um grafo que representa as interações entre jogadores observados fora da tela. Os nós no grafo representam os jogadores e as arestas representam as interações entre eles. Em seguida, os autores treinam um AutoEncoder Variacional (AEV) nas trajetórias observadas dos jogadores para aprender uma representação de baixa dimensão do comportamento dos jogadores. O AEV é treinado para reconstruir as trajetórias observadas e gerar novas trajetórias que são semelhantes às observadas. Por fim, os autores usam a representação aprendida pelo AEV para codificar as trajetórias observadas dos jogadores e gerar trajetórias imputadas para os jogadores fora da tela. As trajetórias imputadas são geradas demonstrando a distribuição de comportamento dos jogadores aprendida condicionada às trajetórias observadas. A Figura 1 apresenta uma sequência de trajetórias geradas a partir do AEV.

Comentado [DSdR1]: Itálico.

Figura 1 – Visualização das trajetórias



Fonte: Omidshafei *et al.* (2022).

Para testar a eficácia de sua abordagem proposta, Omidshafei *et al.* (2022) realizaram experimentos a partir de jogos de futebol do mundo real. Eles utilizaram o módulo de câmera para simular a estimativa do estado dos jogadores fora da tela. Os autores avaliaram o método usando o *framework* de controle de campo (*pitch control*), ao qual depende de dados totalmente observados. Segundo Omidshafei *et al.* (2022), o controle de campo é um método para avaliar a habilidade de uma equipe em controlar o espaço no campo e restringir os movimentos da equipe adversária. Além disso, os autores também compararam o método com várias abordagens de ponta, incluindo aquelas feitas manualmente para o futebol, e mostraram que o método superou todas as outras abordagens em todas as métricas consideradas, conforme pode ser visto na Figura 2.

Figura 2 – Comparação com outros métodos

|            | Model                      | Pitch control MAE |
|------------|----------------------------|-------------------|
| Restricted | Role-invariant VRNN        | 0.0447 ± 0.0204   |
|            | Bidir. Role-invariant VRNN | 0.0209 ± 0.0096   |
| General    | LSTM                       | 0.0592 ± 0.0274   |
|            | Bidir. LSTM                | 0.0296 ± 0.0139   |
|            | Social LSTM <sup>†</sup>   | 0.0474 ± 0.0216   |
|            | Bidir. Social LSTM         | 0.0219 ± 0.0098   |
|            | GVRNN <sup>‡</sup>         | 0.0418 ± 0.0189   |
|            | Graph Imputer (Ours)       | 0.0207 ± 0.0094   |

Fonte: Omidshafiei *et al.* (2022).

Omidshafiei *et al.* (2022) concluem que a abordagem é eficaz na previsão do comportamento de jogadores fora da tela em jogos de futebol. Os autores também demonstraram que o método supera várias abordagens de ponta, incluindo aquelas feitas exclusivamente para o futebol. Porém, ressaltam que o método depende de dados das trajetórias verdadeiras, que nem sempre estão disponíveis na prática. Omidshafiei *et al.* (2022) sugerem avaliar a eficácia do método em configurações mais realistas, onde apenas observações parciais do comportamento dos jogadores estão disponíveis. Como possíveis expansões do método, apontam a necessidade de incorporação de fontes adicionais de informação, como atributos de jogadores ou formações de equipe, para melhorar a precisão das previsões. Os autores também sugeriram que o método poderia ser aplicado a outros domínios, como dinâmica de multidões ou robótica, onde sistemas multiagentes são comuns.

## 2.2 TIZERO: MASTERING MULTI-AGENT FOOTBALL WITH CURRICULUM LEARNING AND SELF-PLAY

Lin *et al.* (2023) desenvolveram um método para treinar times de agentes virtuais a jogar futebol em alto nível. Os autores combinaram duas técnicas de aprendizado de máquina: aprendizado de currículo e autajogo. O aprendizado de currículo envolve aumentar gradualmente a dificuldade das tarefas que os agentes devem executar, enquanto o autajogo envolve fazê-los jogar uns contra os outros para melhorar suas estratégias ao longo do tempo. Ao utilizar essas técnicas, os autores esperavam desenvolver agentes que pudessem cooperar e competir efetivamente como um time, melhorando o desempenho geral do jogo de futebol.

Segundo Lin *et al.* (2023), na abordagem de aprendizado de currículo aumentou-se gradualmente a dificuldade das tarefas aos quais os agentes foram solicitados a executar, começando com tarefas mais simples, como passar e driblar, e progredindo para cenários mais complexos que exigiam coordenação e trabalho em equipe. De acordo com os autores, ao usar tal técnica, os agentes foram capazes de construir sobre suas experiências anteriores e melhorar gradualmente seu desempenho geral.

Lin *et al.* (2023) também utilizaram o autajogo para treinar seus agentes, onde cada agente jogava contra uma cópia de si mesmo com uma política ligeiramente modificada. Essa abordagem permitiu que os agentes aprendessem com suas próprias experiências e ajustassem suas políticas para melhorar seu desempenho ao longo do tempo. Neste caso, os autores utilizaram uma variante do algoritmo de Otimização de Política Próxima de Múltiplos Agentes (OPMA) para treinar seus agentes por meio do autajogo. Esse algoritmo permitiu que os agentes aprendessem com as experiências uns dos outros e ajustassem suas políticas com base em suas observações.

Além disso, Lin *et al.* (2023) introduziram uma abordagem inovadora para o autajogo que envolveu emparelhar os agentes de uma maneira que encorajava a cooperação em vez da competição. Essa abordagem, segundo os autores, resultou no desenvolvimento de agentes que poderiam trabalhar juntos efetivamente como um time, melhorando o desempenho do jogo de futebol. Em termos de resultados, Figura 3 apresenta a comparação do desempenho do TiZero em relação a vários *baselines*, incluindo TiKick, WeKick, JiDi\_3rd, Built-in, Hard Rule-Based-1 e Rule-Based-2.

Figura 3 – Comparação TiZero em relação a outros métodos *baselines*

| Metric          | TiZero (Ours)     | TiKick     | WeKick      | JiDi_3rd    | Built-in Hard | Rule-Based-1 | Rule-Based-2 |
|-----------------|-------------------|------------|-------------|-------------|---------------|--------------|--------------|
| Assist          | <b>1.30(1.02)</b> | 0.61(0.79) | 0.20(0.47)  | 0.35(0.62)  | 0.20(0.55)    | 0.28(0.59)   | 0.22(0.53)   |
| Pass            | <b>19.2(3.44)</b> | 6.99(2.71) | 5.33(2.44)  | 3.96(2.33)  | 11.5(4.63)    | 7.28(2.77)   | 7.50(3.12)   |
| Pass Rate       | <b>0.73(0.07)</b> | 0.65(0.17) | 0.53(0.18)  | 0.44(0.19)  | 0.66(0.12)    | 0.64(0.17)   | 0.63(0.19)   |
| Goal            | <b>3.42(1.69)</b> | 1.79(1.41) | 0.88(0.88)  | 1.43(1.34)  | 0.52(0.91)    | 0.73(0.69)   | 0.64(0.82)   |
| Goal Difference | <b>2.27(1.93)</b> | 0.71(2.08) | -0.47(1.68) | -0.02(2.14) | -1.06(1.93)   | -0.60(1.03)  | -0.71(1.45)  |
| Draw Rate (%)   | <b>8.50</b>       | 22.2       | 29.0        | 23.2        | 24.8          | 28.7         | 27.8         |
| Lose Rate (%)   | <b>6.50</b>       | 23.5       | 44.2        | 33.8        | 59.6          | 48.2         | 49.5         |
| Win Rate (%)    | <b>85.0</b>       | 54.3       | 26.8        | 43.0        | 15.6          | 23.1         | 22.7         |
| TrueSkill       | <b>45.2</b>       | 37.2       | 30.9        | 35.0        | 24.9          | 28.2         | 27.1         |

Fonte: Lin *et al.* (2023).

Comentado [DSdR2]: Itálico.

Comentado [DSdR3]: Itálico.

Segundo Lin *et al.* (2023), o TiZero superou todos os outros métodos em termos de assistência, passe, taxa de passe, gol, diferença de gol, taxa de empate, taxa de derrota, taxa de vitória e TrueSkill. O TiZero apresentou uma média de assistências de 1,30, uma média de passes de 19,2 e uma taxa de passe média de 0,73. Em termos de gols, TiZero marcou uma média de 3,42, com a segunda melhor pontuação de TiKick sendo apenas 1,79. Além disso, também teve a maior diferença de gols, com uma média de 2,27.


Lin *et al.* (2023) acrescentaram várias inovações em técnicas existentes para treinar agentes fortes para o modo de jogo GFootball 11 vs. 11 a partir do zero. Os autores concluem que o TiZero consegue superar todos os sistemas, por uma grande margem, em termos de taxa de vitória e diferença de gols, utilizando comportamentos de coordenação mais complexos do que seus anteriores. Por fim, os autores sugerem a aplicação do sistema para outros domínios e ambientes com cenários mais desafiadores.

### 2.3 TIKICK: TOWARDS PLAYING MULTI-AGENT FOOTBALL FULL GAMES FROM SINGLE-AGENT DEMONSTRATIONS

Huang *et al.* (2021) propuseram uma abordagem para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente. Eles buscavam resolver o desafio de treinar múltiplos agentes para jogar juntos como uma equipe em um ambiente dinâmico e complexo. Os autores combinaram técnicas de aprendizado por imitação e aprendizado por reforço, utilizando uma rede neural para modelar a política do agente e um ambiente de simulação para testar a eficácia da abordagem.

Huang *et al.* (2021) também elaboraram uma abordagem baseada em hierarquia para lidar com o problema da coordenação entre os agentes. Segundo os autores, tal abordagem treina uma política global que define a estratégia da equipe e políticas individuais para cada agente levando em consideração a interação entre eles. A média da diferença de gols em todos os cenários acadêmicos para o MAPPO (esquerda) e TiKick (direita). Os resultados mostram que o método proposto alcança pontuações melhores em todos os cenários, conforme pode ser visto na Figura 4.

Figura 4 – Comparação do MAPPO em relação ao TiKick



Fonte: Huang *et al.* (2021).

Segundo Huang *et al.* (2021), o método possui seis *baselines*, cada uma aprimorando a etapa anterior:

- CQL: CQL (Kumar *et al.*, 2020) é um algoritmo de aprendizado por reforço offline-off-line que tenta aprender valores Q conservadores adicionando penalidades nas funções Q;
- MABC: Q-o algoritmo de clonagem de comportamento multiagente e usa uma perda supervisionada ingênua;
- $\alpha$ -Balance: Adieiona-adiciona um peso de equilíbrio  $\alpha$  à baseline MABC para aliviar o problema do desequilíbrio de classes;
- Min Build-in: Adieiona-adiciona uma perda de minimização de ação embutida à baseline anterior para forçar o jogador designado a escolher a ação não embutida;
- Buffer Ranking: Adieiona-adiciona o truque de classificação de buffer para aproveitar as boas experiências passadas;
- Advantage Weight: Adieiona-adiciona uma perda ponderada por vantagem à baseline anterior e obtém a perda final. Consiste no método utilizado no modelo final do TiKick.

De acordo com Huang *et al.* (2021), os resultados dos experimentos mostraram que a abordagem proposta é capaz de treinar múltiplos agentes para jogar partidas completas de futebol multiagentes a partir de demonstrações de um único agente. A abordagem hierárquica proposta pelos autores também se mostrou eficaz para lidar com o problema da coordenação entre os agentes. Huang *et al.* (2021) também apresentaram uma análise mais detalhada dos resultados, incluindo uma análise de sensibilidade dos hiperparâmetros e uma análise da robustez da abordagem em relação a diferentes cenários de jogo. Segundo os autores, os resultados mostram que a abordagem proposta é capaz de lidar com diferentes configurações do ambiente e é robusta em relação a variações na densidade do agente e na complexidade do ambiente.

Huang *et al.* (2021) ressaltam que a abordagem hierárquica se mostrou eficaz para lidar com o problema da coordenação entre os agentes. No entanto, os autores também apontam algumas limitações em sua abordagem. Em particular, a abordagem requer que o agente aprenda com um único demonstrador, o que pode limitar a variedade de estratégias aprendidas pelos agentes. Além disso, a abordagem é específica para o ambiente de futebol multiagentes e pode não ser diretamente aplicável a outros ambientes multiagentes.

Por fim, Huang *et al.* (2021) sugerem como extensão a incorporação de mais fontes de informação, como informações de vídeo, e a exploração de técnicas de aprendizado por reforço com curadoria, que podem ajudar a melhorar a diversidade de estratégias aprendidas pelos agentes.

### 3 PROPOSTA DE MODELO

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo simular futebol de robôs no ambiente NetLogo utilizando sistemas multiagentes. A metodologia adotada para o desenvolvimento do modelo será detalhada, bem como os requisitos necessários para a sua implementação, ~~além disso, serão apresentados os principais assuntos e fontes bibliográficas que irão fundamentar o estudo proposto.~~

#### 3.1 JUSTIFICATIVA

No Quadro 1 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas são cada trabalho e as linhas as características, com elas podemos entender como será solucionado os problemas propostos por este trabalho.

Quadro 1 – Comparativo dos trabalhos correlatos

| Características \ Trabalhos correlatos | Omidshafei <i>et al.</i> (2022)                                   | Lin <i>et al.</i> (2023)   | Huang <i>et al.</i> (2021)                    |
|--|---|--|---|
| Objetivo                               | Aprimorar o comportamento dos multiagentes fora do campo de visão | Desenvolver um algoritmo estado-da-arte voltado ao futebol de multiagentes | Aplicar AWR ao futebol de multiagentes        |
| Arquitetura de modelagem dos SMAs      | Graph Imputer   | JRPO   | MAPPO   |
| Linguagem de programação               | Não informou  | Python   | Python  |
| Cenários testados                      | Comparação com dados reais utilizando Pitch Control               | Partidas 11 vs 11, 5 minutos   | 1, 2 e 3 vs goleiro Escanteios, Contra-ataque |
| Forma de interação dos agentes         | LSTM bidirecional Graph Network, VRNN                             | Recompensa   | Recompensa                                    |
| Quantidade de repetições por simulação | Não informou  | 3000   | 3000  |

Fonte: elaborado pelo autor.

A partir do Quadro 1 pode-se observar que Huang *et al.* (2021) propuseram uma abordagem mais simples e com menor complexidade computacional em comparação com TiZero. Eles apresentam um sistema de aprendizado por demonstração em que um único agente aprende a jogar futebol multiagente por meio de demonstrações de um jogador experiente. Os autores destacam que os resultados são promissores, embora ainda haja espaço para melhorias em termos de desempenho.

Em relação ao trabalho de Lin *et al.* (2023), é importante destacar que ele apresenta uma abordagem inovadora para treinamento de agentes em ambientes complexos de futebol multiagente, utilizando técnicas de aprendizado por reforço distribuído e autojogo. Os resultados obtidos mostraram que o TiZero superou amplamente os sistemas anteriores em termos de taxa de vitórias e diferença de gols, além de utilizar comportamentos de coordenação mais complexos.

Por fim, Omidshafei *et al.* (2022) apresentam uma abordagem diferente dos dois primeiros trabalhos, focando na predição de comportamentos fora da tela em jogos de futebol multiagente. Os autores propõem um modelo de aprendizado profundo que utiliza informações de rastreamento de jogadores para prever o comportamento de um jogador fora da tela, com resultados positivos. Em resumo, os três trabalhos apresentam abordagens diferentes para lidar com desafios em ambientes de futebol multiagente, cada um com suas vantagens e limitações. TiZero apresenta um alto desempenho, TiKick propõe uma abordagem mais simples e com menor complexidade computacional, enquanto o terceiro artigo foca na predição de comportamentos fora da tela.

Diante deste contexto, este trabalho é relevante por sua contribuição ao avanço da pesquisa em Sistemas Multiagentes (SMA) aplicado à robótica, especialmente em jogos de futebol de robôs. A implementação de uma arquitetura de SMA para coordenação das ações dos robôs em um jogo de futebol pode levar a uma melhoria significativa no desempenho do jogo, possibilitando a participação de equipes mais eficientes e com maior



capacidade de adaptação em competições de robótica. O estudo também pode contribuir para o desenvolvimento de sistemas robóticos mais flexíveis, adaptativos e autônomos, capazes de lidar com incertezas e ambientes dinâmicos. Além disso, a aplicação de SMA em jogos de futebol de robôs pode contribuir quanto a coordenação de múltiplos agentes em outros domínios, como em sistemas de transporte inteligente, logística e redes de sensores distribuídos.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O trabalho proposto deverá contemplar os seguintes Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF):

- a) permitir que o ambiente de jogo seja configurável, permitindo a definição de diferentes tipos de campo, tamanho, obstáculos, entre outros fatores que podem influenciar o desempenho dos robôs (RF);
- b) permitir a criação de equipes de robôs, com diferentes características, tais como velocidade, agilidade, habilidade de ~~passse, etepasse etc.~~ (RF);
- c) permitir que os robôs sejam capazes de se comunicar entre si, trocando informações sobre a posição da bola, posição dos ~~adversários, eteadversários etc.~~ (RF);
- d) permitir a implementação de diferentes estratégias de jogo, tais como táticas de defesa, ataque, ~~mareação, etemarcação etc.~~ (RF);
- e) ter uma interface com o usuário intuitiva e amigável, permitindo a fácil configuração dos parâmetros do jogo, controle da partida e visualização das estatísticas (RF);
- f) ser capaz de simular partidas em tempo real, garantindo a fluidez da experiência do usuário (RNF);
- g) utilizar o paradigma de programação orientada a agentes (RNF);
- h) ser desenvolvido na linguagem de programação Python e na ferramenta NetLogo (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: escolher trabalhos correlatos e entender os assuntos relacionados à futebol de robôs e SMAs;
- b) definição do cenário de simulação: identificar os aspectos relevantes (estado global, dinâmicas globais/-entidades locais) que representem o ambiente dos agentes;
- c) definição de parâmetros iniciais: determinar as informações do ambiente, as quais devem ser fornecidas aos agentes para que estes possam selecionar as ações a serem praticadas;
- d) modelagem dos agentes: determinar das ações básicas dos agentes, e suas reações às entidades do ambiente;
- e) definição e escolha da arquitetura de agentes: pesquisar as principais arquiteturas que possibilitem explorar a conexão entre o comportamento ao nível micro dos indivíduos e os padrões ao nível macro, escolhendo o mais adequado para o desenvolvimento do trabalho;
- f) implementação: desenvolver o artefato computacional de simulação multiagente a partir dos itens (b) até (e), considerando inicialmente a arquitetura BDI, utilizando a linguagem de programação Python e a ferramenta NetLogo;
- g) validação e calibragem: avaliar o comportamento e capacidade dos agentes em se adaptar a diferentes situações e estratégias de jogo. Para isso, serão utilizadas métricas relevantes para futebol de robôs, como a taxa de sucesso em marcar gols, a precisão na tomada de decisão e a eficiência na coordenação de múltiplos robôs.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem realizadas

| etapas / quinzenas                            | 2023 |   |      |   |      |   |      |   |      |   |
|---|------|---|------|---|------|---|------|---|------|---|
|   | jul. |   | ago. |   | set. |   | out. |   | nov. |   |
|   | 1    | 2 | 1    | 2 | 1    | 2 | 1    | 2 | 1    | 2 |
| levantamento bibliográfico                    |      |   |      |   |      |   |      |   |      |   |
| definição do cenário de simulação             |      |   |      |   |      |   |      |   |      |   |
| definição de parâmetros iniciais              |      |   |      |   |      |   |      |   |      |   |
| modelagem do agente                           |      |   |      |   |      |   |      |   |      |   |
| definição e escolha da arquitetura de agentes |      |   |      |   |      |   |      |   |      |   |
| implementação                                 |      |   |      |   |      |   |      |   |      |   |
| validação e calibragem                        |      |   |      |   |      |   |      |   |      |   |

Fonte: elaborado pelo autor.

#### 4 REVISÃO BIBLIOGRÁFICA

Nesta seção serão abordados brevemente os principais assuntos que fundamentarão o estudo a ser realizado: Futebol de robôs e Sistemas Multiagentes.

Segundo Kitano (1999), o futebol de robôs é uma das áreas mais importantes no campo da robótica, sendo amplamente estudado e pesquisado nos últimos anos. Trata-se de um esporte em que robôs jogam futebol em um campo especial, geralmente seguindo regras semelhantes às do futebol humano. Um dos primeiros trabalhos sobre futebol de robôs foi realizado por Hiroaki Kitano em 1993, que criou a primeira liga de futebol de robôs, a RoboCup. Desde então, essa competição tem sido realizada anualmente em todo o mundo e se tornou uma plataforma importante para o desenvolvimento e aprimoramento de técnicas em robótica.

De acordo com Kitano (1999), existem diversas abordagens para a implementação de um time de futebol de robôs, que variam desde técnicas baseadas em visão computacional até técnicas baseadas em aprendizado de máquina. Entre as técnicas de visão computacional, é possível citar o uso de câmeras para a identificação da bola e dos jogadores, ~~enquanto que~~ enquanto as técnicas baseadas em aprendizado de máquina geralmente envolvem a criação de modelos que podem aprender a jogar futebol com base em exemplos. Algumas das principais áreas de pesquisa em futebol de robôs incluem o desenvolvimento de técnicas de percepção, como a detecção e rastreamento da bola e dos jogadores, o desenvolvimento de técnicas de planejamento de trajetória, o desenvolvimento de técnicas de controle de robôs e o desenvolvimento de técnicas de tomada de decisão.

Para SichMan (1995), nos últimos anos, a aplicação de técnicas de inteligência artificial, como o aprendizado por reforço, aprendizado profundo e sistemas multiagentes, tem sido cada vez mais explorada na área de futebol de robôs. A ideia por trás de sistemas multiagentes é definir agentes que consigam resolver serviços complexos. Agentes podem definir seus próprios objetivos e planos, assim como podem realizar interações complexas com os demais agentes. Os agentes são independentes de uma organização de solução de problema única, tanto que eles podem definir ou até mesmo mudar essa organização conforme a resolução do problema for acontecendo. De qualquer forma, para que isso ocorra, os agentes precisam ser capazes de perceber as mudanças e agir no ambiente no qual eles estão inseridos. Eles também têm a capacidade de levar em conta os objetivos e as habilidades de outros agentes, para assim resolver o problema de forma cooperativa.

De acordo com Juchem e Bastos (2001), a estrutura e a arquitetura de modelagem de agentes podem variar de acordo com os objetivos desse agente. A primeira coisa a se fazer para definir qual arquitetura utilizar está baseada em entender qual o tipo de agente do qual se está tratando. Os agentes podem ser cognitivos, que podem ser considerados racionais e tem a capacidade de escolher as ações a executar, dentre as existentes em seu repertório, para chegar em seu objetivo, bem como podem ser reativos, que não necessariamente são agentes racionais, pois eles podem ter seu comportamento definido através de um padrão estímulo-resposta (JUCHEM; BASTOS, 2001). A partir dos dois tipos de agentes descritos, é possível desenvolver uma arquitetura cognitiva (ou deliberativa), que adota o princípio de que agentes são racionais, definindo assim que os agentes cognitivos têm suas deliberações feitas por meio de um processo baseado em raciocínio lógico, escolhendo sua ação por meio da representação simbólica do mundo, um plano e uma função utilizada para a ação. Também pode-se desenvolver uma arquitetura funcional, na qual o agente é composto por módulos que representam cada uma das funcionalidades necessárias para sua operação. Outra arquitetura tradicional muito comum é a arquitetura BDI, que considera três estados mentais do agente: Crença, Desejo e Interação (*Belief, Desire and Intention*). A arquitetura BDI permite que o agente possa decidir, momento a momento, qual ação desempenhar na direção de seus objetivos (JUCHEM; BASTOS, 2001).

#### REFERÊNCIAS

CHEN, Liang *et al.* **Survey of Multi-Agent Strategy Based on Reinforcement Learning**. Chinese Control And Decision Conference (CCDC), Hefei, China, p. 604-609, 2020. Disponível em: <<https://ieeexplore.ieee.org/document/9164559>>. Acesso em: 28 abr. 2023.

GUPTA, Sen *et al.* **Recent Advances in Robotics and Automation**. 2013. Disponível em: <[https://www.researchgate.net/publication/321613321\\_Recent\\_Advances\\_in\\_Robotics\\_and\\_Automation](https://www.researchgate.net/publication/321613321_Recent_Advances_in_Robotics_and_Automation)>. Acesso em: 01 maio 2023.

HUANG, Shiyu *et al.* **TiKick: Toward Playing Multi-agent Football Full Games from Single-agent Demonstrations**. 2021. Disponível em: <<https://arxiv.org/abs/2110.04507>>. Acesso em: 16 abr. 2023.

JUCHEM, Murilo; BASTOS, Ricardo Melo. **Arquitetura de Agentes**. Relatório Técnico, n. 013 arquivado na Pró-Reitoria de Pesquisa, Faculdade de Informática PUCRS, Porto Alegre. 2001. Disponível em: <<https://www.pucrs.br/facin-prov/wp-content/uploads/sites/19/2016/03/tr013.pdf>>. Acesso em: 12 maio 2013.

LIN, Fanqi *et al.* **TiZero: Mastering Multi-Agent Football with Curriculum Learning and Self-Play**. 2023. Disponível em: <<https://arxiv.org/abs/2302.07515>>. Acesso em 16 abr. 2023.

KITANO, Hiroaki *et al.* **RoboCup: Today and tomorrow—What we have learned**. Artificial Intelligence, Volume 110, Issue 2. 1999. Disponível em <<https://www.cs.cmu.edu/~mmv/papers/AIJ99-robocup.pdf>>. Acesso em: 16 maio 2023.

Comentado [DSdR4]: Ordem alfabética.

KUMAR, Aviral *et al.* **Conservative q-learning for offline reinforcement learning**. 2020. Disponível em: <<https://arxiv.org/abs/2006.04779>>. Acesso em: 15 maio 2023.

OMIDSHAFIEI, Shayegan *et al.* **Multiagent off-screen behavior prediction in football**. Sci Rep 12, 8638 (2022).- Disponível em: <https://doi.org/10.1038/s41598-022-12547-0> Acesso em: 15 maio 2023.

SICHMAN, Jaime S. **Exploiting Social Reasoning to Enhance Adaption in Open-Multi-Agent Systems**, São Paulo, SP, 1995. Disponível em <[https://www.researchgate.net/publication/220974703\\_Exploiting\\_Social\\_Reasoning\\_to\\_Enhance\\_Adaption\\_in\\_Open-Multi-Agent\\_Systems](https://www.researchgate.net/publication/220974703_Exploiting_Social_Reasoning_to_Enhance_Adaption_in_Open-Multi-Agent_Systems)>. Acesso em: 09 maio 2023.

TISUE, Seth; WILENSKY, Uri. **NetLogo: A simple environment for modeling complexity**. International Conference on Complex Systems. In: Agent 2004 Conference on Social Dynamics: Interaction, Reflexivity and Emergence. 2004. Disponível em <[https://www.researchgate.net/publication/230818221\\_NetLogo\\_A\\_simple\\_environment\\_for\\_modeling\\_complexity](https://www.researchgate.net/publication/230818221_NetLogo_A_simple_environment_for_modeling_complexity)>. Acesso em 14 maio 2013

WOOLDRIDGE, Michael. **An Introduction to MultiAgent Systems**. 2 ed. Estados Unidos: Wiley, 2009.

# FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR TCC I – PRÉ-PROJETO

Avaliador(a): Dalton Solano dos Reis

| ASPECTOS AVALIADOS     |   | atende | atende parcialmente | não atende |
|------------------------|---|--------|---------------------|------------|
| ASPECTOS TÉCNICOS      | 1. INTRODUÇÃO<br>O tema de pesquisa está devidamente contextualizado/delimitado?  | X      |                     |            |
|                        | O problema está claramente formulado?   | X      |                     |            |
|                        | 2. OBJETIVOS<br>O objetivo principal está claramente definido e é passível de ser alcançado?  | X      |                     |            |
|                        | Os objetivos específicos são coerentes com o objetivo principal?  | X      |                     |            |
|                        | 3. JUSTIFICATIVA<br>São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?   | X      |                     |            |
|                        | São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?  | X      |                     |            |
|                        | 4. METODOLOGIA<br>Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?   | X      |                     |            |
| ASPECTOS METODOLÓGICOS | Os métodos, recursos e o cronograma estão devidamente apresentados?   | X      |                     |            |
|                        | 5. REVISÃO BIBLIOGRÁFICA<br>Os assuntos apresentados são suficientes e têm relação com o tema do TCC?   | X      |                     |            |
|                        | 6. LINGUAGEM USADA (redação)<br>O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?                           | X      |                     |            |
|                        | A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?   | X      |                     |            |
|                        | 7. ORGANIZAÇÃO E APRESENTAÇÃO GRÁFICA DO TEXTO<br>A organização e apresentação dos capítulos, seções, subseções e parágrafos estão de acordo com o modelo estabelecido? | X      |                     |            |
|                        | 8. ILUSTRAÇÕES (figuras, quadros, tabelas)<br>As ilustrações são legíveis e obedecem às normas da ABNT?   | X      |                     |            |
|                        | 9. REFERÊNCIAS E CITAÇÕES<br>As referências obedecem às normas da ABNT?   |        | X                   |            |
|                        | As citações obedecem às normas da ABNT?   | X      |                     |            |
|                        | Todos os documentos citados foram referenciados e vice-versa, isto é, as citações e referências são consistentes?   | X      |                     |            |

4.1.1



UNIVERSIDADE REGIONAL DE BLUMENAU  
CENTRO DE CIÊNCIAS EXATAS E NATURAIS  
DISCIPLINA: TRABALHO DE CONCLUSÃO DE CURSO I  
CURSO: CIÊNCIA DA COMPUTAÇÃO - BCC

#### **ATA DA DEFESA: BANCA DO PRÉ-PROJETO**

Venho, por meio deste, manifestar minha avaliação sobre a **apresentação** do Pré-Projeto de TCC realizado pelo(a) acadêmico(a), **\_ Christian Trisotto Alegri \_** no **PRIMEIRO SEMESTRE DE 2023**, com o título **\_ SISTEMAS MULTIAGENTES APLICADO AO FUTEBOL DE ROBÔS \_**, sob orientação do prof(a). \_\_\_\_\_.

A referida apresentação obteve a seguinte nota:

| Componente da Banca  | Nota<br>(de 0 a 10) |
|--|---------------------|
| Professor(a) Avaliador(a): <b>_ Miguel Alexandre Wisintainer _</b> | <b>8.0</b>          |

**ATENÇÃO.** A nota acima se refere somente a apresentação do pré-projeto e vai ser repassada para o aluno (orientando). Favor preencher os campos acima e enviar por e-mail ao professor de TCC1 ([dalton@furb.br](mailto:dalton@furb.br)). Não passar o arquivo com as anotações da revisão já enviado ao professor de TCC1 para o orientando e nem para o professor orientador. Após o professor de TCC1 receber esta ata preenchida, o professor de TCC1 vai disponibilizar para o orientando/orientador os arquivos com as revisões. Caso julgue necessário fazer mais alguma consideração relacionada ao pré-projeto ou a defesa, favor usar o espaço abaixo.

Observações da apresentação:



#### **ATA DA DEFESA: BANCA DO PRÉ-PROJETO**

Venho, por meio deste, manifestar minha avaliação sobre a **apresentação** do Pré-Projeto de TCC realizado pelo(a) acadêmico(a), **\_ Christian Trisotto Alegri \_** no **PRIMEIRO SEMESTRE DE 2023**, com o título **\_ SISTEMAS MULTIAGENTES APLICADO AO FUTEBOL DE ROBÔS \_**.

A referida apresentação obteve a seguinte nota:

| Componente da Banca   | Nota<br>(de 0 a 10) |
|---|---------------------|
| Professor(a) Orientador(a): <b>_ Aurélio Faustino Hoppe _</b> | <b>8,0</b>          |

A apresentação aconteceu em 12 / 06 / 2023 na sala de reunião virtual do MS-Teams, tendo início às 18 : 01 hs e foi encerrada às 18 : 30 hs.

**ATENÇÃO.** A nota acima se refere somente a apresentação do pré-projeto e vai ser repassada para o aluno (orientando). Favor preencher os campos acima e enviar por e-mail ao professor de TCC1 ([dalton@furb.br](mailto:dalton@furb.br)). Lembro que os arquivos com as anotações das revisões do professor de TCC1 e Avaliador serão enviados para o orientando e professor orientador após o professor de TCC1 receber esta ata preenchida. Caso julgue necessário fazer mais alguma consideração relacionada ao pré-projeto ou a defesa, favor usar o espaço abaixo.

Observações da apresentação: