

Revisão do Projeto

Disciplina: Trabalho de Conclusão de Curso I – BCC

Caro, orientando,

segue abaixo a tabela de cálculo da média das notas obtidas no Pré-Projeto e Projeto, as DUAS revisões do seu projeto contendo a avaliação do professor “avaliador” e professor “TCC1”. Lembro que os ajustes indicados nestas revisões não precisam ser feitos no projeto, mas sim quando levarem o conteúdo do projeto para o artigo (se for o caso). Este material contendo todo o histórico das revisões é encaminhado para o professor de TCC2.

Tabela de cálculo da média das notas:

			PreProjeto										Projeto										Média			
			TCC1					Avaliador					Banca		TCC1					Avaliador						
	Nome	Pessoa	A	P	N	Nota	A	P	N	Nota	Ori.	Esp.	Nota	A	P	N	Nota	A	P	N	Nota					
	Everton Luiz Piccoli	176521	16	0	0	16	10,00	11	4	0	15	9,11	10,00	8,50	9,25	16	0	0	16	10,00	15	0	0	15	10,00	9,7

Atenciosamente,

-CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2023/1

DOGREC: APLICATIVO PARA RECONHECIMENTO DE CACHORROS A PARTIR DE IMAGENS DO FOCINHO

Everton Luiz Piccoli

Prof. Aurélio Faustino Hoppe - Orientador

1 INTRODUÇÃO

Nos dias de hoje, é muito comum encontrar famílias que adotam animais de estimação pelo simples fato deles proporcionarem benefícios emocionais ou até mesmo, referente a parte física das pessoas. Além disso, muitos adotam um animal de estimação para ter companhia, para ensinar às crianças sobre responsabilidade, para ter um animal de guarda, para ajudar a controlar a ansiedade e o estresse, entre outros motivos. Porém, cuidar de *pet* não é uma tarefa fácil, pois eles precisam de cuidados constantes, como alimentação adequada, higiene, exercícios físicos e atenção emocional ou médica. Destaca-se também que muitas pessoas adotam animais de estimação sem realmente entender o compromisso que é cuidar de um animal de forma responsável. Elas podem achar que ter um animal de estimação é divertido e fácil, mas quando percebem que é um trabalho árduo e que requer tempo, dinheiro e energia, acabam abandonando o animal (FERNANDES, 2019).

Segundo pesquisa realizada pelo Instituto Brasil Pet (IBP), atualmente no Brasil existem mais de 185 milhões de animais abandonados ou resgatados após maus-tratos. Desses, 60% dos cachorros resgatados são por maus-tratos e 40% por abandono (PUENTE, 2022). Para entender tal contexto, realizou-se uma pesquisa para tentar identificar os motivos dos abandonos, dentre eles, os principais motivos apontados foram: mau comportamento de seus cães (46,8%), mudança no espaço onde mora o ser humano (29,1%), estilo de vida do dono (25,4%) e expectativa frente à realidade de cuidar de um cachorro (14,9%) (ALVES, 2013).

No Brasil, os animais abandonados são recolhidos por Organizações Não Governamentais (ONGs) e abrigos de cachorros. No entanto, os abrigos geralmente enfrentam vários desafios, como superlotação, falta de recursos financeiros e de pessoal, falta de espaço e instalações inadequadas. Além disso, muitos animais que são deixados nos abrigos têm problemas de saúde, comportamentais ou de idade, o que torna mais difícil encontrar lares adequados. Por outro lado, existem pessoas preocupadas com seus pets, que têm buscado maneiras de monitorar seus cachorros, a fim de garantir a segurança e conhecimento de onde ele se encontra. Para isso, muitas vezes, optam pela utilização de métodos de monitoramentos que são invasivos como os microchips de Radio-Frequency Identification (RFID), Near Field Communication (NFD), entre outros. No entanto, o custo desses equipamentos encontra-se fora da capacidade financeira de grande parte da sociedade brasileira, perfazendo que muitos brasileiros optem pelo uso de uma simples coleira para reconhecer seus cachorros, e caso fujam, utilizem muitas vezes cartazes e redes sociais para encontrá-los (MOREL, 2022).

Segundo Martins (2022), a foto-identificação é uma técnica que vem sendo utilizada nos últimos anos para reconhecimento de animais, pelo simples fato de ser um método totalmente simples e não invasivo, ou seja, um método que não causa nenhum tipo de stress ao animal. Melo (2020) destaca que assim como o ser humano pode ser identificado pela impressão digital de sua mão, os cachorros também têm essas características, mas através de seu nariz ou focinho. Neste contexto, o uso da foto-identificação é uma grande aliada para este processo de identificação, porém para este processo se faz necessário encontrar padrões das marcas naturais dos narizes dos cachorros, como pigmentações, assimetrias entre outras características que devem ser consideradas pontos chaves para o processo de foto-identificação. A autora ainda reforça que o focinho dos cachorros possui padrões complexos, tornando-os únicos, sendo possível identificá-los através do uso de imagens. Jang *et al.* (2020) mencionam que identificar cachorros não é simples, e que já foi tentado a utilização de métodos como o EigenFaces, que é utilizado para reconhecimento de faces humanas, porém com cachorros não obteve muito sucesso. Para o reconhecimento dos padrões do focinho dos cachorros, Jang *et al.* (2020) optaram por utilizar métodos como *Scale-Invariant Feature Transform* (SIFT), *Binary Robust Invariant Scalable Keypoints* (BRISK), *Speeded-Up Robust Features* (SURF) e *Oriented fast and Rotated Brief* (ORB) para recolher características do focinho e através de uma rede neural, tenta-se identificar o cachorro. Outra forma seria através do uso de *Convolutional Neural Network* (CNNs), que são projetadas especificamente para o reconhecimento de padrões em imagens. Essas redes neurais consistem em várias camadas de neurônios que são capazes de detectar características específicas em uma imagem, como bordas, texturas e formas. A partir do contexto abordado, pode-se dizer que as redes neurais são uma ótima ferramenta para realizar a extração de características chaves de um cachorro para conseguir determinar sua raça, aumentando as possibilidades de conseguir identificar o cachorro de forma não invasiva a partir de suas marcas naturais.

Diante deste contexto, este trabalho visa responder a seguinte pergunta de pesquisa: qual é a eficácia da técnica de foto-identificação através de rede neurais convolucionais para reconhecimento de cachorros?

1.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar uma aplicação que seja capaz de identificar cães por meio do processo de foto-identificação, considerando marcas naturais presentes no focinho, buscando auxiliar na identificação de cachorros encontrados nas ruas (abandonados ou que foram perdidos pelos seus responsáveis).

Os objetivos específicos são:

- a) reconhecer cachorros a partir de imagens, utilizando algoritmos de processamento de imagem e redes neurais para extrair características e padrões dos focinhos dos cachorros;
- b) avaliar a precisão e eficácia do modelo desenvolvido em diferentes condições de iluminação, ângulos de captura de imagem e variações de características dos focinhos;
- c) disponibilizar a aplicação desenvolvida em uma plataforma online para utilização por ONGs, abrigos de animais e proprietários de cachorros, visando auxiliar na identificação de animais perdidos ou abandonados.

2 TRABALHOS CORRELATOS

Nesta seção serão descritos trabalhos que possuem características semelhantes aos principais objetivos do estudo proposto. A sub-seção 2.1 apresenta o trabalho de Tu *et al.* (2018) que desenvolveram uma aplicação capaz de detectar cachorros através do uso de imagens de seu corpo ou face. Na sub-seção 2.2 é descrito o trabalho de Bhavani *et al.* (2019), uma aplicação Android desenvolvida para identificar a raça de um cachorro através de imagens. Por fim, a sub-seção 2.3 detalha o trabalho de Vaidya *et al.* (2022) que desenvolveram uma aplicação capaz de identificar cachorros através de sua face, e ainda existindo a possibilidade de detectar a face de um humano e conseguir assemelhar sua face a uma raça de cachorro.

2.1 TRANSFER LEARNING ON CONVOLUTIONAL NEURAL NETWORKS FOR DOG IDENTIFICATION

Tu *et al.* (2018) desenvolveram uma aplicação para identificar cachorros através de imagens da face e do corpo do cachorro, tendo como intuito ajudar na gestão de práticas veterinárias. Os autores acreditavam que a combinação da biometria da raça e da face poderia melhorar a identificação dos cachorros. A partir disso, Tu *et al.* (2018) optaram por dividir o processo em duas etapas. A primeira denominada de “coarse stage”, transfere o aprendizado da GoogLeNet para a BreedNet. Na segunda etapa, “fine stage” realiza-se a identificação da identidade dos cachorros com base nos resultados obtidos no processo de classificação da raça dos cachorros, aumentando as chances de identificação correta dos cachorros.

Segundo Tu *et al.* (2018), foram utilizadas três bases de dados públicas para realizar a classificação de raças e identificação do cachorro, sendo elas: (i) a Columbia Dogs Dataset (CD_Dogs) no qual cada imagem possuía 8 características chaves: olho direito/esquerdo, nariz, ponta da orelha direita/esquerda, topo da cabeça e base da orelha direita/esquerda; (ii) a Standard Dogs Dataset (ST_Dogs) que possui mais partes do corpo do cachorro e, (iii) a Flickr-dog Dataset, que possui apenas duas raças, a Pug e Husky. A Figura 1 apresenta alguns exemplos de imagens existentes em cada uma das bases de dados.

Figura 1 – Base pública de dados com imagens de cachorros



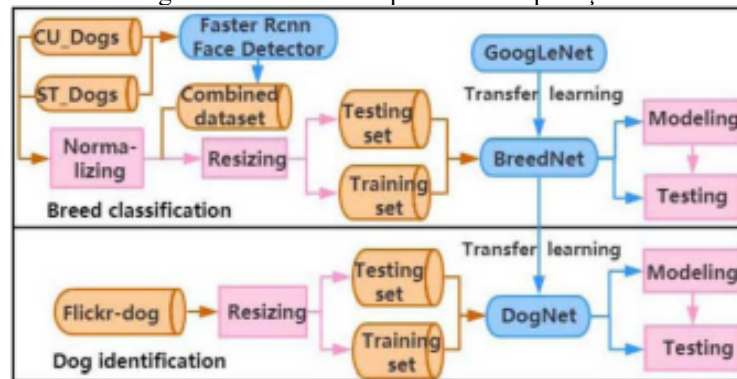
Fonte: Tu *et al.* (2018).

De acordo com Tu *et al.* (2018), o processamento e classificação das imagens foi subdividido em quatro estágios: (i) a normalização da imagem de acordo com as características de cada base de dados; (ii) separação dos dados a serem utilizados no treinamento; (iii) classificação da raça; (iv) identificação do cachorro com base no resultado da identificação das raças. Os autores utilizaram no “coarse stage”, a GoogLeNet, que serviu de base para a rede neural convolucional BreedNet, responsável pela determinação das raças. Para a etapa de identificação, a partir da BreedNet, criou-se a rede neural DogNet.

Tu *et al.* (2018) normalizaram as imagens considerando alguns pontos chaves. Na base de dados da St_Dogs são recortadas partes dos corpos dos cachorros com base nos rótulos para estabelecer a normalização. Já na Cd_Dogs, 8 pontos chaves da face do cachorro são estabelecidos, com isto é realizado o cálculo do ângulo entre o eixo horizontal e a linha conectando os olhos do cachorro. Este ângulo é utilizado para girar a imagem em

sentido horário com o objetivo de estimar a imagem final do cachorro com base em suas proporções. As imagens foram redimensionadas para 224x224 pixels e colocadas em uma base de teste para modelar e treinar os dados a partir de redes neurais. A Figura 2 apresenta o processo utilizado por Tu *et al.* (2018) para identificar raças e a identidade de cachorros.

Figura 2 – Estrutura do processo da aplicação



Fonte: Tu *et al.* (2018).

Tu *et al.* (2018) realizaram dois experimentos. O primeiro utilizou a BreedNet e dois conjuntos de dados, o Cd_Dogs e o St_Dogss. O conjunto de imagens foi subdividido em 70% para treinamento e 30% para validação. Os autores relatam que a BreedNet, utilizando normalização de imagens, obteve 81,74% de eficiência na St_Dogs e 86,63% na base da Cd_Dogs. No segundo experimento, utilizou-se a base de dados Flickr-dog que foi a única utilizada para identificar os cachorros nos experimentos. Segundo Tu *et al.* (2018), a DogNet apresentou eficiência de 76,18% para detectar a raça Pug, enquanto a raça Husky obteve 90,05%. Por fim, os autores concluem que a BreedNet pode ser utilizada na classificação da raça de cachorros pois, em relação as arquiteturas de redes neurais convolucionais existentes, mostrou-se 15% mais eficiente.

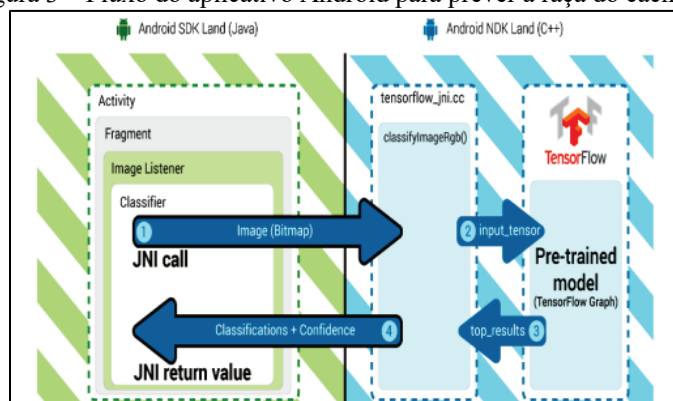
2.2 DOG BREED IDENTIFICATION USING CONVOLUTIONAL NEURAL NETWORKS ON ANDROID

Bhavani *et al.* (2019) desenvolveram um aplicativo Android que possibilita a identificação da raça de um cachorro através de um simples *upload* de imagem no aplicativo. A partir disso, realizou-se a identificação através de Redes Neurais Convolucionais e modelos de extração de dados pré-treinados pelas bibliotecas Keras e Tensorflow.

Segundo Bhavani *et al.* (2019), no treinamento do modelo utilizou-se a base de dados públicas Stanford dogs. Esta base possui mais de 120 tipos de raças de cachorros e para cada raça, tem-se no mínimo de 60 imagens. Ainda de acordo com os autores, para extrair as características das imagens foram utilizados diferentes modelos pré-treinados como Inception-v3, Inception-ResNet-v2, VGG16 e Xception, que eram treinadas na ImageNet e enviados para uma nova camada da aplicação. Bhavani *et al.* (2019), também ressaltam que quando utilizados modelos pré treinados a precisão obtida na extração das características fica acima de 80%.

Bhavani *et al.* (2019) destacam que para realizar a identificação da raça do cachorro é necessário (i) executar o modelo de rede neural no Keras, (ii) converter o modelo para um arquivo Tensorflow, permitindo a geração de gráficos de acompanhamento para otimizar o modelo. Além disso, os autores mencionam que a arquitetura da aplicação é composta de dois repositórios: o Android Standard Development Kit (SDK) e o Android Native Development Kit (NDK) que é responsável por realizar a comunicação com a biblioteca Tensorflow. A Figura 3 demonstra o fluxo do aplicativo para definição da raça do cachorro.

Figura 3 – Fluxo do aplicativo Android para prever a raça do cachorro



Fonte: Bhavani *et al.* (2019).

Bhavani *et al.* (2019) inicialmente enviam uma imagem *bitmap* do SDK para o repositório NDK. Tal imagem é redimensionada e encaminhada para uma rede neural convolucional pré-treinada que retorna um arquivo para o repositório SDK com as possíveis raças da imagem em questão. Ainda segundo os autores, a Xception e a Inception-ResNet-v2 obtiveram 93% e 94% de precisão. Já a Inception-v3 e a VGG16 alcançaram porcentagens um pouco mais baixas em relação aos dois primeiros, sendo 89% e 81% de precisão.

Por fim, Bhavani *et al.* (2019) concluem que as 4 redes neurais convolucionais utilizadas no processo de extração das características apresentam precisões promissoras e eficientes. Além disso, com a utilização de redes neurais pré-treinadas e uma base de dados sólida já existente no aplicativo em seu repositório, enfatizam que o aplicativo Android não precisa de internet para funcionar, recebendo a resposta quase que instantânea após o início do processo de identificação do aplicativo. Eles também relatam que o aplicativo apresenta problemas com o tamanho da imagem e só funciona com imagens tiradas da câmera do celular, apontando que tais melhorias podem ser exploradas em trabalhos futuros.

2.3 A NOVEL DOG BREED IDENTIFICATION USING CONVOLUTIONAL NEURAL NETWORK

Vaidya *et al.* (2022) desenvolveram uma aplicação para identificar raças de cachorros utilizando sua face. Além disso, com a aplicação, também era possível detectar a face de um humano e dizer com qual tipo de raça ele mais se assemelhava. Para isso, os autores subdividiram a aplicação em 3 etapas: (i) detecção de humanos; (ii) utilização do modelo de rede neural pré-treinado, VGG16, para reconhecer cachorros, (iii) envio do resultado da classificação (humano ou cachorro).

Segundo Vaidya *et al.* (2022), primeiramente realizou-se a importação dos dados e as bibliotecas para realizar o treino, validação e teste. Em seguida, Vaidya *et al.* (2022) explicam que para conseguirem realizar a detecção da imagem de um ser humano, utilizou-se a implementação de classificadores HaarCascade disponibilizados na biblioteca OpenCV. Já para a detecção de cachorros, utilizou-se a rede neural pré-treinada VGG16. Além disso, Vaidya *et al.* (2022) também modelaram uma rede neural do zero para conseguir identificar raças, tendo como base a arquitetura ResNet101.

Vaidya *et al.* (2022) ressaltam que nos testes foram utilizadas imagens de cachorros e humanos. A base de dados de cachorros era composta por 8351 imagens, sendo subdividida em 6680 imagens para treinamento, 836 imagens para os testes e 835 imagens para validação. Os autores também destacam que para cada um desses 3 grupos de imagens, havia um total de 133 raças de cachorros. Já em relação aos humanos, a base de dados continha 13233 imagens ordenadas pelo nome dos indivíduos, com dimensão de 250x250 pixels. Além disso, Vaidya *et al.* (2022) apontam que o HaarCascade obteve 98% de eficiência para humanos e apenas 17% na base de dados de cachorro. Já a rede neural construída utilizando transfer learning da arquitetura ResNet101 obteve uma precisão de 81%, identificando corretamente a raça em 680 de um total de 836 imagens de cães. A Figura 4 apresenta um exemplo de predição para imagens de entrada de cachorro e humano.

Figura 4 – Resultado da predição para cachorros e humano



Fonte: Vaidya *et al.* (2022).

Vaidya *et al.* (2022) concluíram que, ao utilizar a biblioteca OpenCV em conjunto com a rede neural pré-treinada VGG16, foi possível detectar com certa efetividade os rostos de humanos e cachorros. Além disso, enfatizaram que o desempenho do modelo construído por transferência de aprendizagem superou as expectativas, alcançando 81% de eficiência em comparação aos 13% do modelo CNN criado do zero. Vaidya *et al.* (2022) também apontam que o modelo ainda pode ser aprimorado ao adicionar mais dados para treinamento e testes, uma vez que atualmente existem apenas 133 raças de cães na base de dados.

3 PROPOSTA DA APLICAÇÃO

Esta seção tem como objetivo apresentar a justificativa para a elaboração deste trabalho, assim como os requisitos e metodologias que serão adotados neste projeto. Também serão apresentadas revisões bibliográficas onde serão abordadas algumas partes dos estudos a serem explorados para elaboração do projeto.

3.1 JUSTIFICATIVA

No Quadro 1 é possível se observar um comparativo entre os trabalhos correlatos escolhidos, onde neles serão abordados as principais características consideradas e resolução de problemas propostos. As linhas contêm as características de cada trabalho e a coluna são os trabalhos correlatos.

Quadro 1 – Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Tu <i>et al.</i> (2018)	Bhavani <i>et al.</i> (2019)	Vaidya <i>et al.</i> (2022)
Objetivo Proposto	Identificação da raça do cachorro e sua identidade	Identificação da raça do cachorro	Identificação da raça do cachorro, identificação de face humana, assemelhando a face a uma raça
Tipo de aplicação	Desktop	Android	Desktop
Redes Neural Utilizadas / Base de dados / Taxa de eficiência	BreedNet/ST-Dogs/81,74% BreedNet/CD_DOGS/86,63% DogNet/Flickr-dog Pug/76,18% DogNet/Flickr-dog Husky/90,05%	Xception / 93% Inception-ResNet-v2 / 94% Inception-v3 / 89% VGG16 / 81%	VGG16 / 81%

Fonte: elaborado pelo autor.

A partir do Quadro 1, pode-se observar que todos os estudos visam a detecção de raças/cachorros via imagens. Tu *et al.* (2018) buscavam detectar a raça do cachorro, tendo como intuito aumentar as chances de identificação do cachorro. Bhavani *et al.* (2019) apenas detectam a raça do cachorro e, Vaidya *et al.* (2022) além de identificar a raça, também a associam a face de um humano.

Também é possível receber que todos os trabalhos utilizaram Redes Neural Convolucional. Tu *et al.* (2018) desenvolveram uma aplicação desktop que utiliza as redes neurais GoogLeNet, BreedNet e DogNet. Bhavani *et al.* (2019) desenvolveram uma aplicação Android, utilizando no processo de extração das características modelos de redes neurais pré-treinados, como a Inception-v3, Inception-ResNet-v2, VGG16 e Xception. Vaidya *et al.* (2022) desenvolveram uma aplicação desktop capaz de identificar a raça do cachorro e também capaz de identificar a face de um humano e assemelhar ela a uma raça de cachorro. Para isso, os autores utilizaram a rede neural VGG16.

Em relação aos resultados, todos alcançaram boas taxas de eficiência. Tu *et al.* (2018) obtiveram na base de dados da ST_DOGS e com a rede neural BreedNet uma taxa de 81,74% para identificar a raça dos cachorros. Enquanto na base de dados CD_DOGS, a taxa foi de 86,63%. Através da rede DogNet, utilizando a base Flickr-dog, obteve-se a taxa de 76,18% para a raça Pug e 90,05% para Husky. Bhavani *et al.* (2019) ressaltam que utilizando a base de dados pública da Stanford dogs obtiveram 93% de eficiência com a rede Xception, 94% com a Inception-ResNet-v2, 89% com a Inception-v3 e 81% com a VGG16. Já Vaidya *et al.* (2022) utilizaram uma base de dados com 8351 imagens de cachorros e outra que continha 13233 imagens de humanos. Neste cenário, atingiram 81% de eficiência utilizando a rede VGG16.

Diante deste contexto, pode-se concluir que dentre os trabalhos pesquisados não há nenhum que tenha como objetivo primário identificar cachorros a partir de marcas naturais. Percebe-se que a maioria dos trabalhos apenas visam identificar a raça de um cachorro. Sendo assim, o trabalho proposto se difere dos demais, pois tem como objetivo reconhecer o cachorro através do processo de foto-identificação utilizando redes neurais convolucionais e imagens de seu focinho. Além disso, também pode-se destacar que a aplicação também poderá contribuir com a: (i) facilidade na identificação de cachorros. A aplicação pode ajudar na localização de animais de estimação, notificando os proprietários quando seus cachorros forem encontrados; (ii) redução do número de animais abandonados. Ao facilitar a identificação de cachorros perdidos ou abandonados, a aplicação pode ajudar a reduzir o número de animais que vagam pelas ruas e acabam em abrigos superlotados; (iii) melhora na segurança dos cachorros. Muitos cachorros são roubados ou perdidos durante caminhadas ou passeios. Com a aplicação, os proprietários podem ter maior segurança em relação aos seus cachorros, pois podem identificá-los rapidamente se forem perdidos ou roubados; (iv) aumento da conscientização sobre a importância da identificação de animais de estimação. Ao desenvolver e disponibilizar a aplicação, pode-se aumentar a conscientização sobre a importância da identificação de animais de estimação. Isso pode levar a um aumento na adoção de práticas de identificação e, por sua vez, ajudar a reduzir o número de animais perdidos ou abandonados. Em termos técnicos, este trabalho poderá contribuir para o desenvolvimento de tecnologias de detecção de identidade de animais através do processo de foto-identificação.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

Os requisitos do trabalho estão divididos em duas partes: requisitos da aplicação móvel e requisitos do módulo de foto-identificação através do focinho.

A aplicação móvel deverá:

- a) manter o cadastro dos cachorros (Requisito Funcional - RF);
- b) permitir ao usuário carregar ou capturar imagens a partir de um dispositivo Android (RF);
- c) enviar notificação para o responsável do cachorro (maior probabilidade) após reconhecimento, contendo a posição geográfica na qual ele possivelmente foi encontrado (RF);
- d) utilizar de armazenamento na nuvem do servidor de aplicação (RNF);
- e) ser desenvolvido para a plataforma Android (Requisito Não Funcional - RNF);
- f) utilizar a linguagem Dart com o SDK Flutter para o desenvolvimento (RNF);
- g) utilizar o ambiente de desenvolvimento Visual Studio Code (RNF);
- h) utilizar o banco de dados SQLite para persistir os dados off-line (RNF).

O módulo de foto-identificação deverá:

- a) realizar o realce e melhoramento de ruídos, distorções e problemas de iluminação utilizando técnicas de processamento de imagens (RF);
- b) efetuar o processo de foto-identificação do cachorro utilizando redes neurais convolucionais para segmentar o focinho e identificar marcas naturais que possam caracterizar o indivíduo, inicialmente será utilizada a rede UNet (RF);
- c) permitir ao usuário visualizar as detecções e resultados obtidos no processo (RF);
- d) aprimorar a rede neural a partir de novas imagens cadastradas pelos usuários (RNF);
- e) utilizar as bibliotecas OpenCV para o processamento de imagens e o Tensorflow para a construção da rede neural artificial (RNF);
- f) utilizar a linguagem Python para desenvolvimento, utilizando a biblioteca Flask para elaborar o servidor REST (RNF);
- g) utilizar um banco de dados No-SQL (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: pesquisar e estudar sobre foto-identificação, reconhecimento de padrões, redes neurais convolucionais e trabalhos correlatos;
- b) elicitação de requisitos da aplicação móvel: baseando-se nas informações da etapa anterior, reavaliar os requisitos propostos para a aplicação;
- c) especificação: utilizar a ferramenta de diagramação *Enterprise Architect* (EA) para elaborar os diagramas de caso de uso e de atividades de acordo com a *Unified Modeling Language* (UML);
- d) implementação: a partir do item (c) implementar a aplicação móvel para a plataforma Android utilizando a linguagem Dart com o SDK Flutter;
- e) testes da aplicação móvel: elaborar testes para validar a usabilidade da aplicação junto aos possíveis usuários;
- f) coleta e montagem da base de dados: coletar imagens de cachorros e montar uma base de dados obtidas/cedidas junto a projetos já existentes na comunidade acadêmica. No caso das imagens coletadas durante a realização do trabalho será solicitado aos responsáveis a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- g) pré-processamento de imagens: realizar a correção de imperfeições nas imagens, como ajuste de iluminação, corte e redimensionamento, para garantir a qualidade dos dados utilizados;
- h) rotulação das imagens: rotular e validar as imagens coletadas a fim de buscar obter a maior eficiência possível nos resultados.
- i) pesquisa e escolha do algoritmo de segmentação: pesquisar os principais algoritmos de segmentação e detecção de objetos, escolhendo o adequado para o desenvolvimento do trabalho. Inicialmente será utilizada a Rede Neural Convolucional UNet para detectar o focinho do cachorro;
- j) pesquisa e escolha do algoritmo para foto-identificação: pesquisar as arquiteturas de RNA aderentes ao processo de foto-identificação de cachorros;
- k) desenvolvimento do modelo de foto-identificação: a partir dos itens (i) e (j), realizar a implementação da arquitetura da rede neural artificial utilizando a biblioteca Tensorflow;
- l) testes do modelo: paralelamente à implementação, realizar testes com base no banco de imagens obtido para verificar a eficiência e assertividade do modelo desenvolvido.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem desenvolvidas

etapas / quinzenas	2023									
	jul.		ago.		set.		out.		nov.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
elicitação de requisitos da aplicação móvel										
especificação										
implementação										
testes da aplicação móvel										
coleta e montagem da base de imagens										
pré-processamento de imagens										
rotulação das imagens										
pesquisa e escolha do algoritmo de segmentação										
pesquisa e escolha do algoritmo para foto-identificação										
desenvolvimento do modelo de foto-identificação										
testes do modelo										

Fonte: elaborado pelo autor.

4 REVISÃO BIBLIOGRÁFICA

Esta seção tem como objetivo explorar os principais assuntos que fundamentarão o estudo a ser realizado neste projeto. A subseção 4.1 aborda sobre foto-identificação. Por fim, a subseção 4.2 discorre sobre reconhecimento de padrões e Redes Neurais.

4.1 FOTO-IDENTIFICAÇÃO

O uso de imagens na identificação de animais tem sido cada vez mais utilizadas nos dias de hoje. Para isso, muitas técnicas vêm sendo produzidas a fim de alcançar o objetivo proposto, e uma dessas técnicas é a de foto-identificação. A foto-identificação permite o reconhecimento individual de muitos animais que possuem um certo padrão de marcas naturais como formas, cores, cicatrizes, entre outras características. Esse método de marcação e recaptura é considerado não invasivo, o que é uma vantagem considerando que existem muitas outras técnicas de marcação artificiais que apresentam um risco maior (BRADFIELD, 2004).

Segundo Martins (2022), a foto-identificação é uma técnica que foi desenvolvida ao longo dos anos, mas que inicialmente teve como foco de estudo os animais terrestres, e que com o passar dos tempos foram se expandindo para várias espécies de animais. A técnica vem auxiliando os estudos, por ser uma forma não invasiva e não interferir no comportamento dos animais a serem estudados, visto que o estudo é baseado na realização de uma fotografia para através dela realizar a análise de marcas naturais do animal a ser reconhecido. Ainda segundo a autora, apesar de atualmente o uso da foto-identificação ser algo muito promissor e seguro, se faz necessário atender a alguns requisitos, sendo eles:

- estabilidade: As marcas naturais do animal da pesquisa devem ser estáveis, ou seja, elas devem se manter constantes ao longo dos anos, para que seja preciso o resultado;
- singularidade: as marcas naturais a serem levantadas no estudo e consideradas, devem ser únicas para ser possível diferenciar os indivíduos, mesmo que não seja possível garantir que a característica é exclusiva. Vale ressaltar que quanto mais complexa uma marca natural, logo mais informações estão associadas a mesma, com isso fazendo ser menos provável se repetir este padrão em outros animais;
- probabilidade de reavistamento: Os indivíduos devem ter a mesma probabilidade de serem identificados ao longo dos anos por suas marcas naturais.

Segundo Ramachandran (2023), os algoritmos utilizados no processo de foto-identificação usam *deep learning* e redes neurais a fim de reconhecer padrões e processar imagens digitais. Ainda segundo o autor, o processo de reconhecimento de uma imagem normalmente envolve uma sequência de etapas a serem executadas durante o processo de validação do modelo a ser desenvolvido, sendo elas as seguintes:

- coleta de dados: Coletar um grande conjunto de imagens rotuladas, que serão utilizadas para treinar o algoritmo de foto-identificação;
- pré-processamento: Esta é a parte de polimento, onde antes de as imagens serem enviadas para treinamentos, elas passam por uma fase, onde são removidos ruídos, distorções ou outros elementos que possam prejudicar a efetividade do treinamento;
- extração de características: Nesta etapa é realizado a partir de imagens pré-processadas, a extração de características que serão consideradas relevantes para distinguir o indivíduo;
- treinamento do modelo: Nesta etapa é realizado o treinamento do modelo com base, no conjunto de imagens rotuladas. No qual, o algoritmo aprende a identificar e categorizar diferentes classes;
- teste e avaliação do modelo: Etapa que realiza testes e validações a fim de identificar possíveis erros a serem corrigidos;

- f) implantação: Nesta etapa, com o modelo validado e testado, ele pode ser utilizado para classificar novas imagens em diferentes cenários.

Segundo Fettermann (2020), a identificação fotográfica ou foto-identificação trata-se de uma técnica muito simples. O termo é utilizado para o rastreamento de animais com base em seus padrões corporais únicos. A autora também reforça que a foto-identificação é como se fosse uma *tag* natural, no qual, cada impressão digital, permite a pesquisadores desenvolver um banco de dados para garantir a conservação da espécie e seus devidos cuidados.

4.2 RECONHECIMENTO DE PADRÕES E REDES NEURAIS

O reconhecimento de padrões analisa os dados recebidos e tenta identificar padrões. A identificação de regularidades nos dados pode então ser usada para fazer previsões, categorizar informações e melhorar os processos de tomada de decisão. Enquanto o reconhecimento de padrão exploratório visa identificar padrões de dados em geral, o reconhecimento de padrão descritivo começa categorizando os padrões detectados. Portanto, o reconhecimento de padrões lida com esses dois cenários, e diferentes métodos de reconhecimento de padrões são aplicados, dependendo do caso de uso e da forma dos dados (BOESCH, 2023).

De acordo com Wizbicki (2014), o reconhecimento de padrões é uma técnica muito utilizada tanto para sistemas computadorizados como pelos próprios seres humanos. Existem muitas técnicas realizadas pelos seres humanos como ilusionismo entre outros que se baseiam no reconhecimento de padrões, assim como existem diversas aplicações de computador que possuem a capacidade de reconhecer vozes, imagens, entre outros com base no reconhecimento de padrões. A técnica utilizada para isso se baseia em conseguir classificar as informações baseando-se em um conhecimento inicial ou através de informações estatísticas de padrões. A autora também ressalta que a habilidade para a realização do reconhecimento de padrões é fundamental no ambiente de análise de imagens. O padrão é definido como uma descrição quantitativa ou estrutural de um objeto ou outra entidade de interesse na imagem. O reconhecimento de padrões por máquina envolve técnicas para a atribuição dos padrões a suas respectivas classes automaticamente com a mínima intervenção humana possível.

Segundo Reis (2012), a técnica de reconhecimento de padrões, pela natureza própria dela, acaba não sendo uma ciência exata, pois enquanto existem alguns padrões que podem ser identificados facilmente por serem bem estruturados ou serem estruturados de forma adequada para serem definidos por uma gramática, existem padrões que são de difícil modelagem ou difícil construção para serem reconhecidos por uma gramática. O autor também menciona que não há soluções gerais para o reconhecimento de padrões e que este dependia exclusivamente dos dados disponíveis sendo eles de aplicação ou tecnologia. Com este cenário é que o uso de redes neurais aparece como uma possível resolução para o problema, pois a construção de redes neurais envolve o entendimento informal do problema a ser resolvido. O autor também aponta as principais vantagens do uso de redes neurais sobre a maioria das técnicas de reconhecimentos de padrões, sendo elas: (i) adaptatividade: que seria a habilidade de se ajustar a novos cenários ou informações; (ii) velocidade, consegue ter uma ótima velocidade na busca de respostas; (iii) tolerância a falhas: capacidades de retorno de boas respostas independente dos dados; (iv) otimalidade: visto como taxa de erros em sistemas de classificação.

Com o conhecimento das redes neurais sendo importantes na área de reconhecimentos de padrão, é importante se abordar sobre uma das redes neurais mais presentes no cenário de processamento de imagens, as redes neurais convolucionais. Rede Neural Convolucional, também conhecida como *Convolutional Neural Network* (CNN), é definida como uma classe de redes neurais que são especializadas no processamento de dados que possuem a topologia semelhante a uma grade, como uma imagem. Uma imagem digital basicamente é uma representação binária de dados visuais que possuem uma série de pixels dispostos em forma de grade que contém valores de pixel para denotar o brilho e a cor de cada pixel. O cérebro humano processa uma enorme quantidade de informações no segundo em que uma imagem é vista. Cada neurônio trabalha em seu próprio campo receptivo e está conectado a outros neurônios de forma que cobrem todo o campo visual. Assim como cada neurônio responde a estímulos apenas na região restrita do campo visual chamada de campo receptivo no sistema de visão biológica, cada neurônio em uma CNN também processa dados apenas em seu campo receptivo. As camadas são organizadas de forma a detectar padrões mais simples primeiro (linhas, curvas etc.) e padrões mais complexos (faces, objetos etc.). Ao usar uma CNN, pode-se habilitar a visão para computadores (MISHRA, 2020).

Com o passar dos anos e com o desenvolvimento da tecnologia foram se criando diversos modelos de CNN para resolver problemas mais específicos de acordo com a área, entre eles pode-se citar os seguintes: (i) R-CNN, Fast R-CNN e Faster R-CNN que são utilizados principalmente na área de detecção de objetos (MISHRA, 2020).; (ii) *Visual Geometry Group* (VGG) uma rede neural convolucional utilizada principalmente na área de reconhecimento de imagens(BOESCH, 2023); (iii) No grupo dos Inception-v3, tem-se a GoogLeNet, como pioneira, pois esta CNN vem a ser um módulo da GoogLeNet. Utilizada principalmente na área de extração de características de imagens para reconhecimento; (iv) ResNet utilizada na área de reconhecimento por imagem (VAIDYA *et al.*, 2022).

Clappis (2019) menciona que uma rede neural convolucional pode ser dividida em até duas partes, sendo elas a parte de extração de características (Convolução, *Padding*, ReLU, Pooling) e uma rede neural tradicional. No qual, a primeira parte possui as seguintes componentes:

- a) Convolução: Podemos entender esse processo como um filtro/*kernel* que transforma uma imagem de entrada;
- b) *Padding*: Processo onde são adicionados alguns pixels ao redor da imagem com o objetivo de manter a dimensionalidade da imagem;
- c) ReLU: Rede neural sem função de ativação. Função não linear, pode ter várias camadas de neurônios ativadas pela sua função. Função: $y = \max(0, x)$;
- d) Pooling: É um processo de redução da imagem, com o objetivo de diminuir a variância a pequenas alterações e reduzir a quantidade de parâmetros a serem treinados pela rede. Existem 3 tipos de Pooling (MaxPooling, SumPooling, AveragePooling), onde todas seguem o mesmo princípio apenas mudando o cálculo do valor final;
- e) Flatten: Basicamente opera uma transformação na matriz da imagem, alterando o formato dela para um array.

Segundo Marques (2017), para se realizar a avaliação de CNNs são utilizadas algumas métricas para comparação e validação dos modelos, onde cada métrica busca avaliar um aspecto diferente no modelo. As principais métricas são:

- a) Acurácia: Esta métrica busca avaliar a quantidade de segmentos de classes positivas e classes negativas que foram classificadas de forma correta;
- b) Precisão: Esta métrica avalia a quantidade de segmentos que foram classificados como positivos, ou seja, que pertencem ao segmento de classe positiva;
- c) Recall: Esta métrica avalia a quantidade de segmentos positivos que foram corretamente classificados. Garantindo uma boa taxa de acerto para a classe positiva dos dados;
- d) F1 ou *F-Score*: Esta métrica considera na sua avaliação a taxa da precisão quanto a da métrica Recall. Onde o valor calculado se baseia na média entre a precisão e a recall, multiplicado pela constante 2;
- e) *Area Under the Receiver Operating Characteristic* (AUROC): Esta métrica busca avaliar através de um gráfico cada segmento apresentado ao classificador, onde no eixo vertical são apresentados os números referentes as classes positivas, enquanto no eixo horizontal são apresentados os números referentes a classe negativa.

REFERÊNCIAS

ALVES, A. J. S. Abandono de cães na América Latina: revisão de literatura. **Revista de Educação Continuada em Medicina Veterinária e Zootecnia do CRMV-SP**, v. 11, n. 2, p. 34-41, 1 jul. 2013.

BHAVANI, D. *et al.* **Dog Breed Identification Using Convolutional Neural Networks on Android**. **CVR Journal of Science and Technology**, [s.l.], v. 17, n. 1, p. 62-66, dez. 2019.

BOESCH, G. **What is Pattern Recognition? A Gentle Introduction (2023)**, [s.l.], 2023. Disponível em: <<http://viso.ai/deep-learning/pattern-recognition/>>. Acesso em: 20 abr. 2023.

BRADFIELD, S. K. **Photographic identification of individual Archey's frogs, *Leiopelma archeyi*, from natural markings**, 2004. DOC Science Internal Series 191. Department of Conservation, Wellington. 36 p.

CLAPPIS, A. M. **Uma introdução as redes neurais convolucionais utilizando o Keras**: Saiba como funciona uma CNN através desse exemplo com o dataset MNIST, [s.l.], 2019. Disponível em: <<http://medium.com/data-hackers/uma-introdu%C3%A7%C3%A3o-as-redes-neurais-convolucionais-utilizando-o-keras-41ee8dcc033e>>. Acesso em: 19 jun. 2023.

FERNANDES, C. **O que ensinamos aos nossos filhos quando abandonamos animais nas ruas**: Ter um pet é uma excelente oportunidade para as crianças desenvolverem maior senso de responsabilidade, solidariedade e afeto, [s.l.], 2019. Disponível em: <<http://www.metropoles.com/e-ducacao/o-que-ensinamos-aos-nossos-filhos-quando-abandonamos-animais-nas-ruas>>. Acesso em: 22 abr. 2023.

FETTERMANN, T. **Foto-identificação de Raias Manta e Tubarões-Baleia**: A identificação individual é uma importante ferramenta para estudos de comportamento animal, ecologia e biologia populacional. [S.L.], 2020. Disponível em: <<https://www.mardeideias.com/post/foto-identifica%C3%A7%C3%A3o-de-raias-manta-e-tubar%C3%B5es-baleia>>. Acesso em: 19 jun. 2023.

JANG, D. H. *et al.* **Dog Identification Method Based on Muzzle Pattern Image**. In: National Institute of Animal Science, Rural Development Administration, 2020, Sejong. Proceedings... Sejong: MDPI, 2020. p. 1-17

MARQUES, V. G. O. **Avaliação do desempenho das redes neurais convolucionais na detecção de ovos de esquistossomose**. 2017. 49 f. Monografia (Curso de Bacharelado em Engenharia da Computação) – Universidade Federal de Pernambuco – UFPE, Recife.

MARTINS, G. V. **A Foto-Identificação como ferramenta de avaliação de populações de boto cinza (SOLTALIA GUIANESIS) (Van Beneden, 1864)**: Elaboração de catálogo para o litoral norte de São Paulo e comparação com áreas adjacentes. 2022. 125 f. Dissertação (Mestrado em Ecologia e Recursos Naturais) – Universidade Estadual do Norte Fluminense Darcy Ribeiro – UENF, Rio de Janeiro.

MELO, J. **Você sabia que o nariz de cachorro funciona como uma impressão digital? Entenda mais sobre essa curiosidade!**, [s.l.], 2020. Disponível em: <<http://www.patasdacasa.com.br/noticia/voce-sabia-que-o-nariz-de-cachorro-funciona-como-uma-impressao-digital-entenda-mais-sobre>>. Acesso em: 23 abr. 2023.

MISHRA, M. **Convolutional Neural Networks, Explained**, [s.l.], 2020. Disponível em: <<http://towardsdatascience.com/convolutional-neural-networks-explained-9cc5188c4939>>. Acesso em: 01 mai. 2023.

MOREL, L. **Com abrigos lotados e sem espaço de resgate, leitor quer novo lar para cãozinho**: Marcus lamenta não ter condições de cuidar do filhote que ele recolheu e mesmo assim, não ter onde deixá-lo, Campo Grande, 2022. Disponível em: <<http://www.campograndenews.com.br/direto-das-ruas/com-abrigos-lotados-e-sem-espaco-de-resgate-leitor-quer-novo-lar-para-caozinho>>. Acesso em: 21 abr. 2023.

PUENTE, B. **Brasil tem quase 185 mil animais resgatados por ONGs, diz instituto**: Cerca de 60% deles foram salvos de situações de maus-tratos, Rio de Janeiro, 2022. Disponível em: <<http://www.cnnbrasil.com.br/nacional/brasil-tem-quase-185-mil-animais-resgatados-por-ongs-diz-instituto/>>. Acesso em: 22 abr. 2023.

RAMACHANDRAN, S.; **What is Image Recognition?** . [s.l.], 2023. Disponível em: <<https://nanonets.com/blog/image-recognition/>>. Acesso em: 19 jun. 2023.

REIS, C.F; Albuquerque, M. P.; Castro, S.B. **Introdução ao Reconhecimento de Padrões utilizando Redes Neurais**. Rio de Janeiro. 2012. Disponível em: <http://cbpfindex.cbpf.br/publication_pdfs/nt00201.2012_12_06_17_35_01.pdf>. Acesso em: 14 jun. 2023.

TU, X. *et al.* **Transfer Learning on Convolutional Neural Networks for Dog Identification**. In: 2018 IEEE 9th International Conference on Software Engineering and Service Science (ICSESS), 2018. Proceedings... Beijing: IEEE, 2018. p. 1-4

VAIDYA, P. *et al.* **A Novel Dog Breed Identification using Convolutional Neural Network**. **PriMera Scientific Engineering**, [s.l.], v. 2, n. 1, p. 16-21, dez, 2022.

WIZBICKI, S. A. **Reconhecimento de Padrões em imagens aplicando visão computacional** 2014. 4 f. Trabalho de Conclusão de Curso (Graduação) – Universidade Regional do Noroeste do Estado do Rio Grande do Sul – UNJUI, Rio Grande do Sul.

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR AVALIADOR – PROJETO

Avaliador(a): **Marcel Hugo**

Atenção: quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

ASPECTOS AVALIADOS		Atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	2. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	3. TRABALHOS CORRELATOS São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?	X		
	4. JUSTIFICATIVA Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada?	X		
	São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	5. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO Os requisitos funcionais e não funcionais foram claramente descritos?	X		
	6. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?	X		
	7. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
	As referências contemplam adequadamente os assuntos abordados (são indicadas obras atualizadas e as mais importantes da área)?	X		
ASPECTOS METODOLÓGICOS	8. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		

O projeto de TCC será reprovado se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos **4 (quatro)** itens dos **ASPECTOS TÉCNICOS** tiverem resposta ATENDE PARCIALMENTE; ou
- pelo menos **4 (quatro)** itens dos **ASPECTOS METODOLÓGICOS** tiverem resposta ATENDE PARCIALMENTE.

PARECER: (X) APROVADO () REPROVADO

-CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2023/1

DOGREC: APLICATIVO PARA RECONHECIMENTO DE CACHORROS A PARTIR DE IMAGENS DO FOCINHO

Everton Luiz Piccoli

Prof. Aurélio Faustino Hoppe - Orientador

5 INTRODUÇÃO

Nos dias de hoje, é muito comum encontrar famílias que adotam animais de estimação pelo simples fato deles proporcionarem benefícios emocionais ou até mesmo, referente a parte física das pessoas. Além disso, muitos adotam um animal de estimação para ter companhia, para ensinar às crianças sobre responsabilidade, para ter um animal de guarda, para ajudar a controlar a ansiedade e o estresse, entre outros motivos. Porém, cuidar de *pet* não é uma tarefa fácil, pois eles precisam de cuidados constantes, como alimentação adequada, higiene, exercícios físicos e atenção emocional ou médica. Destaca-se também que muitas pessoas adotam animais de estimação sem realmente entender o compromisso que é cuidar de um animal de forma responsável. Elas podem achar que ter um animal de estimação é divertido e fácil, mas quando percebem que é um trabalho árduo e que requer tempo, dinheiro e energia, acabam abandonando o animal (FERNANDES, 2019).

Segundo pesquisa realizada pelo Instituto Brasil Pet (IBP), atualmente no Brasil existem mais de 185 milhões de animais abandonados ou resgatados após maus-tratos. Desses, 60% dos cachorros resgatados são por maus-tratos e 40% por abandono (PUENTE, 2022). Para entender tal contexto, realizou-se uma pesquisa para tentar identificar os motivos dos abandonos, dentre eles, os principais motivos apontados foram: mau comportamento de seus cães (46,8%), mudança no espaço onde mora o ser humano (29,1%), estilo de vida do dono (25,4%) e expectativa frente à realidade de cuidar de um cachorro (14,9%) (ALVES, 2013).

No Brasil, os animais abandonados são recolhidos por Organizações Não Governamentais (ONGs) e abrigos de cachorros. No entanto, os abrigos geralmente enfrentam vários desafios, como superlotação, falta de recursos financeiros e de pessoal, falta de espaço e instalações inadequadas. Além disso, muitos animais que são deixados nos abrigos têm problemas de saúde, comportamentais ou de idade, o que torna mais difícil encontrar lares adequados. Por outro lado, existem pessoas preocupadas com seus pets, que têm buscado maneiras de monitorar seus cachorros, a fim de garantir a segurança e conhecimento de onde ele se encontra. Para isso, muitas vezes, optam pela utilização de métodos de monitoramentos que são invasivos como os microchips de Radio-Frequency Identification (RFID), Near Field Communication (NFD), entre outros. No entanto, o custo desses equipamentos encontra-se fora da capacidade financeira de grande parte da sociedade brasileira, perfazendo que muitos brasileiros optem pelo uso de uma simples coleira para reconhecer seus cachorros, e caso fujam, utilizem muitas vezes cartazes e redes sociais para encontrá-los (MOREL, 2022).

Segundo Martins (2022), a foto-identificação é uma técnica que vem sendo utilizada nos últimos anos para reconhecimento de animais, pelo simples fato de ser um método totalmente simples e não invasivo, ou seja, um método que não causa nenhum tipo de stress ao animal. Melo (2020) destaca que assim como o ser humano pode ser identificado pela impressão digital de sua mão, os cachorros também têm essas características, mas através de seu nariz ou focinho. Neste contexto, o uso da foto-identificação é uma grande aliada para este processo de identificação, porém para este processo se faz necessário encontrar padrões das marcas naturais dos narizes dos cachorros, como pigmentações, assimetrias entre outras características que devem ser consideradas pontos chaves para o processo de foto-identificação. A autora ainda reforça que o focinho dos cachorros possui padrões complexos, tornando-os únicos, sendo possível identificá-los através do uso de imagens. Jang *et al.* (2020) mencionam que identificar cachorros não é simples, e que já foi tentado a utilização de métodos como o EigenFaces, que é utilizado para reconhecimento de faces humanas, porém com cachorros não obteve muito sucesso. Para o reconhecimento dos padrões do focinho dos cachorros, Jang *et al.* (2020) optaram por utilizar métodos como *Scale-Invariant Feature Transform* (SIFT), *Binary Robust Invariant Scalable Keypoints* (BRISK), *Speeded-Up Robust Features* (SURF) e *Oriented fast and Rotated Brief* (ORB) para recolher características do focinho e através de uma rede neural, tenta-se identificar o cachorro. Outra forma seria através do uso de *Convolutional Neural Network* (CNNs), que são projetadas especificamente para o reconhecimento de padrões em imagens. Essas redes neurais consistem em várias camadas de neurônios que são capazes de detectar características específicas em uma imagem, como bordas, texturas e formas. A partir do contexto abordado, pode-se dizer que as redes neurais são uma ótima ferramenta para realizar a extração de características chaves de um cachorro para conseguir determinar sua raça, aumentando as possibilidades de conseguir identificar o cachorro de forma não invasiva a partir de suas marcas naturais.

Diante deste contexto, este trabalho visa responder a seguinte pergunta de pesquisa: qual é a eficácia da técnica de foto-identificação através de rede neurais convolucionais para reconhecimento de cachorros?

5.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar uma aplicação que seja capaz de identificar cães por meio do processo de foto-identificação, considerando marcas naturais presentes no focinho, buscando auxiliar na identificação de cachorros encontrados nas ruas (abandonados ou que foram perdidos pelos seus responsáveis).

Os objetivos específicos são:

- d) reconhecer cachorros a partir de imagens, utilizando algoritmos de processamento de imagem e redes neurais para extrair características e padrões dos focinhos dos cachorros;
- e) avaliar a precisão e eficácia do modelo desenvolvido em diferentes condições de iluminação, ângulos de captura de imagem e variações de características dos focinhos;
- f) disponibilizar a aplicação desenvolvida em uma plataforma online para utilização por ONGs, abrigos de animais e proprietários de cachorros, visando auxiliar na identificação de animais perdidos ou abandonados.

6 TRABALHOS CORRELATOS

Nesta seção serão descritos trabalhos que possuem características semelhantes aos principais objetivos do estudo proposto. A sub-seção 2.1 apresenta o trabalho de Tu *et al.* (2018) que desenvolveram uma aplicação capaz de detectar cachorros através do uso de imagens de seu corpo ou face. Na sub-seção 2.2 é descrito o trabalho de Bhavani *et al.* (2019), uma aplicação Android desenvolvida para identificar a raça de um cachorro através de imagens. Por fim, a sub-seção 2.3 detalha o trabalho de Vaidya *et al.* (2022) que desenvolveram uma aplicação capaz de identificar cachorros através de sua face, e ainda existindo a possibilidade de detectar a face de um humano e conseguir assemelhar sua face a uma raça de cachorro.

6.1 TRANSFER LEARNING ON CONVOLUTIONAL NEURAL NETWORKS FOR DOG IDENTIFICATION

Tu *et al.* (2018) desenvolveram uma aplicação para identificar cachorros através de imagens da face e do corpo do cachorro, tendo como intuito ajudar na gestão de práticas veterinárias. Os autores acreditavam que a combinação da biometria da raça e da face poderia melhorar a identificação dos cachorros. A partir disso, Tu *et al.* (2018) optaram por dividir o processo em duas etapas. A primeira denominada de “coarse stage”, transfere o aprendizado da GoogLeNet para a BreedNet. Na segunda etapa, “fine stage” realiza-se a identificação da identidade dos cachorros com base nos resultados obtidos no processo de classificação da raça dos cachorros, aumentando as chances de identificação correta dos cachorros.

Segundo Tu *et al.* (2018), foram utilizadas três bases de dados públicas para realizar a classificação de raças e identificação do cachorro, sendo elas: (i) a Columbia Dogs Dataset (CD_Dogs) no qual cada imagem possuía 8 características chaves: olho direito/esquerdo, nariz, ponta da orelha direita/esquerda, topo da cabeça e base da orelha direita/esquerda; (ii) a Standard Dogs Dataset (ST_Dogs) que possui mais partes do corpo do cachorro e, (iii) a Flickr-dog Dataset, que possui apenas duas raças, a Pug e Husky. A Figura 1 apresenta alguns exemplos de imagens existentes em cada uma das bases de dados.

Figura 5 – Base pública de dados com imagens de cachorros



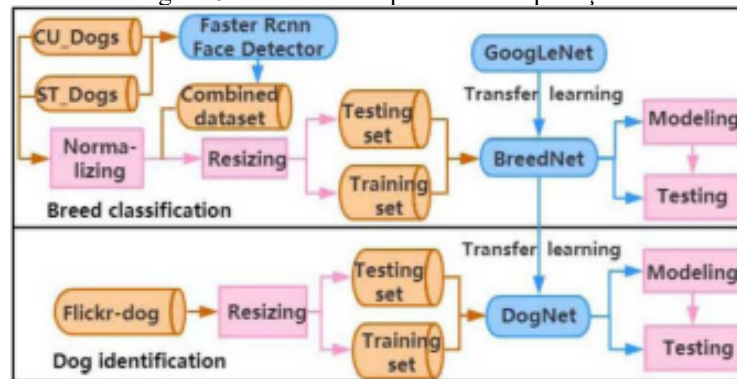
Fonte: Tu *et al.* (2018).

De acordo com Tu *et al.* (2018), o processamento e classificação das imagens foi subdividido em quatro estágios: (i) a normalização da imagem de acordo com as características de cada base de dados; (ii) separação dos dados a serem utilizados no treinamento; (iii) classificação da raça; (iv) identificação do cachorro com base no resultado da identificação das raças. Os autores utilizaram no “coarse stage”, a GoogLeNet, que serviu de base para a rede neural convolucional BreedNet, responsável pela determinação das raças. Para a etapa de identificação, a partir da BreedNet, criou-se a rede neural DogNet.

Tu *et al.* (2018) normalizaram as imagens considerando alguns pontos chaves. Na base de dados da St_Dogs são recortadas partes dos corpos dos cachorros com base nos rótulos para estabelecer a normalização. Já na Cd_Dogs, 8 pontos chaves da face do cachorro são estabelecidos, com isto é realizado o cálculo do ângulo entre o eixo horizontal e a linha conectando os olhos do cachorro. Este ângulo é utilizado para girar a imagem em

sentido horário com o objetivo de estimar a imagem final do cachorro com base em suas proporções. As imagens foram redimensionadas para 224x224 pixels e colocadas em uma base de teste para modelar e treinar os dados a partir de redes neurais. A Figura 2 apresenta o processo utilizado por Tu *et al.* (2018) para identificar raças e a identidade de cachorros.

Figura 6 – Estrutura do processo da aplicação



Fonte: Tu *et al.* (2018).

Tu *et al.* (2018) realizaram dois experimentos. O primeiro utilizou a BreedNet e dois conjuntos de dados, o Cd_Dogs e o St_Dogss. O conjunto de imagens foi subdividido em 70% para treinamento e 30% para validação. Os autores relatam que a BreedNet, utilizando normalização de imagens, obteve 81,74% de eficiência na St_Dogs e 86,63% na base da Cd_Dogs. No segundo experimento, utilizou-se a base de dados Flickr-dog que foi a única utilizada para identificar os cachorros nos experimentos. Segundo Tu *et al.* (2018), a DogNet apresentou eficiência de 76,18% para detectar a raça Pug, enquanto a raça Husky obteve 90,05%. Por fim, os autores concluem que a BreedNet pode ser utilizada na classificação da raça de cachorros pois, em relação as arquiteturas de redes neurais convolucionais existentes, mostrou-se 15% mais eficiente.

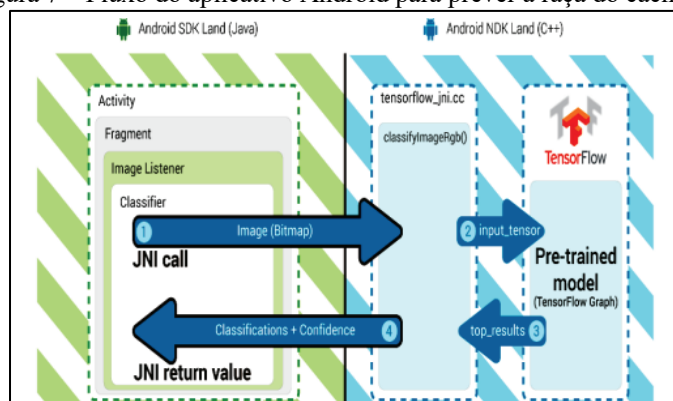
6.2 DOG BREED IDENTIFICATION USING CONVOLUTIONAL NEURAL NETWORKS ON ANDROID

Bhavani *et al.* (2019) desenvolveram um aplicativo Android que possibilita a identificação da raça de um cachorro através de um simples *upload* de imagem no aplicativo. A partir disso, realizou-se a identificação através de Redes Neurais Convolucionais e modelos de extração de dados pré-treinados pelas bibliotecas Keras e Tensorflow.

Segundo Bhavani *et al.* (2019), no treinamento do modelo utilizou-se a base de dados públicas Stanford dogs. Esta base possui mais de 120 tipos de raças de cachorros e para cada raça, tem-se no mínimo de 60 imagens. Ainda de acordo com os autores, para extrair as características das imagens foram utilizados diferentes modelos pré-treinados como Inception-v3, Inception-ResNet-v2, VGG16 e Xception, que eram treinadas na ImageNet e enviados para uma nova camada da aplicação. Bhavani *et al.* (2019), também ressaltam que quando utilizados modelos pré treinados a precisão obtida na extração das características fica acima de 80%.

Bhavani *et al.* (2019) destacam que para realizar a identificação da raça do cachorro é necessário (i) executar o modelo de rede neural no Keras, (ii) converter o modelo para um arquivo Tensorflow, permitindo a geração de gráficos de acompanhamento para otimizar o modelo. Além disso, os autores mencionam que a arquitetura da aplicação é composta de dois repositórios: o Android Standard Development Kit (SDK) e o Android Native Development Kit (NDK) que é responsável por realizar a comunicação com a biblioteca Tensorflow. A Figura 3 demonstra o fluxo do aplicativo para definição da raça do cachorro.

Figura 7 – Fluxo do aplicativo Android para prever a raça do cachorro



Fonte: Bhavani *et al.* (2019).

Bhavani *et al.* (2019) inicialmente enviam uma imagem *bitmap* do SDK para o repositório NDK. Tal imagem é redimensionada e encaminhada para uma rede neural convolucional pré-treinada que retorna um arquivo para o repositório SDK com as possíveis raças da imagem em questão. Ainda segundo os autores, a Xception e a Inception-ResNet-v2 obtiveram 93% e 94% de precisão. Já a Inception-v3 e a VGG16 alcançaram porcentagens um pouco mais baixas em relação aos dois primeiros, sendo 89% e 81% de precisão.

Por fim, Bhavani *et al.* (2019) concluem que as 4 redes neurais convolucionais utilizadas no processo de extração das características apresentam precisões promissoras e eficientes. Além disso, com a utilização de redes neurais pré-treinadas e uma base de dados sólida já existente no aplicativo em seus repositório, enfatizam que o aplicativo Android não precisa de internet para funcionar, recebendo a resposta quase que instantânea após o início do processo de identificação do aplicativo. Eles também relatam que o aplicativo apresenta problemas com o tamanho da imagem e só funciona com imagens tiradas da câmera do celular, apontando que tais melhorias podem ser exploradas em trabalhos futuros.

6.3 A NOVEL DOG BREED IDENTIFICATION USING CONVOLUTIONAL NEURAL NETWORK

Vaidya *et al.* (2022) desenvolveram uma aplicação para identificar raças de cachorros utilizando sua face. Além disso, com a aplicação, também era possível detectar a face de um humano e dizer com qual tipo de raça ele mais se assemelhava. Para isso, os autores subdividiram a aplicação em 3 etapas: (i) detecção de humanos; (ii) utilização do modelo de rede neural pré-treinado, VGG16, para reconhecer cachorros, (iii) envio do resultado da classificação (humano ou cachorro).

Segundo Vaidya *et al.* (2022), primeiramente realizou-se a importação dos dados e as bibliotecas para realizar o treino, validação e teste. Em seguida, Vaidya *et al.* (2022) explicam que para conseguirem realizar a detecção da imagem de um ser humano, utilizou-se a implementação de classificadores HaarCascade disponibilizados na biblioteca OpenCV. Já para a detecção de cachorros, utilizou-se a rede neural pré-treinada VGG16. Além disso, Vaidya *et al.* (2022) também modelaram uma rede neural do zero para conseguir identificar raças, tendo como base a arquitetura ResNet101.

Vaidya *et al.* (2022) ressaltam que nos testes foram utilizadas imagens de cachorros e humanos. A base de dados de cachorros era composta por 8351 imagens, sendo subdividida em 6680 imagens para treinamento, 836 imagens para os testes e 835 imagens para validação. Os autores também destacam que para cada um desses 3 grupos de imagens, havia um total de 133 raças de cachorros. Já em relação aos humanos, a base de dados continha 13233 imagens ordenadas pelo nome dos indivíduos, com dimensão de 250x250 pixels. Além disso, Vaidya *et al.* (2022) apontam que o HaarCascade obteve 98% de eficiência para humanos e apenas 17% na base de dados de cachorro. Já a rede neural construída utilizando transfer learning da arquitetura ResNet101 obteve uma precisão de 81%, identificando corretamente a raça em 680 de um total de 836 imagens de cães. A Figura 4 apresenta um exemplo de predição para imagens de entrada de cachorro e humano.

Figura 8 – Resultado da predição para cachorros e humano



Fonte: Vaidya *et al.* (2022).

Vaidya *et al.* (2022) concluíram que, ao utilizar a biblioteca OpenCV em conjunto com a rede neural pré-treinada VGG16, foi possível detectar com certa efetividade os rostos de humanos e cachorros. Além disso, enfatizaram que o desempenho do modelo construído por transferência de aprendizagem superou as expectativas, alcançando 81% de eficiência em comparação aos 13% do modelo CNN criado do zero. Vaidya *et al.* (2022) também apontam que o modelo ainda pode ser aprimorado ao adicionar mais dados para treinamento e testes, uma vez que atualmente existem apenas 133 raças de cães na base de dados.

7 PROPOSTA DA APLICAÇÃO

Esta seção tem como objetivo apresentar a justificativa para a elaboração deste trabalho, assim como os requisitos e metodologias que serão adotados neste projeto. Também serão apresentadas revisões bibliográficas onde serão abordadas algumas partes dos estudos a serem explorados para elaboração do projeto.

7.1 JUSTIFICATIVA

No Quadro 1 é possível se observar um comparativo entre os trabalhos correlatos escolhidos, onde neles serão abordados as principais características consideradas e resolução de problemas propostos. As linhas contêm as características de cada trabalho e a coluna são os trabalhos correlatos.

Quadro 3 – Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Tu <i>et al.</i> (2018)	Bhavani <i>et al.</i> (2019)	Vaidya <i>et al.</i> (2022)
Objetivo Proposto	Identificação da raça do cachorro e sua identidade	Identificação da raça do cachorro	Identificação da raça do cachorro, identificação de face humana, assemelhando a face a uma raça
Tipo de aplicação	Desktop	Android	Desktop
Redes Neural Utilizadas / Base de dados / Taxa de eficiência	BreedNet/ST-Dogs/81,74% BreedNet/CD_DOGS/86,63% DogNet/Flickr-dog Pug/76,18% DogNet/Flickr-dog Husky/90,05%	Xception / 93% Inception-ResNet-v2 / 94% Inception-v3 / 89% VGG16 / 81%	VGG16 / 81%

Fonte: elaborado pelo autor.

A partir do Quadro 1, pode-se observar que todos os estudos visam a detecção de raças/cachorros via imagens. Tu *et al.* (2018) buscavam detectar a raça do cachorro, tendo como intuito aumentar as chances de identificação do cachorro. Bhavani *et al.* (2019) apenas detectam a raça do cachorro e, Vaidya *et al.* (2022) além de identificar a raça, também a associam a face de um humano.

Também é possível receber que todos os trabalhos utilizaram Redes Neural Convolucional. Tu *et al.* (2018) desenvolveram uma aplicação desktop que utiliza as redes neurais GoogLeNet, BreedNet e DogNet. Bhavani *et al.* (2019) desenvolveram uma aplicação Android, utilizando no processo de extração das características modelos de redes neurais pré-treinados, como a Inception-v3, Inception-ResNet-v2, VGG16 e Xception. Vaidya *et al.* (2022) desenvolveram uma aplicação desktop capaz de identificar a raça do cachorro e também capaz de identificar a face de um humano e assemelhar ela a uma raça de cachorro. Para isso, os autores utilizaram a rede neural VGG16.

Em relação aos resultados, todos alcançaram boas taxas de eficiência. Tu *et al.* (2018) obtiveram na base de dados da ST_DOGS e com a rede neural BreedNet uma taxa de 81,74% para identificar a raça dos cachorros. Enquanto na base de dados CD_DOGS, a taxa foi de 86,63%. Através da rede DogNet, utilizando a base Flickr-dog, obteve-se a taxa de 76,18% para a raça Pug e 90,05% para Husky. Bhavani *et al.* (2019) ressaltam que utilizando a base de dados pública da Stanford dogs obtiveram 93% de eficiência com a rede Xception, 94% com a Inception-ResNet-v2, 89% com a Inception-v3 e 81% com a VGG16. Já Vaidya *et al.* (2022) utilizaram uma base de dados com 8351 imagens de cachorros e outra que continha 13233 imagens de humanos. Neste cenário, atingiram 81% de eficiência utilizando a rede VGG16.

Diante deste contexto, pode-se concluir que dentre os trabalhos pesquisados não há nenhum que tenha como objetivo primário identificar cachorros a partir de marcas naturais. Percebe-se que a maioria dos trabalhos apenas visam identificar a raça de um cachorro. Sendo assim, o trabalho proposto se difere dos demais, pois tem como objetivo reconhecer o cachorro através do processo de foto-identificação utilizando redes neurais convolucionais e imagens de seu focinho. Além disso, também pode-se destacar que a aplicação também poderá contribuir com a: (i) facilidade na identificação de cachorros. A aplicação pode ajudar na localização de animais de estimação, notificando os proprietários quando seus cachorros forem encontrados; (ii) redução do número de animais abandonados. Ao facilitar a identificação de cachorros perdidos ou abandonados, a aplicação pode ajudar a reduzir o número de animais que vagam pelas ruas e acabam em abrigos superlotados; (iii) melhora na segurança dos cachorros. Muitos cachorros são roubados ou perdidos durante caminhadas ou passeios. Com a aplicação, os proprietários podem ter maior segurança em relação aos seus cachorros, pois podem identificá-los rapidamente se forem perdidos ou roubados; (iv) aumento da conscientização sobre a importância da identificação de animais de estimação. Ao desenvolver e disponibilizar a aplicação, pode-se aumentar a conscientização sobre a importância da identificação de animais de estimação. Isso pode levar a um aumento na adoção de práticas de identificação e, por sua vez, ajudar a reduzir o número de animais perdidos ou abandonados. Em termos técnicos, este trabalho poderá contribuir para o desenvolvimento de tecnologias de detecção de identidade de animais através do processo de foto-identificação.

7.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

Os requisitos do trabalho estão divididos em duas partes: requisitos da aplicação móvel e requisitos do módulo de foto-identificação através do focinho.

A aplicação móvel deverá:

- f) manter o cadastro dos cachorros (Requisito Funcional - RF);
- g) permitir ao usuário carregar ou capturar imagens a partir de um dispositivo Android (RF);
- h) enviar notificação para o responsável do cachorro (maior probabilidade) após reconhecimento, contendo a posição geográfica na qual ele possivelmente foi encontrado (RF);
- i) utilizar de armazenamento na nuvem do servidor de aplicação (RNF);
- j) ser desenvolvido para a plataforma Android (Requisito Não Funcional - RNF);
- k) utilizar a linguagem Dart com o SDK Flutter para o desenvolvimento (RNF);
- l) utilizar o ambiente de desenvolvimento Visual Studio Code (RNF);
- m) utilizar o banco de dados SQLite para persistir os dados off-line (RNF).

O módulo de foto-identificação deverá:

- n) realizar o realce e melhoramento de ruídos, distorções e problemas de iluminação utilizando técnicas de processamento de imagens (RF);
- o) efetuar o processo de foto-identificação do cachorro utilizando redes neurais convolucionais para segmentar o focinho e identificar marcas naturais que possam caracterizar o indivíduo, inicialmente será utilizada a rede UNet (RF);
- p) permitir ao usuário visualizar as detecções e resultados obtidos no processo (RF);
- q) aprimorar a rede neural a partir de novas imagens cadastradas pelos usuários (RNF);
- r) utilizar as bibliotecas OpenCV para o processamento de imagens e o Tensorflow para a construção da rede neural artificial (RNF);
- s) utilizar a linguagem Python para desenvolvimento, utilizando a biblioteca Flask para elaborar o servidor REST (RNF);
- t) utilizar um banco de dados No-SQL (RNF).

7.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- u) levantamento bibliográfico: pesquisar e estudar sobre foto-identificação, reconhecimento de padrões, redes neurais convolucionais e trabalhos correlatos;
- v) elicitação de requisitos da aplicação móvel: baseando-se nas informações da etapa anterior, reavaliar os requisitos propostos para a aplicação;
- w) especificação: utilizar a ferramenta de diagramação *Enterprise Architect* (EA) para elaborar os diagramas de caso de uso e de atividades de acordo com a *Unified Modeling Language* (UML);
- x) implementação: a partir do item (c) implementar a aplicação móvel para a plataforma Android utilizando a linguagem Dart com o SDK Flutter;
- y) testes da aplicação móvel: elaborar testes para validar a usabilidade da aplicação junto aos possíveis usuários;
- z) coleta e montagem da base de dados: coletar imagens de cachorros e montar uma base de dados obtidas/cedidas junto a projetos já existentes na comunidade acadêmica. No caso das imagens coletadas durante a realização do trabalho será solicitado aos responsáveis a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- aa) pré-processamento de imagens: realizar a correção de imperfeições nas imagens, como ajuste de iluminação, corte e redimensionamento, para garantir a qualidade dos dados utilizados;
- bb) rotulação das imagens: rotular e validar as imagens coletadas a fim de buscar obter a maior eficiência possível nos resultados.
- cc) pesquisa e escolha do algoritmo de segmentação: pesquisar os principais algoritmos de segmentação e detecção de objetos, escolhendo o adequado para o desenvolvimento do trabalho. Inicialmente será utilizada a Rede Neural Convolucional UNet para detectar o focinho do cachorro;
- dd) pesquisa e escolha do algoritmo para foto-identificação: pesquisar as arquiteturas de RNA aderentes ao processo de foto-identificação de cachorros;
- ee) desenvolvimento do modelo de foto-identificação: a partir dos itens (i) e (j), realizar a implementação da arquitetura da rede neural artificial utilizando a biblioteca Tensorflow;
- ff) testes do modelo: paralelamente à implementação, realizar testes com base no banco de imagens obtido para verificar a eficiência e assertividade do modelo desenvolvido.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 4 – Cronograma de atividades a serem desenvolvidas

etapas / quinzenas	2023									
	jul.		ago.		set.		out.		nov.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
elicitação de requisitos da aplicação móvel										
especificação										
implementação										
testes da aplicação móvel										
coleta e montagem da base de imagens										
pré-processamento de imagens										
rotulação das imagens										
pesquisa e escolha do algoritmo de segmentação										
pesquisa e escolha do algoritmo para foto-identificação										
desenvolvimento do modelo de foto-identificação										
testes do modelo										

Fonte: elaborado pelo autor.

8 REVISÃO BIBLIOGRÁFICA

Esta seção tem como objetivo explorar os principais assuntos que fundamentarão o estudo a ser realizado neste projeto. A subseção 4.1 aborda sobre foto-identificação. Por fim, a subseção 4.2 discorre sobre reconhecimento de padrões e Redes Neurais.

8.1 FOTO-IDENTIFICAÇÃO

O uso de imagens na identificação de animais tem sido cada vez mais utilizadas nos dias de hoje. Para isso, muitas técnicas vêm sendo produzidas a fim de alcançar o objetivo proposto, e uma dessas técnicas é a de foto-identificação. A foto-identificação permite o reconhecimento individual de muitos animais que possuem um certo padrão de marcas naturais como formas, cores, cicatrizes, entre outras características. Esse método de marcação e recaptura é considerado não invasivo, o que é uma vantagem considerando que existem muitas outras técnicas de marcação artificiais que apresentam um risco maior (BRADFIELD, 2004).

Segundo Martins (2022), a foto-identificação é uma técnica que foi desenvolvida ao longo dos anos, mas que inicialmente teve como foco de estudo os animais terrestres, e que com o passar dos tempos foram se expandindo para várias espécies de animais. A técnica vem auxiliando os estudos, por ser uma forma não invasiva e não interferir no comportamento dos animais a serem estudados, visto que o estudo é baseado na realização de uma fotografia para através dela realizar a análise de marcas naturais do animal a ser reconhecido. Ainda segundo a autora, apesar de atualmente o uso da foto-identificação ser algo muito promissor e seguro, se faz necessário atender a alguns requisitos, sendo eles:

- gg) estabilidade: As marcas naturais do animal da pesquisa devem ser estáveis, ou seja, elas devem se manter constantes ao longo dos anos, para que seja preciso o resultado;
- hh) singularidade: as marcas naturais a serem levantadas no estudo e consideradas, devem ser únicas para ser possível diferenciar os indivíduos, mesmo que não seja possível garantir que a característica é exclusiva. Vale ressaltar que quanto mais complexa uma marca natural, logo mais informações estão associadas a mesma, com isso fazendo ser menos provável se repetir este padrão em outros animais;
- ii) probabilidade de reavistamento: Os indivíduos devem ter a mesma probabilidade de serem identificados ao longo dos anos por suas marcas naturais.

Segundo Ramachandran (2023), os algoritmos utilizados no processo de foto-identificação usam *deep learning* e redes neurais a fim de reconhecer padrões e processar imagens digitais. Ainda segundo o autor, o processo de reconhecimento de uma imagem normalmente envolve uma sequência de etapas a serem executadas durante o processo de validação do modelo a ser desenvolvido, sendo elas as seguintes:

- jj) coleta de dados: Coletar um grande conjunto de imagens rotuladas, que serão utilizadas para treinar o algoritmo de foto-identificação;
- kk) pré-processamento: Esta é a parte de polimento, onde antes de as imagens serem enviadas para treinamentos, elas passam por uma fase, onde são removidos ruídos, distorções ou outros elementos que possam prejudicar a efetividade do treinamento;
- ll) extração de características: Nesta etapa é realizado a partir de imagens pré-processadas, a extração de características que serão consideradas relevantes para distinguir o indivíduo;
- mm) treinamento do modelo: Nesta etapa é realizado o treinamento do modelo com base, no conjunto de imagens rotuladas. No qual, o algoritmo aprende a identificar e categorizar diferentes classes;
- nn) teste e avaliação do modelo: Etapa que realiza testes e validações a fim de identificar possíveis erros a serem corrigidos;

- oo) implantação: Nesta etapa, com o modelo validado e testado, ele pode ser utilizado para classificar novas imagens em diferentes cenários.

Segundo Fettermann (2020), a identificação fotográfica ou foto-identificação trata-se de uma técnica muito simples. O termo é utilizado para o rastreamento de animais com base em seus padrões corporais únicos. A autora também reforça que a foto-identificação é como se fosse uma *tag* natural, no qual, cada impressão digital, permite a pesquisadores desenvolver um banco de dados para garantir a conservação da espécie e seus devidos cuidados.

8.2 RECONHECIMENTO DE PADRÕES E REDES NEURAIS

O reconhecimento de padrões analisa os dados recebidos e tenta identificar padrões. A identificação de regularidades nos dados pode então ser usada para fazer previsões, categorizar informações e melhorar os processos de tomada de decisão. Enquanto o reconhecimento de padrão exploratório visa identificar padrões de dados em geral, o reconhecimento de padrão descritivo começa categorizando os padrões detectados. Portanto, o reconhecimento de padrões lida com esses dois cenários, e diferentes métodos de reconhecimento de padrões são aplicados, dependendo do caso de uso e da forma dos dados (BOESCH, 2023).

De acordo com Wizbicki (2014), o reconhecimento de padrões é uma técnica muito utilizada tanto para sistemas computadorizados como pelos próprios seres humanos. Existem muitas técnicas realizadas pelos seres humanos como ilusionismo entre outros que se baseiam no reconhecimento de padrões, assim como existem diversas aplicações de computador que possuem a capacidade de reconhecer vozes, imagens, entre outros com base no reconhecimento de padrões. A técnica utilizada para isso se baseia em conseguir classificar as informações baseando-se em um conhecimento inicial ou através de informações estatísticas de padrões. A autora também ressalta que a habilidade para a realização do reconhecimento de padrões é fundamental no ambiente de análise de imagens. O padrão é definido como uma descrição quantitativa ou estrutural de um objeto ou outra entidade de interesse na imagem. O reconhecimento de padrões por máquina envolve técnicas para a atribuição dos padrões a suas respectivas classes automaticamente com a mínima intervenção humana possível.

Segundo Reis (2012), a técnica de reconhecimento de padrões, pela natureza própria dela, acaba não sendo uma ciência exata, pois enquanto existem alguns padrões que podem ser identificados facilmente por serem bem estruturados ou serem estruturados de forma adequada para serem definidos por uma gramática, existem padrões que são de difícil modelagem ou difícil construção para serem reconhecidos por uma gramática. O autor também menciona que não há soluções gerais para o reconhecimento de padrões e que este dependia exclusivamente dos dados disponíveis sendo eles de aplicação ou tecnologia. Com este cenário é que o uso de redes neurais aparece como uma possível resolução para o problema, pois a construção de redes neurais envolve o entendimento informal do problema a ser resolvido. O autor também aponta as principais vantagens do uso de redes neurais sobre a maioria das técnicas de reconhecimentos de padrões, sendo elas: (i) adaptatividade: que seria a habilidade de se ajustar a novos cenários ou informações; (ii) velocidade, consegue ter uma ótima velocidade na busca de respostas; (iii) tolerância a falhas: capacidades de retorno de boas respostas independente dos dados; (iv) otimalidade: visto como taxa de erros em sistemas de classificação.

Com o conhecimento das redes neurais sendo importantes na área de reconhecimentos de padrão, é importante se abordar sobre uma das redes neurais mais presentes no cenário de processamento de imagens, as redes neurais convolucionais. Rede Neural Convolucional, também conhecida como *Convolutional Neural Network* (CNN), é definida como uma classe de redes neurais que são especializadas no processamento de dados que possuem a topologia semelhante a uma grade, como uma imagem. Uma imagem digital basicamente é uma representação binária de dados visuais que possuem uma série de pixels dispostos em forma de grade que contém valores de pixel para denotar o brilho e a cor de cada pixel. O cérebro humano processa uma enorme quantidade de informações no segundo em que uma imagem é vista. Cada neurônio trabalha em seu próprio campo receptivo e está conectado a outros neurônios de forma que cobrem todo o campo visual. Assim como cada neurônio responde a estímulos apenas na região restrita do campo visual chamada de campo receptivo no sistema de visão biológica, cada neurônio em uma CNN também processa dados apenas em seu campo receptivo. As camadas são organizadas de forma a detectar padrões mais simples primeiro (linhas, curvas etc.) e padrões mais complexos (faces, objetos etc.). Ao usar uma CNN, pode-se habilitar a visão para computadores (MISHRA, 2020).

Com o passar dos anos e com o desenvolvimento da tecnologia foram se criando diversos modelos de CNN para resolver problemas mais específicos de acordo com a área, entre eles pode-se citar os seguintes: (i) R-CNN, Fast R-CNN e Faster R-CNN que são utilizados principalmente na área de detecção de objetos (MISHRA, 2020).; (ii) *Visual Geometry Group* (VGG) uma rede neural convolucional utilizada principalmente na área de reconhecimento de imagens(BOESCH, 2023); (iii) No grupo dos Inception-v3, tem-se a GoogLeNet, como pioneira, pois esta CNN vem a ser um módulo da GoogLeNet. Utilizada principalmente na área de extração de características de imagens para reconhecimento; (iv) ResNet utilizada na área de reconhecimento por imagem (VAIDYA *et al.*, 2022).

Clappis (2019) menciona que uma rede neural convolucional pode ser dividida em até duas partes, sendo elas a parte de extração de características (Convolução, *Padding*, ReLU, Pooling) e uma rede neural tradicional. No qual, a primeira parte possui as seguintes componentes:

- pp) Convolução: Podemos entender esse processo como um filtro/*kernel* que transforma uma imagem de entrada;
- qq) *Padding*: Processo onde são adicionados alguns pixels ao redor da imagem com o objetivo de manter a dimensionalidade da imagem;
- rr) ReLU: Rede neural sem função de ativação. Função não linear, pode ter várias camadas de neurônios ativadas pela sua função. Função: $y = \max(0, x)$;
- ss) Pooling: É um processo de redução da imagem, com o objetivo de diminuir a variância a pequenas alterações e reduzir a quantidade de parâmetros a serem treinados pela rede. Existem 3 tipos de Pooling (MaxPooling, SumPooling, AveragePooling), onde todas seguem o mesmo princípio apenas mudando o cálculo do valor final;
- tt) Flatten: Basicamente opera uma transformação na matriz da imagem, alterando o formato dela para um array.

Segundo Marques (2017), para se realizar a avaliação de CNNs são utilizadas algumas métricas para comparação e validação dos modelos, onde cada métrica busca avaliar um aspecto diferente no modelo. As principais métricas são:

- uu) Acurácia: Esta métrica busca avaliar a quantidade de segmentos de classes positivas e classes negativas que foram classificadas de forma correta;
- vv) Precisão: Esta métrica avalia a quantidade de segmentos que foram classificados como positivos, ou seja, que pertencem ao segmento de classe positiva;
- ww) Recall: Esta métrica avalia a quantidade de segmentos positivos que foram corretamente classificados. Garantindo uma boa taxa de acerto para a classe positiva dos dados;
- xx) F1 ou *F-Score*: Esta métrica considera na sua avaliação a taxa da precisão quanto a da métrica Recall. Onde o valor calculado se baseia na média entre a precisão e a recall, multiplicado pela constante 2;
- yy) *Area Under the Receiver Operating Characteristic* (AUROC): Esta métrica busca avaliar através de um gráfico cada segmento apresentado ao classificador, onde no eixo vertical são apresentados os números referentes as classes positivas, enquanto no eixo horizontal são apresentados os números referentes a classe negativa.

REFERÊNCIAS

ALVES, A. J. S. Abandono de cães na América Latina: revisão de literatura. **Revista de Educação Continuada em Medicina Veterinária e Zootecnia do CRMV-SP**, v. 11, n. 2, p. 34-41, 1 jul. 2013.

BHAVANI, D. *et al.* **Dog Breed Identification Using Convolutional Neural Networks on Android**. **CVR Journal of Science and Technology**, [s.l.], v. 17, n. 1, p. 62-66, dez. 2019.

BOESCH, G. **What is Pattern Recognition? A Gentle Introduction (2023)**, [s.l.], 2023. Disponível em: <<http://viso.ai/deep-learning/pattern-recognition/>>. Acesso em: 20 abr. 2023.

BRADFIELD, S. K. **Photographic identification of individual Archey's frogs, *Leiopelma archeyi*, from natural markings**, 2004. DOC Science Internal Series 191. Department of Conservation, Wellington. 36 p.

CLAPPIS, A. M. **Uma introdução as redes neurais convolucionais utilizando o Keras**: Saiba como funciona uma CNN através desse exemplo com o dataset MNIST, [s.l.], 2019. Disponível em: <<http://medium.com/data-hackers/uma-introdu%C3%A7%C3%A3o-as-redes-neurais-convolucionais-utilizando-o-keras-41ee8dcc033e>>. Acesso em: 19 jun. 2023.

FERNANDES, C. **O que ensinamos aos nossos filhos quando abandonamos animais nas ruas**: Ter um pet é uma excelente oportunidade para as crianças desenvolverem maior senso de responsabilidade, solidariedade e afeto, [s.l.], 2019. Disponível em: <<http://www.metropoles.com/e-ducacao/o-que-ensinamos-aos-nossos-filhos-quando-abandonamos-animais-nas-ruas>>. Acesso em: 22 abr. 2023.

FETTERMANN, T. **Foto-identificação de Raias Manta e Tubarões-Baleia**: A identificação individual é uma importante ferramenta para estudos de comportamento animal, ecologia e biologia populacional. [S.L.], 2020. Disponível em: <<https://www.mardeideias.com/post/foto-identifica%C3%A7%C3%A3o-de-raias-manta-e-tubar%C3%B5es-baleia>>. Acesso em: 19 jun. 2023.

JANG, D. H. *et al.* **Dog Identification Method Based on Muzzle Pattern Image**. In: National Institute of Animal Science, Rural Development Administration, 2020, Sejong. Proceedings... Sejong: MDPI, 2020. p. 1-17

MARQUES, V. G. O. **Avaliação do desempenho das redes neurais convolucionais na detecção de ovos de esquistossomose**. 2017. 49 f. Monografia (Curso de Bacharelado em Engenharia da Computação) – Universidade Federal de Pernambuco – UFPE, Recife.

MARTINS, G. V. A **Foto-Identificação como ferramenta de avaliação de populações de boto cinza (SOLTALIA GUIANESIS) (Van Beneden, 1864)**: Elaboração de catálogo para o litoral norte de São Paulo e comparação com áreas adjacentes. 2022. 125 f. Dissertação (Mestrado em Ecologia e Recursos Naturais) – Universidade Estadual do Norte Fluminense Darcy Ribeiro – UENF, Rio de Janeiro.

MELO, J. **Você sabia que o nariz de cachorro funciona como uma impressão digital? Entenda mais sobre essa curiosidade!**, [s.l.], 2020. Disponível em: <<http://www.patasdacasa.com.br/noticia/voce-sabia-que-o-nariz-de-cachorro-funciona-como-uma-impressao-digital-entenda-mais-sobre>>. Acesso em: 23 abr. 2023.

MISHRA, M. **Convolutional Neural Networks, Explained**, [s.l.], 2020. Disponível em: <<http://towardsdatascience.com/convolutional-neural-networks-explained-9cc5188c4939>>. Acesso em: 01 mai. 2023.

MOREL, L. **Com abrigos lotados e sem espaço de resgate, leitor quer novo lar para cãozinho**: Marcus lamenta não ter condições de cuidar do filhote que ele recolheu e mesmo assim, não ter onde deixá-lo, Campo Grande, 2022. Disponível em: <<http://www.campograndenews.com.br/direto-das-ruas/com-abrigos-lotados-e-sem-espaco-de-resgate-leitor-quer-novo-lar-para-caozinho>>. Acesso em: 21 abr. 2023.

PUENTE, B. **Brasil tem quase 185 mil animais resgatados por ONGs, diz instituto**: Cerca de 60% deles foram salvos de situações de maus-tratos, Rio de Janeiro, 2022. Disponível em: <<http://www.cnnbrasil.com.br/nacional/brasil-tem-quase-185-mil-animais-resgatados-por-ongs-diz-instituto/>>. Acesso em: 22 abr. 2023.

RAMACHANDRAN, S.; **What is Image Recognition?** . [s.l.], 2023. Disponível em: <<https://nanonets.com/blog/image-recognition/>>. Acesso em: 19 jun. 2023.

REIS, C.F; Albuquerque, M. P.; Castro, S.B. **Introdução ao Reconhecimento de Padrões utilizando Redes Neurais**. Rio de Janeiro. 2012. Disponível em: <http://cbpfindex.cbpf.br/publication_pdfs/nt00201.2012_12_06_17_35_01.pdf>. Acesso em: 14 jun. 2023.

TU, X. *et al.* **Transfer Learning on Convolutional Neural Networks for Dog Identification**. In: 2018 IEEE 9th International Conference on Software Engineering and Service Science (ICSESS), 2018. Proceedings... Beijing: IEEE, 2018. p. 1-4

VAIDYA, P. *et al.* **A Novel Dog Breed Identification using Convolutional Neural Network**. **PriMera Scientific Engineering**, [s.l.], v. 2, n. 1, p. 16-21, dez, 2022.

WIZBICKI, S. A. **Reconhecimento de Padrões em imagens aplicando visão computacional** 2014. 4 f. Trabalho de Conclusão de Curso (Graduação) – Universidade Regional do Noroeste do Estado do Rio Grande do Sul – UNJUI, Rio Grande do Sul.

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR TCC I – PROJETO

Avaliador(a): Dalton Solano dos Reis

ASPECTOS AVALIADOS		atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	9. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	10. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	11. JUSTIFICATIVA São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	12. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados?	X		
	13. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
ASPECTOS METODOLÓGICOS	14. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		
	15. ORGANIZAÇÃO E APRESENTAÇÃO GRÁFICA DO TEXTO A organização e apresentação dos capítulos, seções, subseções e parágrafos estão de acordo com o modelo estabelecido?	X		
	16. ILUSTRAÇÕES (figuras, quadros, tabelas) As ilustrações são legíveis e obedecem às normas da ABNT?	X		
	17. REFERÊNCIAS E CITAÇÕES As referências obedecem às normas da ABNT?	X		
	As citações obedecem às normas da ABNT?	X		
	Todos os documentos citados foram referenciados e vice-versa, isto é, as citações e referências são consistentes?	X		

O projeto de TCC será reprovado se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos **4 (quatro)** itens dos **ASPECTOS TÉCNICOS** tiverem resposta ATENDE PARCIALMENTE; ou
- pelo menos **4 (quatro)** itens dos **ASPECTOS METODOLÓGICOS** tiverem resposta ATENDE PARCIALMENTE.

PARECER:

(X) APROVADO

() REPROVADO