

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
(X) PRÉ-PROJETO	() PROJETO	ANO/SEMESTRE: 2021/2

ANÁLISE DO COMPORTAMENTO DO TRÂNSITO DE BLUMENAU EM RELAÇÃO A ASPECTOS SOCIOECONÔMICOS

Célio Rodrigues Junior

Prof. Aurélio Faustino Hoppe – orientador

1 INTRODUÇÃO

Com a evolução da tecnologia, carros e motocicletas ficaram relativamente baratos, tanto no Brasil quanto em outros países do mundo. Por outro lado, com o aumento da frota de veículos, escancara-se um dos grandes problemas das cidades, o congestionamento. Com base nesse problema, estudos científicos do fluxo de tráfego tiveram seu início na década de 1930 e se desenvolveram, através de várias teorias, o que compõe a teoria do fluxo de tráfego (GERLOUGH; HUBER, 1975).

Segundo Da Silva (1994), a teoria do fluxo de tráfego consiste na aplicação de conceitos da matemática, da teoria da probabilidade e da física à descrição do comportamento do tráfego veicular rodoviário. São estudados desde fluxos de tráfego vistos como meios indivisíveis até os menores elementos que os compõem (veículos) vistos individualmente.

Bas *et al.* (2007) destacam que são criadas constantemente várias ferramentas para simular ou analisar o trânsito e, um dos recursos mais utilizados são as câmeras de vídeo. As câmeras de vídeo foram introduzidas pela primeira vez no gerenciamento de tráfego para vigilância rodoviária, transmitindo imagens de circuito fechado de televisão a um operador humano para interpretação. Os sistemas de gerenciamento de tráfego atuais utilizam processamento de vídeo digital para analisar automaticamente a cena de interesse e extrair informações para monitoramento de tráfego.

De acordo com Zou *et al.* (2019), uma das formas de se converter imagens em dados de fluxos, é através de aprendizado de máquina, como por exemplo, utilizando algoritmos de detecção de objetos. A detecção de objetos é uma importante tarefa de visão computacional que é usada para detectar instâncias de categorias específicas de objetos visuais, como carros em imagens digitais. O objetivo da detecção de objetos é desenvolver modelos computacionais e tecnologias para fornecer uma das informações mais básicas necessárias para aplicações de visão computacional, que é quais objetos estão na cena e onde eles estão. Ainda segundo os autores, a detecção de objetos tornou-se amplamente usada em muitas aplicações práticas, como direção autônoma, visão de robô, vigilância por vídeo etc.

Segundo Zou *et al.* (2019), nos últimos anos, vários estudos foram realizados sobre o tráfego usando visão computacional e aprendizado de máquina. Grande parte dessas pesquisas tiveram como foco as principais cidades do mundo, como por exemplo Xangai, na China. Nessas metrópoles, por serem em países desenvolvidos e com mais recursos financeiros, já existem ferramentas de análise de tráfego, o que facilita a obtenção de dados e análises. Como exemplo de ferramenta, pode-se destacar o *Sydney Coordinated Adaptive Traffic System* (SCATS). Segundo a fornecedora, *NSW Government* (2021), SCATS é um sistema de controle de tráfego projetado para otimizar o fluxo de tráfego. Dados são processados em tempo real, através de algoritmos inteligentes, para ajustar o tempo para responder aos sinais de tráfego em situações inesperadas, prever padrões de tráfego e manter o fluxo de tráfego. Além disso, há também a Pumatronix que trabalha com pesquisa e desenvolvimento de soluções para Sistemas de Transporte Inteligente (ITS) que contribui para a mobilidade urbana e rodoviária, segurança, modernização das cidades, e fiscalização no trânsito (PUMATRONIX, 2021). Em contrapartida no Brasil, especialmente nas cidades não metropolitanas, não é fácil obter dados e ferramentas de análise. Ainda de acordo com Zou *et al.* (2019), no país, devido à dificuldade de acesso a essas ferramentas, é difícil analisar as interferências e os fatores que afetam o trânsito, o que torna difícil analisar e gerenciar o mesmo. Portanto, vê-se a necessidade de um sistema de análise de tráfego que possa contribuir para as decisões relacionadas ao tráfego com base em números quantitativos e estruturados de acordo com o que está ao seu redor em cenários regionalizados.

Diante deste contexto, esse trabalho se propõe a criar um artefato computacional que estabelece o comportamento do fluxo do trânsito de Blumenau. Serão utilizadas técnicas de aprendizado de máquinas e visão computacional para coletar dados quantitativos sobre o trânsito de Blumenau. Assim como, também serão levados em consideração informações da região (comércios, escolas, densidade populacional etc.) em períodos espaciais e temporais distintos.

1.1 OBJETIVOS

Esse trabalho tem como objetivo desenvolver um artefato computacional que seja capaz de estabelecer as relações básicas entre as variáveis de demanda, de oferta, de operação viária, de localidade e socioeconômicas de vias pré-cadastradas da cidade de Blumenau.

Os objetivos específicos são:

- a) realizar a detecção dos veículos utilizando técnicas de processamento de imagem e aprendizado de máquinas;
- b) criar uma base de dados unificada correlacionando os dados do fluxo do trânsito e informações socioeconômicas e da infraestrutura regional;
- c) classificar seções de estradas buscando evidências para estabelecer fatores que afetam o trânsito e os motivos de sua ocorrência.

2 TRABALHOS CORRELATOS

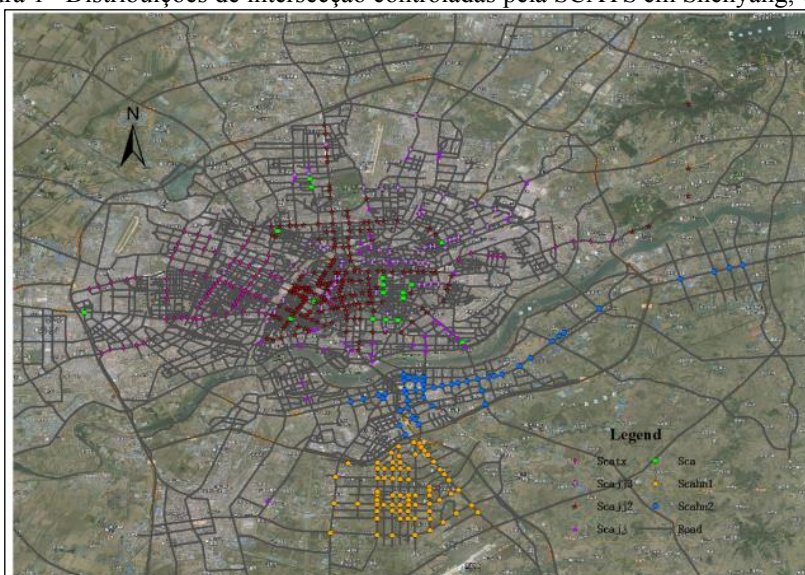
Neste capítulo são apresentados três trabalhos correlatos semelhantes ao proposto. A seção 2.1 apresenta uma análise empírica sobre o trânsito de Shenyang, na China (Wang *et al.*, 2018). Na seção 2.2 é apresentado um método de avaliação de pontos de congestionamentos por meio sistema de informação geográfica (Zhang *et al.*, 2017a). Por fim, na seção 2.3 é investigado um padrão de congestionamento de 24 horas da rede rodoviária através da velocidade (Zhang *et al.*, 2017b).

2.1 ANALYZING URBAN TRAFFIC DEMAND DISTRIBUTION AND THE CORRELATION BETWEEN TRAFFIC FLOW AND THE BUILT ENVIRONMENT BASED ON DETECTOR DATA AND POIS

Wang *et al.* (2018) desenvolveram um método de análise empírica via *Sidney Coordinated Adaptive Traffic System* (SCATS) e dados ambientais para compreender as características de distribuição temporal e espacial de tráfego das cidades a fim de obter evidências empíricas para a análise e gestão do tráfego rodoviário urbano além de verificar o quão universais podem ser os resultados, aplicando uma análise semelhante para cidades europeias. Segundo o autor, SCATS é um sistema australiano de controle de tráfego em tempo real, que pode alterar o tempo dos semáforos de acordo com as mudanças no fluxo de veículos. Por meio dos dados lidos pelos detectores, o sistema pode responder às mudanças no fluxo do veículo ao longo do dia e se adaptar a eventos aleatórios, como dias chuvosos e feriados, sem a intervenção do operador. Essa adaptação funciona 24 horas por dia, 365 dias por ano. Junto com o SCATS, existe também um sistema estatístico denominado *SCATS Traffic Reporter*, que publica relatórios sobre as informações coletadas pelo sistema SCATS, como a veículos durante o dia, para poder realizar pesquisas de gestão sobre estradas controladas pelo sistema.

Segundo Wang *et al.* (2018), as informações funcionais sobre a rede de tráfego rodoviário urbano foram obtidas do SCATS em Shenyang, na China, que é uma das maiores cidades na região nordeste da china tendo uma população automotiva de 1.46 milhões. Os sistemas SCATS da cidade tinham um total de 525 intersecções na área urbana principal da cidade, conforme mostra a Figura 1.

Figura 1– Distribuições de intersecção controladas pela SCATS em Shenyang, China



Fonte: Wang *et al.* (2018).

Considerando a regularidade dos padrões de viagens dos residentes, Wang *et al.* (2018) selecionaram de forma randômica dados de um cruzamento típico e a estrada de entrada oeste que liga esse cruzamento, durante uma semana (de 29 de julho de 2014 a 4 de agosto de 2014). Do ponto de vista do fluxo total, com exceção domingo (3 de agosto de 2014), a demanda de tráfego neste cruzamento foi relativamente estável, e o dia em que ocorreu o maior número de tráfego foi na sexta-feira (1 de agosto de 2014).

Segundo Wang *et al.* (2018), os principais fatores ambientais construídos que afetam o estado do tráfego ou os comportamentos de viagem podem ser divididos em fatores relacionados ao tráfego e ao uso do solo. Com isso, o detector geográfico foi introduzido para avaliar os parâmetros ambientais construídos que podem ser responsáveis pelo estado do tráfego rodoviário. Além de fatores ambientais, Wang *et al.* (2018) se utilizaram de outros fatores para determinar o fluxo do tráfego, como por exemplo, os fatores de tipo de rua, números de estações de ônibus em um segmento de 100 metros, proporção de área comercial, dentre outros.

Wang *et al.* (2018) observaram que os horários de pico durante o dia concentram-se principalmente no pico da manhã (07h00-09h15) e no pico noturno (16h15-18h15). A frequência de pico dos dois picos juntos foi responsável por 82,22% do horário de pico. A taxa de fluxo máxima de um dia ocorre principalmente durante o período de pico da manhã, sendo responsável por 62,54% do horário de pico. Além disso, os autores descobriram que o fluxo do tráfego urbano estava concentrado principalmente em algumas estradas. Cerca de 66% das estradas de pequeno e médio porte cobrem cerca de 38% do fluxo de tráfego, e 34% das estradas de médio e grande porte atendem a cerca de 62% do fluxo de tráfego. Os autores também observaram que, de maneira geral, o fluxo nos cruzamentos durante os horários de pico aumenta à medida que aumenta o número de faixas de entrada. No entanto, diferentes conjuntos de amostras mostram que quando o número de faixas de entrada é 14, a capacidade máxima de suporte de cada tipo de indivíduo é a melhor.

Wang *et al.* (2018) mencionam que, em termos da distribuição temporal da demanda de tráfego, os horários de pico de diferentes cruzamentos e vias são considerados heterogêneos, revelando a flexibilidade do tempo de deslocamento. Os principais picos de viagens são os picos da manhã e da noite. O maior horário de pico do dia é pela manhã, o que indica que os destinos e as rotas das pessoas mudam depois que saem do trabalho, causando menos carga de tráfego para as estradas. Portanto, os autores acreditam que horários e locais de trabalho flexíveis são uma forma eficaz de reduzir o número de veículos e melhorar as condições de tráfego. Além disso, existe uma correlação linear positiva significativa entre o número de faixas e o fluxo médio de tráfego de serviço. Quanto maior o número de faixas, seja em estradas ou em cruzamentos, maior o número de veículos atendidos. No entanto, o valor máximo do fluxo de tráfego revela a diferença nas capacidades do serviço. Tais resultados talvez só sejam válidos neste caso, por isso mais dados de outras cidades são necessários para explorar se existem regras universais, pois para Wang *et al.* (2018) seria interessante explorar o quão universais são suas descobertas, conduzindo uma análise semelhante para cidades europeias e outras, para que possam ter uma melhor compreensão dos sistemas de transporte urbano.


2.2 IMPACT ANALYSIS OF LAND USE ON TRAFFIC CONGESTION USING REAL-TIME TRAFFIC AND POI

Zhang *et al.* (2017a) apresentaram um método de avaliação de pontos de congestionamentos por meio Sistema de Informação Geográfica (SIG), sendo uma alternativa eficaz frente aos modelos convencionais de quatro etapas que normalmente operam com base em dados de pesquisa individuais de alto custo, baixa precisão e baixa eficiência. Além disso, também não consideram informações geográficas, como as coordenadas de longitude e latitude, as categorias e as informações de localização específicas. Tendo o intuito de contribuir para a formulação de políticas de planejamento do uso do solo urbano, os autores exploraram a correlação entre o congestionamento do tráfego e diferentes atributos do uso do solo urbano, estabelecendo a evolução dos modelos geográficos do congestionamento do tráfego urbano.

Zhang *et al.* (2017a) tentaram obter uma melhor classificação das *Points of Interest* (POI) de Pequim, que é uma boa representação do propósito de viagem dos residentes. Os resultados mostram que, trabalho, escola, compras, lazer e "ir para casa" são as principais razões para os residentes de Pequim viajarem, respondendo por cerca de 85% do volume total de viagens. Este estudo também extrai cerca de 90.000 POIs dentro do quarto anel viário em Pequim usando software web crawler, que são robôs usado por buscadores para encontrar e indexar páginas de um site. Os dados do POI possuem quatro tipos de informações: nome, categoria, longitude e latitude. Através do processamento, as características do uso do solo são determinadas e a relação entre o congestionamento do tráfego e os diferentes tipos de uso do solo são identificadas. A quantificação do POI focou na área edificada, que é o principal indicador da cidade em fase de planejamento, e reflete de forma objetiva os atuais indicadores populacionais, de emprego, socioeconômicos e específicos de desenvolvimento regional. Devido ao grande número de POIs, não era prático usar-se de todos, portanto, os POIs foram selecionados aleatoriamente para investigação. Na pesquisa de campo realizada em maio de 2016, entre 58 e 67 pontos de interesse foram selecionados aleatoriamente para cada tipo de uso de terreno.

Além das POIs, Zhang *et al.* (2017a) utilizaram informações de mapas vindas de aplicativos de mapas. Os aplicativos de mapas usam as informações dos estados das estradas para navegar pelas estradas e planejar as viagens dos motoristas. As imagens dos mapas nos motores de busca da web são compostas por diferentes camadas: camada inferior, camada do meio e a camada superior. Zhang *et al.* (2017a) utilizaram a camada superior que contém as informações de tráfego representadas nas cores vermelho, amarelo e verde. Os dados em tempo real foram coletados a cada 5 minutos, um total de 60 vezes por dia, no pico da manhã (7h00 às 9h30) durante a semana e no pico da noite (17h às 19h30), na primeira semana de março de 2016. A Figura 2 apresenta o resultado dos dados obtidos, onde as linhas em vermelho representam áreas de congestionamento, as linhas em amarelo representam trânsito normal e as linhas em verde representam trânsito suave.

Figura 2 – O esquema do tráfego rodoviário em tempo real no pico da manhã do dia útil.



Fonte: Zhang *et al.* (2017a).

Depois de coletar os dados de tráfego em tempo real, Zhang *et al.* (2017a) transformaram manualmente os dados em vetores, armazenando-os em formato de camada ShapeFile, que é um formato de armazenamento vetorial digital usado para armazenar localização geométrica e informações de atributos relacionados. A partir disso, criou-se um programa escrito na linguagem de programação Python para avaliar os pixels e pontos discretos na camada vetorial com pigmento. O programa sobrepõe o tempo de congestionamento em um único horário acumulado durante cada período de pico da manhã/noite. Os autores usam o atributo de tempo de congestionamento para agrupar áreas congestionadas. Também é utilizado o método de interpolação para tornar o agrupamento razoável e mais próximo da situação real de todo o espaço. Zhang *et al.* (2017a) utilizaram regressão linear múltipla para determinar a relação entre o uso da terra e o congestionamento do tráfego. Neste caso, analisaram o tempo de congestionamento e a proporção de terra em cada área do cluster. As áreas selecionadas são cinco tipos de terrenos para residências, educacionais, comerciais e de lazer. Como a variável dependente é ordenada e multi-classificada, a análise ordinal é realizada usando IBM SPSS *Statistics* 19.0, que é um serviço em nuvem que fornece recursos de análise estatística e disponibilidade.

Segundo Zhang *et al.* (2017a), os resultados mostram que o tempo de congestionamento está positivamente correlacionado com a proporção de terrenos empresariais, comerciais e educacionais. Isso ocorre porque as viagens nos picos de manhã e à noite durante a semana estão relacionados a ida à escola ou ao trabalho. Os autores descobriram que áreas com mais terrenos comerciais causarão sério congestionamento de tráfego, porque os moradores começam e terminam no mesmo horário (manhã e noite). Por outro lado, as áreas com uma proporção menor de terrenos comerciais são menos congestionadas porque os residentes têm tempos de viagem diferentes.

Zhang *et al.* (2017a) relatam que o método proposto é uma alternativa viável para analisar o congestionamento de tráfego a partir de dados de mapas online. Além disso, pode servir de orientação política, sendo uma referência para o planejamento do uso do solo urbano. Os autores ainda apontam que o modelo de regressão pode ajudar a prever e estimar a correlação entre o uso do solo e a intensidade do congestionamento, sem depender de modelos de tráfego mais complexos, como o método de tráfego de quatro etapas. Zhang *et al.* (2017) também destacam que são necessários outros testes em outras áreas buscando determinar um padrão de relação entre os tipos de terreno e o congestionamento de tráfego.

2.3 ANALYZING SPATIOTEMPORAL CONGESTION PATTERN ON URBAN ROADS BASED ON TAXI GPS DATA

Zhang *et al.* (2017b) investigaram o padrão de congestionamento de 24 horas da rede rodoviária através da velocidade, usando agrupamento *Fuzzy C-mean* (FCM) para classificar seções de estradas problemáticas em contínuas de baixa velocidade ou congestionamento não convencionais. Os autores tinham como intuito averiguar a relação entre o congestionamento do tráfego e o ambiente construído, incluindo fatores relacionados ao tráfego e ao uso do solo.

Segundo Zhang *et al.* (2017b), a coleta de dados foi feita a partir dos dados obtidos pelos táxis de Xangai, que foi coletada em 10 de abril de 2015, uma sexta-feira de intenso tráfego. Os dados foram fornecidos pela *Qiangshen Company*, empresa que fornece serviços de transporte de táxi e miniônibus, em uma competição online de dados abertos. A base de dados tem 114.633.142 registros e o intervalo de tempo é de 30 segundos. O registro original incluía ID de táxi, status, hora do sinal recebido, hora do sinal medido, longitude, latitude, velocidade etc. Além disso, apenas as viagens de táxi ocupado foram utilizadas para geração de padrão de velocidade, porque um táxi vazio não refletiria as condições reais de tráfego causadas pela desaceleração para busca de passageiros, deslocamento ou redução do combustível durante o táxi vazio. Com foco no congestionamento de tráfego, considerando apenas as vias primárias e secundárias no centro de Xangai, um total de 853 trechos de estradas foram selecionados, que possuíam dados de tráfego e ambientais, representando os trechos com maior congestionamento durante a jornada de trabalho. Na preparação dos dados, Zhang *et al.* (2017b) descartaram alguns dos dados que não correspondem às estradas mais próximas em 15m, permanecendo imóveis por mais de 5 minutos, ou com velocidade acima de 120 km/h e desvio repentino de distância acima de 1 km/min. Trinta visitas por hora foram definidas como *threshold* para os segmentos, buscando evitar a propagação do erro.

Segundo Zhang *et al.* (2017b), se estabeleceu o padrão de velocidade a partir de 551 segmentos. A análise de *clustering* foi usada para agregar segmentos de estradas em grupos com base em padrões de velocidade. Inicialmente, o padrão de velocidade de cada segmento foi representado como um vetor de 24 dimensões. Um método de soft clustering, denominado *Fuzzy C-means* (FCM), faz com que os pontos de dados possam pertencer a vários clusters ao mesmo tempo por grau de associação, sendo mais preciso, de modo que os resultados do modelo numérico poderiam ser usados em métodos de regressão. Com isso, 4 clusters estão devidamente separados, o cluster 1 tem 235 objetos, o cluster 2 tem 177 objetos, o cluster 3 tem 107 objetos e o cluster 4 tem 32 objetos. O cluster 1 foi definido como uma “*Congested Segments*” com uma velocidade média de 22,58 km/h. Comparado com outros clusters, sua trajetória de velocidade é mantida em um nível baixo e a tendência é relativamente estável. A característica do Cluster 2 é que a velocidade é média, com média de 29,51 km/h, representando a “*Normal Speed Segments*”. O cluster 3 pode ser considerado um estado crítico, exibindo mudanças e flutuações de velocidade mais altas durante os horários de pico, por isso é marcado como uma “*Unimpeded Segments*”. A velocidade média é 41,11 km/h, sendo 7 km/h mais alta do que o Cluster 2, que é um valor relativamente pequeno. O limite de velocidade do segundo nível é 40 km/h. O cluster 4 é rotulado como “*High Speed Segments*”, com a maior velocidade média 61,63 km/h e o menor tamanho de amostra de 32.

Zhang *et al.* (2017b) analisaram 12 fatores que influenciam no tráfego, incluindo a distância até o hospital mais próximo, o número de estacionamento a 500m e o número de escolas a 500m. O cluster FCM classifica as seções da estrada durante 24 horas, mas ainda é duvidoso se o tráfego e os fatores relacionados ao uso do solo têm um impacto significativo no congestionamento. O *Geographical detector* foi introduzido para julgar os parâmetros ambientais construídos. Os autores também utilizaram o *GLOBAL MORAN's I*, que mede a correlação espacial, testando se os objetos observados são semelhantes a objetos espacialmente vizinhos. Para o valor do intervalo *MORAN I*, $[-1, 1]$, $I = 0$ significa independência espacial completa, $I > 0$ significa correlação positiva e $I < 0$ significa correlação negativa. O *I* de MORAN é calculado cluster a cluster. Segundo os autores, todos os valores *I* de MORAN foram maiores que zero. Dessa forma, o detector geográfico e o do *I* de MORAN comprovaram a influência desses fatores nos resultados de agrupamento e na similaridade espacial dos trechos rodoviários próximos. Portanto, segundo Zhang *et al.* (2017b), os modelos espaciais envolvendo autocorrelação espacial e sistemas multivariados mostraram-se mais adequados. No entanto, também aplicou-se um atraso espacial denominado modelo de média móvel autorregressivo espacial misto (SARMA) para resolver dependências e erros de objetos mais próximos e com maior impacto.

Zhang *et al.* (2017b) destacam que no cluster 1, todos os fatores importantes mostram pressão de tráfego contínua. A estação rodoviária e os estacionamento próximos também trouxeram um fluxo constante de tráfego. Para os segmentos de estradas pertencentes ao Cluster 1, 55,1% das escolas são universidades ou escolas profissionais. Além disso, a demanda por hospitais é muito elevada, estimulando o fluxo de transporte particular e táxis. Pequenos centros, como estações de ônibus ou de logística, costumam ser acompanhados por congestionamentos de tráfego intenso. O cluster 2 tem uma forte tendência de tráfego de oscilação. Fatores importantes que contribuem para o fenômeno do deslocamento incluem efeitos comerciais do uso do solo, estações de metrô e escolas. No entanto, fatores de influência como pontos de ônibus, estacionamento e hospitais próximos

tornaram-se menos significativos e a velocidade média geralmente aumentou. Em segmentos de estrada mais longas geralmente significa menos controle de sinal, o que também é um fator chave. As seções de estradas no cluster 3 são dominadas por estradas arteriais e fatores de interferência, como estações de ônibus e estacionamentos, diminuíram ou aumentaram, e a proporção de terreno para tráfego é extremamente alta. Para o cluster 4, a velocidade média dos principais objetos associados está próxima ao limite de velocidade de 60 km / h, e os fatores ambientais estabelecidos ao seu redor são semelhantes aos da periferia. Estações de ônibus de baixa densidade, estações de metrô e hospitais comprovam essa conclusão. De acordo com os resultados obtidos, Zhang *et al.* (2017b) apontam que a localização em relação ao anel rodoviário e a proporção de casas têm pouco efeito na formação de congestionamentos.

De acordo com Zhang *et al.* (2017b), embora os resultados sejam promissores, mais pesquisas são necessárias para melhorar o desempenho do modelo. Os autores também apontam que os dados de GPS de táxi não cobriam toda a área de Xangai, limitando-se principalmente às áreas urbanas. Além disso, apenas um dia da semana foi analisado, sendo necessário a análise de vários dias. Já em relação ao processo de análise espacial, o modelo proposto não considerou a interação de fatores ambientais. Por fim, Zhang *et al.* (2017b) destacam a análise de curto prazo revelou algumas características importantes ou fenômenos óbvios que só aparecem durante os horários de pico.

3 PROPOSTA

Neste capítulo são definidas as justificativas de elaboração dessa ferramenta, assim como os requisitos funcionais, não funcionais e a metodologia aplicada.

3.1 JUSTIFICATIVA

No Quadro 1 é apresentado um comparativo dos trabalhos correlatos. As linhas representam as características e as colunas os trabalhos.

Quadro 1 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Wang <i>et al.</i> (2018)	Zhang <i>et al.</i> (2017a)	Zhang <i>et al.</i> (2017b)
Objetivo	Fornecer evidências empíricas para a análise e gestão do tráfego rodoviário urbano	Contribuir para a formulação de políticas de planejamento do uso do solo urbano	Averiguar a relação entre o congestionamento do tráfego e o ambiente construído
Origem da Base de Dados	Detectors e Câmeras de Trânsito	Web crawler	GPS de Taxis
Obtenção dos Dados	SCATS e POIs	SIG e POIs	Dados Taxi fornecidos pela <i>Qiangshen Company</i>
Forma de Agrupamento	Análise Empírica	Cluster <i>K-Means</i>	Cluster <i>Fuzzy C-Means</i>
Fatores de Agrupamento	Não se aplica	Padrões de velocidade	Tempo de congestionamento
Número de Fatores levados em consideração	12	5	12
Técnica de Análise	Empírica	Regressão linear múltipla, IBM SPSS <i>Statistics</i> 19.0	<i>Geographical Detector</i> , <i>GLOBAL MORRAL'I</i>

Fonte: elaborado pelo autor.

A partir da Quadro 1, pode-se observar que Wang *et al.* (2018) tinham como objetivo fornecer uma base para a análise e gestão do tráfego rodoviário urbano. Zhang *et al.* (2017a) buscaram contribuir para a formulação do planejamento do uso do solo urbano. Já Zhang *et al.* (2017b) se concentraram em estudar a relação entre o ambiente construído e o congestionamento de tráfego. Wang *et al.* (2018) utilizaram as informações de detectores e câmeras de trânsito através dos SCATS, que é um sistema australiano de controle de tráfego em tempo real, que

pode alterar o tempo dos semáforos de acordo com as mudanças no fluxo de veículos, utilizando os *Point of Interest* (POIs) da cidade analisada. Zhang *et al.* (2017a) também utilizaram, os POIs, da cidade e um web crawler, que capturam informações das páginas, para obter as informações desses pontos de interesse, e juntá-los com as informações do SIG, que conecta dados ao mapa e combina dados de localização com várias informações descritivas. Por outro lado, Zhang *et al.* (2017b) obtiveram os dados através da empresa *Qiangshen Company*, que fornece serviços de transporte de táxi e miniônibus e, ao qual, disponibilizaram informações do táxi, longitude e latitude e velocidade dos deslocamentos realizados durante 24h.

Em termos de tratamento dos dados, Wang *et al.* (2018) realizaram uma análise empírica com base em suas experiências e nos dados obtidos. Já Zhang *et al.* (2017a) aplicaram uma função de agrupamento padrão, o *K-Means*, levando em consideração os padrões de velocidade. Zhang *et al.* (2017b) também utilizaram uma função de agrupamento, o *Fuzzy C-Means*, ao qual permite que um ponto possa pertencer a vários *clusters* ao mesmo tempo de acordo com seu grau de associação. Neste caso, os autores se basearam no atributo de tempo de congestionamento para a formação dos *clusters*.

Para a análise de dados, Zhang *et al.* (2017b) utilizaram 12 fatores como o tipo de estrada, comprimento do segmento de estrada, distância até a rampa mais próxima, número de estações de ônibus ao longo do segmento rodoviário por 100m, distância até a estação de metrô mais próxima, a localização relativa aos anéis das vias expressas urbanas, número de estacionamentos abertos à sociedade em um raio de 500m por 100m, número de escolas em 500m por 100m, distância até o hospital mais próximo, área comercial, área residencial, área de transporte. Foi utilizado a ferramenta *Geographical Detector*, aplicando o *GLOBAL MORRALL* para realizar uma correlação espacial e testar se os objetos observados possuem similaridades com os objetivos de adjacência espacial. Os autores indicam que há sim uma relação dos fatores apontados acima com o congestionamento, mostrando que em áreas onde não há presença de tantos fatores, o trânsito tende a fluir melhor. Zhang *et al.* (2017a) consideram 5 fatores que correspondem ao tipo de área a qual aquele terreno pertence, sendo elas terrenos educacionais, terrenos comerciais, terrenos residenciais, terrenos industriais, terrenos de lazer. Aplicando regressão linear múltiplas e a ferramenta IBM SPSS Statistics 19.0 para testar a correlação entre o trânsito e os tipos de terreno. Os autores apontam que há sim uma correlação positiva entre o tipo de terreno e o tempo de congestionamento. Por fim, Wang *et al.* (2018) consideraram os mesmos 12 fatores de Zhang *et al.* (2017b), realizando uma análise empírica. Eles concluíram que os horários de picos da manhã e noite cobrem a grande parte de tempo de congestionamento, onde viram que o pico da manhã é o mais crítico, sugerindo então que o pico da manhã teria como explicação a viagem das pessoas de casa ao trabalho, e ele é maior que o da noite pois ocorre que as pessoas podem ter horários de saídas diferentes e que nem sempre eles fazem o trajeto para casa, podendo ir a algum outro lugar.

Os trabalhos correlatos descritos apresentam técnicas e ferramentas de como fazer análise do trânsito e do ambiente para chegar em conclusões socioeconômicas em relação a população local. Este trabalho se propõe a fazer uma análise comportamental do trânsito de Blumenau em relação a aspectos socioeconômicos. Com isso, se propõe a utilizar as imagens disponibilizadas pela SETERB para monitorar a movimentação de veículos em uma determinada área. O tráfego do local será estabelecido via análise de imagens utilizando algoritmos de detecção de objetos da rede neural convolucional Yolo V3. Além disso, também se levará em consideração informações da região (comércios, escolas, densidade populacional etc.), horários e dias da semana e do mês, bem como o impacto das mudanças climáticas e fornecimento de combustível. Para tanto, pretende-se comparar e observar uma mesma região em diferentes períodos, como períodos com ou sem aulas, bem como comparações com regiões semelhantes. Também acredita-se que a complexidade deste trabalho encontra-se em quantificar as relações do fluxo do trânsito, que a partir desses valores será possível mensurar o seu comportamento. Contudo, este trabalho se torna relevante, pois será o primeiro estudo voltado ao trânsito de Blumenau. A partir disso, espera-se determinar quais fatores têm maior impacto no comportamento do tráfego, e que eventualmente, possam ajudar na gestão ou na identificação de qual período torna-se viável utilizar o trânsito.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O artefato computacional a ser desenvolvido deverá:

- permitir que o usuário faça o cadastro da localização das câmeras que capturam as imagens no trânsito (Requisito Funcional - RF);
- permitir que o usuário faça o *upload* dos vídeos que serão usados para detectar o fluxo de veículos na região (RF);
- utilizar algoritmos de detecção de objetos, tais como o Yolo V3, para realizar a detecção e contagem dos veículos (RF);
- vincular informações socioeconômicas obtidas do Instituto Brasileiro de Geografia e Estatística (IBGE) aos segmentos de trânsito a serem analisados (RF);
- calcular a função de deslocamento e a capacidade limite de tráfego (RF);

- f) calcular a função de desempenho ou curva de operação da via (fluxo livre, congestionamento, demanda maior que a capacidade) (RF);
- g) estabelecer a previsão do atraso e da formação de filas (RF);
- h) gerar ranking dos fatores que mais influenciam no trânsito (comércios, escolas, hospitais etc.) (RF);
- i) ser desenvolvido na linguagem de programação Python (Requisito Não Funcional - RNF);
- j) utilizar um banco de dados não relacional para guardar os dados gerados (RNF);
- k) utilizar o Keras para o auxílio na utilização de um algoritmo de detecção de objetos (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: pesquisar trabalhos correlatos e entender os assuntos relacionados à mobilidade urbana e monitoramento, fatores que estabelecem seu comportamento, sistemas de monitoramento de tráfego e detecção de objetos;
- b) coleta de imagens de câmeras de trânsito: coletar as imagens que serão usadas nos testes do método proposto. Além da utilização da base de imagens disponibilizadas pela SETERB serão pesquisadas opções de bases de dados públicas;
- c) rotulação das imagens coletadas: rotular as imagens que serão utilizadas, permitindo assim que o algoritmo detecção de objetos possa ter sua assertividade testada;
- d) pesquisa e escolha do método de detecção de objetos: pesquisar os principais algoritmos de detecção de objetos, escolhendo o mais adequado para o desenvolvimento do trabalho. Inicialmente será utilizado o Yolo V3;
- e) desenvolvimento: desenvolver o método de detecção, correlacionando a localização das informações do item (e), utilizando a linguagem de programação Python e a biblioteca Yolo V3;
- f) validação do método de detecção de objetos: verificar a assertividade do método proposto a partir do percentual de objetos detectados corretamente, e caso necessário, alterar os requisitos para atender o problema a ser resolvido;
- g) obtenção das informações socioeconômicas: obter informações regionais, dentre elas, localização de escolas, comércios, indústrias e densidade através de bases de dados públicas tais como, a do IBGE;
- h) correlação das informações: a partir dos itens (e) e (g) correlacionar e armazenar as informações em um banco de dados;
- i) levantamento de formas para calcular a demanda, oferta e operação viária: pesquisar equações que possam estabelecer o comportamento do fluxo do trânsito;
- j) implementação das métricas de fluxo: a partir dos itens (h) e (i) implementar as equações utilizando a linguagem Python e disponibilizados seus resultados na forma de ranking;
- k) validação do comportamento: em paralelo ao desenvolvimento, verificar a assertividade do artefato computacional para estabelecer o fluxo de veículos em uma dada região e o seu comportamento levando em consideração informações locais, e caso necessário, alterar os requisitos para atender o problema a ser resolvido.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem realizadas

etapas / quinzenas	2021				2022											
	nov.		dez.		jan.		fev.		mar.		abr.		maio		jun.	
	1	2	1	2	1	2	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico																
coleta de imagens de câmeras de trânsito																
rotulação das imagens coletadas																
pesquisa e escolha do método de detecção de objetos																
desenvolvimento																
validação do método de detecção de objetos																
obtenção das informações socioeconômicas																
correlação das informações																
levantamento de formas para calcular a demanda, oferta e operação viária																
implementação das métricas de fluxo																
validação do comportamento																

Fonte: elaborado pelo autor.

4 REVISÃO BIBLIOGRÁFICA

Neste capítulo será abordado brevemente os principais assuntos que fundamentarão o estudo a ser realizado: mobilidade urbana e monitoramento, fatores que estabelecem seu comportamento, sistemas de monitoramento de tráfego e detecção de objetos.

A mobilidade é inerente às relações humanas e sociais. Para se locomover, o indivíduo pode contar com meios próprios, como os pés, e com equipamentos e tecnologia, como, por exemplo, o uso de automóveis. Também é limitado pelo espaço em que ocorre seu movimento (como a cidade) e pela forma de movimento, que é a produção e o produto dessas relações interpessoais. Então, mobilidade é a relação entre um indivíduo e seu espaço disponível e sua disponibilidade (BUOSI, 2018, apud BOHUSCH, 2013). A mobilidade urbana pode ser entendida como a capacidade dos indivíduos de se movimentarem com base na infraestrutura de transporte disponível. É a facilidade de movimentar pessoas e mercadorias no centro da cidade, com viagens no espaço urbano considerando não apenas a ocorrência proporcionada pela cidade, mas também considera a possibilidade (BUOSI, 2018, apud ALVES; RAIÁ JUNIOR, 2009).

Nesse contexto de mobilidade, alguns fatores podem determinar seu comportamento. Dentre elas, mudanças na inflação, o que significa mudanças significativas no consumo; tendo em vista que as compras não ocorrem mais na comunidade, os supermercados estão cada vez mais envolvidos nas atividades comerciais, aumentando assim a mobilidade dos carros; flexibilidade nos horários de execução das atividades principais (tendo em vista que as compras não ocorrem mais na comunidade, os supermercados estão cada vez mais envolvidos nas atividades comerciais, aumentando assim a mobilidade dos carros; flexibilidade nos horários de execução das atividades principais (SANTOS 2009, apud Mcidade, 2006) e as facilidades para comprar automóveis, o que torna cada vez mais motorizadas algumas pessoas que antes não podiam obter automóveis (SANTOS 2009, apud NTU, 2006).

Para entender essa mobilidade, ou seja, o fluxo de tráfego, sistemas de monitoramento de tráfego precisam ser usados para medir as condições de tráfego, como câmeras de vigilância de vídeo de tráfego, e outra tecnologia de detecção que coleta diretamente o movimento do veículo, como smartphones, sistemas de navegação de veículos e drones câmeras etc. Mas, o problema é como coletar dados de tráfego precisos, como fluxo de tráfego real. Uma das formas, segundo Tsuboi (2021), seria utilizar técnicas de aprendizado de máquinas em câmeras de trânsito espalhadas pela cidade para a detecção de veículos no trânsito. Para isso, pode-se utilizar o algoritmo de detecção *You Only Look Once* (YOLO). YOLO é um detector de objetos em tempo real, que usa *Deformable Part Based Model* (DPM) e *Region-based Convolution Neural Network* (R-CNN) para detectar e caracterizar objetos, como animais, automóveis, pessoas etc. Com a detecção, há como fazer a contagens de veículos, e com isso, gerar informações sobre fluxo de veículos (REDMON *et al.*, 2016).

REFERÊNCIAS

- BAS, Erhan et al. Automatic Vehicle Counting from Video for Traffic Flow Analysis. 2007 Ieee Intelligent Vehicles Symposium, [S.l.], p. 392-397, jun. 2007. IEEE. <http://dx.doi.org/10.1109/ivs.2007.4290146>. Disponível em: <https://ieeexplore.ieee.org/document/4290146?arnumber=4290146>. Acesso em: 25 set. 2021.
- BUOSI, Marcelo de Almeida. Mobilidade inteligente: proposta de framework de big data analytics para análise de dados de mobilidade urbana em uma smart city. 2018. 152 f. Dissertação (Mestrado) - Curso de Administração, Centro de Ciências Socioeconômicas, Universidade do Estado de Santa Catarina, Florianópolis, 2018. Disponível em: <https://sistemabu.udesc.br/pergamumweb/vinculos/00004f/00004f56.pdf>. Acesso em: 25 set. 2021.
- GERLOUGH, Daniel L.; HUBER, Matthew J. Traffic Flow Theory: a monograph. Washington, D.C: Trb, 1975. 233 p. Disponível em: <https://sistemabu.udesc.br/pergamumweb/vinculos/00004f/00004f56.pdf>. Acesso em: 25 set. 2021.
- GOVERNMENT, Nsw. SCATS. Disponível em: <https://www.scats.nsw.gov.au/>. Acesso em: 30 set. 2021.
- PUMATRONIX. Quem Somos. 2021. Disponível em: <https://pumatronix.com/quem-somos/>. Acesso em: 30 set. 2021.
- REDMON, Joseph et al. You Only Look Once: unified, real-time object detection. 2016 Ieee Conference On Computer Vision And Pattern Recognition (Cvpr), [S.l.], p. 779-788, jun. 2016. IEEE. <http://dx.doi.org/10.1109/cvpr.2016.91>.
- SANTOS, Lilian da Silva. Análise da influência da variação espacial da oferta de um modo de transporte público urbano no comportamento de viagem de seus usuários. 2009. 148 f. Dissertação (Mestrado) - Curso de Faculdade de Tecnologia, Departamento de Engenharia Civil e Ambiental, Universidade de Brasília, Brasília, 2009. Disponível em: https://repositorio.unb.br/bitstream/10482/4185/1/2009_LiliandaSilvaSantos.pdf. Acesso em: 30 set. 2021.
- SILVA, Paulo Cesar Marques da. Teoria do fluxo de tráfego: engenharia de tráfego. ENGENHARIA DE TRÁFEGO. 1994. Disponível em: <http://www.sinaldetransito.com.br/artigos/teoria-do-fluxo-de-traffic.pdf>. Acesso em: 30 set. 2021.
- TSUBOI, Tsutomu. Traffic Flow Analysis and Management. Design Of Cities And Buildings - Sustainability And Resilience In The Built Environment, [S.l.], p. 1-15, 2 jun. 2021. IntechOpen. <http://dx.doi.org/10.5772/intechopen.95087>. Disponível em: <https://www.intechopen.com/chapters/75082>. Acesso em: 29 set. 2021.

WANG, Shiguang *et al.* Analyzing urban traffic demand distribution and the correlation between traffic flow and the built environment based on detector data and POIs. *European Transport Research Review*, [S.l.], v. 10, n. 2, p. 10-50, jun. 2018. Springer Science and Business Media LLC. <http://dx.doi.org/10.1186/s12544-018-0325-5>. Disponível em: <https://etr.springeropen.com/articles/10.1186/s12544-018-0325-5>. Acesso em: 25 set. 2021.

ZHANG, Kaisheng *et al.* Analyzing spatiotemporal congestion pattern on urban roads based on taxi GPS data. *Journal Of Transport And Land Use*, [S.l.], v. 10, n. 1, p. 675-694, 19 jun. 2017. Center for Transportation Studies. <http://dx.doi.org/10.5198/jtlu.2017.954>. Disponível em: <https://www.jtlu.org/index.php/jtlu/article/view/954>. Acesso em: 25 set. 2021.

ZHANG, Tianqi *et al.* Impact Analysis of Land Use on Traffic Congestion Using Real-Time Traffic and POI. *Journal Of Advanced Transportation*, [S.l.], v. 2017, p. 1-8, 2017. Hindawi Limited. <http://dx.doi.org/10.1155/2017/7164790>. Disponível em: <https://www.hindawi.com/journals/jat/2017/7164790/>. Acesso em: 25 set. 2021.

ZOU, Zhengxia *et al.* Object Detection in 20 Years: a survey. *Corr*, [S. l.], v. /190505055, p. 1-39, 28 maio 2019. Disponível em: <https://arxiv.org/abs/1905.05055>. Acesso em: 30 set. 2021.