

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
( X ) PRÉ-PROJETO	( ) PROJETO	ANO/SEMESTRE: 2022/2

## RECONHECIMENTO FACIAL DE BUGIOS-RUIVOS POR MEIO DE MODELOS DE APRENDIZADO DE MÁQUINA

Minéia Maschio

Andreza Sartori – Orientadora

Julio Cesar de Souza Junior - Coorientador

### 1 INTRODUÇÃO

Diariamente, o mundo sofre com vários problemas ambientais que afetam a saúde dos humanos e alteram o ciclo reprodutivo da flora e da fauna. Um desses problemas globais é a extinção de espécies, causado por desmatamento, pressão populacional, produção insustentável, caça, pesca, mudanças climáticas e a destruição da camada de ozônio (WATANABE, 2011). Segundo Crouse *et al.* (2017), para manter a conservação de espécies é necessário o monitoramento de longo prazo desses animais, portanto a identificação individual é fundamental.

Para isso, os pesquisadores realizam atualmente a captura e marcação dos animais com identificadores únicos, utilizando colares e/ou marcas coloridas, até mesmo aproveitando a variação natural de indivíduos de uma mesma espécie como cicatrizes, padrões de pele e pelagem, tamanho do corpo e forma. O procedimento de captura pode ser feito por meio de redes de neblinas ou caixas de ninho (para pássaros), armadilhas, e para alguns mamíferos maiores como os primatas é utilizado zarabatana ou rifle de ar. Muitos desses meios de identificação dependem do conhecimento dos pesquisadores, podendo gerar falhas no reconhecimento ou são métodos invasivos, que podem causar estresse, danos na pele e lesões, assim como afetam na dinâmica daquele grupo e trazem risco a reprodução. Para pesquisas de longo prazo, o reconhecimento de indivíduos de uma população requer muitas horas de campo para que dados individuais possam ser coletados. Além disso, a pesquisa pode ser prejudicada por interrupções na coleta de dados por falta de verba e instabilidade política (CROUSE *et al.*, 2017).

O Projeto Bugio – FURB, criado em 1991, tem como objetivo realizar estudos de ecologia e comportamento de bugios-ruivos em seu habitat natural. Os bugios-ruivos (da subespécie *Alouatta Guariba Clamitans*) são resgatados a partir de ocorrências atendidas pela Polícia Militar Ambiental, na qual são vítimas de atropelamentos, choques elétricos, ataques de cães e doenças. Para realizar o monitoramento dos bugios, os pesquisadores e veterinários do projeto usam microchips e os animais são devolvidos na natureza se tiverem uma boa recuperação e condições apropriadas para sobreviver na floresta, caso contrário, são reabilitados e mantidos em cativeiro na sede do Projeto sob cuidados humanos. Para utilizar os chips subcutâneos é necessário a captura e sedação do animal, o que em alguns casos pode causar sequelas permanentes como cicatrizes e feridas, trazendo impacto na reabilitação do bugio (FURB, 2001).

Uma outra forma de identificar o bugio-ruivo individualmente é por meio de reconhecimento facial utilizando suas características singulares, o que possibilita o auxílio ao Projeto Bugio – FURB com um método rápido para identificar indivíduos, não invasivo e que requer pouco treinamento por parte de veterinários e pesquisadores. Masi *et al.* (2018) afirma que os principais desafios para o reconhecimento facial são a pose, iluminação e expressão, tornando necessário uma quantidade de mídia elevada para treinamento do modelo, o que é inviável para o aprendizado computacional. Portanto, o modelo deve ser capaz de abstrair distrações presentes na mídia como as variações de poses, mudanças de iluminação e a diversidade de expressões faciais. Segundo Schofield *et al.* (2019), modelos de Visão Computacional são utilizados no reconhecimento de padrões para identificar várias espécies através da face, como a Rede Neural Convulocional que é composta de múltiplas camadas de processamento que aprendem a partir de dados com alto nível de abstração, permitindo o desempenho em tarefas complexas.

Diante do contexto apresentado, este trabalho se propõe a auxiliar o Projeto Bugio – FURB, dando continuidade ao trabalho proposto por Krause (2019), que desenvolveu um modelo de reconhecimento facial de bugios-ruivos. O objetivo é desenvolver um novo protótipo para identificação facial a partir de imagens e vídeos de bugios-ruivos. Almeja-se que o modelo consiga melhorar a velocidade de reconhecimento individual e também possua uma melhor precisão.

#### 1.1 OBJETIVOS

Este trabalho possui como objetivo disponibilizar um protótipo para identificar individualmente bugios-ruivos por meio de um modelo de Redes Neurais Artificiais (RNA), a fim de dar continuidade ao trabalho de Krause (2019).

Os objetivos específicos são:

- a) identificar o modelo de Aprendizado de Máquina e Visão Computacional mais apropriado para detecção e reconhecimento de primatas;
- b) validar a eficácia dos modelos selecionados;
- c) validar a eficácia do protótipo com os pesquisadores do Projeto Bugio.

## 2 PROTÓTIPO ATUAL

Krause (2019) propôs em seu trabalho desenvolver um protótipo para reconhecimento facial de bugios-ruivos utilizando Redes Neurais Convolucionais sendo elas Inception-ResNet v2, ResNet50 e Xception. Para a extração de características foi utilizada a técnica Triplet Loss nas Redes Neurais Artificiais e para a classificação foram utilizados os algoritmos de Aprendizado de Máquina k-Nearest Neighbors (k-NN), Radius Nearest Neighbors (r-NN) e Support Vector Machine (SVM). Com os modelos gerados, o autor utilizou o One-Shot Learning que possibilita aprender novas classes a partir de poucos exemplos treinando apenas o algoritmo de classificação.

As imagens foram obtidas nas dependências do Projeto Bugio-FURB, na cidade de Indaial, em que foram coletadas 179 fotos de 20 bugios diferentes. Para treinar o algoritmo de reconhecimento facial as imagens foram recortadas manualmente contendo somente a face do animal. Além disso, para aumentar a base de dados foi utilizada a estratégia *data augmentation*, aplicando em cada imagem transformações (iluminação, rotação, escala, embaçamento) assim obtendo mais 9 imagens, gerando no total uma base de 1790 imagens (KRAUSE, 2019).

Para o treinamento da RNA a base de dados foi dividida em duas partes, sendo 85% para treinamento e 15% para validação. Além disso, o conjunto de imagens foi dividido em 40 lotes e cada lote possui 64 imagens. Nos testes, com a função Triplet Loss, foi identificado um problema de desbalanceamento dos lotes, no qual tiveram casos com uma imagem para cada classe. A função Triplet Loss necessita ter pelo menos duas imagens para cada classe (âncora e positivo), e também uma classe distinta (negativo) para contribuir no aprendizado. A fim de resolver esse problema, foi implementado um gerador de lotes para que as classes ficassem balanceadas dentro de cada lote (KRAUSE, 2019).

Segundo Krause (2019), a rede ResNet50 obteve uma acurácia abaixo das outras redes, atingindo apenas 75,98% com o algoritmo SVM. A rede Inception-ResNet atingiu um resultado bom, chegando em 99,78% de acurácia, porém é uma rede mais custosa computacionalmente no processo de treinamento e inferência. O melhor resultado foi obtido com a rede Xception que atingiu 99,94% de acurácia nos algoritmos k-NN e SVM.

Para demonstrar a funcionalidade do protótipo foi desenvolvido um aplicativo, na qual é possível carregar imagem, prever classe e adicionar uma nova imagem na base. Krause (2019) conclui que atingiu o objetivo de reconhecer facialmente bugios-ruivos, mesmo possuindo algumas limitações, como deixar a imagem previamente recortada contendo apenas a face do bugio. Por fim, como trabalho futuro, Krause (2019) propôs implementar uma RNA responsável por detectar a face e novas funcionalidades como classificar mais imagens ao mesmo tempo.

## 3 TRABALHOS CORRELATOS

Nesta seção serão apresentados três trabalhos correlatos. O trabalho de Schofield *et al.* (2019) realiza o reconhecimento facial de chimpanzés por meio de um modelo de Rede Neural Convolucional (Convolutional Neural Network – CNN), e, além disso, faz a detecção e classificação de gênero. Guo *et al.* (2020) propõem utilizar modelos de CNN e Aprendizado de Máquina, para detectar, identificar e rastrear indivíduos de várias espécies por meio de vídeos e imagens. Por fim, Deb *et al.* (2018) realizam o reconhecimento facial de 14 espécies de primatas utilizando CNN e disponibilizam um aplicativo para auxiliar pesquisadores.

### 3.1 CHIMPAZEE FACE RECOGNITION FROM VÍDEOS IN THE WILD USING DEEP LEARNING

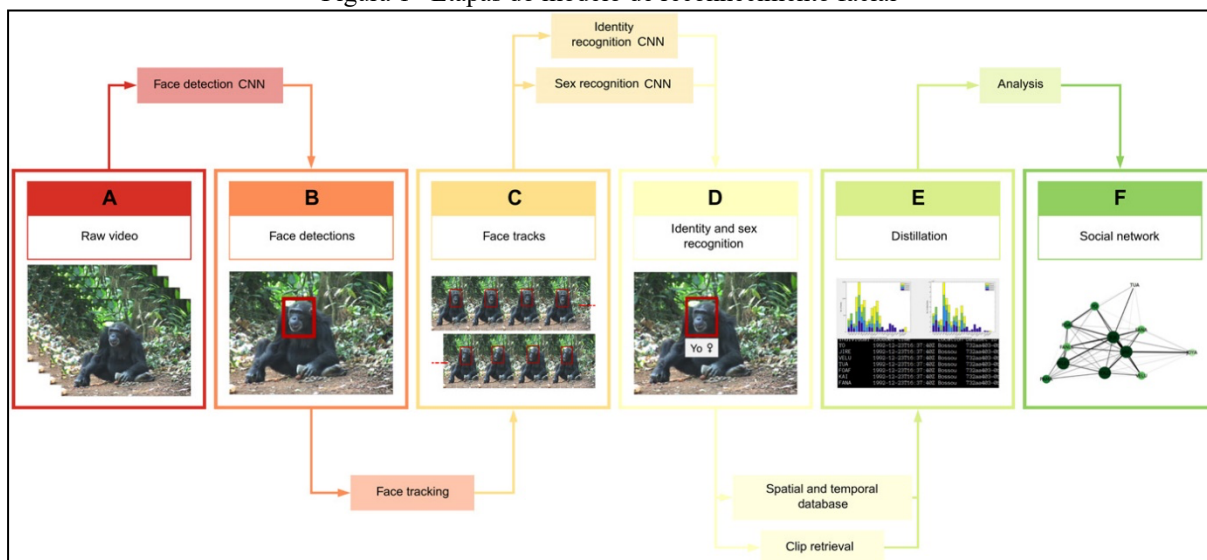
O trabalho de Schofield *et al.* (2019) tem como objetivo rastrear e identificar chimpanzés em arquivos de vídeos. O autor propôs aplicar um modelo de CNN nas etapas de detecção, rastreamento, reconhecimento de sexo e identidade dos primatas. Além disso, os autores utilizam um método baseado em vídeo, que melhora a precisão ao reunir várias detecções do mesmo indivíduo antes que a classificação termine.

A base de dados utilizada no trabalho de Schofield *et al.* (2019) tem em torno de 14 anos de arquivos de vídeo de chimpanzés. Esses vídeos foram coletados na floresta Bossou, sudeste da Guiné, África Ocidental, local denominado como laboratório “ao ar livre”. O conjunto de dados apresenta 23 chimpanzés, sendo 14 fêmeas e 9 machos. Os registros foram realizados entre 2000 e 2012, e no grupo de indivíduos contém desde primatas bebês a adultos.

Conforme demonstrado na Figura 1, o modelo de reconhecimento realiza algumas etapas para classificar um indivíduo. As duas primeiras, A e B consistem em extrair as imagens do vídeo bruto (A) e detectar a face (B) utilizando o modelo Single Shot Detector (SSD). Na terceira etapa é realizado o rastreamento do rosto (C) implementando um rastreador Kanade-Lucas-Tomasi (KLT) para agrupar as detecções. A quarta etapa (D) realiza a identificação facial e o reconhecimento de gênero feitos por um modelo de CNN, que tem como base a rede

VGG-M. Por fim, o sistema gera faixas de rostos e metadados rotulados com informações temporais e espaciais (E) e também uma análise das interações do indivíduo com outros primatas (F).

Figura 1– Etapas do modelo de reconhecimento facial



Fonte: Schofield *et al.* (2019).

Segundo Schofield *et al.* (2019), o conjunto de treinamento para o modelo consistiu em 15.274 rastros de faces obtidos de quatro anos diferentes (2000, 2004, 2008 e 2012). O detector de face alcançou uma precisão média de 81% ao detectar rostos, e o modelo de reconhecimento facial atingiu 92,47% de precisão para identidade e 96,16% para identificação de gênero. Os resultados obtidos incluem as faces de todos os pontos de vista (frontal, perfil e perfil extremo). Para o reconhecimento utilizando apenas faces frontais, a precisão aumenta para 95,07% para identidade e 97,36% para identificação de sexo. Além disso, o modelo demonstrou que consegue identificar um mesmo indivíduo por vários anos, possibilitando a análise de eventos na história de uma comunidade de animais, por exemplo, a quantidade da população.

Schofield *et al.* (2019) concluem que existem algumas limitações no trabalho desenvolvido, como por exemplo, a quantidade pequena de indivíduos, composta de 23 chimpanzés, bem como a falta de mistura genética, pois o estudo foi feito com base nos vídeos de uma reserva selvagem. Entende-se que, alguns erros ao identificar os chimpanzés foram ocasionados por semelhanças faciais e ao adicionar mais indivíduos ao banco de dados o desempenho tende a melhorar. Por fim, destaca-se o problema ao rastrear os indivíduos quando a cabeça está totalmente virada ou obscurecida, como melhoria o autor propõe adicionar informações de indivíduos próximos ou até mesmo reconhecer o corpo inteiro do animal.

### 3.2 AUTOMATIC IDENTIFICATION OF INDIVIDUAL PRIMATES WITH DEEP LEARNING TECHNIQUES

Guo *et al.* (2020) desenvolveu um sistema denominado Tri-AI que realiza a detecção automatizada de rostos e de identificação individual aplicando métodos de aprendizado profundo. O autor projetou uma Rede Neural Convolutiva com três canais de mecanismos de atenção, que identifica primatas e algumas outras espécies de carnívoros. O objetivo do trabalho é detectar, identificar e rastrear indivíduos a partir de vídeos ou imagens estáticas de várias espécies.

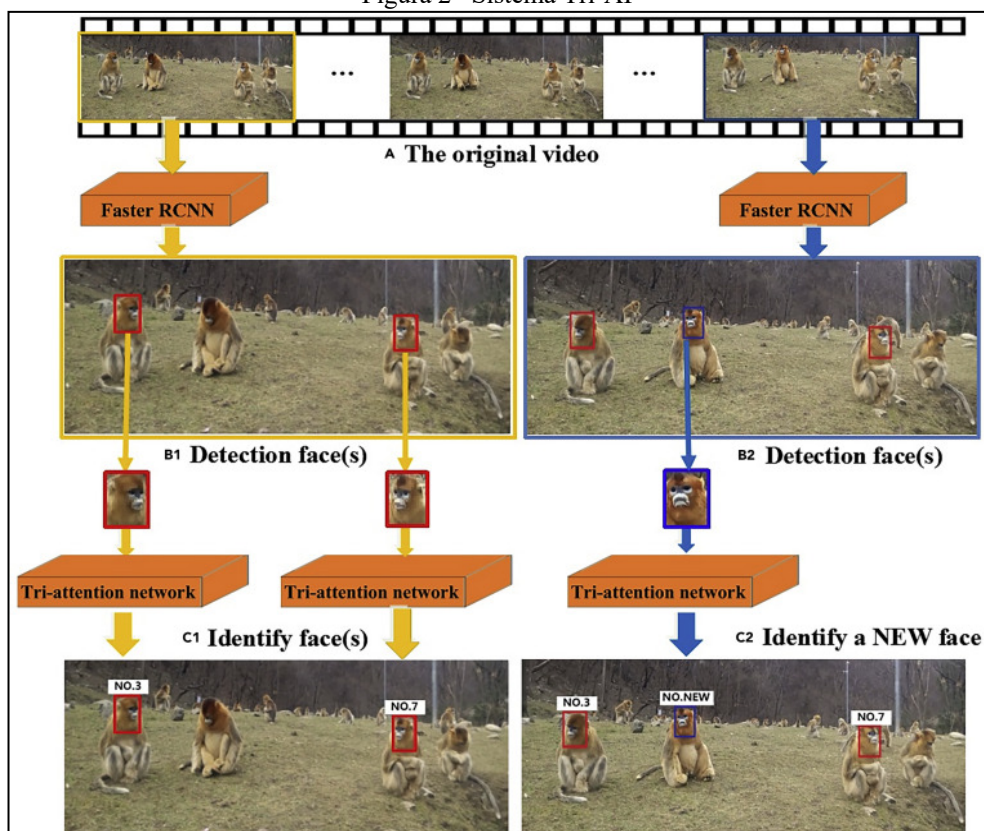
O conjunto de dados para treinamento é composto por 102.399 imagens de 1.040 indivíduos de 41 espécies de primatas, cuja a identidade era conhecida. Foram usados também 6.562 imagens de 91 indivíduos de 4 espécies de carnívoros. As principais espécies de primatas analisadas foram os macacos dourados de nariz arrebitado e macacos tibetanos. As imagens do macaco dourado de nariz arrebitado foram capturadas em dias diferentes, enquanto dos demais animais foram retiradas em um dia de zoológico.

Guo *et al.* (2020) identifica duas grandes etapas em seu sistema Tri-AI. Conforme apresentado na Figura 2 a primeira etapa (B1 e B2) é a detecção facial utilizando a ferramenta Faster RCNN, eficaz para detecção de objetos. O Faster RCNN foi pré-treinado com uma parte das imagens do banco de dados, isto é, foram utilizadas 1.200 imagens de macaco dourado de nariz arrebitado para rotular e detectar o rosto. Foram selecionadas aleatoriamente 500 imagens para cada espécie na fase de testes. As espécies utilizadas foram: o macaco dourado de nariz arrebitado que obteve 91,13% de precisão na detecção facial; o macaco tibetano que obteve 97,71% de precisão; e o tigre que obteve 97,70% de precisão.

Na segunda etapa (C1 e C2), apresentada na Figura 2 ocorre a identificação individual dos primatas usando a rede *Tri-attention*, que possui três canais, na qual cada canal tem seu modelo próprio de rede de atenção. O

primeiro canal possui um modelo de objeto para extrair as características faciais globais, outro canal que foca a região facial de interesse e por fim, um canal que seleciona uma região chave para extrair características faciais específicas. Portanto a rede *Tri-attention* extrai três tipos de características que são analisadas em níveis diferentes, que são combinadas para realizar a identificação individual.

Figura 2– Sistema Tri-AI



Fonte: Guo *et al.* (2020).

O modelo Tri-AI identifica e nomeia os primatas que foram reconhecidos conforme apresentado na Figura 2 com as setas amarelas. Se o modelo encontrar uma nova face de primata, um novo nome ou ID é dado e o primata é adicionado ao banco de dados conforme apresentado na Figura 2 com as setas azuis. Quando o sistema tem mais de 60 imagens de um novo indivíduo, o conjunto de dados é atualizado e a *Tri-attention* é treinada novamente. O Tri-AI atingiu a precisão de 94,11% na identificação individual e possui um tempo médio de detecção e reconhecimento da face de 31 imagens por segundo.

Segundo Guo *et al.* (2020), seu modelo lida bem com imagens coloridas e cinzas, podendo realizar monitoramento em tempo real durante o dia ou a noite. No entanto, o Tri-AI não tem bom resultado ao identificar animais com estrutura de face atípica ou estranha, por exemplo, os elefantes que possuem uma tromba longa e bastante diferente. Por fim, foi identificado que é necessário o aumento do conjunto de dados, pois em 24 espécies de primatas haviam menos de 12 indivíduos para realizar o treinamento do modelo.

### 3.3 FACE RECOGNITION: PRIMATES IN THE WILD

Deb *et al.* (2018) desenvolveu um aplicativo para identificação individual de primatas com uma nova arquitetura CNN denominada PrimNet. No trabalho, o autor relata que existe uma grande dificuldade em realizar o reconhecimento facial com uma base de dados pequena, e o SphereNet 4, modelo de reconhecimento facial com RNA que possui bons resultados de precisão para conjunto de dados pequeno, foi utilizado para treinar o conjunto de dados dos primatas, no qual sofreu *overfitting*. Por este motivo, o autor propôs duas modificações ao SphereNet 4, reduzir o número de parâmetros deixando a RNA mais esparsa através do estratagema de convolução de grupo para todas as camadas e aprimorar o poder de discriminação de camadas ocultas, deixando a rede mais ampla através do aumento do número de canais.

O conjunto de dados contém três tipos de primatas sendo eles lêmures, macacos dourados e chimpanzés. Foram obtidas 3.000 imagens faciais de lêmures, contendo 129 indivíduos de 12 espécies diferentes. Para ampliar a variação de ambiente, as imagens foram capturadas em dois dias consecutivos. O banco de dados dos macacos dourados possui 1.450 imagens faciais de 49 macacos. Foram utilizados também 241 vídeos, na qual extraíram imagens que foram recortadas e alinhadas. Por fim, para a base dos chimpanzés, foram utilizados dois

conjuntos de dados, um com 2.109 imagens faciais de 24 indivíduos e o outro com 5.078 imagens faciais de 78 indivíduos.

Para a detecção facial, Deb *et al.* (2018) propôs anotar manualmente três pontos de referência: o olho esquerdo, o olho direito e o centro da boca, com isso, é realizado o alinhamento da face, conforme a Figura 3. Em uma arquitetura CNN tradicional, cada filtro de convolução aplica-se a todos os canais no mapa de recursos de entrada, mas na arquitetura PrimNet é utilizado convolução de grupo. Em uma convolução de grupo, os canais de entrada e os neurônios para cada grupo são separados uniformemente, na qual cada neurônio processa apenas os canais de entrada que entram em seu próprio grupo, podendo reduzir o número de parâmetros em mais de 50%. O PrimNet é treinado utilizando a função AM-Softmax que demonstrou ser eficaz na aprendizagem com rostos humanos.

Figura 3 – Alinhamento da face nas imagens dos primatas



Fonte: Deb *et al.* (2018).

O PrimNet obteve uma precisão de 93,75% na identificação individual de lêmures, 90,26% na identificação individual de macacos dourados e 75,82% na identificação individual de chimpanzés. Deb *et al.* (2018) conclui que, comparado a um sistema de reconhecimento de primatas de referência como o LemurFaceID e os sistemas de reconhecimento de rosto humano como SphereFace e FaceNet, o PrimNet foi superior na verificação e identificação de indivíduos. O autor ainda pretende melhorar o conjunto de dados dos primatas e expandir para outras espécies, e também desenvolver um detector facial de primatas.

#### 4 PROPOSTA DO PROTÓTIPO

Nesta seção serão apresentados os principais Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF), a metodologia a ser utilizada e o cronograma a ser seguido no decorrer do trabalho.

##### 4.1 JUSTIFICATIVA

No Quadro 1 é apresentado um comparativo entre os trabalhos correlatos. As linhas representam as características e as colunas os trabalhos.

Quadro 1 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Schofield <i>et al.</i> (2019)	Guo <i>et al.</i> (2020)	Deb <i>et al.</i> (2018)
Animal reconhecido facialmente e quantidade	23 Chimpanzés	196 Macacos dourado de nariz arrebitado e 30 macacos tibetano	129 Lêmures, 49 macacos dourados e 90 chimpanzés
Total de imagens utilizados para o treinamento do modelo	10.000.000	108.961	11.637
Tipo de mídia utilizada	Imagem e vídeo	Imagem e vídeo	Imagem
Modelo de Aprendizado de Máquina para reconhecimento facial	CNN com base na VGG-16	Tri-AI	PrimNet
Precisão no reconhecimento facial alcançado	92,47%	94,11%	93,75%
Modelo de Aprendizado de Máquina para detecção facial	Modelo KLT	Faster RCNN	-

Fonte: elaborado pelo autor.

Conforme o Quadro 1 todos os autores utilizaram espécies de primatas diferentes para realizar o reconhecimento facial. Schofield *et al.* (2019) focou seus testes em Chimpanzés. Guo *et al.* (2020) utilizou 41 espécies de primatas, sendo as espécies mais citadas o macaco dourado de nariz arrebitado e o macaco tibetano. As espécies utilizadas por Deb *et al.* (2018) foram os lêmures, macacos dourados e chimpanzés. Os três trabalhos utilizaram Redes Neurais Convolucionais para reconhecimento individual. Neste trabalho serão utilizados modelos de Redes Neurais Convolucionais para reconhecer bugios-ruivos da espécie *Alouatta Guariba Clamitans*.

Schofield *et al.* (2019) utilizou o modelo KLT para realizar a detecção facial em vídeos e imagens baseada em fluxo óptico, agrupando faces que pertencem ao mesmo indivíduo. Guo *et al.* (2020) utilizou o Faster RCNN, que possui em sua estrutura uma Rede de Propostas Regionais usado para selecionar as áreas suspeitas onde os objetos podem existir, e o Faster RCNN é usado para identificar se essas áreas na verdade são os objetos. Deb *et al.* (2018) não utilizou nenhum modelo de Aprendizado de Máquina para detecção facial. Em seu protótipo, é necessário realizar a marcação do olho direito, olho esquerdo e centro da boca manualmente para detectar e alinhar a face. Nota-se que, quando são utilizados vídeos como tipo de mídia, tal qual Schofield *et al.* (2019) e Guo *et al.* (2020), os autores viram a necessidade utilizar modelos de Aprendizado de Máquina para detecção facial.

Diante dessas características pode-se afirmar que o uso de Redes Neurais Convolucionais para detecção e reconhecimento facial de primatas é eficaz, podendo auxiliar vários pesquisadores na identificação de primatas, por ser uma maneira mais rápida de identificação que não prejudica animais fisicamente. O presente trabalho visa dar continuidade ao trabalho de Krause (2019) aplicando novas técnicas de Visão Computacional e Aprendizado de Máquina para reconhecer individualmente bugios-ruivos, a fim de inserir novas informações ao conjunto de dados, melhorar a precisão na identificação facial e realizar o reconhecimento facial em vídeos também. Por fim, este trabalho visa auxiliar o Projeto Bugio com um novo protótipo para reconhecimento automático facial de bugios, que possibilita a identificação do animal sem a necessidade de captura dos animais, visando agilizar o processo de análise, estudo e controle dos animais.

#### 4.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

Os requisitos do protótipo são:

- realizar classificação do indivíduo a partir de imagens e vídeos (Requisito Funcional - RF);
- extrair características relevantes da imagem (RF);
- realizar o melhoramento das imagens (ruidos, distorções e problema de iluminação) utilizando técnicas de Processamento de Imagens (RF);
- exibir resultados da identificação individual por meio de identificadores como ID ou Nome (RF);
- o protótipo deve usar técnicas de Redes Neurais Convolucionais a serem definidas nos testes (Requisito Não Funcional – RNF);
- o protótipo deve utilizar a linguagem Python para aplicação de Redes Neurais Convolucionais (RNF).

#### 4.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- levantamento bibliográfico: realizar levantamento bibliográfico sobre bugios-ruivos, técnicas e modelos de Aprendizado de Máquina e Visão Computacional relacionadas ao reconhecimento facial,



- bem como trabalhos correlatos;
- submissão de requerimento ao Comitê de Ética: submeter o requerimento ao Comitê de Ética da FURB para utilizar as imagens de animais;
  - coleta e atualização da base de dados: coletar novas imagens e vídeos de bugios-ruivo e seus dados morfológicos, bem como atualizar as imagens e os dados já coletados;
  - elicitación de requisitos: com base no levantamento bibliográfico reavaliar os requisitos propostos para o protótipo;
  - definição de modelos: definir qual o modelo de Aprendizado de Máquina e Visão Computacional é o mais adequado para as etapas de extração de características, treinamento e classificação dos indivíduos;
  - implementação do protótipo de reconhecimento facial: realizar a implementação do protótipo de reconhecimento facial baseado nos requisitos propostos;
  - testes: realizar teste para verificar a precisão do reconhecimento facial;
  - validação: validar o protótipo com um responsável do Projeto Bugio.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 - Cronograma

etapas / quinzenas	2023									
	fev.		mar.		abr.		maio		jun.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
submissão de requerimento ao Comitê de Ética										
coleta e atualização da base de dados										
elicitación de requisitos										
definição de modelos										
implementação do protótipo de reconhecimento facial:										
testes										
validação										

Fonte: elaborado pelo autor.

## 5 REVISÃO BIBLIOGRÁFICA

Esta seção descreve brevemente os assuntos que fundamentarão o estudo a ser realizado: bugio-ruivo, Aprendizado de Máquina e Visão Computacional com enfoque em Redes Neurais Artificiais e reconhecimento facial.

O bugio-ruivo possui como característica morfológica marcante a hipertrofia do osso hioide. O interior do osso é oco, o que forma uma câmara de ressonância de som, produzindo o ronco ou rugido característico dessa espécie (FURB, 2001). A hipertrofia do osso hioide é presente nos ambos sexos, no entanto a espécie apresenta dimorfismo sexual fazendo com que os machos sejam maiores em todas as dimensões, como o próprio osso hioide, o crânio, o tamanho do corpo e a arcada dentária (OLIVEIRA, 2020). Os bugios também apresentam dimorfismo por dicromatismo. Os machos possuem pelagem ruivo avermelhada e as fêmeas pelagem mais escura, outra característica importante é que essa pelagem é mais comprida nos lados da face, formando uma espécie de barba (OLIVEIRA, 2022).

Visão Computacional é uma área da Aprendizado de Máquina que visa a extração automática e semiautomática de informações de imagens digitais, na qual existe o processo de extração de características para realizar tarefas que podem incluir classificação, segmentação, reconhecimento, detecção, entre outras (LÜRIG *et al.*, 2021). O processamento da imagem pode variar, mas algumas etapas são essenciais como a segmentação, extração de características e aplicação de um método de redução de dimensão como Análise de Componente Principais, para diminuir o peso computacional do processo, como também adotar uma técnica de classificação (FRACAROLI *et al.*, 2020). Segundo Fracaroli *et al.* (2020), as técnicas de classificação incluem técnicas estáticas, RNA, SVM e lógica fuzzy. Segundo LIU *et al.* (2020), as RNAs trouxeram progresso em vários problemas de visão computacional, inclusive problemas de reconhecimento facial. Guo *et al.* (2019) afirma que a RNA é um modelo computacional não linear motivado nos sistemas biológicos no processamento de informações. As RNAs consistem em um número de unidades menores denominadas neurônios organizados entre a entrada de dados e a saída de resultados, esses neurônios funcionam e se comportam como neurônios biológicos na qual aprendem por um processo de retropropagação, portanto a saída precisa de um conjunto de dados que é conhecido anteriormente como entrada na rede (TAHIR *et al.*, 2019).

O reconhecimento facial é uma subárea da Visão Computacional que trata de identificar o indivíduo por meio das características faciais individuais, cruzando as características daquele rosto com os de um banco de dados (BRITO, 2021). Para cada indivíduo é necessário extrair características e armazená-las. Ao fazer o reconhecimento facial em uma nova face é realizado a detecção da face e extração de recursos, assim é comparada com todas as

classes armazenadas anteriormente, a imagem pode ser classificada como um indivíduo que já existe na base ou um novo indivíduo (KHAN, 2019). Segundo Schneider *et al.* (2020), avanços computacionais em Aprendizado Profundo despertou interesse na área de reconhecimento facial devido ao poder computacional aprimorado e a disponibilidade de grandes conjuntos de dados. No entanto, existe um problema que é a necessidade de coletar e identificar milhares de imagens rotuladas individualmente para treinar Redes Neurais Convolucionais. Uma solução para quantidade de imagens limitadas é realizar o *image augmentation* que consiste em aumentar o conjunto de dados por meio de variação em uma imagem, como espelhamento, deslocamento, rotação, desfoque, distorção de cor, corte aleatório, entre outros.

## REFERÊNCIAS

- BRITO, Alexandre. **Reconhecimento Facial Bovino: Uma Alternativa Aos Métodos Tradicionais de Rastreio**. 2021. 46 f. Trabalho de Conclusão de Curso (Bacharelado) – Curso de Engenharia de Controle e Automação, Universidade de Caxias do Sul, Caxias do Sul. Disponível em: <https://repositorio.ucs.br/xmlui/handle/11338/9364>. Acesso em: 22 set. 2022.
- CROUSE, David *et al.* LemurFaceID: a face recognition system to facilitate individual identification of lêmures. **BMC Zoology**, [s.l.], v. 2, n. 1, p. 1-14, fev. 2017. Disponível em: <https://link.springer.com/article/10.1186/s40850-016-0011-9#citeas>. Acesso em: 11 ago. 2022.
- DEB, Debayan *et al.* Face Recognition: Primates in the wild. **2018 IEEE 9th International Conference on Biometrics :Theory, Applications and Systems (BTAS)**, Redondo Beach, v. 9, n. 1, p. 1-10, abr. 2018. Disponível em: <https://ieeexplore.ieee.org/abstract/document/8698538>. Acesso em: 24 jun. 2022.
- FRACAROLI, Juliana Aparecida *et al.* Computer vision applied to food and agricultural products. **Revista Ciência Agronômica**, [s.l.], v. 51, Special Agriculture 4.0, p. 1-20, out. 2020. Disponível em: <https://www.scielo.br/j/rca/a/wZzwb7DZjLd85nHTLB5DDbv/abstract/?lang=en>. Acesso em: 22 set. 2022.
- FURB. **Projeto Bugio**. [2001?]. Disponível em: <http://www.furb.br/web/5579/projeto-bugio/apresentacao>. Acesso em: 07 set. 2022.
- GUO, Guodong *et al.* A survey on deep learning based face recognition. **Computer Vision and Image Understanding**, [s.l.], v. 189, n. 1, p. 102805, dez. 2019. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S1077314219301183>. Acesso em: 23 out. 2022.
- GUO, Songtao *et al.* Automatic identification of individual primates with deep learning techniques. **Iscience**, [s.l.], v. 23, n. 8, p. 1-32, ago. 2020. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2589004220306027>. Acesso em: 26 ago. 2022.
- KHAN, Sheharyar. **Final Report Image Analysis and Understanding “Face Recognition”**. 2019. 14 f. Revisão técnica - Departamento de Ciência da Computação, Universidade de Ciência e Tecnologia do Sudoeste Mianyang, Sichuan. Disponível em: [https://www.researchgate.net/profile/Sheharyar-Khan-6/publication/350487445\\_Image\\_Analysis\\_and\\_Understanding\\_Face\\_Recognition/links/624908be5e2f8c7a0355b420/Image-Analysis-and-Understanding-Face-Recognition.pdf](https://www.researchgate.net/profile/Sheharyar-Khan-6/publication/350487445_Image_Analysis_and_Understanding_Face_Recognition/links/624908be5e2f8c7a0355b420/Image-Analysis-and-Understanding-Face-Recognition.pdf). Acesso em: 26 set. 2022.
- KRAUSE Jr, Orlando. **Reconhecimento Facial de Bugios-Ruivo Através de Redes Neurais Convolucionais**. 2019. 18 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Centro de Ciências Exatas e Naturais, Universidade Regional de Blumenau, Blumenau. Disponível em: <https://www.furb.br/dsc/tcc/index.php?cd=6&tcc=2016>. Acesso em: 22 ago. 2022.
- LIU, Li *et al.* Efficient Visual Recognition. **International Journal of Computer Vision**, [s.l.], v. 128, n. 8-9, p. 1-5, jul. 2020. Disponível em: <https://link.springer.com/article/10.1007/s11263-020-01351-w>. Acesso em: 04 out. 2022.
- LÜRIG, Moritz D. *et al.* Computer Vision, Machine Learning, and the Promise of Phenomics in Ecology and Evolutionary Biology. **Frontiers in Ecology and Evolution**, [s.l.], v. 9, n. 1, p. 1-19, abr. 2021. Disponível em: <https://www.frontiersin.org/articles/10.3389/fevo.2021.642774/full>. Acesso em: 22 out. 2022.
- MASI, Iacopo *et al.* Deep Face Recognition: A Survey. **2018 31 st SIBGRAPI conference on graphics patterns and images (SIBGRAPI)**, [s.l.], n. 1, p. 471-478, out. 2018. Disponível em: <https://ieeexplore.ieee.org/abstract/document/8614364>. Acesso em: 24 out. 2022.
- OLIVEIRA, Gisela Barbosa Sobral de. **História Natural e comportamento social de bugios-ruivos (Alouatta Clamitans, Primates: Atelidae) em um dos maiores fragmentos de Mata Atlântica do mundo**. 2020. 200 f. Tese (Doutorado em Ciências) – Faculdade de Medicina Veterinária, Universidade de São Paulo, São Paulo. Disponível em: <https://www.teses.usp.br/teses/disponiveis/10/10131/tde-25062021-170455/en.php>. Acesso em: 24 out. 2022.
- OLIVEIRA, Lucas Gusen de. **O Bugio Ruivo (Alouatta guariba Clamitans) como instrumento cultural e ambiental no município de São Francisco de Paula – RS**. 2022. 41 f. Trabalho de Conclusão de Curso (Bacharelado em Gestão Ambiental) – Universidade Estadual do Rio Grande do Sul, Rio Grande do Sul. Disponível em: <https://repositorio.uergs.edu.br/xmlui/handle/123456789/2364>. Acesso em: 24 out. 2022.
- SCHNEIDER, Stefan *et al.* Three critical factors affecting automated image species recognition performance for camera traps. **Ecology and Evolution**, [s.l.], v. 10, n. 7, p. 3503-3517, mar. 2020. Disponível em: <https://onlinelibrary.wiley.com/doi/full/10.1002/ece3.6147>. Acesso em: 29 set. 2022.



SCHOFIELD, Daniel *et al.* Chimpazee face recognition from vídeos in the wild usign deep learning. **Science Advances**, [s.1], v. 5, n. 9, p. 1-9, set. 2019. Disponível em: <https://www.science.org/doi/abs/10.1126/sciadv.aaw0736>. Acesso em: 24 ago. 2022.

TAHIR, Khan Muhammad *et al.* Artificial Neural Networks for Prediction of Tuberculosis Disease. **Frontiers in Ecology and Evolution**, [s.1], v. 10, n. 1, p 1-9, mar. 2019. Disponível em: <https://www.frontiersin.org/articles/10.3389/fmicb.2019.00395/full>. Acesso em: 18 out. 2022.

WATANABE, Carmen Ballão. **Conservação Ambiental**. Paraná: Curitiba: IFPR / e-Tec Brasil, 2011. Disponível em: [http://proedu.mp.br/bitstream/handle/123456789/445/Conservacao\\_Ambiental.pdf?sequence=1](http://proedu.mp.br/bitstream/handle/123456789/445/Conservacao_Ambiental.pdf?sequence=1). Acesso em: 07 set 2022.

## FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR AVALIADOR – PRÉ-PROJETO

Avaliador(a): Aurélio Faustino Hoppe

Atenção: quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

ASPECTOS AVALIADOS		Atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?			
	O problema está claramente formulado?			
	2. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?			
	Os objetivos específicos são coerentes com o objetivo principal?			
	3. TRABALHOS CORRELATOS São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?			
	4. JUSTIFICATIVA Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada?			
	São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?			
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?			
	5. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO Os requisitos funcionais e não funcionais foram claramente descritos?			
	6. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?			
	Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?			
	7. REVISÃO BIBLIOGRÁFICA Os assuntos apresentados são suficientes e têm relação com o tema do TCC?			
	As referências contemplam adequadamente os assuntos abordados (são indicadas obras atualizadas e as mais importantes da área)?			
ASPECTOS METODOLÓGICOS	8. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?			
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?			