

Revisão do Projeto

Disciplina: Trabalho de Conclusão de Curso I – BCC

Caro, orientando,

segue abaixo a tabela de cálculo da média das notas obtidas no Pré-Projeto e Projeto, as DUAS revisões do seu projeto contendo a avaliação do professor “avaliador” e professor “TCC1”. Lembro que os ajustes indicados nestas revisões não precisam ser feitos no projeto, mas sim quando levarem o conteúdo do projeto para o artigo (se for o caso). Este material contendo todo o histórico das revisões é encaminhado para o professor de TCC2.

Tabela de cálculo da média das notas:

	Nome	Pessoa	PreProjeto										Projeto													
			TCC1				Avaliador				Ori.	Banca Esp.	TCC1				Avaliador				Média					
			A	P	N	Nota	A	P	N	Nota			A	P	N	Nota	A	P	N	Nota						
	Eduarda Engels	203937	14	2	0	16	9,58	14	1	0	15	9,78	10,00	10,00	10,00	16	0	0	16	10,00	15	0	0	15	10,00	9,9

Atenciosamente,

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2023/1

MODELO DE APRENDIZADO DE MÁQUINA PARA ANÁLISE CINEMÁTICA DA MARCHA EM PACIENTES HEMIPLÉGICOS APÓS AVC

Eduarda Engels

Prof. Aurélio Faustino Hoppe – Orientador

1 INTRODUÇÃO

Segundo dados oficiais do Ministério da Saúde e das organizações mundiais de saúde, como a Organização Mundial de Saúde (OMS) e a Organização Pan-Americana da Saúde (OPAS), o Brasil apresenta a quarta maior taxa de mortalidade por Acidente Vascular Cerebral (AVC) entre os países da América Latina e Caribe (MINISTÉRIO DA SAÚDE, 2022). Ainda de acordo com a Secretaria de Atenção à Saúde (2022), em 2020, o AVC representava a segunda maior causa de morte do país, ficando atrás apenas de doenças do aparelho circulatório, tendo 43,9 óbitos por 100 mil habitantes.

De acordo com a Organização Mundial de Saúde (2019), o AVC afeta um ou mais vasos sanguíneos por um processo patológico que pode ocorrer pela falta de sangue nas veias, gerando isquemia, ou rompimento dos vasos sanguíneos causando hemorragia. Schmidt *et al.* (2019) ressaltam que a maior parte dos sobreviventes de AVC permanecem com sequelas, podendo ser física, comunicativa, sensitivas, funcionais, entre outras.

Segundo Luo *et al.* (2019), a sequência física mais comum ocasionada pelo AVC é a hemiplegia que é uma condição neurológica que se caracteriza pela paralisia de um dos lados do corpo, afetando significativamente a cinemática da marcha, como a simetria entre as pernas e a coordenação dos movimentos. Ainda segundo os autores, a análise cinemática da marcha em pacientes hemiplégicos fornece informações importantes sobre as alterações no padrão de marcha, como a redução no comprimento do passo, menor flexão do quadril e diminuição do tempo de apoio do membro afetado.

De acordo com o Secretaria de Atenção à Saúde (2022), o tratamento da hemiplegia geralmente envolve uma abordagem multidisciplinar, que inclui fisioterapia, terapia ocupacional e fonoaudiologia. O objetivo da terapia é maximizar a independência funcional do paciente, minimizando as limitações impostas pela paralisia. Uma das estratégias utilizadas na terapia é o treinamento oromotor precoce (desenvolvimento adequado da fala e da alimentação), que tem como objetivo normalizar as funções respiratória, de deglutição e de mastigação. Já as intervenções de reabilitação incluem exercícios específicos para melhorar a cinemática da marcha, com treinamento de passadas em esteira com suporte de peso corporal e terapia manual para aumentar o desempenho do movimento articular (MINISTÉRIO DA SAÚDE, 2022).

De acordo com Harris, Khoo e Demircan (2022), além da análise cinemática, existem diversas ferramentas de análise da hemiplegia que necessitam de equipamentos específicos e métodos de análise sofisticados, como sistemas de captura de movimento, plataformas de força e análise de imagem. Tais equipamentos exigem um alto investimento financeiro e podem não estar disponíveis em todos os centros de reabilitação, limitando o acesso e a avaliação da efetividade das intervenções terapêuticas. Nesse contexto, a utilização de técnicas de aprendizado de máquina apresenta-se como uma ferramenta promissora para o desenvolvimento de modelos preditivos que possam auxiliar na tomada de decisão clínica, possibilitando a identificação precoce de possíveis alterações na cinemática da marcha e o ajuste adequado do tratamento de acordo com as necessidades de cada paciente.

Diante deste cenário, surge a seguinte pergunta de pesquisa: "Como o uso de técnicas de aprendizado de máquina pode auxiliar na análise cinemática da marcha em pacientes hemiplégicos após um AVC?". Para isso, este trabalho será desenvolvido em parceria com o CER II FURB que é o Centro Especializado em Reabilitação II da Universidade Regional de Blumenau (FURB), localizado em Blumenau, Santa Catarina, Brasil. Trata-se de uma unidade especializada na prestação de serviços de reabilitação para pessoas com deficiências. Contando com uma equipe multidisciplinar composta por médicos, fisioterapeutas, terapeutas ocupacionais, fonoaudiólogos, psicólogos, assistentes sociais e outros profissionais, o centro fornece avaliação, diagnóstico, tratamento e acompanhamento individualizado, adaptados às necessidades de cada paciente. Os serviços incluem fisioterapia, terapia ocupacional, fonoaudiologia, entre outros, com o objetivo de promover a reabilitação e melhorar a qualidade de vida dos pacientes atendidos.

1.1 OBJETIVOS

O objetivo deste trabalho é criar um modelo de aprendizado de máquina de análise cinemática capaz de identificar anomalias na marcha em pacientes hemiplégicos pós AVC.

Os objetivos específicos são:

- Identificar padrões complexos nas séries temporais de cinemática da marcha a partir de imagens;
- Classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- Avaliar a eficácia do modelo em relação à avaliação tradicional da cinemática da marcha;
- Identificar possíveis limitações e desafios na utilização de técnicas de aprendizado de máquina no contexto de análise cinemática.

2 TRABALHOS CORRELATOS

Nesta seção serão apresentados trabalhos que possuem características semelhantes aos principais objetivos do estudo proposto. Na subseção 2.1 é detalhado o trabalho de Benjinariu *et al.* (2021), ao qual desenvolveram uma aplicação para estimar o ângulo de flexão do joelho a fim de detectar anomalias na marcha humana por meio de redes neurais artificiais. A subseção 2.2 descreve o trabalho de Luo *et al.* (2019), que busca medir o nível de marcha de pacientes com hemiplegia por meio de árvore de decisão. Por fim, a subseção 2.3 apresenta o trabalho de Slijepcevic *et al.* (2021), que utilizam o método *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a compreensão dos resultados dos classificadores de aprendizado de máquina em relação a análise automatizada da marcha.


2.1 IMAGE PROCESSING FOR THE REHABILITATION ASSESSMENT OF LOCOMOTION INJURIES AND POST STROKE DISABILITIES

Benjinariu *et al.* (2021) utilizam a análise de movimento para auxiliar na reabilitação locomotora, com foco em tratamento de Acidente Vascular Cerebral (AVC), nos membros inferiores do corpo. Os autores aplicaram métodos de aprendizado de máquina para extração e análise da marcha. Os atribuídos utilizados foram inerciais (acelerações), posturais (ângulos formados por segmento do corpo humano) ou espaço-temporal (comprimento da passada, frequência e variabilidade da passada).

Benjinariu *et al.* (2021) utilizaram como base de dados vídeos adquiridos de pacientes que estão se recuperando de fraturas nos membros inferiores, aos quais foram filmados em um plano frontal e sagital com uma taxa média de 30 segundos. Os autores extraíram os ângulos e a velocidade de diferentes articulações em diferentes ações como caminhar, trotar e correr. Para a classificação, utilizam o classificador *Random Forest* (RF) implementado na linguagem de programação C++.

De acordo com Benjinariu *et al.* (2021), a *Human Pose Estimation* (HPE) consiste em determinar a posição do corpo humano utilizando imagens, tarefa desafiadora, que pode ser abordada por meio de diversos métodos, que vão desde o uso de sensores até marcadores. Os modelos baseados em *Convolutional Neural Network* (CNN) utilizam esqueletos, contornos e volumes para modelar o corpo humano. No processo de detecção, um conjunto de pontos anatômicos-chave é calculado para cada indivíduo na imagem, utilizando-se o OpenPose, que processa o vídeo quadro a quadro, resultando em uma lista de pontos-chave especificados por coordenadas 2D. Segundo os autores, isso permite identificar partes esquerda e direita do corpo, bem como se ele está sendo visto de frente ou de costas. A Figura 1 exemplifica o processo de redução do número de pontos e a posição correta das pernas por meio dos pontos-chave.

Figura 1 – Pontos-Chaves usando o OpenPose



Fonte: Benjinariu *et al.* (2021).


Segundo Benjinariu *et al.* (2021), as posições dos pontos-chave definem a condição patológica da pessoa, ao qual, realiza-se a análise a partir dos ângulos dos segmentos das pernas. Os autores também destacam que o ângulo do quadril entre Espinha Iliaca AnteroSuperior (ELAS) e a linha média da coxa deve ser de 90°, assim como, a linha média da coxa e do tornozelo também precisam estar alinhados com o joelho na posição ortostática (quando estiver em pé). Outra constatação é que, durante o caminhar, os ângulos do joelho diminuem, e, se chegarem a 10° de variação, para dentro ou fora, há indícios de um caso patológico.

De acordo com Benjinariu *et al.* (2021), nem todos os quadros foram considerados durante a implementação do OpenPose, pois nem sempre os pontos podiam ser identificados ou a silhueta do paciente era visível. Analisando os ângulos obtidos, o valor máximo do ângulo no joelho direito é de 192° e no esquerdo é de 194°, indicando uma situação patológica pois o joelho se move para fora enquanto caminha. O valor médio dos

Comentado [AS1]: Podes aqui colocar Redes Neurais Artificiais (RNA) e depois só colocar a sigla.

ângulos está dentro do limite de 10° na variação interna. Os valores de ângulos na linha EIAS trouxeram valores altos como 30° por conta do posicionamento dos pontos na detecção automática. No entanto, a variação do ângulo EIAS nas imagens dos pacientes é grande. A Figura 2 apresenta a evolução dos ângulos dos *frames* 425 a 453, no qual são inferiores a 180°, apontando que ambos os joelhos estão para fora.

Figura 2 – Variação angular dos joelhos nos quadros 425-453



Fonte: Benjinariu *et al.* (2021).

Benjinariu *et al.* (2021) afirmam que a pesquisa ainda está em andamento e os resultados obtidos para avaliação de reabilitação da locomoção são promissores. Para as próximas atualizações, pretendem aumentar o número de sequências de vídeos utilizados e incluir gravações com pacientes reabilitados ou saudáveis para comparação de avaliação automática. Também querem rever a detecção de pontos-chave aplicando outros métodos de HPE.


2.2 RANDOM FOREST-BASED CLASSIFICATION AND ANALYSIS OF HEMIPLEGIA GAIT USING LOW-COST DEPTH CAMERAS

Luo *et al.* (2019) utilizaram o sensor Microsoft Kinect para capturar a marcha no espaço-tempo e a cinemática articular a partir de configurações simples a fim de investigar o potencial da ferramenta em realizar análise da marcha hemiplegia. Os autores coletaram os dados no Departamento de Medicina de Reabilitação do Hospital Popular de Jiangxi.

Segundo Luo *et al.* (2019), foram recrutados 60 indivíduos, sendo 40 saudáveis e 20 pacientes com hemiplegia, que tiveram que realizar o movimento padrão de andar em linha reta 4 metros em frente ao sensor Kinect, repetindo este processo 9 vezes. Os dados extraídos para compor as características espaço-tempo foram a velocidade e o comprimento da passada.

Luo *et al.* (2019) calcularam o ponto médio das juntas em relação as coordenadas do planar direito e esquerdo. A partir disso, segundo os autores, torna-se possível calcular a distância euclidiana entre os dois para estimar o comprimento inicial. Na Figura 3 item (A) pode-se observar a detecção do participante em tempo real, no item (B) o esqueleto com as juntas enumeradas, no item (C), a marcha extraída durante a caminhada e, por fim, no item (D) a extração de esquerda e direita com movimentos para cima e para baixo do centro de massa.

Figura 3 – Dados da marcha extraídos com MS Kinect

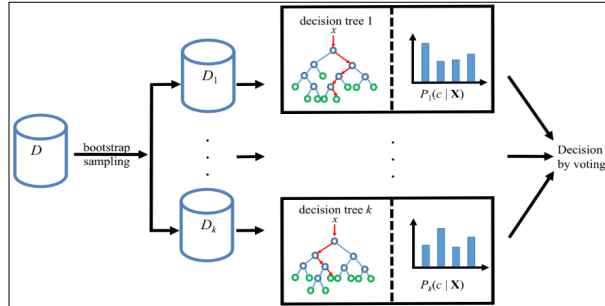


Fonte: Luo *et al.* (2019).

Segundo Luo *et al.* (2019), a característica chave para realizar a análise cinemática é o centro da massa do indivíduo. Para isso, eles utilizaram um método de segmentação corporal que corta o corpo humano em pequenos segmentos. Posteriormente, na linguagem de programação Python, aplicou-se o *Random Forest* (RF) para realizar a classificação das combinações. Ainda segundo os autores, a partir de um conjunto de dados de treinamento aleatório, utiliza-se o Índice de Gini para definir as características ótimas para efetuar a divisão dos participantes. A Figura 4 exemplifica a aplicação de múltiplas árvores de decisão, no qual D denota o conjunto de dados de entrada.

Comentado [AS2]: Deve-se evitar fazer parágrafos muito curtos.


Figura 4 – Método de classificação *Random Forest*



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) utilizaram um número maior de amostras de pessoas saudáveis, tendo em vista sua proporção em relação a população de indivíduos sem hemiplegia. Para estabelecer o melhor método de classificação, os autores utilizaram a curva *Receiver Operator Characteristic* (ROC), no qual cada ponto corresponde a um par de *False-Positive Rate* (FPR) ou *True-Positive Rate* (TPR). Portanto, a curva de ROC deveria ter o TPR mais alto e o FPR mais baixo, ou seja, quanto mais próximo do canto superior esquerdo a curva estiver, melhor será a classificação, conforme ilustra a Figura 5.

Figura 5 – ROC comparando os métodos de classificação



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) comparam os resultados da classificação do RF em relação as redes *Bayesianas* e a *Support Vector Machine* (SVM). Dentre eles, o RF obteve, em média, 90% de precisão entre todas as combinações de características, pois as árvores de decisão são independentes entre si. Os autores também afirmam que pretendem utilizar mais o MS Kinect para capturar as características das passadas e o ângulo do pé para análise da marcha.

2.3 EXPLAINING MACHINE LEARNING MODELS FOR CLINICAL GAIT ANALYSIS


Segundo Slijepcevic *et al.* (2021), a Análise Clínica da Marcha (ACM) se concentra em analisar e descrever quantitativamente aspectos cinemáticos (ângulos articulares), cinéticos (forças de reação do solo e momentos articulares) e musculares (eletromiografia). Neste contexto, os autores exploraram métodos de *Explainable Artificial Intelligence* (XAI) para identificar como os modelos de ML produzem suas previsões por meio do *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a transparência na classificação método automatizada clínica da marcha baseada em séries temporais.

Slijepcevic *et al.* (2021) optaram pelos classificadores *Support Vector Machine* (SVM), *Multilayer Perceptron* (MLP) e *Convolutional Neural Network* (CNN) como abordagens de ML para comparar a precisão e os padrões de relevância das entradas. O SVM foi treinado utilizando o método de otimização quadrática. Para a MLP, utilizou-se três camadas não lineares e conectadas com a função SoftMax na camada de saída. Já no modelo CNN, aplicou-se três camadas *convolucionais* consecutivas, sendo mapeado por um vetor com mais de 2 mil dimensões. Segundo os autores, os modelos MLP e CNN foram treinados usando o gradiente descendente estocástico e a média absoluta com os pesos sendo iniciados aleatoriamente.

Slijepcevic *et al.* (2021) estruturam os treinos dos modelos de classificação de acordo com as etapas presentes no fluxo de classificação da Figura 6. Inicialmente, obtém-se os dados de entrada através do *Ground Reaction Forces* (GRFs) de ambas as pernas. No item (B), realiza-se a classificação com base nas forças tridimensionais de GRFs. Posteriormente, no item (C), utiliza-se as pontuações relevantes referentes ao espectro

do sinal de entrada através da LRP. Por fim, nos itens (D) e (E) busca-se explicar os resultados de forma estatística ou na perspectiva clínica.


Figura 6 – Fluxo de classificação automatizada de marcha



Fonte: Slijepcevic *et al.* (2021).

Slijepcevic *et al.* (2021) utilizaram dados de 132 pacientes com distúrbios da marcha e de 62 saudáveis, de ambos os gêneros e com diferentes características físicas, para medir as GRFs. Segundo os autores, o conjunto de dados incluiu três classes de distúrbios ortopédicos da marcha associados ao quadril, joelho e tornozelo. Para capturar as GRFs tridimensionais, foram utilizados quatro componentes: força horizontal, força médio-lateral, força anteroposterior horizontal e força vertical, gerando um vetor de entrada com 1x606 dimensões para cada tentativa de marcha. Slijepcevic *et al.* (2021), também utilizaram o cálculo de linha *Zero-Rule Baseline* (ZRB) que se refere a precisão teórica obtida pela atribuição de rótulos de classe de acordo com a probabilidade de classes anteriores. Os resultados indicaram uma diferença mínima entre os classificadores. Na Figura 7 apresenta a acurácia obtida pelos modelos CNN, SVM e MLP. Segundo os autores, a precisão de classificação média mostrou-se superior ao ZRB em todos os casos. Em relação a normalização, Slijepcevic *et al.* (2021) verificaram a análise de variância, relatando que a diferença encontrada entre as tarefas não foi relevante, sendo que a precisão média de classificação foi acima de 80%.

Figura 7 – Accuracy dos modelos ML



Fonte: Slijepcevic *et al.* (2021).

De acordo com Slijepcevic *et al.* (2021), o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões. Além disso, segundo os autores, a utilização dele é apenas indicada se o método de classificação alcançar conclusões significativas, pois ao analisar um modelo não confiável, pode resultar em ruídos e padrões instáveis. Além disso, Slijepcevic *et al.* (2021) também observaram que a normalização dos dados de entrada acaba sendo um fator importante para o ML, pois caso os intervalos entre os valores forem divergentes afeta negativamente a previsão. Por fim, os autores ressaltam que os métodos de XAI, para explicar as previsões de modelos ML, são promissores e podem ajudar na justificativa das classificações automáticas de CGA.

3 PROPOSTA DE MODELO

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo propor um modelo de aprendizado de máquina para análise cinemática da marcha em pacientes com AVC. A metodologia adotada para o desenvolvimento do modelo será detalhada, bem como os requisitos necessários para a sua implementação.

3.1 JUSTIFICATIVA

No Quadro 1 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas são cada trabalho e as linhas as características, com elas podemos entender como será solucionado os problemas propostos por este trabalho.

Quadro 1 – Comparativo dos trabalhos correlatos

Trabalhos Correlatos	Benjinariu <i>et al.</i> (2021)	Luo <i>et al.</i> (2019)	Sljipecevic <i>et al.</i> (2021)
Características			
Patologia de identificação	Acidente Vascular Cerebral (AVC)	Hemiplegia	Acidente Vascular Cerebral (AVC)
Objetivo	Identificar anormalidades na marcha humana	Identificar anormalidades na marcha humana	Esclarecer as previsões de modelos de classificação
Membros analisados para avaliação	Inferiores	Inferiores	Inferiores
Técnica de análise utilizada	RF e CNN	RF, SVM e Bayesianas	CNN, SVM, MLP e LRP
Técnica de identificação do corpo humano	HPE	Pontos do esqueleto	LRP
Número de pacientes avaliados	Não mencionado	60	194
Taxa de acerto	Não mencionado	>90%	>80%
Dispositivo para captura de dados	Smartphone (video)	MS Kinect	Plataformas de força (GRFs)
Linguagem de programação	C++	Não mencionado	Python

Fonte: elaborado pela autora.

A partir do Quadro 1 pode-se observar que todos os autores utilizam modelos de avaliação dos membros inferiores para a identificação de anomalias da marcha. Destaca-se o trabalho de Sljipecevic *et al.* (2021) ao qual realizaram uma comparação entre os modelos de classificação de marcha (SVM, MLP e CNN). Além disso, também utilizaram inteligência artificial explicável (método *Layer-wise Relevance Propagation*) para poder justificar os resultados das previsões e aprimorar a classificação clínica automatizada da marcha humana em pacientes com AVC. Nos testes, os autores utilizaram dados de GRFs de 194 pacientes. Por fim, Sljipecevic *et al.* (2021) concluem que método o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões.

Benjinariu *et al.* (2021) utilizaram redes neurais para estimar o ângulo de flexão do joelho, assim como detectar anomalias na marcha humana de pacientes que sofreram AVC. Para isso, os autores utilizaram a biblioteca do OpenPose, implementado em C++, que permite detectar a parte esquerda e direita do corpo, assim como a direção, se o corpo está sendo visto de frente ou de trás. A captura dos dados foi realizada através de um smartphone e os resultados foram apresentados na forma de um gráfico que demonstra a variação angular dos joelhos que são extraídos a partir da posição de pontos-chave para indicar a condição patológica da pessoa. Por fim, os autores apontam que, apesar da pesquisa estar em andamento, os resultados são promissores e que, ao longo do tempo, serão utilizados mais vídeos para aperfeiçoar o modelo.

Luo *et al.* (2019) tinham como intuito identificar anomalias, assim como estabelecer o nível de marcha em pacientes com hemiplegia por meio de uma árvore de decisão e um conjunto de entrada aleatório. Os autores utilizaram o sensor de profundidade Microsoft Kinect (MS Kinect) para detectar o movimento em tempo real. A partir disso, construíram uma base de dados com as características de 60 indivíduos. Posteriormente, Luo *et al.* (2019) aplicaram um método de segmentação corporal para subdividir o corpo humano em pequenos segmentos, aos quais foram utilizados como entrada pelos algoritmos *Random Forest* (RF), redes *Bayesianas* e a *Support Vector Machine* (SVM). Segundo os autores, a RF apresentou a melhor precisão, cerca de 90%.

Com base no cenário descrito acima, pode-se observar que os trabalhos utilizam diferentes métodos de análise para identificar anomalias na marcha humana. Contudo, percebe-se a necessidade do desenvolvimento de um modelo mais adequado para analisar as informações cinemáticas dos pacientes, considerando as limitações de equipamento de captura e da quantidade e especificidade da população estudada. Diante disso, o diferencial do trabalho proposto encontra-se justamente no desenvolvimento de um modelo de aprendizado de máquina específico para a análise cinemática da marcha em pacientes hemiplégicos após AVC, sendo que, para o desenvolvimento deste trabalho será utilizado dados, assim como, o suporte dos profissionais do Centro Especializado de Reabilitação da FURB.

Acredita-se que o uso do modelo de aprendizado de máquina possa proporcionar uma análise mais objetiva e contínua do progresso do paciente, trazendo uma contribuição significativa para a área da reabilitação, auxiliando na elaboração de terapias mais eficientes e personalizadas para os pacientes, além de poder ser aplicado em outras pessoas com problemas de locomoção. Contudo, espera-se facilitar o trabalho do profissional de saúde, possibilitando ajustes mais precisos e individualizados nas intervenções de reabilitação assim como, melhorando efetividade dos tratamentos atualmente oferecidos.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O trabalho proposto deverá contemplar os seguintes Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF):

- Permitir o cadastro de pacientes (RF);
- Permitir ao usuário capturar ou importar vídeos dos membros inferiores do corpo (RF);
- Realizar o realce e melhoramento de ruídos, distorções e problemas de iluminação utilizando técnicas de processamento de imagens (RF);
- Efetuar a análise cinemática a partir dos membros inferiores utilizando redes neurais convolucionais e/ou recorrentes (RF);
- Estabelecer o nível de funcionalidade do paciente a partir do movimento corporal (RF);
- Manter o usuário informado sobre a situação do processamento das imagens/vídeos (RF);
- Aprimorar o modelo a partir de novos vídeos cadastros pelos usuários (RNF);
- Utilizar as bibliotecas OpenCV para o processamento de imagens e o Keras ou Tensorflow para a construção da rede neural artificial (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- Levantamento bibliográfico: estudar os assuntos relacionados à acidente vascular cerebral, análise cinemática, aprendizado de máquina e trabalhos correlatos;
- Acompanhamento clínico: acompanhar atendimentos realizados no Centro de Reabilitação da Furb II, com pacientes que sofreram AVC, para entendimento do problema e constatação de necessidades;
- Submissão ao conselho de ética: escrita e cadastro do trabalho na plataforma Brasil e submissão para o conselho de ética da FURB. Ressaltando que em cada experimento será solicitado aos pacientes a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- Coleta de dados: coleta de dados de cinemática da marcha em pacientes hemiplégicos após AVC, realizando a gravação de vídeos;
- Definição de algoritmos para extrair a cinemática da marcha: pesquisar métodos de processamento de imagens para extrair/estabelecer medidas a partir de imagens/vídeos;
- Definição de algoritmos para classificação das fases da marcha: pesquisar as técnicas de aprendizado de máquina (convolucionais ou recorrentes) para classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- Análise temporal: realização de análises temporais para avaliar a variação temporal dos parâmetros de cinemática da marcha e identificar mudanças ao longo do tempo;
- Desenvolvimento do modelo: a partir dos itens (g), (h) e (i), realizar a implementação da análise cinemática utilizando a biblioteca OpenCV, a linguagem de programação Python e as bibliotecas Keras e Tensorflow;
- Testes do modelo: paralelamente à implementação, realizar testes com base nos vídeos obtidos para verificar a eficiência e assertividade do modelo elaborado utilizando a validação cruzada assim como a comprovação dos resultados a partir de um grupo de pacientes hemiplégicos após AVC em conjunto com profissionais da saúde.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 – Cronograma de atividades a serem realizadas

etapas / quinzenas	2023									
	jul.		ago.		set.		out.		nov.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
acompanhamento clínico										
submissão ao conselho de ética										
coleta de dados										
definição de algoritmos para extrair a cinemática da marcha										
definição de algoritmos para classificação das fases da marcha										
análise temporal										
desenvolvimento do modelo										
testes do modelo										

Fonte: elaborado pela autora.

4 REVISÃO BIBLIOGRÁFICA


Nesta seção serão apresentados os principais conceitos que fundamentam o estudo proposto. A subseção 4.1 aborda Acidente Vascular Cerebral (AVC), considerando suas características e consequências. Na subseção 4.2 apresenta a análise cinemática da marcha, que consiste na técnica de avaliação da locomoção humana. Por fim, na subseção 4.3 conceitua-se o aprendizado de máquina e suas principais técnicas.

4.1 ACIDENTE VASCULAR CEREBRAL

O Acidente Vascular Cerebral (AVC) é mais comum na fase adulta, sendo um dos sinais mais frequentes a ocorrência súbita de fraqueza ou dormência na face, braço e perna, afetando um lado do corpo (SECRETARIA DE ATENÇÃO À SAÚDE, 2022). Para o National Institutes of Health (2023), o AVC ocorre quando o fluxo sanguíneo de uma área do cérebro é interrompido, podendo ser causado por um coágulo sanguíneo (AVC isquêmico) ou por um vaso sanguíneo rompido (AVC hemorrágico). Essa condição pode levar a danos cerebrais permanentes ou até mesmo em óbito caso não seja tratado imediatamente.

Ferla, Grave e Perico (2015) destacam que a causa mais comum do AVC está relacionada a doenças cardiovasculares que afetam a circulação cerebral. As artérias média, posterior e anterior são frequentemente afetadas, assim como seus ramos menores que penetram nas regiões mais profundas do cérebro. O diagnóstico é feito com base nos sintomas apresentados pelo paciente e em exames de imagem, como tomografias computadorizadas ou ressonância magnética cerebral (SECRETARIA DE ATENÇÃO À SAÚDE, 2022). A Figura 8 exemplifica o AVC hemorrágico no lado esquerdo e o AVC Isquêmico no lado direito, através de uma tomografia craniana.

Figura 8 – Tomografia do crânio com variações do AVC



Fonte: Aguiar (2018).

Oliveira *et al.* (2017) afirmam que o AVC resulta em sequelas físicas, funcionais e comunicativas, gerando incapacidade e dependência nos indivíduos afetados. Essas sequelas podem incluir perda de força, sensibilidade e capacidade de movimentação em diferentes partes do corpo, além de distúrbios de linguagem, depressão, distúrbios visuais, perda de equilíbrio e coordenação. Segundo os autores, o AVC causa danos neurológicos que impactam diversas áreas da vida dos pacientes, como a mobilidade, a comunicação e a independência funcional.

Além disso, Azolin (2016) destaca que a hemiplegia e a hemiparesia são características comuns após a sobrevivência a um AVC. Essas condições envolvem a perda completa ou parcial do controle motor de um lado do corpo, respectivamente. Essa perda de controle motor resulta em dificuldades para manter uma postura assimétrica e uma distribuição adequada de peso no hemicorpo afetado. A assimetria e a dificuldade em manter o controle postural comprometem a orientação e a estabilidade do paciente, tornando desafiador realizar movimentos e sustentar o equilíbrio corporal.

Segundo Aguiar (2018), o AVC é uma das principais causas de morbidade e mortalidade em todo o mundo. O autor ressalta que a prevenção e o tratamento adequados são fundamentais para reduzir o impacto do AVC na saúde pública. A identificação e o controle dos fatores de risco, como hipertensão arterial, diabetes, tabagismo, sedentarismo e obesidade, desempenham um papel crucial na implementação de medidas preventivas. Além disso, o autor destaca a importância de uma abordagem multidisciplinar no tratamento do AVC, envolvendo equipes médicas especializadas, fisioterapeutas, fonoaudiólogos e profissionais de reabilitação. Essa abordagem visa à recuperação funcional e à melhoria da qualidade de vida dos pacientes afetados pelo AVC.

De acordo com Oliveira *et al.* (2017), a reabilitação desempenha um papel crucial na minimização das sequelas, na melhoria da capacidade funcional e na promoção da reintegração social. Diversos métodos e técnicas de reabilitação, como fisioterapia, terapia ocupacional, fonoaudiologia e psicologia, são destacados como essenciais para auxiliar na recuperação dos pacientes após um AVC.

Segundo a Secretaria de Atenção à Saúde (2022), o AVC é mais comum na fase adulta e o paciente apresenta diversas limitações em consequência do evento e a recuperação é diferente em cada caso. Além disso, o atendimento médico imediato, aliado à uma reabilitação adequada, pode minimizar as incapacidades, evitar sequelas mais severas e proporcionar ao indivíduo o retorno mais breve possível às suas atividades cotidianas.


4.2 CINEMÁTICA DA MARCHA

Segundo Kim *et al.* (2018), identificar anormalidades na marcha é fundamental para o diagnóstico e tratamento de doenças e lesões que afetam o caminhar de uma pessoa, como o Acidente Vascular Cerebral (AVC), lesões medulares, doenças neuromusculares e ortopédicas. Além disso, os autores também afirmam que ao utilizar a análise cinemática da marcha para avaliar os efeitos de um programa de treinamento em pacientes com hemiplegia pode-se reduzir e alcançar resultados melhores na simetria da marcha em menos tempo.

De acordo com Caparelli (2017), a análise da marcha permite auxiliar o tratamento dos indivíduos e melhorar a compreensão do processo de marcha através de pesquisa. O autor destaca a importância de compreender as características espaço-temporais da marcha, como o comprimento da passada, a duração da passada e a velocidade. Esses parâmetros fornecem informações valiosas sobre a eficiência e o padrão de movimento durante a caminhada.

Caparelli (2017) afirma que a marcha é um meio natural de locomoção do corpo, envolvendo o uso alternado das duas pernas para proporcionar suporte e propulsão. O comprimento da passada refere-se à distância entre o contato inicial do calcanhar de um membro no solo e o próximo contato deste mesmo no chão, enquanto o passo é a distância longitudinal entre o contato no solo do calcanhar de um membro e o calcanhar contralateral. A frequência dos passos é conhecida como cadência. A Figura 9 apresenta a diferença entre a passada e o passo.


Figura 9 – Definição de passo e passada



Fonte: Caparelli (2017).

Segundo Caparelli (2017), a partida da marcha normalmente ocorre quando o indivíduo que deseja levantar o pé direito, iniciando o apoio neste mesmo lado e, em seguida, transferindo o peso para o pé esquerdo, permitindo que o pé direito se descole do solo. A eficiência desses movimentos depende da mobilidade articular livre e da atividade muscular adequada. Durante a marcha, o quadril desempenha um papel crucial, com uma amplitude de movimento típica de 10° de extensão e 30° de flexão na articulação. Clinicamente, a posição zero é definida como o tronco e a coxa em postura ereta. O joelho desempenha diversas funções durante a marcha, como sustentar o peso corporal, amortecer o impacto, aumentar o comprimento da passada e permitir o movimento do pé durante a fase de balanço. Na Figura 10 mostra o caminhar com as fases da marcha.

Figura 10 - Fases da Marcha Humana



Fonte: Caparelli (2017).

Caparelli (2017) enfatiza a importância da análise da marcha como uma ferramenta essencial no auxílio ao tratamento de indivíduos e no avanço do conhecimento por meio de pesquisas. O autor destaca que as redes neurais artificiais têm se mostrado uma abordagem de modelagem superior para aplicações relacionadas à marcha, como a predição e o ajuste de dados. Essa técnica oferece oportunidades promissoras para melhorar a precisão e a eficiência dos estudos biomecânicos da marcha.

A Secretaria de Atenção à Saúde (2022) afirma que a utilização de equipamentos de alta tecnologia, como câmeras de captura de movimento e sensores, tem se mostrado fundamental para avaliar diversos parâmetros da marcha, como comprimento do passo, contato com o solo e distribuição do peso. Essas ferramentas auxiliam na identificação de possíveis anormalidades e contribuem para o diagnóstico e tratamento de doenças e lesões que afetam a marcha. Caparelli (2017) também ressalta o papel crucial das tecnologias avançadas na análise da marcha, como as câmeras de captura de movimento e os sensores. Esses dispositivos permitem uma avaliação mais precisa e objetiva de diversos parâmetros da marcha, incluindo a cinemática articular, a distribuição de forças e a cinética do movimento. Essas informações são fundamentais para compreender as alterações biomecânicas decorrentes de patologias ou lesões, auxiliando no diagnóstico e no planejamento do tratamento.

4.3 APRENDIZADO DE MÁQUINA

De acordo com Alpaydin (2012), *Machine Learning* (ML) é um ramo da inteligência artificial que utiliza técnicas computacionais para permitir que um sistema aprenda e melhore com a experiência. Segundo o autor, ML

Comentado [AS3]: Podes usar o termo em português

é uma abordagem de modelagem de dados que automatiza a construção de modelos analíticos. Entre suas principais características, destacam-se (i) o aprendizado automático, que aprendem a partir dos dados e se ajusta para melhoria de desempenho, (ii) a generalização, ou seja, fazer previsões e classificações em novos dados que não foram utilizados no treinamento, e (iii) a adaptabilidade, os modelos podem se adaptar as situações melhorando sua resposta com o tempo.

Alpaydin (2012) ainda destaca que o uso de cada arquitetura ou algoritmo de ML depende do tipo do problema a ser resolvido e as características dos dados existentes. Dentre as principais técnicas, encontram a Árvore de Decisão, o *Support Vector Machine* (SVM) e os algoritmos de clusterização. A árvore de decisão utiliza um modelo de estrutura hierárquica para tomar decisões com bases nos dados, dividindo em subconjuntos menores e regras para a classificação dos dados. O SVM, separa as classes dos dados em um hiperplano. Já os algoritmos de agrupamento, utilizam características semelhantes para dividir um conjunto de dados em *clusters* (ALPAYDIN, 2012).

Segundo Alpaydin (2012), dentre os algoritmos de ML, destacam-se a redes neurais artificiais, inspirada no cérebro humano, que consistem em redes interconectadas que aprendem a partir dos dados. Já a *Convolutional Neural Network* (CNN) é capaz de extrair características relevantes das imagens, como bordas e texturas para a classificação ou reconhecimento de objetos. Por outro lado, as redes neurais recorrentes são usadas para técnicas de processamentos de sequência de dados, possuindo conexões que permitem que as informações sejam propagadas de uma etapa da sequência para a próxima, permitindo a captura de informações contextuais e para realizar previsões.

De acordo com Olah (2015), as redes *Long Short-Term Memory* (LSTM) foram desenvolvidas para superar as limitações das *Recurrent Neural Network* (RNN) tradicionais, que apresentam dificuldades em capturar dependências de longo prazo em sequências de dados. O autor introduz a ideia de células de memória como a unidade fundamental da LSTM. Essas células possuem uma estrutura de *loop* interno que permite o armazenamento e a recuperação de informações ao longo do tempo, evitando a perda de gradiente.

Olah (2015) destaca que os principais elementos de uma célula LSTM são os portões de entrada, esquecimento e saída. Esses portões são utilizados para controlar o fluxo de informações dentro da célula e determinar quais informações devem ser retidas, esquecidas ou produzidas como saída. Com o uso desses mecanismos, a LSTM é capaz de capturar dependências de longo prazo em sequências de dados. Uma das vantagens deste modelo é sua habilidade de manter gradientes mais estáveis ao longo do tempo, o que permite o treinamento eficiente de redes neurais profundas em sequências de dados complexas.

Assim como o LSTM, o *Gated Recurrent Unit* (GRU) utiliza portões para controlar o fluxo de informações dentro da rede. O GRU é composto por dois principais portões, um portão de redefinição (*reset gate*) e um portão de atualização (*update gate*). Os portões ajudam a controlar o fluxo de informações dentro da rede e permitem que o GRU capture dependências de longo prazo. O portão de redefinição decide quais informações antigas devem ser descartadas, enquanto o portão de atualização decide quais novas informações devem ser mantidas. Os portões são compostos por funções de ativação, como a função sigmoide, que variam de 0 a 1 e determinam a importância das informações.

Segundo Cho (2014), a principal característica do GRU é que ela possui um mecanismo de atualização adaptativo, onde o portão de atualização controla quanto das informações antigas deve ser misturado com as novas informações. Isso permite que o GRU se adapte dinamicamente às características da sequência de entrada e ajuste a importância das informações antigas e novas. Recomendado para aplicações que envolvem sequências de dados por possuir capacidade de capturar dependências de longo prazo e evitar o desvanecimento do gradiente.

REFERÊNCIAS

AGUIAR, Paulo V. *et al.* **Application of the NetLogo Tool in Ischemic Stroke Simulation**. In: ENCONTRO NACIONAL DE INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL (ENIAC), 15, 2018, São Paulo. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2018, p. 596-607.

ALPAYDIN, Ethem. **Introduction to Machine Learning**. Cambridge: Cambridge University Press (CUP), 2012.

AZOLIN, Valéria P. **Avaliação do controle postural e sua relação com o hemisfério acometido no acidente vascular cerebral**. 2016. 59 f. Monografia (Especialização) – Especialização em Reabilitação Físico-Motora, Universidade Federal de Santa Maria, Rio Grande do Sul.

BENJINARIU, Silviu-Ioan *et al.* **Image Processing for the Rehabilitation Assessment of Locomotion Injuries and Post Stroke Disabilities**. 2021 International Conference On E-Health And Bioengineering (Ehb), Iasi, Romania, p. 2-5, 2021.

CAPARELLI, Thiago Bruno *et al.* **Reconstrução de Parâmetros Biomecânicos da Marcha por meio de Ciclogramas e Redes Neurais Artificiais**. 2017. Tese de doutorado na área de concentração Processamento da Informação, Universidade Federal de Uberlândia, Uberlândia. Disponível em: <https://repositorio.ufu.br/bitstream/123456789/20879/3/Reconstru%C3%A7%C3%A3oPar%C3%A2metrosBiomec%C3%A2nicos.pdf>. Acesso em: 11 jun. 2023.

Comentado [AS4]: Coloca também o nome em português

Comentado [AS5]: Esta frase tem a impressão de que falta uma conclusão. Precisa rever a redação.

CHO, Kyunghyun *et al.* Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. **Proceedings Of The 2014 Conference On Empirical Methods In Natural Language Processing (Emnlp)**, [S.L.], v. 1, p. 1-10, 2014. Association for Computational Linguistics. <http://dx.doi.org/10.3115/v1/d14-1179>. Disponível em: <https://aclanthology.org/D14-1179/>. Acesso em: 19 jun. 2023.

FERLA, Fabiola. L.; GRAVE, Magali; PERICO, Eduardo. Fisioterapia no tratamento do controle de tronco e equilíbrio de pacientes pós AVC. **Revista Neurociências**, [S.L.], v. 23, n. 2, p. 211-217, 30 jun. 2015.

HARRIS, Elsa J.; KHOO, I-Hung; DEMIRCAN, Emel. A Survey of Human Gait-Based Artificial Intelligence Applications. **Frontiers In Robotics And AI**, Long Beach, v. 8, p. 1-28, jan. 2022. Frontiers Media SA.

KIM, JH. *et al.* Effect of gait training with functional electrical stimulation on gait capacity in stroke survivors with chronic hemiplegia: a randomized controlled trial. **Annals of Rehabilitation Medicine**, v. 42, n. 4, p. 560-571, 2018.

LUO, Guoliang. *et al.* Random forest–based classification and analysis of hemiplegia gait using low-cost depth cameras. **Medical & Biological Engineering & Computing**, [S.L.], v. 58, n. 2, p. 373-382, 18 dez. 2019. Springer Science and Business Media LLC.

NATIONAL INSTITUTES OF HEALTH. **Stroke**: what is a stroke? National Institute Of Neurological Disorders And Stroke, Rockville. Disponível em: <https://www.ninds.nih.gov/health-information/disorders/stroke>. Acesso em: 07 maio 2023.

OLAH, Christopher. Understanding LSTM Networks. **Colah's Blog**, San Francisco, 27 ago. 2015. Disponível em: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>. Acesso em: 19 jun 2023.

OLIVEIRA, Edilaine C. *et al.* Cuidados pós-alta em pacientes idosos com sequelas de acidente vascular cerebral: planejamento de alta hospitalar. **Revista Saúde e Desenvolvimento**, [S.L.], v. 11, n. 9, p. 172-197, 2017.

ORGANIZAÇÃO MUNDIAL DE SAÚDE. **Global Health Estimates 2019**: Deaths by Cause, Age, Sex, by Country and by Region, 2000-2019. Disponível em: <https://www.who.int/data/gho/data/themes/mortality-and-global-health-estimates/gh-leading-causes-of-death>. Acesso em: 07 maio 2023.

SCHMIDT, Michelle Hillig. *et al.* **Acidente Vascular Cerebral e diferentes limitações**: uma análise interdisciplinar. Arquivos de Ciências da Saúde da Unipar, [S.L.], v. 23, n. 2, p. 1-2, 16 maio 2019. Universidade Paranaense.

SECRETARIA DE ATENÇÃO À SAÚDE. **Diretrizes de Atenção à Reabilitação de Pessoa com Acidente Vascular Cerebral**. Ministério da Saúde, Brasília - DF, p. 3-74, 18 nov. 2022. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/s/saude-da-pessoa-com-deficiencia/publicacoes/diretrizes-de-atencao-a-reabilitacao-da-pessoa-com-acidente-vascular-cerebral.pdf/view>. Acesso em: 07 maio 2023.

SLJEPCEVIC, Djordje *et al.* Explaining Machine Learning Models for Clinical Gait Analysis. **ACM Transactions On Computing For Healthcare**, New York, v. 3, n. 2, p. 1-27, 20 dec. 2021. Association for Computing Machinery (ACM).

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR AVALIADOR – PROJETO

Avaliador(a): **Andreza Sartori**

Atenção: quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

ASPECTOS AVALIADOS		Atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	2. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	3. TRABALHOS CORRELATOS São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?	X		
	4. JUSTIFICATIVA Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada?	X		
	São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	5. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO Os requisitos funcionais e não funcionais foram claramente descritos?	X		
	6. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?	X		
	7. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
ASPECTOS METODOLÓGICOS	As referências contemplam adequadamente os assuntos abordados (são indicadas obras atualizadas e as mais importantes da área)?	X		
	8. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		

O projeto de TCC será reprovado se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos **4 (quatro)** itens dos **ASPECTOS TÉCNICOS** tiverem resposta ATENDE PARCIALMENTE; ou
- pelo menos **4 (quatro)** itens dos **ASPECTOS METODOLÓGICOS** tiverem resposta ATENDE PARCIALMENTE.

PARECER: (X) APROVADO () REPROVADO

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2023/1

MODELO DE APRENDIZADO DE MÁQUINA PARA ANÁLISE CINEMÁTICA DA MARCHA EM PACIENTES HEMIPLÉGICOS APÓS AVC

Eduarda Engels

Prof. Aurélio Faustino Hoppe – Orientador

5 INTRODUÇÃO

Segundo dados oficiais do Ministério da Saúde e das organizações mundiais de saúde, como a Organização Mundial de Saúde (OMS) e a Organização Pan-Americana da Saúde (OPAS), o Brasil apresenta a quarta maior taxa de mortalidade por Acidente Vascular Cerebral (AVC) entre os países da América Latina e Caribe (MINISTÉRIO DA SAÚDE, 2022). Ainda de acordo com a Secretaria de Atenção à Saúde (2022), em 2020, o AVC representava a segunda maior causa de morte do país, ficando atrás apenas de doenças do aparelho circulatório, tendo 43,9 óbitos por 100 mil habitantes.

De acordo com a Organização Mundial de Saúde (2019), o AVC afeta um ou mais vasos sanguíneos por um processo patológico que pode ocorrer pela falta de sangue nas veias, gerando isquemia, ou rompimento dos vasos sanguíneos causando hemorragia. Schmidt *et al.* (2019) ressaltam que a maior parte dos sobreviventes de AVC permanecem com sequelas, podendo ser física, comunicativa, sensitivas, funcionais, entre outras.

Segundo Luo *et al.* (2019), a sequência física mais comum ocasionada pelo AVC é a hemiplegia que é uma condição neurológica que se caracteriza pela paralisia de um dos lados do corpo, afetando significativamente a cinemática da marcha, como a simetria entre as pernas e a coordenação dos movimentos. Ainda segundo os autores, a análise cinemática da marcha em pacientes hemiplégicos fornece informações importantes sobre as alterações no padrão de marcha, como a redução no comprimento do passo, menor flexão do quadril e diminuição do tempo de apoio do membro afetado.

De acordo com o Secretaria de Atenção à Saúde (2022), o tratamento da hemiplegia geralmente envolve uma abordagem multidisciplinar, que inclui fisioterapia, terapia ocupacional e fonoaudiologia. O objetivo da terapia é maximizar a independência funcional do paciente, minimizando as limitações impostas pela paralisia. Uma das estratégias utilizadas na terapia é o treinamento oromotor precoce (desenvolvimento adequado da fala e da alimentação), que tem como objetivo normalizar as funções respiratória, de deglutição e de mastigação. Já as intervenções de reabilitação incluem exercícios específicos para melhorar a cinemática da marcha, com treinamento de passadas em esteira com suporte de peso corporal e terapia manual para aumentar o desempenho do movimento articular (MINISTÉRIO DA SAÚDE, 2022).

De acordo com Harris, Khoo e Demircan (2022), além da análise cinemática, existem diversas ferramentas de análise da hemiplegia que necessitam de equipamentos específicos e métodos de análise sofisticados, como sistemas de captura de movimento, plataformas de força e análise de imagem. Tais equipamentos exigem um alto investimento financeiro e podem não estar disponíveis em todos os centros de reabilitação, limitando o acesso e a avaliação da efetividade das intervenções terapêuticas. Nesse contexto, a utilização de técnicas de aprendizado de máquina apresenta-se como uma ferramenta promissora para o desenvolvimento de modelos preditivos que possam auxiliar na tomada de decisão clínica, possibilitando a identificação precoce de possíveis alterações na cinemática da marcha e o ajuste adequado do tratamento de acordo com as necessidades de cada paciente.

Diante deste cenário, surge a seguinte pergunta de pesquisa: "Como o uso de técnicas de aprendizado de máquina pode auxiliar na análise cinemática da marcha em pacientes hemiplégicos após um AVC?". Para isso, este trabalho será desenvolvido em parceria com o CER II FURB que é o Centro Especializado em Reabilitação II da Universidade Regional de Blumenau (FURB), localizado em Blumenau, Santa Catarina, Brasil. Trata-se de uma unidade especializada na prestação de serviços de reabilitação para pessoas com deficiências. Contando com uma equipe multidisciplinar composta por médicos, fisioterapeutas, terapeutas ocupacionais, fonoaudiólogos, psicólogos, assistentes sociais e outros profissionais, o centro fornece avaliação, diagnóstico, tratamento e acompanhamento individualizado, adaptados às necessidades de cada paciente. Os serviços incluem fisioterapia, terapia ocupacional, fonoaudiologia, entre outros, com o objetivo de promover a reabilitação e melhorar a qualidade de vida dos pacientes atendidos.

5.1 OBJETIVOS

O objetivo deste trabalho é criar um modelo de aprendizado de máquina de análise cinemática capaz de identificar anomalias na marcha em pacientes hemiplégicos pós AVC.

Os objetivos específicos são:

- i) Identificar padrões complexos nas séries temporais de cinemática da marcha a partir de imagens;
- j) Classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- k) Avaliar a eficácia do modelo em relação à avaliação tradicional da cinemática da marcha;
- l) Identificar possíveis limitações e desafios na utilização de técnicas de aprendizado de máquina no contexto de análise cinemática.

6 TRABALHOS CORRELATOS

Nesta seção serão apresentados trabalhos que possuem características semelhantes aos principais objetivos do estudo proposto. Na subseção 2.1 é detalhado o trabalho de Benjinariu *et al.* (2021), ao qual desenvolveram uma aplicação para estimar o ângulo de flexão do joelho a fim de detectar anomalias na marcha humana por meio de redes neurais artificiais. A subseção 2.2 descreve o trabalho de Luo *et al.* (2019), que busca medir o nível de marcha de pacientes com hemiplegia por meio de árvore de decisão. Por fim, a subseção 2.3 apresenta o trabalho de Slijepcevic *et al.* (2021), que utilizam o método *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a compreensão dos resultados dos classificadores de aprendizado de máquina em relação a análise automatizada da marcha.


6.1 IMAGE PROCESSING FOR THE REHABILITATION ASSESSMENT OF LOCOMOTION INJURIES AND POST STROKE DISABILITIES

Benjinariu *et al.* (2021) utilizam a análise de movimento para auxiliar na reabilitação locomotora, com foco em tratamento de Acidente Vascular Cerebral (AVC), nos membros inferiores do corpo. Os autores aplicaram métodos de aprendizado de máquina para extração e análise da marcha. Os atribuídos utilizados foram inerciais (acelerações), posturais (ângulos formados por segmento do corpo humano) ou espaço-temporal (comprimento da passada, frequência e variabilidade da passada)

Benjinariu *et al.* (2021) utilizaram como base de dados vídeos adquiridos de pacientes que estão se recuperando de fraturas nos membros inferiores, aos quais foram filmados em um plano frontal e sagital com uma taxa média de 30 segundos. Os autores extraíram os ângulos e a velocidade de diferentes articulações em diferentes ações como caminhar, trotar e correr. Para a classificação, utilizam o classificador *Random Forest* (RF) implementado na linguagem de programação C++.

De acordo com Benjinariu *et al.* (2021), a *Human Pose Estimation* (HPE) consiste em determinar a posição do corpo humano utilizando imagens, tarefa desafiadora, que pode ser abordada por meio de diversos métodos, que vão desde o uso de sensores até marcadores. Os modelos baseados em *Convolutional Neural Network* (CNN) utilizam esqueletos, contornos e volumes para modelar o corpo humano. No processo de detecção, um conjunto de pontos anatômicos-chave é calculado para cada indivíduo na imagem, utilizando-se o OpenPose, que processa o vídeo quadro a quadro, resultando em uma lista de pontos-chave especificados por coordenadas 2D. Segundo os autores, isso permite identificar partes esquerda e direita do corpo, bem como se ele está sendo visto de frente ou de costas. A Figura 1 exemplifica o processo de redução do número de pontos e a posição correta das pernas por meio dos pontos-chave.

Figura 11 – Pontos-Chaves usando o OpenPose




Fonte: Benjinariu *et al.* (2021).

Segundo Benjinariu *et al.* (2021), as posições dos pontos-chave definem a condição patológica da pessoa, ao qual, realiza-se a análise a partir dos ângulos dos segmentos das pernas. Os autores também destacam que o ângulo do quadril entre Espinha Iliaca AnteroSuperior (ELAS) e a linha média da coxa deve ser de 90°, assim como, a linha média da coxa e do tornozelo também precisam estar alinhados com o joelho na posição ortostática (quando estiver em pé). Outra constatação é que, durante o caminhar, os ângulos do joelho diminuem, e, se chegarem a 10° de variação, para dentro ou fora, há indícios de um caso patológico.

De acordo com Benjinariu *et al.* (2021), nem todos os quadros foram considerados durante a implementação do OpenPose, pois nem sempre os pontos podiam ser identificados ou a silhueta do paciente era visível. Analisando os ângulos obtidos, o valor máximo do ângulo no joelho direito é de 192° e no esquerdo é de 194°, indicando uma situação patológica pois o joelho se move para fora enquanto caminha. O valor médio dos

ângulos está dentro do limite de 10° na variação interna. Os valores de ângulos na linha EIAS trouxeram valores altos como 30° por conta do posicionamento dos pontos na detecção automática. No entanto, a variação do ângulo EIAS nas imagens dos pacientes é grande. A Figura 2 apresenta a evolução dos ângulos dos *frames* 425 a 453, no qual são inferiores a 180°, apontando que ambos os joelhos estão para fora.

Figura 12 – Variação angular dos joelhos nos quadros 425-453



Fonte: Benjinariu *et al.* (2021).

Benjinariu *et al.* (2021) afirmam que a pesquisa ainda está em andamento e os resultados obtidos para avaliação de reabilitação da locomoção são promissores. Para as próximas atualizações, pretendem aumentar o número de sequências de vídeos utilizados e incluir gravações com pacientes reabilitados ou saudáveis para comparação de avaliação automática. Também querem rever a detecção de pontos-chave aplicando outros métodos de HPE.


6.2 RANDOM FOREST-BASED CLASSIFICATION AND ANALYSIS OF HEMIPLEGIA GAIT USING LOW-COST DEPTH CAMERAS

Luo *et al.* (2019) utilizaram o sensor Microsoft Kinect para capturar a marcha no espaço-tempo e a cinemática articular a partir de configurações simples a fim de investigar o potencial da ferramenta em realizar análise da marcha hemiplegia. Os autores coletaram os dados no Departamento de Medicina de Reabilitação do Hospital Popular de Jiangxi.

Segundo Luo *et al.* (2019), foram recrutados 60 indivíduos, sendo 40 saudáveis e 20 pacientes com hemiplegia, que tiveram que realizar o movimento padrão de andar em linha reta 4 metros em frente ao sensor Kinect, repetindo este processo 9 vezes. Os dados extraídos para compor as características espaço-tempo foram a velocidade e o comprimento da passada

Luo *et al.* (2019) calcularam o ponto médio das juntas em relação as coordenadas do planar direito e esquerdo. A partir disso, segundo os autores, torna-se possível calcular a distância euclidiana entre os dois para estimar o comprimento inicial. Na Figura 3 item (A) pode-se observar a detecção do participante em tempo real, no item (B) o esqueleto com as juntas enumeradas, no item (C), a marcha extraída durante a caminhada e, por fim, no item (D) a extração de esquerda e direita com movimentos para cima e para baixo do centro de massa.

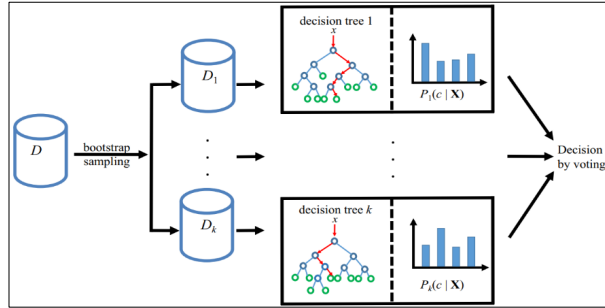
Figura 13 – Dados da marcha extraídos com MS Kinect



Fonte: Luo *et al.* (2019).

Segundo Luo *et al.* (2019), a característica chave para realizar a análise cinemática é o centro da massa do indivíduo. Para isso, eles utilizaram um método de segmentação corporal que corta o corpo humano em pequenos segmentos. Posteriormente, na linguagem de programação Python, aplicou-se o *Random Forest* (RF) para realizar a classificação das combinações. Ainda segundo os autores, a partir de um conjunto de dados de treinamento aleatório, utiliza-se o Índice de Gini para definir as características ótimas para efetuar a divisão dos participantes. A Figura 4 exemplifica a aplicação de múltiplas árvores de decisão, no qual D denota o conjunto de dados de entrada.


Figura 14 – Método de classificação *Random Forest*



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) utilizaram um número maior de amostras de pessoas saudáveis, tendo em vista sua proporção em relação a população de indivíduos sem hemiplegia. Para estabelecer o melhor método de classificação, os autores utilizaram a curva *Receiver Operator Characteristic* (ROC), no qual cada ponto corresponde a um par de *False-Positive Rate* (FPR) ou *True-Positive Rate* (TPR). Portanto, a curva de ROC deveria ter o TPR mais alto e o FPR mais baixo, ou seja, quanto mais próximo do canto superior esquerdo a curva estiver, melhor será a classificação, conforme ilustra a Figura 5.

Figura 15 – ROC comparando os métodos de classificação



Fonte: Luo *et al.* (2019).

Luo *et al.* (2019) comparam os resultados da classificação do RF em relação às redes *Bayesianas* e a *Support Vector Machine* (SVM). Dentre eles, o RF obteve, em média, 90% de precisão entre todas as combinações de características, pois as árvores de decisão são independentes entre si. Os autores também afirmam que pretendem utilizar mais o MS Kinect para capturar as características das passadas e o ângulo do pé para análise da marcha.

6.3 EXPLAINING MACHINE LEARNING MODELS FOR CLINICAL GAIT ANALYSIS


Segundo Slijepcevic *et al.* (2021), a Análise Clínica da Marcha (ACM) se concentra em analisar e descrever quantitativamente aspectos cinemáticos (ângulos articulares), cinéticos (forças de reação do solo e momentos articulares) e musculares (eletromiografia). Neste contexto, os autores exploraram métodos de *Explainable Artificial Intelligence* (XAI) para identificar como os modelos de ML produzem suas previsões por meio do *Layer-wise Relevance Propagation* (LRP), tendo como objetivo aumentar a transparência na classificação método automatizada clínica da marcha baseada em séries temporais.

Slijepcevic *et al.* (2021) optaram pelos classificadores *Support Vector Machine* (SVM), *Multilayer Perceptron* (MLP) e *Convolutional Neural Network* (CNN) como abordagens de ML para comparar a precisão e os padrões de relevância das entradas. O SVM foi treinado utilizando o método de otimização quadrática. Para a MLP, utilizou-se três camadas não lineares e conectadas com a função SoftMax na camada de saída. Já no modelo CNN, aplicou-se três camadas *convolucionais* consecutivas, sendo mapeado por um vetor com mais de 2 mil dimensões. Segundo os autores, os modelos MLP e CNN foram treinados usando o gradiente descendente estocástico e a média absoluta com os pesos sendo iniciados aleatoriamente.

Slijepcevic *et al.* (2021) estruturaram os treinos dos modelos de classificação de acordo com as etapas presentes no fluxo de classificação da Figura 6. Inicialmente, obtém-se os dados de entrada através do *Ground Reaction Forces* (GRFs) de ambas as pernas. No item (B), realiza-se a classificação com base nas forças tridimensionais de GRFs. Posteriormente, no item (C), utiliza-se as pontuações relevantes referentes ao espectro

do sinal de entrada através da LRP. Por fim, nos itens (D) e (E) busca-se explicar os resultados de forma estatística ou na perspectiva clínica.


Figura 16 – Fluxo de classificação automatizada de marcha



Fonte: Slijepcevic *et al.* (2021).

Slijepcevic *et al.* (2021) utilizaram dados de 132 pacientes com distúrbios da marcha e de 62 saudáveis, de ambos os gêneros e com diferentes características físicas, para medir as GRFs. Segundo os autores, o conjunto de dados incluiu três classes de distúrbios ortopédicos da marcha associados ao quadril, joelho e tornozelo. Para capturar as GRFs tridimensionais, foram utilizados quatro componentes: força horizontal, força médio-lateral, força anteroposterior horizontal e força vertical, gerando um vetor de entrada com 1x606 dimensões para cada tentativa de marcha. Slijepcevic *et al.* (2021), também utilizaram o cálculo de linha *Zero-Rule Baseline* (ZRB) que se refere a precisão teórica obtida pela atribuição de rótulos de classe de acordo com a probabilidade de classes anteriores. Os resultados indicaram uma diferença mínima entre os classificadores. Na Figura 7 apresenta a acurácia obtida pelos modelos CNN, SVM e MLP. Segundo os autores, a precisão de classificação média mostrou-se superior ao ZRB em todos os casos. Em relação a normalização, Slijepcevic *et al.* (2021) verificaram a análise de variância, relatando que a diferença encontrada entre as tarefas não foi relevante, sendo que a precisão média de classificação foi acima de 80%.

Figura 17 – Accuracy dos modelos ML



Fonte: Slijepcevic *et al.* (2021).

De acordo com Slijepcevic *et al.* (2021), o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões. Além disso, segundo os autores, a utilização dele é apenas indicada se o método de classificação alcançar conclusões significativas, pois ao analisar um modelo não confiável, pode resultar em ruídos e padrões instáveis. Além disso, Slijepcevic *et al.* (2021) também observaram que a normalização dos dados de entrada acaba sendo um fator importante para o ML, pois caso os intervalos entre os valores forem divergentes afeta negativamente a previsão. Por fim, os autores ressaltam que os métodos de XAI, para explicar as previsões de modelos ML, são promissores e podem ajudar na justificativa das classificações automáticas de CGA.

7 PROPOSTA DE MODELO

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo propor um modelo de aprendizado de máquina para análise cinemática da marcha em pacientes com AVC. A metodologia adotada para o desenvolvimento do modelo será detalhada, bem como os requisitos necessários para a sua implementação.

7.1 JUSTIFICATIVA

No Quadro 1 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas são cada trabalho e as linhas as características, com elas podemos entender como será solucionado os problemas propostos por este trabalho.

Quadro 3 – Comparativo dos trabalhos correlatos

Trabalhos Correlatos	Benjinariu <i>et al.</i> (2021)	Luo <i>et al.</i> (2019)	Sljipecevic <i>et al.</i> (2021)
Características			
Patologia de identificação	Acidente Vascular Cerebral (AVC)	Hemiplegia	Acidente Vascular Cerebral (AVC)
Objetivo	Identificar anormalidades na marcha humana	Identificar anormalidades na marcha humana	Esclarecer as previsões de modelos de classificação
Membros analisados para avaliação	Inferiores	Inferiores	Inferiores
Técnica de análise utilizada	RF e CNN	RF, SVM e Bayesianas	CNN, SVM, MLP e LRP
Técnica de identificação do corpo humano	HPE	Pontos do esqueleto	LRP
Número de pacientes avaliados	Não mencionado	60	194
Taxa de acerto	Não mencionado	>90%	>80%
Dispositivo para captura de dados	Smartphone (video)	MS Kinect	Plataformas de força (GRFs)
Linguagem de programação	C++	Não mencionado	Python

Fonte: elaborado pela autora.

A partir do Quadro 1 pode-se observar que todos os autores utilizam modelos de avaliação dos membros inferiores para a identificação de anomalias da marcha. Destaca-se o trabalho de Sljipecevic *et al.* (2021) ao qual realizaram uma comparação entre os modelos de classificação de marcha (SVM, MLP e CNN). Além disso, também utilizaram inteligência artificial explicável (método *Layer-wise Relevance Propagation*) para poder justificar os resultados das previsões e aprimorar a classificação clínica automatizada da marcha humana em pacientes com AVC. Nos testes, os autores utilizaram dados de GRFs de 194 pacientes. Por fim, Sljipecevic *et al.* (2021) concluem que método o LRP consegue determinar onde a previsão está fundamentada, porém não explica o motivo para esses padrões.

Benjinariu *et al.* (2021) utilizaram redes neurais para estimar o ângulo de flexão do joelho, assim como detectar anomalias na marcha humana de pacientes que sofreram AVC. Para isso, os autores utilizaram a biblioteca do OpenPose, implementado em C++, que permite detectar a parte esquerda e direita do corpo, assim como a direção, se o corpo está sendo visto de frente ou de trás. A captura dos dados foi realizada através de um smartphone e os resultados foram apresentados na forma de um gráfico que demonstra a variação angular dos joelhos que são extraídos a partir da posição de pontos-chave para indicar a condição patológica da pessoa. Por fim, os autores apontam que, apesar da pesquisa estar em andamento, os resultados são promissores e que, ao longo do tempo, serão utilizados mais vídeos para aperfeiçoar o modelo.

Luo *et al.* (2019) tinham como intuito identificar anomalias, assim como estabelecer o nível de marcha em pacientes com hemiplegia por meio de uma árvore de decisão e um conjunto de entrada aleatório. Os autores utilizaram o sensor de profundidade Microsoft Kinect (MS Kinect) para detectar o movimento em tempo real. A partir disso, construíram uma base de dados com as características de 60 indivíduos. Posteriormente, Luo *et al.* (2019) aplicaram um método de segmentação corporal para subdividir o corpo humano em pequenos segmentos, aos quais foram utilizados como entrada pelos algoritmos *Random Forest* (RF), redes *Bayesianas* e a *Support Vector Machine* (SVM). Segundo os autores, a RF apresentou a melhor precisão, cerca de 90%.

Com base no cenário descrito acima, pode-se observar que os trabalhos utilizam diferentes métodos de análise para identificar anomalias na marcha humana. Contudo, percebe-se a necessidade do desenvolvimento de um modelo mais adequado para analisar as informações cinemáticas dos pacientes, considerando as limitações de equipamento de captura e da quantidade e especificidade da população estudada. Diante disso, o diferencial do trabalho proposto encontra-se justamente no desenvolvimento de um modelo de aprendizado de máquina específico para a análise cinemática da marcha em pacientes hemiplégicos após AVC, sendo que, para o desenvolvimento deste trabalho será utilizado dados, assim como, o suporte dos profissionais do Centro Especializado de Reabilitação da FURB.

Acredita-se que o uso do modelo de aprendizado de máquina possa proporcionar uma análise mais objetiva e contínua do progresso do paciente, trazendo uma contribuição significativa para a área da reabilitação, auxiliando na elaboração de terapias mais eficientes e personalizadas para os pacientes, além de poder ser aplicado em outras pessoas com problemas de locomoção. Contudo, espera-se facilitar o trabalho do profissional de saúde, possibilitando ajustes mais precisos e individualizados nas intervenções de reabilitação assim como, melhorando efetividade dos tratamentos atualmente oferecidos.

7.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O trabalho proposto deverá contemplar os seguintes Requisitos Funcionais (RF) e Requisitos Não Funcionais (RNF):

- m) Permitir o cadastro de pacientes (RF);
- n) Permitir ao usuário capturar ou importar vídeos dos membros inferiores do corpo (RF);
- o) Realizar o realce e melhoramento de ruídos, distorções e problemas de iluminação utilizando técnicas de processamento de imagens (RF);
- p) Efetuar a análise cinemática a partir dos membros inferiores utilizando redes neurais convolucionais e/ou recorrentes (RF);
- q) Estabelecer o nível de funcionalidade do paciente a partir do movimento corporal (RF);
- r) Manter o usuário informado sobre a situação do processamento das imagens/vídeos (RF);
- s) Aprimorar o modelo a partir de novos vídeos cadastros pelos usuários (RNF);
- t) Utilizar as bibliotecas OpenCV para o processamento de imagens e o Keras ou Tensorflow para a construção da rede neural artificial (RNF).

7.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- j) Levantamento bibliográfico: estudar os assuntos relacionados à acidente vascular cerebral, análise cinemática, aprendizado de máquina e trabalhos correlatos;
- k) Acompanhamento clínico: acompanhar atendimentos realizados no Centro de Reabilitação da Furb II, com pacientes que sofreram AVC, para entendimento do problema e constatação de necessidades;
- l) Submissão ao conselho de ética: escrita e cadastro do trabalho na plataforma Brasil e submissão para o conselho de ética da FURB. Ressaltando que em cada experimento será solicitado aos pacientes a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- m) Coleta de dados: coleta de dados de cinemática da marcha em pacientes hemiplégicos após AVC, realizando a gravação de vídeos;
- n) Definição de algoritmos para extrair a cinemática da marcha: pesquisar métodos de processamento de imagens para extrair/estabelecer medidas a partir de imagens/vídeos;
- o) Definição de algoritmos para classificação das fases da marcha: pesquisar as técnicas de aprendizado de máquina (convolucionais ou recorrentes) para classificar automaticamente as fases da marcha em pacientes hemiplégicos e correlacioná-las com o nível de funcionalidade do paciente;
- p) Análise temporal: realização de análises temporais para avaliar a variação temporal dos parâmetros de cinemática da marcha e identificar mudanças ao longo do tempo;
- q) Desenvolvimento do modelo: a partir dos itens (g), (h) e (i), realizar a implementação da análise cinemática utilizando a biblioteca OpenCV, a linguagem de programação Python e as bibliotecas Keras e Tensorflow;
- r) Testes do modelo: paralelamente à implementação, realizar testes com base nos vídeos obtidos para verificar a eficiência e assertividade do modelo elaborado utilizando a validação cruzada assim como a comprovação dos resultados a partir de um grupo de pacientes hemiplégicos após AVC em conjunto com profissionais da saúde.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 4 – Cronograma de atividades a serem realizadas

etapas / quinzenas	2023									
	jul.		ago.		set.		out.		nov.	
	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico										
acompanhamento clínico										
submissão ao conselho de ética										
coleta de dados										
definição de algoritmos para extrair a cinemática da marcha										
definição de algoritmos para classificação das fases da marcha										
análise temporal										
desenvolvimento do modelo										
testes do modelo										

Fonte: elaborado pela autora.

8 REVISÃO BIBLIOGRÁFICA


Nesta seção serão apresentados os principais conceitos que fundamentam o estudo proposto. A subseção 4.1 aborda Acidente Vascular Cerebral (AVC), considerando suas características e consequências. Na subseção 4.2 apresenta a análise cinemática da marcha, que consiste na técnica de avaliação da locomoção humana. Por fim, na subseção 4.3 conceitua-se o aprendizado de máquina e suas principais técnicas.

8.1 ACIDENTE VASCULAR CEREBRAL

O Acidente Vascular Cerebral (AVC) é mais comum na fase adulta, sendo um dos sinais mais frequentes a ocorrência súbita de fraqueza ou dormência na face, braço e perna, afetando um lado do corpo (SECRETARIA DE ATENÇÃO À SAÚDE, 2022). Para o National Institutes of Health (2023), o AVC ocorre quando o fluxo sanguíneo de uma área do cérebro é interrompido, podendo ser causado por um coágulo sanguíneo (AVC isquêmico) ou por um vaso sanguíneo rompido (AVC hemorrágico). Essa condição pode levar a danos cerebrais permanentes ou até mesmo em óbito caso não seja tratado imediatamente.

Ferla, Grave e Perico (2015) destacam que a causa mais comum do AVC está relacionada a doenças cardiovasculares que afetam a circulação cerebral. As artérias média, posterior e anterior são frequentemente afetadas, assim como seus ramos menores que penetram nas regiões mais profundas do cérebro. O diagnóstico é feito com base nos sintomas apresentados pelo paciente e em exames de imagem, como tomografias computadorizadas ou ressonância magnética cerebral (SECRETARIA DE ATENÇÃO À SAÚDE, 2022). A Figura 8 exemplifica o AVC hemorrágico no lado esquerdo e o AVC Isquêmico no lado direito, através de uma tomografia craniana.

Figura 18 – Tomografia do crânio com variações do AVC



Fonte: Aguiar (2018).

Oliveira *et al.* (2017) afirmam que o AVC resulta em sequelas físicas, funcionais e comunicativas, gerando incapacidade e dependência nos indivíduos afetados. Essas sequelas podem incluir perda de força, sensibilidade e capacidade de movimentação em diferentes partes do corpo, além de distúrbios de linguagem, depressão, distúrbios visuais, perda de equilíbrio e coordenação. Segundo os autores, o AVC causa danos neurológicos que impactam diversas áreas da vida dos pacientes, como a mobilidade, a comunicação e a independência funcional.

Além disso, Azolin (2016) destaca que a hemiplegia e a hemiparesia são características comuns após a sobrevivência a um AVC. Essas condições envolvem a perda completa ou parcial do controle motor de um lado do corpo, respectivamente. Essa perda de controle motor resulta em dificuldades para manter uma postura assimétrica e uma distribuição adequada de peso no hemicorpo afetado. A assimetria e a dificuldade em manter o controle postural comprometem a orientação e a estabilidade do paciente, tornando desafiador realizar movimentos e sustentar o equilíbrio corporal.

Segundo Aguiar (2018), o AVC é uma das principais causas de morbidade e mortalidade em todo o mundo. O autor ressalta que a prevenção e o tratamento adequados são fundamentais para reduzir o impacto do AVC na saúde pública. A identificação e o controle dos fatores de risco, como hipertensão arterial, diabetes, tabagismo, sedentarismo e obesidade, desempenham um papel crucial na implementação de medidas preventivas. Além disso, o autor destaca a importância de uma abordagem multidisciplinar no tratamento do AVC, envolvendo equipes médicas especializadas, fisioterapeutas, fonoaudiólogos e profissionais de reabilitação. Essa abordagem visa à recuperação funcional e à melhoria da qualidade de vida dos pacientes afetados pelo AVC.

De acordo com Oliveira *et al.* (2017), a reabilitação desempenha um papel crucial na minimização das sequelas, na melhoria da capacidade funcional e na promoção da reintegração social. Diversos métodos e técnicas de reabilitação, como fisioterapia, terapia ocupacional, fonoaudiologia e psicologia, são destacados como essenciais para auxiliar na recuperação dos pacientes após um AVC.

Segundo a Secretaria de Atenção à Saúde (2022), o AVC é mais comum na fase adulta e o paciente apresenta diversas limitações em consequência do evento e a recuperação é diferente em cada caso. Além disso, o atendimento médico imediato, aliado à uma reabilitação adequada, pode minimizar as incapacidades, evitar sequelas mais severas e proporcionar ao indivíduo o retorno mais breve possível às suas atividades cotidianas.


8.2 CINEMÁTICA DA MARCHA

Segundo Kim *et al.* (2018), identificar anormalidades na marcha é fundamental para o diagnóstico e tratamento de doenças e lesões que afetam o caminhar de uma pessoa, como o Acidente Vascular Cerebral (AVC), lesões medulares, doenças neuromusculares e ortopédicas. Além disso, os autores também afirmam que ao utilizar a análise cinemática da marcha para avaliar os efeitos de um programa de treinamento em pacientes com hemiplegia pode-se reduzir e alcançar resultados melhores na simetria da marcha em menos tempo.

De acordo com Caparelli (2017), a análise da marcha permite auxiliar o tratamento dos indivíduos e melhorar a compreensão do processo de marcha através de pesquisa. O autor destaca a importância de compreender as características espaço-temporais da marcha, como o comprimento da passada, a duração da passada e a velocidade. Esses parâmetros fornecem informações valiosas sobre a eficiência e o padrão de movimento durante a caminhada.

Caparelli (2017) afirma que a marcha é um meio natural de locomoção do corpo, envolvendo o uso alternado das duas pernas para proporcionar suporte e propulsão. O comprimento da passada refere-se à distância entre o contato inicial do calcanhar de um membro no solo e o próximo contato deste mesmo no chão, enquanto o passo é a distância longitudinal entre o contato no solo do calcanhar de um membro e o calcanhar contralateral. A frequência dos passos é conhecida como cadência. A Figura 9 apresenta a diferença entre a passada e o passo.


Figura 19 – Definição de passo e passada



Fonte: Caparelli (2017).

Segundo Caparelli (2017), a partida da marcha normalmente ocorre quando o indivíduo que deseja levantar o pé direito, iniciando o apoio neste mesmo lado e, em seguida, transferindo o peso para o pé esquerdo, permitindo que o pé direito se descole do solo. A eficiência desses movimentos depende da mobilidade articular livre e da atividade muscular adequada. Durante a marcha, o quadril desempenha um papel crucial, com uma amplitude de movimento típica de 10° de extensão e 30° de flexão na articulação. Clinicamente, a posição zero é definida como o tronco e a coxa em postura ereta. O joelho desempenha diversas funções durante a marcha, como sustentar o peso corporal, amortecer o impacto, aumentar o comprimento da passada e permitir o movimento do pé durante a fase de balanço. Na Figura 10 mostra o caminhar com as fases da marcha.

Figura 20 - Fases da Marcha Humana



Fonte: Caparelli (2017).

Caparelli (2017) enfatiza a importância da análise da marcha como uma ferramenta essencial no auxílio ao tratamento de indivíduos e no avanço do conhecimento por meio de pesquisas. O autor destaca que as redes neurais artificiais têm se mostrado uma abordagem de modelagem superior para aplicações relacionadas à marcha, como a predição e o ajuste de dados. Essa técnica oferece oportunidades promissoras para melhorar a precisão e a eficiência dos estudos biomecânicos da marcha.

A Secretaria de Atenção à Saúde (2022) afirma que a utilização de equipamentos de alta tecnologia, como câmeras de captura de movimento e sensores, tem se mostrado fundamental para avaliar diversos parâmetros da marcha, como comprimento do passo, contato com o solo e distribuição do peso. Essas ferramentas auxiliam na identificação de possíveis anormalidades e contribuem para o diagnóstico e tratamento de doenças e lesões que afetam a marcha. Caparelli (2017) também ressalta o papel crucial das tecnologias avançadas na análise da marcha, como as câmeras de captura de movimento e os sensores. Esses dispositivos permitem uma avaliação mais precisa e objetiva de diversos parâmetros da marcha, incluindo a cinemática articular, a distribuição de forças e a cinética do movimento. Essas informações são fundamentais para compreender as alterações biomecânicas decorrentes de patologias ou lesões, auxiliando no diagnóstico e no planejamento do tratamento.

8.3 APRENDIZADO DE MÁQUINA

De acordo com Alpaydin (2012), *Machine Learning* (ML) é um ramo da inteligência artificial que utiliza técnicas computacionais para permitir que um sistema aprenda e melhore com a experiência. Segundo o autor, ML

é uma abordagem de modelagem de dados que automatiza a construção de modelos analíticos. Entre suas principais características, destacam-se (i) o aprendizado automático, que aprendem a partir dos dados e se ajusta para melhoria de desempenho, (ii) a generalização, ou seja, fazer previsões e classificações em novos dados que não foram utilizados no treinamento, e (iii) a adaptabilidade, os modelos podem se adaptar as situações melhorando sua resposta com o tempo.

Alpaydin (2012) ainda destaca que o uso de cada arquitetura ou algoritmo de ML depende do tipo do problema a ser resolvido e as características dos dados existentes. Dentre as principais técnicas, encontram a Árvore de Decisão, o *Support Vector Machine* (SVM) e os algoritmos de clusterização. A árvore de decisão utiliza um modelo de estrutura hierárquica para tomar decisões com bases nos dados, dividindo em subconjuntos menores e regras para a classificação dos dados. O SVM, separa as classes dos dados em um hiperplano. Já os algoritmos de agrupamento, utilizam características semelhantes para dividir um conjunto de dados em *clusters* (ALPAYDIN, 2012).

Segundo Alpaydin (2012), dentre os algoritmos de ML, destacam-se as redes neurais artificiais, inspirada no cérebro humano, que consistem em redes interconectadas que aprendem a partir dos dados. Já a *Convolutional Neural Network* (CNN) é capaz de extrair características relevantes das imagens, como bordas e texturas para a classificação ou reconhecimento de objetos. Por outro lado, as redes neurais recorrentes são usadas para técnicas de processamentos de sequência de dados, possuindo conexões que permitem que as informações sejam propagadas de uma etapa da sequência para a próxima, permitindo a captura de informações contextuais e para realizar previsões.

De acordo com Olah (2015), as redes *Long Short-Term Memory* (LSTM) foram desenvolvidas para superar as limitações das *Recurrent Neural Network* (RNN) tradicionais, que apresentam dificuldades em capturar dependências de longo prazo em sequências de dados. O autor introduz a ideia de células de memória como a unidade fundamental da LSTM. Essas células possuem uma estrutura de *loop* interno que permite o armazenamento e a recuperação de informações ao longo do tempo, evitando a perda de gradiente.

Olah (2015) destaca que os principais elementos de uma célula LSTM são os portões de entrada, esquecimento e saída. Esses portões são utilizados para controlar o fluxo de informações dentro da célula e determinar quais informações devem ser retidas, esquecidas ou produzidas como saída. Com o uso desses mecanismos, a LSTM é capaz de capturar dependências de longo prazo em sequências de dados. Uma das vantagens deste modelo é sua habilidade de manter gradientes mais estáveis ao longo do tempo, o que permite o treinamento eficiente de redes neurais profundas em sequências de dados complexas.

Assim como o LSTM, o *Gated Recurrent Unit* (GRU) utiliza portões para controlar o fluxo de informações dentro da rede. O GRU é composto por dois principais portões, um portão de redefinição (*reset gate*) e um portão de atualização (*update gate*). Os portões ajudam a controlar o fluxo de informações dentro da rede e permitem que o GRU capture dependências de longo prazo. O portão de redefinição decide quais informações antigas devem ser descartadas, enquanto o portão de atualização decide quais novas informações devem ser mantidas. Os portões são compostos por funções de ativação, como a função sigmoide, que variam de 0 a 1 e determinam a importância das informações.

Segundo Cho (2014), a principal característica do GRU é que ela possui um mecanismo de atualização adaptativo, onde o portão de atualização controla quanto das informações antigas deve ser misturado com as novas informações. Isso permite que o GRU se adapte dinamicamente às características da sequência de entrada e ajuste a importância das informações antigas e novas. Recomendado para aplicações que envolvem sequências de dados por possuir capacidade de capturar dependências de longo prazo e evitar o desvanecimento do gradiente.

REFERÊNCIAS

AGUIAR, Paulo V. *et al.* **Application of the NetLogo Tool in Ischemic Stroke Simulation**. In: ENCONTRO NACIONAL DE INTELIGÊNCIA ARTIFICIAL E COMPUTACIONAL (ENIAC), 15, 2018, São Paulo. Anais [...]. Porto Alegre: Sociedade Brasileira de Computação, 2018, p. 596-607.

ALPAYDIN, Ethem. **Introduction to Machine Learning**. Cambridge: Cambridge University Press (CUP), 2012.

AZOLIN, Valéria P. **Avaliação do controle postural e sua relação com o hemisfério acometido no acidente vascular cerebral**. 2016. 59 f. Monografia (Especialização) – Especialização em Reabilitação Físico-Motora, Universidade Federal de Santa Maria, Rio Grande do Sul.

BENJINARIU, Silviu-Ioan *et al.* **Image Processing for the Rehabilitation Assessment of Locomotion Injuries and Post Stroke Disabilities**. 2021 International Conference On E-Health And Bioengineering (Ehb), Iasi, Romania, p. 2-5, 2021.

CAPARELLI, Thiago Bruno *et al.* **Reconstrução de Parâmetros Biomecânicos da Marcha por meio de Ciclogramas e Redes Neurais Artificiais**. 2017. Tese de doutorado na área de concentração Processamento da Informação, Universidade Federal de Uberlândia, Uberlândia. Disponível em: <https://repositorio.ufu.br/bitstream/123456789/20879/3/Reconstru%C3%A7%C3%A3oPar%C3%A2metrosBiomec%C3%A2nicos.pdf>. Acesso em: 11 jun. 2023.

CHO, Kyunghyun *et al.* Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation. **Proceedings Of The 2014 Conference On Empirical Methods In Natural Language Processing (Emnlp)**, [S.L.], v. 1, p. 1-10, 2014. Association for Computational Linguistics. <http://dx.doi.org/10.3115/v1/d14-1179>. Disponível em: <https://aclanthology.org/D14-1179/>. Acesso em: 19 jun. 2023.

FERLA, Fabiola. L.; GRAVE, Magali; PERICO, Eduardo. Fisioterapia no tratamento do controle de tronco e equilíbrio de pacientes pós AVC. **Revista Neurociências**, [S.L.], v. 23, n. 2, p. 211-217, 30 jun. 2015.

HARRIS, Elsa J.; KHOO, I-Hung; DEMIRCAN, Emel. A Survey of Human Gait-Based Artificial Intelligence Applications. **Frontiers In Robotics And AI**, Long Beach, v. 8, p. 1-28, jan. 2022. Frontiers Media SA.

KIM, JH. *et al.* Effect of gait training with functional electrical stimulation on gait capacity in stroke survivors with chronic hemiplegia: a randomized controlled trial. **Annals of Rehabilitation Medicine**, v. 42, n. 4, p. 560-571, 2018.

LUO, Guoliang. *et al.* Random forest–based classification and analysis of hemiplegia gait using low-cost depth cameras. **Medical & Biological Engineering & Computing**, [S.L.], v. 58, n. 2, p. 373-382, 18 dez. 2019. Springer Science and Business Media LLC.

NATIONAL INSTITUTES OF HEALTH. **Stroke**: what is a stroke? National Institute Of Neurological Disorders And Stroke, Rockville. Disponível em: <https://www.ninds.nih.gov/health-information/disorders/stroke>. Acesso em: 07 maio 2023.

OLAH, Christopher. Understanding LSTM Networks. **Colah's Blog**, San Francisco, 27 ago. 2015. Disponível em: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>. Acesso em: 19 jun 2023.

OLIVEIRA, Edilaine C. *et al.* Cuidados pós-alta em pacientes idosos com sequelas de acidente vascular cerebral: planejamento de alta hospitalar. **Revista Saúde e Desenvolvimento**, [S.L.], v. 11, n. 9, p. 172-197, 2017.

ORGANIZAÇÃO MUNDIAL DE SAÚDE. **Global Health Estimates 2019**: Deaths by Cause, Age, Sex, by Country and by Region, 2000-2019. Disponível em: <https://www.who.int/data/gho/data/themes/mortality-and-global-health-estimates/gh-leading-causes-of-death>. Acesso em: 07 maio 2023.

SCHMIDT, Michelle Hillig. *et al.* **Acidente Vascular Cerebral e diferentes limitações**: uma análise interdisciplinar. Arquivos de Ciências da Saúde da Unipar, [S.L.], v. 23, n. 2, p. 1-2, 16 maio 2019. Universidade Paranaense.

SECRETARIA DE ATENÇÃO À SAÚDE. **Diretrizes de Atenção à Reabilitação de Pessoa com Acidente Vascular Cerebral**. Ministério da Saúde, Brasília - DF, p. 3-74, 18 nov. 2022. Disponível em: <https://www.gov.br/saude/pt-br/assuntos/saude-de-a-a-z/s/saude-da-pessoa-com-deficiencia/publicacoes/diretrizes-de-atencao-a-reabilitacao-da-pessoa-com-acidente-vascular-cerebral.pdf/view>. Acesso em: 07 maio 2023.

SLJEPCEVIC, Djordje *et al.* Explaining Machine Learning Models for Clinical Gait Analysis. **ACM Transactions On Computing For Healthcare**, New York, v. 3, n. 2, p. 1-27, 20 dec. 2021. Association for Computing Machinery (ACM).

FORMULÁRIO DE AVALIAÇÃO BCC – PROFESSOR TCC I – PROJETO

Avaliador(a): Dalton Solano dos Reis

ASPECTOS AVALIADOS		atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	9. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	10. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	11. JUSTIFICATIVA São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	12. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados?	X		
ASPECTOS METODOLÓGICOS	13. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
	14. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		
	15. ORGANIZAÇÃO E APRESENTAÇÃO GRÁFICA DO TEXTO A organização e apresentação dos capítulos, seções, subseções e parágrafos estão de acordo com o modelo estabelecido?	X		
	16. ILUSTRAÇÕES (figuras, quadros, tabelas) As ilustrações são legíveis e obedecem às normas da ABNT?	X		
	17. REFERÊNCIAS E CITAÇÕES As referências obedecem às normas da ABNT?	X		
	As citações obedecem às normas da ABNT?	X		
	Todos os documentos citados foram referenciados e vice-versa, isto é, as citações e referências são consistentes?	X		

O projeto de TCC será reprovado se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos 4 (quatro) itens dos **ASPECTOS TÉCNICOS** tiverem resposta ATENDE PARCIALMENTE; ou
- pelo menos 4 (quatro) itens dos **ASPECTOS METODOLÓGICOS** tiverem resposta ATENDE PARCIALMENTE.

PARECER: (X) APROVADO () REPROVADO