

PROJETO TCC - BCC	ANO/SEMESTRE:	2020.2
-------------------	---------------	--------

DETECÇÃO DE PARKINSON ATRAVÉS DE DESENHOS EM ESPIRAL DE ARQUIMEDES E ONDAS UTILIZANDO PROCESSAMENTO DE IMAGENS

Sidnei Lanser

Prof. Aurélio Faustino Hoppe – Orientador

1 INTRODUÇÃO

De acordo com a Biblioteca Virtual em Saúde (2015, p. 1), a Doença de Parkinson (DP) é “uma doença neurológica que afeta os movimentos da pessoa. Causa tremores, lentidão de movimentos, rigidez muscular, desequilíbrio, além de alterações na fala e na escrita”. Para Andrade *et al.* (2017 apud Jacintho, 2019, p. 1), “a DP ou mal de Parkinson, é uma das doenças neurodegenerativas com maior prevalência na população mundial, manifestando-se nos mais variados tipos de pessoas, sendo mais frequente em pessoas com idade acima dos 50 anos”. Fonoff (2019b) aponta que o Parkinson é uma doença crônica degenerativa, com características evolutivas, que se manifestam em 1% da população mundial acima dos 65 anos. Além disso, também afirma que o Parkinson não afeta somente aqueles que sofrem da doença, mas também os que convivem com o paciente, uma vez que em um estágio avançado e sem o tratamento adequado, o paciente pode ficar incapaz até mesmo para cuidar de si mesmo. Fonoff (2019a) afirma que o Parkinson é uma doença que não tem cura, porém tratamentos medicamentosos podem ajudar a controlar os sintomas. Kaszubska (2019, p. 1) destaca que muitos tratamentos são eficazes, mas, quando a doença é descoberta de forma precoce. No entanto, o mais comum é que os casos sejam apenas descobertos quando os pacientes já se encontram em estágios mais avançados, passando a apresentar sintomas reconhecíveis (presença de tremores, rigidez nas pernas, braços e tronco, lentidão e diminuição dos movimentos e instabilidade na postura), que geralmente surgem quando muitas células nervosas do cérebro já sofreram danos irreversíveis.

Segundo Goulart e Pereira (2005), para determinar o estágio e a evolução da doença, os médicos normalmente utilizam alguma escala de classificação. Entre os diversos tipos de escalas que foram desenvolvidas devido à diversidade dos sintomas, sendo elas: a escala de graus de incapacidade de Hoehn e Yahr, a escala de Sydney, a escala unificada de avaliação da doença de Parkinson, chamada de Unified Parkinson's Disease Rating Scale (UPDRS), a Parkinson Activity Scale (PAS), entre outras. Tais escalas avaliam desde a condição clínica geral, as incapacidades, as funções motoras e mentais até a qualidade de vida dos pacientes. Nos exames clínicos, os médicos normalmente analisam as extremidades em situação de repouso sobre uma superfície, além de movimentos realizados em atividades cotidianas (LEITE, 2010).

De acordo com Legrand *et al.* (2017), para mensurar a gravidade do distúrbio, pode-se realizar um teste padrão onde o paciente precisa desenhar uma espiral arquimediana. Watase (2019) aponta que ela é caracterizada por ter uma distância de separação uniforme em toda suas voltas, a qual equivale à $2\pi b$. Já Almeida (2011) ressalta que a espiral arquimediana, ou espiral de Arquimedes, tem vários atributos os quais fazem com que ela tenha o uso atrativo em testes para detecção do tremor humano, entre eles, seu formato simples e fácil de entender e sua suavidade e raio crescente, o qual reduz a ocorrência de falso positivos causados por mudança na direção do movimento. Neste sentido, Chakraborty *et al.* (2020) apontam que o desenho de espirais e ondas, assim como a caligrafia, pode ser facilmente distinguida de uma pessoa para outra, bem como de uma pessoa portadora para uma não portadora da DP.

Diante deste contexto, este trabalho propõe disponibilizar um método que identifique a doença de Parkinson a partir de desenhos de espirais de Arquimedes e ondas utilizando processamento de imagens e aprendizado de máquina.

1.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar um método que identifique portadores da doença de Parkinson a partir de desenhos de espirais de Arquimedes e ondas.

Os objetivos específicos são:

- avaliar a aplicabilidade das técnicas de aprendizado de máquina e processamento de imagens quanto à detecção da DP a partir de desenhos em espirais de Arquimedes e ondas;
- identificar padrões de variabilidade da performance motora dos portadores de Parkinson;
- analisar a eficiência dos métodos desenvolvidos.

2 TRABALHOS CORRELATOS

Nesta seção são apresentados três trabalhos correlatos que possuem semelhanças à proposta deste projeto. A seção 2.1 apresenta o trabalho de Mucha *et al.* (2018), que realizaram uma comparação dos métodos tradicionais

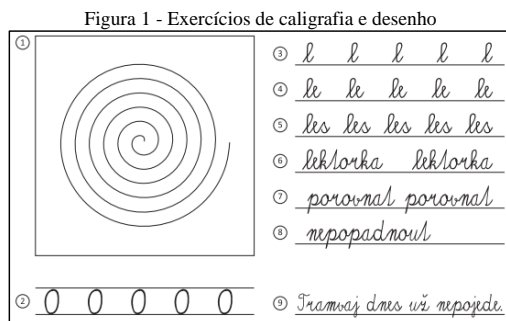
Comentado [JM1]: trocar por: tem-se...

Comentado [JM2]: mais de um?

para detecção da disgrafia com o uso de Cálculo Fracionário. A seção 2.2 descreve o trabalho de Smits *et al.* (2014), que avaliaram se a caligrafia padronizada poderia fornecer medidas quantitativas para distinguir pacientes que possuem ou não a doença de Parkinson. A seção 2.3 discorre sobre o trabalho de Zham *et al.* (2017), que analisaram a velocidade e pressão da caneta para caracterizar a doença de Parkinson.

2.1 IDENTIFICATION AND MONITORING OF PARKINSON'S DISEASE DYSGRAPHIA BASED ON FRACTIONAL-ORDER DERIVATIVES OF ONLINE HANDWRITING

Mucha *et al.* (2018) compararam um conjunto de características cinemáticas normalmente observadas em análises quantitativas da disgrafia¹ em portadores da doença de Parkinson com base em Cálculo Fracionário². Para isso, os autores utilizaram 9 amostras de diferentes exercícios de caligrafia escritos no idioma Tcheco e desenhos, de 33 pessoas portadoras da doença de Parkinson e 36 pessoas saudáveis. Os autores destacam que todos os pacientes eram destros, estavam bem descansados e sentados de forma confortável durante os testes, para que houvesse o mínimo de interferência possível de fatores exteriores. A Figura 1 apresenta os exemplos de caligrafia e desenho utilizados nos testes.



Fonte: Mucha *et al.* (2018).

Segundo Mucha *et al.* (2018), os dados foram coletados e quantificados em medidas como velocidade, aceleração e características baseadas em Cálculo Fracionário. As características foram descritas utilizando a média, mediana, desvio padrão e máximo. Tais características foram divididas em nove conjuntos de acordo com o tipo do movimento (à superfície, no ar e combinado) e a abordagem de cálculo.

Para avaliar e comparar o poder das características da caligrafia e discriminar os portadores de Parkinson dos saudáveis, Mucha *et al.* (2018) realizaram uma análise de classificação binária, no qual cada elemento deve ser classificado dentre dois grupos. Para isso, os autores utilizaram árvores de gradiente elevado, especificamente o algoritmo XGBoost, que foi escolhido devido a sua capacidade de alcançar bom desempenho, mesmo para árvores de pequeno porte.

Para treinar e avaliar os modelos, Mucha *et al.* (2018) utilizaram validação cruzada estratificada de 10 vezes com 20 repetições para os modelos de aprendizagem supervisionados. Avaliou-se o desempenho dos modelos treinados através do Coeficiente de Correlação de Matthew (CCM), Classificação de Precisão (CP), sensibilidade (SEN) e especificidade (SPE). Já em relação à avaliação da relevância das características da caligrafia para prever os valores das características clínicas selecionadas, Mucha *et al.* (2018) aplicaram a análise de regressão multivariada, árvore de impulso (XGBoost) e algoritmos de aprendizagem supervisionada. Neste caso, os modelos de regressão foram avaliados pelo Erro Médio Absoluto (EMA), Erro Médio Quadrático (EMQ) e taxa de Erro Estimada (EE).

Mucha *et al.* (2018) concluem que em comparação com os parâmetros convencionais, as características da caligrafia derivada por Cálculo Fracionário são mais significativas que as características clínicas dos pacientes e proporcionaram uma avaliação da gravidade da doença (erro em torno de 12%). Por outro lado, a maior precisão de classificação (97,14%) foi obtida pelos parâmetros convencionais, enquanto o melhor resultado obtido utilizando o Cálculo Fracionário foi de 87,14%. Mucha *et al.* (2018) sugerem que a utilização do Cálculo Fracionário em combinação com tarefas devidamente selecionadas (contínuas e/ou repetitivas, como a espiral arquimediana) poderia melhorar a avaliação computadorizada da severidade da doença de Parkinson.

¹ Disgrafia: incapacidade do indivíduo de produzir uma escrita que seja “culturalmente aceitável” (RODRIGUES; CASTRO; CIASCA, 2008).

² Cálculo Fracionário: ramo da física matemática que trata de equações integro-diferenciais (MAINARDI, 2010).


Por fim, Mucha *et al.* (2018) também apontam que os resultados obtidos ainda precisam ser confirmados por pesquisas científicas subsequentes, uma vez que o estudo tem várias limitações e sugestões de melhorias, como por exemplo, o fato da base de dados ser pequeno para generalizá-lo, ou pelo fato de utilizarem apenas medidas cinemáticas. Além disso, também destacam que para avaliar melhor as características de discriminação da doença de Parkinson pelo Cálculo Fracionário, outros tipos de recursos como temporais, espaciais e dinâmicos, devem ser considerados, assim como outras aproximações (como de Caputo) ou medidas (como a Entropia).

2.2 STANDARDIZED HANDWRITING TO ASSESS BRADYKINESIA, MICROGRAPHIA AND TREMOR IN PARKINSON'S DISEASE

Smits *et al.* (2014) fizeram um estudo a fim de avaliar se a caligrafia padronizada pode fornecer medidas quantitativas para distinguir pacientes que possuem ou não a doença de Parkinson em uma combinação semelhante de sexo e idade. Os autores desenvolveram *scripts* customizados em Matlab para analisar as tarefas de desenho e escrita, identificando através da velocidade de movimento, a bradicinesia³ e, do tamanho da escrita, a micrografia⁴. Além disso, também foi analisada a frequência para estabelecer o tremor em repouso.

Segundo Smits *et al.* (2014), foram avaliados 10 pacientes portadores da doença de Parkinson (6 homens e 4 mulheres) em fases relativamente iniciais, com idade média de 69 anos (intervalo de 63-81) e 10 pacientes não portadores da doença (6 homens e 4 mulheres), com idade média de 68 anos (intervalo de 61-78), todos destros. Cada participante realizou cinco tarefas, na mesma ordem para limitar a variabilidade dos resultados das tarefas, sendo estas: uma tarefa de repouso; traçado em círculo, desenho de linhas em oito direções diferentes e espiral (Figura 2); escrita de *el* em loop (Figura 3) e uma frase completa para avaliar a micrografia.


Figura 2 - Template utilizado para o desenho das figuras geométricas



Fonte: Smits *et al.* (2014).

De acordo com Smits *et al.* (2014), examinou-se a densidade espectral, que no pico mais elevado atingiu mais de 30 (mm/s²)/Hz para três pacientes com a doença de Parkinson, os quais foram avaliados clinicamente como tendo o tritador de repouso, enquanto para os demais participantes o resultado foi menor que 2 (mm/s²)/Hz. Os autores também observaram que o comprimento das frases e a altura do guião da frase não diferiram significativamente entre os pacientes portadores de Parkinson e os saudáveis. Já a altura da letra 'e' e a largura e altura da letra 'l' na tarefa 'elel' eram menores nos portadores de Parkinson, mas não tanto quanto a largura da letra 'e', que era significativamente menor nos pacientes com Parkinson ($p \leq 0.0014$). Além disso, nenhum outro efeito significativamente relevante foi encontrado em relação ao tamanho da escrita e à redução progressiva do tamanho da escrita, conforme pode ser visto na Figura 3, onde as amostras da esquerda são de pacientes saudáveis e as da esquerda de pacientes portadores da DP.

Figura 3 - Exemplo de tarefa "elel"



Fonte: Smits *et al.* (2014).

Smits *et al.* (2014) também notaram que os pacientes com DP realizam movimentos significativamente mais lentos do que os saudáveis. Além disso, os autores ainda relatam que os grupos foram semelhantes em função

³ Bradicinesia: lentidão de movimentos, fraqueza, tremor e rigidez (BERARDELLI *et al.*, 2001).

⁴ Micrografia: diminuição gradual do tamanho da grafia (SIMONET *et al.*, 2019).

Comentado [JM3]: Verificar espaçamento, está diferente do título da seção 2.1

da idade, apontando diminuição da velocidade de movimento nos pacientes com Parkinson, reflexo da bradicinesia e não apenas a lentidão relacionada com a idade. No entanto, as características de bradicinesia mostraram grandes diferenças entre os dois grupos. Contudo, Smits *et al.* (2014) destacam que quase todas as características mostraram uma clara diferença entre os grupos ($p < 0,05$), embora nem todas elas tenham sobrevivido à correção Bonferroni, que é um método para lidar com problemas de comparações múltiplas. Além disso, este estudo não inclui uma comparação com o exame clínico dos sintomas motores da doença.


Smits *et al.* (2014) concluem que as tarefas de caligrafia padronizada podem fornecer medidas quantitativas para a avaliação da bradicinesia, micrografia e tremor e que várias destas medidas distinguiram os portadores da doença de Parkinson clinicamente diagnosticados dos que não a possuem. No entanto, ressaltam que o pequeno número de amostras pode produzir resultados estatisticamente insignificativos.

2.3 DISTINGUISHING DIFFERENT STAGES OF PARKINSON'S DISEASE USING COMPOSITE INDEX OF SPEED AND PEN-PRESSURE OF SKETCHING A SPIRAL

Zham *et al.* (2017) utilizaram o Índice Composto de Velocidade e Pressão da Caneta (CISP) como característica para analisar a gravidade da doença de Parkinson. Os autores qualificam a gravidade dos sintomas motores de todos os pacientes usando a parte III da Escala de Classificação Unificada da doença de Parkinson (UPDRS)⁵ e para a avaliação geral da fase da doença usaram a Escala de Hoehn e Yahr Modificada (H&Y)⁶.

De acordo com Zham *et al.* (2017), os pacientes desenharam espirais arquimedianas guiadas em uma folha A3 no qual a velocidade, pressão da caneta e CISP foram computadas e analisadas a fim de obter sua correlação com a gravidade da doença. A Figura 4 apresenta exemplos de espirais arquimedianas.

Figura 4 - Espirais arquimedianas guiadas desenhadas pelos pacientes



Fonte: Zham *et al.* (2017).

Segundo Zham *et al.* (2017), o Teste U de Mann-Whitney⁷ confirmou que a CISP é adequada para distinguir os pacientes que possuem a doença de Parkinson dos que não a possuem, enquanto o Teste de Kruskal-Wallis⁸ confirmou que é significativamente diferente para a doença de Parkinson SL-1 e SL-3. Isso mostra que o CISP pode ser usado durante o esboço em espiral para diferenciar os portadores da doença entre SL-1 e SL-3, mas não SL-2. Já o teste não paramétrico da amostra k Kruskal-Wallis mostra que existe diferença estatisticamente significativa entre os grupos para CISP, enquanto que a velocidade e a pressão da caneta não mostraram diferença estatisticamente significativa. Isto indica que a velocidade e a pressão da caneta por si só não são adequadas para diferenciar entre os diferentes níveis de severidade.

De acordo com Zham *et al.* (2017), a velocidade, a pressão da caneta e a CISP de esboço de uma espiral estão negativamente correlacionadas com a severidade da doença de Parkinson. Eles concluem que embora estas três características tenham sido significativamente afetadas pela gravidade da doença, a correlação foi mais forte com a CISP de esboço, uma vez que a análise estatística mostrou uma diferença significativa da CISP entre SL-1 e SL-3, mas não para a velocidade e a pressão da caneta. Contudo, a CISP não foi capaz de diferenciar entre SL-1 e SL-2 ou entre SL-2 e SL-3.

⁵ UPDRS: escala da DP que avalia os sinais, sintomas e determinadas atividades dos pacientes por meio do autorrelato e da observação clínica (MELLO; BOTELHO, 2010).

⁶ H&Y: escala de avaliação da incapacidade dos portadores da DP capaz de indicar seu estado geral de forma rápida e prática (MELLO; BOTELHO, 2010).

⁷ Teste U: também conhecido como teste de Wilcoxon, compara a distribuição dos dados de uma mesma amostra avaliada mais de uma vez (CAMPOS *et al.*, 2016)

⁸ Teste de Kruskal-Wallis: teste não paramétrico para comparar mais de duas amostras sem o uso de controle local (PONTES, 2000).

Comentado [JM4]: Mesma observação anterior

3 PROPOSTA DO MÉTODO

Esta seção tem como objetivo apresentar a justificativa para o desenvolvimento do trabalho, assim como seus requisitos e a metodologia de desenvolvimento a ser usada.

3.1 JUSTIFICATIVA

No Quadro 1 há comparativo entre os trabalhos que embasam este estudo sobre a identificação da doença de Parkinson, sendo que as linhas apresentam as características e as colunas os trabalhos.

Quadro 1 - Comparativo entre trabalhos correlatos

Correlatos Características	Mucha <i>et al.</i> (2018)	Smits <i>et al.</i> (2014)	Zham <i>et al.</i> (2017)
Tipo de patologia detectada	Disgrafia	- Bradicinesia - Micrografia	Parkinson
Tipo da atividade	- Desenho em espiral - Escrita	- Repouso - Desenho em linha, círculo e espiral - Escrita	Desenho em espiral
Técnica analisada	Cálculo Fracionário	Caligrafia padronizada	CISP
Taxa de assertividade	87.14%	Não disponível	CISP sob ROC = 86,2% ROC sob CISP = 83,2%
Amostras avaliada (portadores/saudáveis)	33/36	10/10	27/28
Quantidade de exercícios avaliados	9	5	1

Fonte: elaborado pelo autor.

Conforme pode ser observado no Quadro 1, a patologia detectada em cada um dos estudos é diferente. Enquanto Mucha *et al.* (2018) detectam apenas a disgrafia, Smits *et al.* (2014) detectam a bradicinesia e também a micrografia. Já Zham *et al.* (2017) focam na doença de Parkinson. O tipo de atividade realizada para a avaliação do paciente em cada um dos estudos é muito semelhante, tendo em todos os três trabalhos uma ou mais atividades de desenho, uma ou mais atividades de escrita (exceto para Zham *et al.* (2017)). Smits *et al.* (2014) também utilizam atividades relacionadas ao tremor e repouso.

Já em relação ao número de exercícios aplicados, pode-se observar que apenas o trabalho de Zham *et al.* (2017) utilizou um exercício, mas que ainda assim, é o exercício de desenho de espirais, presente também no trabalho de Mucha *et al.* (2018) e de Smits *et al.* (2014). Apesar de Smits *et al.* (2014) utilizarem 5 exercícios, o exercício de desenho de linha contempla 8 direções diferentes. Os demais exercícios avaliados no estudo de Mucha *et al.* (2018) e de Smits *et al.* (2014) são semelhantes, diferindo apenas pelos exercícios de repouso e desenho em círculo, utilizados no estudo de Smits *et al.* (2014).

Todas as abordagens de análise foram distintas. Enquanto Mucha *et al.* (2018) analisaram a eficiência da técnica de Cálculo Fracionário, Smits *et al.* (2014) analisam a caligrafia padronizada e Zham *et al.* (2017) optaram pela CISP. Todos os trabalhos têm um número semelhante de amostras avaliadas com e sem a doença e Parkinson. Porém, a quantidade de amostras pode ser considerada pequena, uma vez que Mucha *et al.* (2018) foram os que aplicaram em um número maior de pessoas, 69 no total. Quanto à taxa de assertividade, nota-se que Mucha *et al.* (2018) e Zham *et al.* (2017) possuem uma taxa muito semelhante, com diferença de menos de 1%. Smits *et al.* (2014) não apresentam uma taxa de assertividade para seu estudo.

Diante do cenário descrito, pode-se perceber que nenhum dos trabalhos utiliza a atividade de desenho de onda como método avaliativo, ao qual será um dos métodos de desenho utilizados no trabalho proposto, junto com o método de desenho de espiral que é utilizado em todos os trabalhos. Além disso, outro diferencial deste trabalho é a utilização de técnicas de aprendizado, do tipo rede neurais convolucionais, para detectar o desenho gerado e, que posteriormente, será utilizado para estabelecer o grau similaridade em relação a um gabarito ou padrões de performance motora, neste caso, a partir de técnicas de processamento de imagens. Contudo, espera-se contribuir e até mesmo facilitar o processo de detecção da doença de Parkinson em estágios iniciais da doença, assim como outros tipos de patologias, tendo como base a análise do tremor do paciente.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

Abaixo são apresentados os requisitos funcionais (RF) e os requisitos não funcionais (RNF) do método que será desenvolvido. O método deverá:

- a) utilizar desenhos de espirais e ondas para detecção da DP (RF);
- b) realizar o realce e melhoramento das imagens (ruídos, distorções e problemas de iluminação) utilizando técnicas processamento de imagens (RF);
- c) utilizar técnicas de aprendizado de máquina, especificamente redes neurais convoluionais para realizar a detecção dos desenhos (RF);
- d) extrair informações geométricas dos espirais e ondas (RF);
- e) realizar a linearização das ondas ou espirais para um plano 2D (RF);
- f) estabelecer o grau de similaridade entre os gabaritos e os desenhos feitos pelos usuários (RF);
- g) identificar padrões que possam apontar a utilização ou não da mão dominante ou potencialmente apontar a presença de alguma patologia vinculada a DP (RF);
- h) estabelecer e disponibilizar dados sobre a performance motora dos usuários (RF);
- i) ser desenvolvida na linguagem de programação Python (RNF);
- j) utilizar as bibliotecas OpenCV para o processamento de imagens e Keras para o aprendizado de máquina (RNF);
- k) ser capaz de realizar a análise em um tempo máximo de 1 minuto (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: pesquisar e estudar sobre Parkinson, processamento de imagem, redes neurais convolucionais e trabalhos correlatos;
- b) pesquisa e escolha do método desenho: pesquisar qual é o método de desenho mais efetivo para o cenário, seja este desenho a mão livre, ligação de pontos, contorno ou outro;
- c) composição da base de dados: coletar imagens da internet de desenhos manuais de ondas e espirais para compor uma base de dados de casos saudáveis e casos portadores de Parkinson e, caso não haja um número satisfatório de imagens, coletar também mais amostras juntamente com profissionais especialistas na doença. Durante a realização desta etapa será solicitado aos pacientes a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- d) rotulação das imagens que compõe a base de dados: rotular as imagens que compõe a base de dados separando-as em tipo de exercício, tipo de amostra (saudável ou portador de Parkinson) e em imagens de teste e treinamento da rede neural convolucional;
- e) definição da arquitetura da rede neural: definir a arquitetura da rede neural mais aderente ao processo de detecção do desenho feito pelo usuário;
- f) desenvolvimento do método de detecção dos desenhos: a partir do item (e) implementar o método que irá detectar desenhos utilizando a linguagem Python e a biblioteca Keras;
- g) análise dos resultados: avaliar se o método desenvolvido consegue identificar os desenhos corretamente assim verificando sua acurácia e desempenho;
- h) levantamento de formas para identificar características e calcular a similaridade: pesquisar métodos de processamento de imagens utilizados para extrair medidas ou padrões a partir de imagens;
- i) desenvolvimento: a partir do item (h) desenvolver métodos para identificar padrões motores assim como calcular o grau de similaridade entre o gabarito e o desenho feito pelo usuário utilizando a linguagem Python e a biblioteca OpenCV;
- j) testes do método: avaliar a assertividade do método e juntamente com o especialista da área verificar se ele, como um todo, pode ser utilizado para a detectar a doença ou outras patologias ligadas ao Parkinson.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Comentado [JM5]: compõem

Quadro 2 - Cronograma de atividades a serem realizadas

etapas / quinzenas	2020				2021											
	nov.		dez.		jan.		fev.		mar.		abr.		maio		jun.	
	1	2	1	2	1	2	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico																
pesquisa e escolha do método de desenho																
composição da base de dados																
rotulação das imagens que compõe a base de dados																
definição da arquitetura da rede neural																
desenvolvimento do método de detecção dos desenhos																
análise dos resultados																
levantamento de formas para identificar características e calcular a similaridade																
desenvolvimento																
testes do método																

Fonte: elaborado pelo autor.

4 REVISÃO BIBLIOGRÁFICA

Esta seção descreve sobre os assuntos que fundamentarão o estudo a ser realizado. A seção 4.1 discorre sobre o Parkinson e processamento de imagens. Já a seção 4.2 aborda redes neurais convolucionais.

4.1 PARKINSON E PROCESSAMENTO DE IMAGENS

A doença de Parkinson é a segunda doença neurodegenerativa mais comum, afetando de 2 a 3% da população com mais de 65 anos (POEWE *et al.*, 2017). Earls e Lee (2020) apontam que a doença de Parkinson é patologicamente caracterizada pela má distribuição e agregação da proteína alfa-nucleica em inclusões insolúveis. A DP foi descrita pela primeira vez por James Parkinson há mais de 200 anos, em um ensaio intitulado “An Essay on the Shaking Pulse”, de 1817. Apesar do tempo, ainda não se sabe qual a causa dessa neurodegeneração e o motivo pelo qual ela afeta apenas alguns indivíduos de idade avançada (CHEN; TURNBULL; REEVE, 2019).

Fonoff (2019a) aponta que ainda há um longo caminho até a cura do Parkinson, mas existem diversos tratamentos disponíveis, os quais, como apontado por Savitt, Dawson e Dawson (2006), fazem a correção de dopamina cerebral através da farmacologia. Spagnol *et al.* (2020, p. 130) apontam que tais tratamentos têm como objetivo repor a dopamina, utilizando para tal “drogas anticolinérgicas, antidepressivas, amantadina, piribedil, dopaminérgicos e a levodopa, introduzida no final da década de 1960”. Savitt, Dawson e Dawson (2006) ressaltam que apesar de fornecerem um alívio temporário, tais terapias medicamentosas, não interrompem a progressão da DP no paciente. Duker e Ezpay (2013) destacam a possibilidade de procedimentos cirúrgicos, sendo recomendados apenas para tratar os sintomas motores de rigidez e bradicinesia.

De acordo com Haase *et al.* (2017), o tremor de repouso, rigidez, bradicinesia e instabilidade postural são os sinais clínicos essenciais da doença, sendo o aparecimento dos sintomas de forma repentina raro. A rigidez não é evidente na fase inicial da DP, no qual os pacientes com frequência se queixam de “peso” e “dureza” dos membros. Quando se trata de rigidez, existem dois tipos: sinal da roda denteada (alterna contração e relaxamento) e o sinal do cano de chumbo (resistência uniforme) (UMPHRED, 2004 apud HAASE *et al.*, 2017, p. 80).

Delisa e Gans (2002, apud HAASE *et al.*, 2017, p. 81) também apontam que a bradicinesia é um dos sinais que mais diferenciam a DP de outras alterações motoras. Uniyal e Raychoudhury (2014) destacam que 90% dos pacientes da DP sofrem de perturbações na fala e voz. Com a evolução da doença, novas alterações surgem, comprometendo assim a qualidade de vida do paciente. Segundo Uniyal e Raychoudhury (2014), apesar de não ser fatal, a doença pode levar a uma grave incapacidade do paciente entre 10 e 20 anos.

Para detectar a DP, segundo Moreira *et al.* (2007), realiza-se exames clínicos e físicos. Nutt e Wooten (2005, p. 1021, tradução nossa) apontam que são avaliados para um diagnóstico a “[...] presença das principais características de lentidão e escassez de movimentos (bradicinesia e akinesia) e tremor quando o membro está em repouso ou em resistência ao movimento passivo das articulações (rigidez), ou ambos.”. Outro método utilizado para avaliar a gravidade dos sintomas motores da DP, conforme apontado por Kuosmanen *et al.* (2019), é o desenho em espiral, o qual costuma ser realizado com caneta e papel, sob observação de um clínico. Barbosa e Sallem (2019) apontam que em fases iniciais ou até mesmo quando mais avançada, o reconhecimento pode ser mais difícil, uma vez que o quadro clínico pode se apresentar de forma fragmentária, sendo dividida em dois tipos básicos: (i) aquela no qual há a presença de acinesia e/ou rigidez, chamada de forma rígidoacinetica; (ii) aquela que apenas o tremor está presente, chamada de forma hipercinetica.


Comentado [JM6]: incluir ponto

Comentado [JM7]: tirar espaço em branco

Comentado [JM8]: tirar espaço em branco

Kuosmanen *et al.* (2019, p. 1) ressaltam que o uso do desenho em espiral é um teste padrão para a avaliação de pacientes com perturbações de movimento. A Figura 5 apresenta um exemplo da detecção da DP, onde no item (a) encontra-se o espiral desenhado por um paciente saudável (à esquerda) e por um portador da DP (à direita). No item (b), pode-se observar as suas respectivas linearizações.

Figura 5 - Exemplo de técnica utilizada para a detecção da DP em espirais



Fonte: Surangsirat e Thanawattano (2012)

Segundo Almeida (2011), a técnica de linearização consiste em transformar o desenho da espiral em uma linha de coordenadas polares, facilitando assim o processo de estimativa do tremor. A partir dela, estima-se a diferença entre a linearização da espiral desenhada pelo paciente e a considerada “ideal”. Além disso, Surangsirat e Thanawattano (2012) destacam que outras características podem ser utilizadas para complementar a análise junto ao desenho da espiral, por exemplo, a pressão exercida sobre a caneta e o tempo que o paciente demora para completar a atividade de desenho. Para obter-se a linearização, primeiro se faz necessário a detecção do desenho da espiral. Para tal, um dos algoritmos disponíveis é a Transformada de Hough.

Segundo Tarsha-Kurdi, Landes e Grussenmeyer (2007), a Transformada de Hough costuma ser usada no processamento de imagens para a detecção de primitivos geométricos. Porém, como apontado por Hassanein *et al.* (2015), ao longo dos anos vem sendo usada para vários outros tipos de análise ou até mesmo para identificação de formas irregulares.

Após a identificação da linha, segundo Watase (2019), realiza-se a linearização da espiral através da obtenção das coordenadas X e Y da mesma e sua conversão para uma função do raio, na qual o ângulo deve ser zero (quando a espiral for uma espiral “ideal”), ou seja, uma reta. Para isso, Almeida (2011) aplica a seguinte operação: (1) $x = r \cos(\theta)$; (2) $y = r \sin(\theta)$; (3) $r = \sqrt{x^2 + y^2}$; (4) $r = m\theta$. Após a linearização, é preciso comparar ambas imagens (a reta “ideal” e a desenhada pelo paciente) para saber se a reta desenhada pelo paciente corresponde à “ideal”.


4.2 REDES NEURAIS CONVOLUCIONAIS

Segundo Schmidhuber (2015), a primeira rede neural artificial que mereceu o atributo de “profunda”, foi a Neocognitron, proposta por Kunihiro Fukushima em 1979. Ela originou as redes neurais convolucionais (em inglês, *Convolutional Neural Network* (CNN)), no qual “[...] o campo receptivo (tipicamente retangular) de uma unidade convolutiva com determinado peso de vetor (um filtro) é deslocado passo a passo através de uma matriz bidimensional de valores de entrada, tais como os pixels de uma imagem (normalmente existem vários filtros deste tipo)” (SCHMIDHUBER, 2015, p. 10, tradução nossa).

De acordo com Brownlee (2018), a CNN é uma rede neural artificial que se tornou dominante em várias tarefas da visão computacional, sendo o método mais utilizado para qualquer tipo de problema de análise envolvendo uma imagem como dado de entrada, uma vez que esta tem muita habilidade para desenvolver uma representação interna de imagens bidimensionais. Para Yamashita *et al.* (2018), uma CNN é projetada para aprender automaticamente e de forma adaptável através de retropropagação. Ainda segundo os autores, ela se diferencia de outros métodos empregados na área pois não requer a extração de características de modo artesanal e, ao mesmo tempo, por necessitar de muito mais dados, devido aos seus milhões de parâmetros de aprendizagem.

Segundo Vinayakumar, Soman e Poornachandran (2017, p. 1224, tradução nossa), a CNN “é composta por uma camada *convolution 1D*, uma camada *pooling 1D*, uma camada *fully connected* e uma função não linear de ativação *ReLU*” e é uma extensão das tradicionais Feedforward Neural Networks (FNN). Na Figura 6 pode-se observar uma clássica arquitetura CNN.

Figura 6 - Arquitetura CNN



Fonte: Chatterjee (2019).

A partir da Figura 6 pode observar que uma CNN é composta pelas seguintes camadas: (a) input, corresponde à imagem de entrada; (b) convolution, é uma camada composta por uma série de filtros os quais são chamados de *kernel* e representam uma característica cada. Caso o filtro passe pela imagem e encontre algo que corresponda ao que está procurando, a operação convolucional gerará um grande número, ativando assim o filtro para tal característica. Caso contrário, o filtro não é ativado; (c) relu, que é uma camada de ativação a qual está presente após a camada convolucional (item b) e que ajuda a rede com a aprendizagem das funções difíceis e também com a redução do *overfitting*; (d) pooling, é um vetor de transformação escalar, o qual, assim como as convoluções, opera em cada região da imagem. Krinski e Todt (2019) apontam que nesta camada um filtro passa sobre o dado de entrada (item a) e as operações max (máximo), min (mínimo) e avg (média) de pooling são aplicadas; (e) flatten, essa camada costuma ser usada na divisão das duas partes da CNN: Hidden layer e Classification. Segundo Wang *et al.* (2020), é uma camada de nivelamento muitas vezes necessária antes da classificação para que a camada fully connected (item f) possa realizar as classificações; (f) fully connected é uma *Perceptron* multicamada composta por três outras camadas, sendo elas: (i) input: camada para qual a CNN manda as características geradas; (ii) hidden: é uma sequência de neurônios que aprenderão durante o treino da CNN. Pode haver mais de uma camada hidden em uma *perceptron* multicamadas; (iii) output: é também uma sequência de neurônios, porém com ativação diferente; (g) a função softmax costuma ser usada em um problema para gerar para cada categoria as suas probabilidades.

De acordo com Shrestha e Mahmood (2019, p. 53040, tradução nossa), a implementação de uma rede neural é constituída por “(1) obter o conjunto de dados de treino e de teste; (2) treinar a rede; (3) fazer a predição com o dado de teste”. Quanto as arquiteturas da CNN, Ingargiola (2019) aponta que elas têm uma vaga inspiração no córtex visual. Ainda segundo o autor, após ganhar um concurso com grande margem, a arquitetura AlexNet deu início a uma onda de interesse em *Deep Learning*.

De acordo com Yuan e Zhang (2016 apud Jiang *et al.*, 2019, p. 4), a AlexNet é uma rede CNN de estrutura pouco profunda, sendo capaz de extrair muitas características da imagem. Shin *et al.* (2016) destacam outras arquiteturas diferentes da AlexNet, entre elas a GoogLeNet-CNN, segundo Alaskar *et al.* (2019), utilizada para a extração e classificação de características e, a ImageNet, que segundo Kornblith e Shlens (2019), é uma base de dados utilizada por outras arquiteturas de rede para reconhecimento de objetos.

REFERÊNCIAS

- ALASKAR, Haya *et al.* Application of Convolutional Neural Networks for Automated Ulcer Detection in Wireless Capsule Endoscopy Images. *Sensors*, [S.l.], v. 19, n. 6, p. 1265-1281, mar. 2019.
- ALMEIDA, Maria F. S. de. *Análise Temporal da Relação entre o Tremor Fisiológico Cinético e o Envelhecimento com Base em Desenhos Digitalizados da Espiral de Arquimedes*. 2011. 145 f. Tese (Doutorado) - Curso de Engenharia Elétrica, Universidade Federal de Uberlândia, Uberlândia.
- BARBOSA, Egberto Reis; SALLEM, Flávio Augusto Sekeff. Doença de Parkinson. *Revista Neurociências*, [S.l.], v. 13, n. 3, p. 158-165, jan. 2019.
- BERARDELLI, Alfredo *et al.* Mark. Pathophysiology of bradykinesia in Parkinson's disease. *Brain*, [S.l.], v. 124, n. 11, p. 2131-2146, nov. 2001.
- BIBLIOTECA VIRTUAL EM SAÚDE. *Doença de Parkinson*. [S.l.], [2015]. Disponível em: <<https://bvsm.sau.de.gov.br/dicas-em-saude/2059-doenca-de-parkinson>>. Acesso em: 02 set. 2020.
- BROWNLEE, Jason. *When to use MLP, CNN, and RNN neural networks*: What neural network is appropriate for your predictive modeling problem?. [S.l.], [2019]. Disponível em: <<https://machinelearningmastery.com/when-to-use-mlp-cnn-and-rnn-neural-networks/>>. Acesso em: 10 out. 2020.

Comentado [JM9]: esse trecho ficou estranho, porque tem ponto, o que finaliza a frase iniciada em “A partir da Figura 6...” verificar, reescrever.

Comentado [JM10]: Mesma observação anterior.

Comentado [JM11]: idem

Comentado [JM12]: tirar crase

Comentado [JM13]: esse trecho está estranho, parece que Shin et al é o autor do texto original, mas depois tem outras duas referências.

CAMPOS, Maene *et al.* Confiabilidade do Teste dos Cinco Dígitos em adultos brasileiros. **Jornal Brasileiro de Psiquiatria**, [S.l.], v. 65, n. 2, p. 135-139, jun. 2016.

CHAKRABORTY, Sabyasachi *et al.* Parkinson's Disease Detection from Spiral and Wave Drawings using Convolutional Neural Networks: a multistage classifier approach. In: 22ND INTERNATIONAL CONFERENCE ON ADVANCED COMMUNICATION TECHNOLOGY (ICACT), 2020, PyeongChang. **Proceedings Of The Ieee**. PyeongChang: IEEE, 2020, p. 298-303.

CHATTERJEE, Chandra C. **Basics of the Classic CNN**: how a classic cnn (convolutional neural network) work?. [S.l.], [2019]. Disponível em: <<https://towardsdatascience.com/basics-of-the-classic-cnn-a3dce1225add>>. Acesso em: 10 nov. 2020.

CHEN, Chun; TURNBULL, Doug M.; REEVE, Amy K.. Mitochondrial Dysfunction in Parkinson's Disease—Cause or Consequence? **Biology**, [S.l.], v. 8, n. 2, p. 38-64, 11 maio 2019.

DUKER, Andrew P.; ESPAY, Alberto J.. Surgical Treatment of Parkinson Disease. **Neurologic Clinics**, [S.l.], v. 31, n. 3, p. 799-808, ago. 2013.

EARLS, Rachael H.; LEE, Jae-Kyung. The role of natural killer cells in Parkinson's disease. **Experimental & Molecular Medicine**, [S.l.], p. 1517-1525, set. 2020.

FONOFF, Erich. **A doença de Parkinson tem cura?** [S.l.], [2019a] Disponível em: <<https://www.erichfonoff.com.br/parkinson-tem-cura/>>. Acesso em: 10 out. 2020.

FONOFF, Erich. **Doença de Parkinson**. [S.l.], [2019b] Disponível em: <<https://www.erichfonoff.com.br/doenca-de-parkinson/>>. Acesso em: 09 out. 2020.

GOULART, Fátima; PEREIRA, Luciana X. Uso de escalas para avaliação da doença de Parkinson em fisioterapia. **Fisioterapia e Pesquisa**, [S.l.], v. 11, n. 1, p. 49-56, abr. 2005.

HAASE, Deisy C. B *et al.* Atuação da fisioterapia no paciente com Doença de Parkinson. **Fisioterapia em Movimento**, [S.l.], v. 21, n. 1, set. 2017.

HASSANEIN, Allam S. *et al.* A Survey on Hough Transform, Theory, Techniques and Applications. **IJCSI International Journal of Computer Science Issues**, [S.l.], v. 12, n. 2, p. 139-156, jan. 2015.

INGARGIOLA, Antonino. **Deep-dive into Convolutional Networks**: from the building-blocks to the most advanced architectures, touching on interpretability, and bias. [S.l.], [2019]. Disponível em: <<https://towardsdatascience.com/deep-dive-into-convolutional-networks-48db75969fdf>>. Acesso em: 19 nov. 2020.

JACINTHO, Juan Carlos. **Protótipo de baixo custo para quantizar tremores na doença de Parkinson**. 2019. 6 f. TCC (Graduação) - Curso de Ciência da Computação, Furb - Universidade Regional de Blumenau, Blumenau.

JIANG, Bo *et al.* Fusion of machine vision technology and AlexNet-CNNs deep learning network for the detection of postharvest apple pesticide residues. **Artificial Intelligence In Agriculture**, [S.l.], v. 1, p. 1-8, mar. 2019.

KASZUBSKA, Gosia. **Screening tech advances early detection of Parkinson's disease**: Screening technology to catch Parkinson's disease in its earliest stages could be available within three years, following an agreement between RMIT University and start-up company Jesse Medical. [S.l.], [2019]. Disponível em: <https://www.rmit.edu.au/news/all-news/2019/nov/screening-tech-detection-parkinsons>. Acesso em: 06 set. 2020.

KORNBLITH, Simon; SHLENS, Jonathon. Do Better ImageNet Models Transfer Better?. In: CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2019, [S.l.]. **Proceedings Of The Ieee**. [S.l.]: IEEE, 2019, p. 2661-2671.

KRINSKI, Bruno Alexandre; TODT, Eduardo. Convolutional neural network. [S.l.], 30 nov. 2019. Disponível em: http://www.inf.ufpr.br/todt/IAaplicada/CNN_Presentation.pdf. Acesso em: 26 nov. 2020.

KUOSMANEN, Elina *et al.* Measuring Parkinson's disease motor symptoms with smartphone-based drawing tasks. In: THE 2019 ACM INTERNATIONAL JOINT CONFERENCE ON PERSASIVE AND UBIQUITOUS COMPUTING, 2019, New York. **Proceedings Of The 2019 Acm International Joint Conference On Pervasive And Ubiquitous Computing And Proceedings Of The 2019 Acm International Symposium On Wearable Computers - Ubicomp/ISWC '19**., Londres: Association for Computing Machinery, 2019, p. 1182-1185.

LEGRAND, André Pierre *et al.* New insight in spiral drawing analysis methods – Application to action tremor quantification. **Clinical Neurophysiology**, [S.l.], v. 128, n. 10, p. 1823-1834, out. 2017.

LEITE, Marco A. A. Tremor essencial. **Revista Hospital Universitário Pedro Ernesto**. Rio de janeiro, v. 9, n. 1, p. 20-29, jan/jun. 2010.

MAINARDI, Francesco. **Fractional calculus and waves in linear viscoelasticity**: an introduction to mathematical models. [S.l.]: Imperial College Press, 2010.

MELLO, Marcella P. B. de; BOTELHO, Ana C. G. Correlação das escalas de avaliação utilizadas na doença de Parkinson com aplicabilidade na fisioterapia. **Fisioterapia em Movimento**, [S.l.], v. 23, n. 1, p. 121-127, mar. 2010.

MOREIRA, Camilla S. *et al.* Doença de Parkinson: como diagnosticar e tratar. **Revista Científica da Faculdade de Medicina de Campos**, [S.l.], v. 2, n. 2, p. 19-29, dez. 2007.

MUCHA, Jan *et al.* Identification and Monitoring of Parkinson's Disease Dysgraphia Based on Fractional-Order Derivatives of Online Handwriting. **Applied Sciences**, [S.l.], v. 8, n. 12, p. 2566-2583, 11 dez. 2018.

NUTT, John G.; WOOTEN, G. Frederick. Diagnosis and Initial Management of Parkinson's Disease. **New England Journal Of Medicine**, [S.l.], v. 353, n. 10, p. 1021-1027, 8 set. 2005.

POEWE, Werner *et al.* Parkinson disease. **Nature Reviews Disease Primers**, [S.l.], v. 3, n. 49-55, p. 1, mar. 2017.

PONTES, Antonio Carlos Fonseca. **Obtenção dos níveis de significância para os testes de Kruskal-Wallis, Friedman e comparações múltiplas não-paramétricas**. 2000. 142 f. Dissertação (Mestrado) - Curso de Agronomia, Escola Superior de Agricultura Luiz de Queiroz, Piracicaba.

RODRIGUES, Sônia das D.; CASTRO, Maria J. M. G. de; CIASCA, Sylvia M. Relação entre indícios de disgrafia funcional e desempenho acadêmico. **Revista Cefac**, [S.l.], v. 11, n. 2, p. 221-227, dez. 2008.

SAVITT, Joseph. M.; DAWSON, Valina L.; DAWSON, Ted M. Diagnosis and treatment of Parkinson disease: molecules to medicine. **Journal Of Clinical Investigation**, [S.l.], v. 116, n. 7, p. 1744-1754, jul. 2006.

SCHMIDHUBER, Jürgen. Deep learning in neural networks: an overview. **Neural Networks**, [S.l.], v. 61, p. 85-117, jan. 2015.

SHIN, Hoo-Chang *et al.* Deep Convolutional Neural Networks for Computer-Aided Detection: cnn architectures, dataset characteristics and transfer learning. **Ieee Transactions On Medical Imaging**, [S.l.], v. 35, n. 5, p. 1285-1298, maio 2016.

SHRESTHA, Ajay; MAHMOOD, Ausif. Review of Deep Learning Algorithms and Architectures. **Ieee Access**, [S.l.], v. 7, p. 53040-53065, abr. 2019.

SIMONET, Claire *et al.* The motor prodromes of parkinson's disease: from bedside observation to large-scale application. **Journal Of Neurology**, [S.l.], p. 1-1, dez. 2019.

SPAGNOL, Giovanna Pereira *et al.* Tratamentos Farmacológicos e Cirúrgicos da Doença de Parkinson: uma revisão da literatura. **Diário da Teoria e Prática na Enfermagem** 3, [S.l.], p. 128-136, fev. 2020.

SMITS, Esther J *et al.* Standardized Handwriting to Assess Bradykinesia, Micrographia and Tremor in Parkinson's Disease. **Plos One**, [S.l.], v. 9, n. 5, p. 1, 22 maio 2014.

SURANGSRIRAT, Decho; THANAWATTANO, Chusak. Android application for spiral analysis in Parkinson's Disease. In: 2012 PROCEEDINGS OF IEEE SOUTHEASTCON, 2012, Orlando. **2012 Proceedings Of Ieee Southeastcon**, Orlando: IEEE, 2012, p. 1-6, mar.

TARSHA-KURDI, Faye; LANDES, Tania; GRUSSENMEYER, Pierre. Hough-Transform and Extended RANSAC Algorithms for Automatic Detection of 3D Building Roof Planes from Lidar Data. In: ISPRS WORKSHOP ON LASER SCANNING 2007 AND SILVILASER 2007, 2007, Espoo. **Proceedings...** Espoo: HAL, 2007, p.407-412.

UNIYAL, Deepak; RAYCHOUDHURY, Vaskar. Pervasive Healthcare: A Comprehensive Survey of Tools and Techniques. **Arxiv**, [S.l.], p. 1-48, 7 nov. 2014.

VINAYAKUMAR, Ravi; SOMAN, Kotti. P.; POORNACHANDRAN, Prabakaran. Applying convolutional neural network for network intrusion detection. In: 2017 INTERNATIONAL CONFERENCE ON ADVANCES IN COMPUTING, COMMUNICATIONS AND INFORMATICS (ICACCI), 2017, [S.l.]. **Proceedings Of The Ieee**. [S.l.]: IEEE, 2017, p. 1222-1228.

WANG, Zijie J *et al.* CNN EXPLAINER: learning convolutional neural networks with interactive visualization. In: IEEE TRANSACTIONS ON VISUALIZATION AND COMPUTER GRAPHICS, 2020, [S.l.]. **Proceedings Of The Ieee**. [S.l.]: IEEE, 2020, p. 1-11.

WATASE, Gabriela Sayuri. **Desenvolvimento de um software para a classificação de tremor de membro superior a partir de movimentos de escrita**. 2019. 35 f. TCC (Graduação) - Curso de Engenharia Biomédica, Universidade Federal do Abc, São Bernardo do Campo.

YAMASHITA, Rikiya *et al.* Convolutional neural networks: an overview and application in radiology. **Insights Into Imaging**, [S.l.], v. 9, n. 4, p. 611-629, jun. 2018.

ZHAM, Poonam *et al.* Distinguishing Different Stages of Parkinson's Disease Using Composite Index of Speed and Pen-Pressure of Sketching a Spiral. **Frontiers In Neurology**, [S.l.], v. 8, p. 1-7, set. 2017.

ASSINATURAS

(Atenção: todas as folhas devem estar rubricadas)

Assinatura do(a) Aluno(a): _____

Assinatura do(a) Orientador(a): _____

Assinatura do(a) Coorientador(a) (se houver): _____

Observações do orientador em relação a itens não atendidos do pré-projeto (se houver):

FORMULÁRIO DE AVALIAÇÃO – PROFESSOR AVALIADOR

Acadêmico(a): _____

Avaliador(a): Joyce Martins _____

ASPECTOS AVALIADOS ¹		atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	1. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?		X	
	2. TRABALHOS CORRELATOS São apresentados trabalhos correlatos, bem como descritas as principais funcionalidades e os pontos fortes e fracos?	X		
	3. JUSTIFICATIVA Foi apresentado e discutido um quadro relacionando os trabalhos correlatos e suas principais funcionalidades com a proposta apresentada?	X		
	São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
	4. REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO Os requisitos funcionais e não funcionais foram claramente descritos?	X		
	5. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados e são compatíveis com a metodologia proposta?	X		
	6. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
ASPECTOS METODOLÓGICOS	As referências contemplam adequadamente os assuntos abordados (são indicadas obras atualizadas e as mais importantes da área)?	X		
	7. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?		X	
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		

PARECER – PROFESSOR AVALIADOR: (PREENCHER APENAS NO PROJETO)

O projeto de TCC ser deverá ser revisado, isto é, necessita de complementação, se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos 5 (cinco) tiverem resposta ATENDE PARCIALMENTE.

PARECER: (x) APROVADO () REPROVADO

Assinatura: Joyce Martins _____ Data: 08/12/2020 _____

¹ Quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.

PROJETO TCC - BCC	ANO/SEMESTRE:	2020.2
-------------------	---------------	--------

DETECÇÃO DE PARKINSON ATRAVÉS DE DESENHOS EM ESPIRAL DE ARQUIMEDES E ONDAS UTILIZANDO PROCESSAMENTO DE IMAGENS

Sidnei Lanser

Prof. Aurélio Faustino Hoppe – Orientador

1 INTRODUÇÃO

De acordo com a Biblioteca Virtual em Saúde (2015, p. 1), a Doença de Parkinson (DP) é “uma doença neurológica que afeta os movimentos da pessoa. Causa tremores, lentidão de movimentos, rigidez muscular, desequilíbrio, além de alterações na fala e na escrita”. Para Andrade *et al.* (2017 apud Jacintho, 2019, p. 1), “a DP ou mal de Parkinson, é uma das doenças neurodegenerativas com maior prevalência na população mundial, manifestando-se nos mais variados tipos de pessoas, sendo mais frequente em pessoas com idade acima dos 50 anos”. Fonoff (2019b) aponta que o Parkinson é uma doença crônica degenerativa, com características evolutivas, que se manifestam em 1% da população mundial acima dos 65 anos. Além disso, também afirma que o Parkinson não afeta somente aqueles que sofrem da doença, mas também os que convivem com o paciente, uma vez que em um estágio avançado e sem o tratamento adequado, o paciente pode ficar incapaz até mesmo para cuidar de si mesmo. Fonoff (2019a) afirma que o Parkinson é uma doença que não tem cura, porém tratamentos medicamentosos podem ajudar a controlar os sintomas. Kaszubska (2019, p. 1) destaca que muitos tratamentos são eficazes, mas, quando a doença é descoberta de forma precoce. No entanto, o mais comum é que os casos sejam apenas descobertos quando os pacientes já se encontram em estágios mais avançados, passando a apresentar sintomas reconhecíveis (presença de tremores, rigidez nas pernas, braços e tronco, lentidão e diminuição dos movimentos e instabilidade na postura), que geralmente surgem quando muitas células nervosas do cérebro já sofreram danos irreversíveis.

Segundo Goulart e Pereira (2005), para determinar o estágio e a evolução da doença, os médicos normalmente utilizam alguma escala de classificação. Entre os diversos tipos de escalas que foram desenvolvidas devido à diversidade dos sintomas, sendo elas: a escala de graus de incapacidade de Hoehn e Yahr, a escala de Sydney, a escala unificada de avaliação da doença de Parkinson, chamada de Unified Parkinson's Disease Rating Scale (UPDRS), a Parkinson Activity Scale (PAS), entre outras. Tais escalas avaliam desde a condição clínica geral, as incapacidades, as funções motoras e mentais até a qualidade de vida dos pacientes. Nos exames clínicos, os médicos normalmente analisam as extremidades em situação de repouso sobre uma superfície, além de movimentos realizados em atividades cotidianas (LEITE, 2010).

De acordo com Legrand *et al.* (2017), para mensurar a gravidade do distúrbio, pode-se realizar um teste padrão onde o paciente precisa desenhar uma espiral arquimediana. Watase (2019) aponta que ela é caracterizada por ter uma distância de separação uniforme em toda suas voltas, a qual equivale à $2\pi b$. Já Almeida (2011) ressalta que a espiral arquimediana, ou espiral de Arquimedes, tem vários atributos os quais fazem com que ela tenha o uso atrativo em testes para detecção do tremor humano, entre eles, seu formato simples e fácil de entender e sua suavidade e raio crescente, o qual reduz a ocorrência de falso positivos causados por mudança na direção do movimento. Neste sentido, Chakraborty *et al.* (2020) apontam que o desenho de espirais e ondas, assim como a caligrafia, pode ser facilmente distinguida de uma pessoa para outra, bem como de uma pessoa portadora para uma não portadora da DP.

Diante deste contexto, este trabalho propõe disponibilizar um método que identifique a doença de Parkinson a partir de desenhos de espirais de Arquimedes e ondas utilizando processamento de imagens e aprendizado de máquina.

1.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar um método que identifique portadores da doença de Parkinson a partir de desenhos de espirais de Arquimedes e ondas.

Os objetivos específicos são:

- avaliar a aplicabilidade das técnicas de aprendizado de máquina e processamento de imagens quanto à detecção da DP a partir de desenhos em espirais de Arquimedes e ondas;
- identificar padrões de variabilidade da performance motora dos portadores de Parkinson;
- analisar a eficiência dos métodos desenvolvidos.

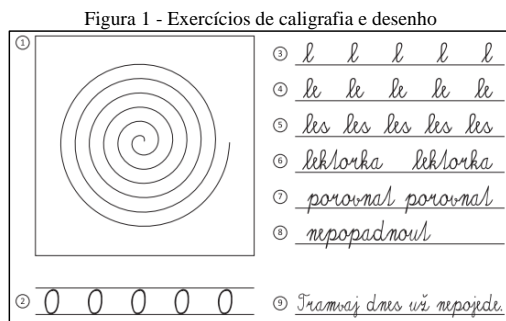
2 TRABALHOS CORRELATOS

Nesta seção são apresentados três trabalhos correlatos que possuem semelhanças à proposta deste projeto. A seção 2.1 apresenta o trabalho de Mucha *et al.* (2018), que realizaram uma comparação dos métodos tradicionais

para detecção da disgrafia com o uso de Cálculo Fracionário. A seção 2.2 descreve o trabalho de Smits *et al.* (2014), que avaliaram se a caligrafia padronizada poderia fornecer medidas quantitativas para distinguir pacientes que possuem ou não a doença de Parkinson. A seção 2.3 discorre sobre o trabalho de Zham *et al.* (2017), que analisaram a velocidade e pressão da caneta para caracterizar a doença de Parkinson.

2.1 IDENTIFICATION AND MONITORING OF PARKINSON'S DISEASE DYSGRAPHIA BASED ON FRACTIONAL-ORDER DERIVATIVES OF ONLINE HANDWRITING

Mucha *et al.* (2018) compararam um conjunto de características cinemáticas normalmente observadas em análises quantitativas da disgrafia¹ em portadores da doença de Parkinson com base em Cálculo Fracionário². Para isso, os autores utilizaram 9 amostras de diferentes exercícios de caligrafia escritos no idioma Tcheco e desenhos, de 33 pessoas portadoras da doença de Parkinson e 36 pessoas saudáveis. Os autores destacam que todos os pacientes eram destros, estavam bem descansados e sentados de forma confortável durante os testes, para que houvesse o mínimo de interferência possível de fatores exteriores. A Figura 1 apresenta os exemplos de caligrafia e desenho utilizados nos testes.



Fonte: Mucha *et al.* (2018).

Segundo Mucha *et al.* (2018), os dados foram coletados e quantificados em medidas como velocidade, aceleração e características baseadas em Cálculo Fracionário. As características foram descritas utilizando a média, mediana, desvio padrão e máximo. Tais características foram divididas em nove conjuntos de acordo com o tipo do movimento (à superfície, no ar e combinado) e a abordagem de cálculo.

Para avaliar e comparar o poder das características da caligrafia e discriminar os portadores de Parkinson dos saudáveis, Mucha *et al.* (2018) realizaram uma análise de classificação binária, no qual cada elemento deve ser classificado dentre dois grupos. Para isso, os autores utilizaram árvores de gradiente elevado, especificamente o algoritmo XGBoost, que foi escolhido devido a sua capacidade de alcançar bom desempenho, mesmo para árvores de pequeno porte.

Para treinar e avaliar os modelos, Mucha *et al.* (2018) utilizaram validação cruzada estratificada de 10 vezes com 20 repetições para os modelos de aprendizagem supervisionados. Avaliou-se o desempenho dos modelos treinados através do Coeficiente de Correlação de Matthew (CCM), Classificação de Precisão (CP), sensibilidade (SEN) e especificidade (SPE). Já em relação à avaliação da relevância das características da caligrafia para prever os valores das características clínicas selecionadas, Mucha *et al.* (2018) aplicaram a análise de regressão multivariada, árvore de impulso (XGBoost) e algoritmos de aprendizagem supervisionada. Neste caso, os modelos de regressão foram avaliados pelo Erro Médio Absoluto (EMA), Erro Médio Quadrático (EMQ) e taxa de Erro Estimada (EE).

Mucha *et al.* (2018) concluem que em comparação com os parâmetros convencionais, as características da caligrafia derivada por Cálculo Fracionário são mais significativas que as características clínicas dos pacientes e proporcionaram uma avaliação da gravidade da doença (erro em torno de 12%). Por outro lado, a maior precisão de classificação (97,14%) foi obtida pelos parâmetros convencionais, enquanto o melhor resultado obtido utilizando o Cálculo Fracionário foi de 87,14%. Mucha *et al.* (2018) sugerem que a utilização do Cálculo Fracionário em combinação com tarefas devidamente selecionadas (contínuas e/ou repetitivas, como a espiral arquimediana) poderia melhorar a avaliação computadorizada da severidade da doença de Parkinson.

¹ Disgrafia: incapacidade do indivíduo de produzir uma escrita que seja “culturalmente aceitável” (RODRIGUES; CASTRO; CIASCA, 2008).

² Cálculo Fracionário: ramo da física matemática que trata de equações integro-diferenciais (MAINARDI, 2010).


Por fim, Mucha *et al.* (2018) também apontam que os resultados obtidos ainda precisam ser confirmados por pesquisas científicas subsequentes, uma vez que o estudo tem várias limitações e sugestões de melhorias, como por exemplo, o fato da base de dados ser pequeno para generalizá-lo, ou pelo fato de utilizarem apenas medidas cinemáticas. Além disso, também destacam que para avaliar melhor as características de discriminação da doença de Parkinson pelo Cálculo Fracionário, outros tipos de recursos como temporais, espaciais e dinâmicos, devem ser considerados, assim como outras aproximações (como de Caputo) ou medidas (como a Entropia).

2.2 STANDARDIZED HANDWRITING TO ASSESS BRADYKINESIA, MICROGRAPHIA AND TREMOR IN PARKINSON'S DISEASE

Smits *et al.* (2014) fizeram um estudo a fim de avaliar se a caligrafia padronizada pode fornecer medidas quantitativas para distinguir pacientes que possuem ou não a doença de Parkinson em uma combinação semelhante de sexo e idade. Os autores desenvolveram *scripts* customizados em Matlab para analisar as tarefas de desenho e escrita, identificando através da velocidade de movimento, a bradicinesia³ e, do tamanho da escrita, a micrografia⁴. Além disso, também foi analisada a frequência para estabelecer o tremor em repouso.

Segundo Smits *et al.* (2014), foram avaliados 10 pacientes portadores da doença de Parkinson (6 homens e 4 mulheres) em fases relativamente iniciais, com idade média de 69 anos (intervalo de 63-81) e 10 pacientes não portadores da doença (6 homens e 4 mulheres), com idade média de 68 anos (intervalo de 61-78), todos destros. Cada participante realizou cinco tarefas, na mesma ordem para limitar a variabilidade dos resultados das tarefas, sendo estas: uma tarefa de repouso; traçado em círculo, desenho de linhas em oito direções diferentes e espiral (Figura 2); escrita de *el* em loop (Figura 3) e uma frase completa para avaliar a micrografia.


Figura 2 - Template utilizado para o desenho das figuras geométricas



Fonte: Smits *et al.* (2014).

De acordo com Smits *et al.* (2014), examinou-se a densidade espectral, que no pico mais elevado atingiu mais de 30 (mm/s²)/Hz para três pacientes com a doença de Parkinson, os quais foram avaliados clinicamente como tendo o tritador de repouso, enquanto para os demais participantes o resultado foi menor que 2 (mm/s²)/Hz. Os autores também observaram que o comprimento das frases e a altura do guião da frase não diferiram significativamente entre os pacientes portadores de Parkinson e os saudáveis. Já a altura da letra 'e' e a largura e altura da letra 'l' na tarefa 'elel' eram menores nos portadores de Parkinson, mas não tanto quanto a largura da letra 'e', que era significativamente menor nos pacientes com Parkinson ($p \leq 0.0014$). Além disso, nenhum outro efeito significativamente relevante foi encontrado em relação ao tamanho da escrita e à redução progressiva do tamanho da escrita, conforme pode ser visto na Figura 3, onde as amostras da esquerda são de pacientes saudáveis e as da esquerda de pacientes portadores da DP.

Figura 3 - Exemplo de tarefa "elel"



Fonte: Smits *et al.* (2014).

Smits *et al.* (2014) também notaram que os pacientes com DP realizam movimentos significativamente mais lentos do que os saudáveis. Além disso, os autores ainda relatam que os grupos foram semelhantes em função

³ Bradicinesia: lentidão de movimentos, fraqueza, tremor e rigidez (BERARDELLI *et al.*, 2001).

⁴ Micrografia: diminuição gradual do tamanho da grafia (SIMONET *et al.*, 2019).

da idade, apontando diminuição da velocidade de movimento nos pacientes com Parkinson, reflexo da bradicinesia e não apenas a lentidão relacionada com a idade. No entanto, as características de bradicinesia mostraram grandes diferenças entre os dois grupos. Contudo, Smits *et al.* (2014) destacam que quase todas as características mostraram uma clara diferença entre os grupos ($p < 0,05$), embora nem todas elas tenham sobrevivido à correção Bonferroni, que é um método para lidar com problemas de comparações múltiplas. Além disso, este estudo não inclui uma comparação com o exame clínico dos sintomas motores da doença.


Smits *et al.* (2014) concluem que as tarefas de caligrafia padronizada podem fornecer medidas quantitativas para a avaliação da bradicinesia, micrografia e tremor e que várias destas medidas distinguiram os portadores da doença de Parkinson clinicamente diagnosticados dos que não a possuem. No entanto, ressaltam que o pequeno número de amostras pode produzir resultados estatisticamente insignificativos.

2.3 DISTINGUISHING DIFFERENT STAGES OF PARKINSON'S DISEASE USING COMPOSITE INDEX OF SPEED AND PEN-PRESSURE OF SKETCHING A SPIRAL

Zham *et al.* (2017) utilizaram o Índice Composto de Velocidade e Pressão da Caneta (CISP) como característica para analisar a gravidade da doença de Parkinson. Os autores qualificam a gravidade dos sintomas motores de todos os pacientes usando a parte III da Escala de Classificação Unificada da doença de Parkinson (UPDRS)⁵ e para a avaliação geral da fase da doença usaram a Escala de Hoehn e Yahr Modificada (H&Y)⁶.

De acordo com Zham *et al.* (2017), os pacientes desenharam espirais arquimedianas guiadas em uma folha A3 no qual a velocidade, pressão da caneta e CISP foram computadas e analisadas a fim de obter sua correlação com a gravidade da doença. A Figura 4 apresenta exemplos de espirais arquimedianas.

Figura 4 - Espirais arquimedianas guiadas desenhadas pelos pacientes



Fonte: Zham *et al.* (2017).

Segundo Zham *et al.* (2017), o Teste U de Mann-Whitney⁷ confirmou que a CISP é adequada para distinguir os pacientes que possuem a doença de Parkinson dos que não a possuem, enquanto o Teste de Kruskal-Wallis⁸ confirmou que é significativamente diferente para a doença de Parkinson SL-1 e SL-3. Isso mostra que o CISP pode ser usado durante o esboço em espiral para diferenciar os portadores da doença entre SL-1 e SL-3, mas não SL-2. Já o teste não paramétrico da amostra k Kruskal-Wallis mostra que existe diferença estatisticamente significativa entre os grupos para CISP, enquanto que a velocidade e a pressão da caneta não mostraram diferença estatisticamente significativa. Isto indica que a velocidade e a pressão da caneta por si só não são adequadas para diferenciar entre os diferentes níveis de severidade.

De acordo com Zham *et al.* (2017), a velocidade, a pressão da caneta e a CISP de esboço de uma espiral estão negativamente correlacionadas com a severidade da doença de Parkinson. Eles concluem que embora estas três características tenham sido significativamente afetadas pela gravidade da doença, a correlação foi mais forte com a CISP de esboço, uma vez que a análise estatística mostrou uma diferença significativa da CISP entre SL-1 e SL-3, mas não para a velocidade e a pressão da caneta. Contudo, a CISP não foi capaz de diferenciar entre SL-1 e SL-2 ou entre SL-2 e SL-3.

⁵ UPDRS: escala da DP que avalia os sinais, sintomas e determinadas atividades dos pacientes por meio do autorrelato e da observação clínica (MELLO; BOTELHO, 2010).

⁶ H&Y: escala de avaliação da incapacidade dos portadores da DP capaz de indicar seu estado geral de forma rápida e prática (MELLO; BOTELHO, 2010).

⁷ Teste U: também conhecido como teste de Wilcoxon, compara a distribuição dos dados de uma mesma amostra avaliada mais de uma vez (CAMPOS *et al.*, 2016).

⁸ Teste de Kruskal-Wallis: teste não paramétrico para comparar mais de duas amostras sem o uso de controle local (PONTES, 2000).

3 PROPOSTA DO MÉTODO

Esta seção tem como objetivo apresentar a justificativa para o desenvolvimento do trabalho, assim como seus requisitos e a metodologia de desenvolvimento a ser usada.

3.1 JUSTIFICATIVA

No Quadro 1 há comparativo entre os trabalhos que embasam este estudo sobre a identificação da doença de Parkinson, sendo que as linhas apresentam as características e as colunas os trabalhos.

Quadro 1 - Comparativo entre trabalhos correlatos

Correlatos Características	Mucha <i>et al.</i> (2018)	Smits <i>et al.</i> (2014)	Zham <i>et al.</i> (2017)
Tipo de patologia detectada	Disgrafia	- Bradicinesia - Micrografia	Parkinson
Tipo da atividade	- Desenho em espiral - Escrita	- Repouso - Desenho em linha, círculo e espiral - Escrita	Desenho em espiral
Técnica analisada	Cálculo Fracionário	Caligrafia padronizada	CISP
Taxa de assertividade	87.14%	Não disponível	CISP sob ROC = 86,2% ROC sob CISP = 83,2%
Amostras avaliada (portadores/saudáveis)	33/36	10/10	27/28
Quantidade de exercícios avaliados	9	5	1

Fonte: elaborado pelo autor.

Conforme pode ser observado no Quadro 1, a patologia detectada em cada um dos estudos é diferente. Enquanto Mucha *et al.* (2018) detectam apenas a disgrafia, Smits *et al.* (2014) detectam a bradicinesia e também a micrografia. Já Zham *et al.* (2017) focam na doença de Parkinson. O tipo de atividade realizada para a avaliação do paciente em cada um dos estudos é muito semelhante, tendo em todos os três trabalhos uma ou mais atividades de desenho, uma ou mais atividades de escrita (exceto para Zham *et al.* (2017)). Smits *et al.* (2014) também utilizam atividades relacionadas ao tremor e repouso.

Já em relação ao número de exercícios aplicados, pode-se observar que apenas o trabalho de Zham *et al.* (2017) utilizou um exercício, mas que ainda assim, é o exercício de desenho de espirais, presente também no trabalho de Mucha *et al.* (2018) e de Smits *et al.* (2014). Apesar de Smits *et al.* (2014) utilizarem 5 exercícios, o exercício de desenho de linha contempla 8 direções diferentes. Os demais exercícios avaliados no estudo de Mucha *et al.* (2018) e de Smits *et al.* (2014) são semelhantes, diferindo apenas pelos exercícios de repouso e desenho em círculo, utilizados no estudo de Smits *et al.* (2014).

Todas as abordagens de análise foram distintas. Enquanto Mucha *et al.* (2018) analisaram a eficiência da técnica de Cálculo Fracionário, Smits *et al.* (2014) analisam a caligrafia padronizada e Zham *et al.* (2017) optaram pela CISP. Todos os trabalhos têm um número semelhante de amostras avaliadas com e sem a doença e Parkinson. Porém, a quantidade de amostras pode ser considerada pequena, uma vez que Mucha *et al.* (2018) foram os que aplicaram em um número maior de pessoas, 69 no total. Quanto à taxa de assertividade, nota-se que Mucha *et al.* (2018) e Zham *et al.* (2017) possuem uma taxa muito semelhante, com diferença de menos de 1%. Smits *et al.* (2014) não apresentam uma taxa de assertividade para seu estudo.

Diante do cenário descrito, pode-se perceber que nenhum dos trabalhos utiliza a atividade de desenho de onda como método avaliativo, ao qual será um dos métodos de desenho utilizados no trabalho proposto, junto com o método de desenho de espiral que é utilizado em todos os trabalhos. Além disso, outro diferencial deste trabalho é a utilização de técnicas de aprendizado de máquina, do tipo Rede Neurais Convolucionais, para detectar o desenho gerado e, que posteriormente, será utilizado para estabelecer o grau similaridade em relação a um gabarito ou padrões de performance motora, neste caso, a partir de técnicas de processamento de imagens. Contudo, espera-se contribuir e até mesmo facilitar o processo de detecção da doença de Parkinson em estágios iniciais da doença, assim como outros tipos de patologias, tendo como base a análise do tremor do paciente.

3.2 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

Abaixo são apresentados os requisitos funcionais (RF) e os requisitos não funcionais (RNF) do método que será desenvolvido. O método deverá:

- a) utilizar desenhos de espirais e ondas para detecção da DP (RF);
- b) realizar o realce e melhoramento das imagens (ruídos, distorções e problemas de iluminação) utilizando técnicas processamento de imagens (RF);
- c) utilizar técnicas de aprendizado de máquina, especificamente redes neurais convoluionais para realizar a detecção dos desenhos (RF);
- d) extrair informações geométricas dos espirais e ondas (RF);
- e) realizar a linearização das ondas ou espirais para um plano 2D (RF);
- f) estabelecer o grau de similaridade entre os gabaritos e os desenhos feitos pelos usuários (RF);
- g) identificar padrões que possam apontar a utilização ou não da mão dominante ou potencialmente apontar a presença de alguma patologia vinculada a DP (RF);
- h) estabelecer e disponibilizar dados sobre a performance motora dos usuários (RF);
- i) ser desenvolvida na linguagem de programação Python (RNF);
- j) utilizar as bibliotecas OpenCV para o processamento de imagens e Keras para o aprendizado de máquina (RNF);
- k) ser capaz de realizar a análise em um tempo máximo de 1 minuto (RNF).

3.3 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: pesquisar e estudar sobre Parkinson, processamento de imagem, redes neurais convolucionais e trabalhos correlatos;
- b) pesquisa e escolha do método desenho: pesquisar qual é o método de desenho mais efetivo para o cenário, seja este desenho a mão livre, ligação de pontos, contorno ou outro;
- c) composição da base de dados: coletar imagens da internet de desenhos manuais de ondas e espirais para compor uma base de dados de casos saudáveis e casos portadores de Parkinson e, caso não haja um número satisfatório de imagens, coletar também mais amostras juntamente com profissionais especialistas na doença. Durante a realização desta etapa será solicitado aos pacientes a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- d) rotulação das imagens que compõe a base de dados: rotular as imagens que compõe a base de dados separando-as em tipo de exercício, tipo de amostra (saudável ou portador de Parkinson) e em imagens de teste e treinamento da rede neural convolucional;
- e) definição da arquitetura da rede neural artificial: definir a arquitetura da rede neural artificial mais aderente ao processo de detecção do desenho feito pelo usuário;
- f) desenvolvimento do método de detecção dos desenhos: a partir do item (e) implementar o método que irá detectar desenhos utilizando a linguagem Python e a biblioteca Keras;
- g) análise dos resultados: avaliar se o método desenvolvido consegue identificar os desenhos corretamente assim verificando sua acurácia e desempenho;
- h) levantamento de formas para identificar características e calcular a similaridade: pesquisar métodos de processamento de imagens utilizados para extrair medidas ou padrões a partir de imagens;
- i) desenvolvimento: a partir do item (h) desenvolver métodos para identificar padrões motores assim como calcular o grau de similaridade entre o gabarito e o desenho feito pelo usuário utilizando a linguagem Python e a biblioteca OpenCV;
- j) testes do método: avaliar a assertividade do método e juntamente com o especialista da área verificar se ele, como um todo, pode ser utilizado para a detectar a doença ou outras patologias ligadas ao Parkinson.

As etapas serão realizadas nos períodos relacionados no Quadro 2.

Quadro 2 - Cronograma de atividades a serem realizadas

etapas / quinzenas	2020						2021											
	nov.		dez.		jan.		fev.		mar.		abr.		maio		jun.			
	1	2	1	2	1	2	1	2	1	2	1	2	1	2	1	2	1	2
levantamento bibliográfico																		
pesquisa e escolha do método desenho																		
composição da base de dados																		
rotulação das imagens que compõe a base de dados																		
definição da arquitetura da rede neural artificial																		
desenvolvimento do método de detecção dos desenhos																		
análise dos resultados																		
levantamento de formas para identificar características e calcular a similaridade																		
desenvolvimento																		
testes do método																		

Fonte: elaborado pelo autor.

4 REVISÃO BIBLIOGRÁFICA

Esta seção descreve sobre os assuntos que fundamentarão o estudo a ser realizado. A seção 4.1 discorre sobre o Parkinson e processamento de imagens. Já a seção 4.2 aborda redes neurais convolucionais.

4.1 PARKINSON E PROCESSAMENTO DE IMAGENS

A doença de Parkinson é a segunda doença neurodegenerativa mais comum, afetando de 2 a 3% da população com mais de 65 anos (POEWE *et al.*, 2017). Earls e Lee (2020) apontam que a doença de Parkinson é patologicamente caracterizada pela má distribuição e agregação da proteína alfa-nucleica em inclusões insolúveis. A DP foi descrita pela primeira vez por James Parkinson há mais de 200 anos, em um ensaio intitulado “An Essay on the Shaking Pulse”, de 1817. Apesar do tempo, ainda não se sabe qual a causa dessa neurodegeneração e o motivo pelo qual ela afeta apenas alguns indivíduos de idade avançada (CHEN; TURNBULL; REEVE, 2019).

Fonoff (2019a) aponta que ainda há um longo caminho até a cura do Parkinson, mas existem diversos tratamentos disponíveis, os quais, como apontado por Savitt, Dawson e Dawson (2006), fazem a correção de dopamina cerebral através da farmacologia. Spagnol *et al.* (2020, p. 130) apontam que tais tratamentos têm como objetivo repor a dopamina, utilizando para tal “drogas anticolinérgicas, antidepressivas, amantadina, piribedil, dopaminérgicos e a levodopa, introduzida no final da década de 1960”. Savitt, Dawson e Dawson (2006) ressaltam que apesar de fornecerem um alívio temporário, tais terapias medicamentosas, não interrompem a progressão da DP no paciente. Duker e Ezpay (2013) destacam a possibilidade de procedimentos cirúrgicos, sendo recomendados apenas para tratar os sintomas motores de rigidez e bradicinesia.

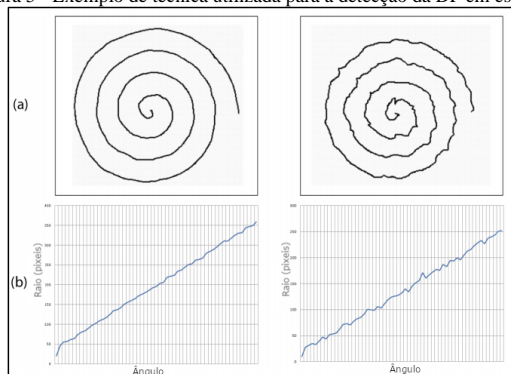
De acordo com Haase *et al.* (2017), o tremor de repouso, rigidez, bradicinesia e instabilidade postural são os sinais clínicos essenciais da doença, sendo o aparecimento dos sintomas de forma repentina raro. A rigidez não é evidente na fase inicial da DP, no qual os pacientes com frequência se queixam de “peso” e “dureza” dos membros. Quando se trata de rigidez, existem dois tipos: sinal da roda denteada (alterna contração e relaxamento) e o sinal do cano de chumbo (resistência uniforme) (UMPHRED, 2004 apud HAASE *et al.*, 2017, p. 80).

Delisa e Gans (2002, apud HAASE *et al.*, 2017, p. 81) também apontam que a bradicinesia é um dos sinais que mais diferenciam a DP de outras alterações motoras. Uniyal e Raychoudhury (2014) destacam que 90% dos pacientes da DP sofrem de perturbações na fala e voz. Com a evolução da doença, novas alterações surgem, comprometendo assim a qualidade de vida do paciente. Segundo Uniyal e Raychoudhury (2014), apesar de não ser fatal, a doença pode levar a uma grave incapacidade do paciente entre 10 e 20 anos.

Para detectar a DP, segundo Moreira *et al.* (2007), realiza-se exames clínicos e físicos. Nutt e Wooten (2005, p. 1021, tradução nossa) apontam que são avaliados para um diagnóstico a “[...] presença das principais características de lentidão e escassez de movimentos (bradicinesia e akinesia) e tremor quando o membro está em repouso ou em resistência ao movimento passivo das articulações (rigidez), ou ambos.”. Outro método utilizado para avaliar a gravidade dos sintomas motores da DP, conforme apontado por Kuosmanen *et al.* (2019), é o desenho em espiral, o qual costuma ser realizado com caneta e papel, sob observação de um clínico. Barbosa e Sallem (2019) apontam que em fases iniciais ou até mesmo quando mais avançada, o reconhecimento pode ser mais difícil, uma vez que o quadro clínico pode se apresentar de forma fragmentária, sendo dividida em dois tipos básicos: (i) aquela no qual há a presença de acinesia e/ ou rigidez, chamada de forma rígidoacinetica; (ii) aquela que apenas o tremor está presente, chamada de forma hipercinetica.

Kuosmanen *et al.* (2019, p. 1) ressaltam que o uso do desenho em espiral é um teste padrão para a avaliação de pacientes com perturbações de movimento. A Figura 5 apresenta um exemplo da detecção da DP, onde no item (a) encontra-se o espiral desenhado por um paciente saudável (à esquerda) e por um portador da DP (à direita). No item (b), pode-se observar as suas respectivas linearizações.

Figura 5 - Exemplo de técnica utilizada para a detecção da DP em espirais



Fonte: Surangsirart e Thanawattano (2012)

Segundo Almeida (2011), a técnica de linearização consiste em transformar o desenho da espiral em uma linha de coordenadas polares, facilitando assim o processo de estimativa do tremor. A partir dela, estima-se a diferença entre a linearização da espiral desenhada pelo paciente e a considerada “ideal”. Além disso, Surangsirart e Thanawattano (2012) destacam que outras características podem ser utilizadas para complementar a análise junto ao desenho da espiral, por exemplo, a pressão exercida sobre a caneta e o tempo que o paciente demora para completar a atividade de desenho. Para obter-se a linearização, primeiro se faz necessário a detecção do desenho da espiral. Para tal, um dos algoritmos disponíveis é a Transformada de Hough.

Segundo Tarsha-Kurdi, Landes e Grussenmeyer (2007), a Transformada de Hough costuma ser usada no processamento de imagens para a detecção de primitivos geométricos. Porém, como apontado por Hassanein *et al.* (2015), ao longo dos anos vem sendo usada para vários outros tipos de análise ou até mesmo para identificação de formas irregulares.

Após a identificação da linha, segundo Watase (2019), realiza-se a linearização da espiral através da obtenção das coordenadas X e Y da mesma e sua conversão para uma função do raio, na qual o ângulo deve ser zero (quando a espiral for uma espiral “ideal”), ou seja, uma reta. Para isso, Almeida (2011) aplica a seguinte operação: (1) $x = r \cos(\theta)$; (2) $y = r \sin(\theta)$; (3) $r = \sqrt{x^2 + y^2}$; (4) $r = m\theta$. Após a linearização, é preciso comparar ambas as imagens (a reta “ideal” e a desenhada pelo paciente) para saber se a reta desenhada pelo paciente corresponde à “ideal”.

4.2 REDES NEURAIS CONVOLUCIONAIS


Segundo Schmidhuber (2015), a primeira rede neural artificial que mereceu o atributo de “profunda”, foi a Neocognitron, proposta por Kuniyihiko Fukushima em 1979. Ela originou as redes neurais convolucionais (em inglês, *Convolutional Neural Network* (CNN)), no qual “[...] o campo receptivo (tipicamente retangular) de uma unidade convolutiva com determinado peso de vetor (um filtro) é deslocado passo a passo através de uma matriz bidimensional de valores de entrada, tais como os pixels de uma imagem (normalmente existem vários filtros deste tipo)” (SCHMIDHUBER, 2015, p. 10, tradução nossa).

De acordo com Brownlee (2018), a CNN é uma rede neural artificial que se tornou dominante em várias tarefas da visão computacional, sendo o método mais utilizado para qualquer tipo de problema de análise envolvendo uma imagem como dado de entrada, uma vez que esta tem muita habilidade para desenvolver uma representação interna de imagens bidimensionais. Para Yamashita *et al.* (2018), uma CNN é projetada para aprender automaticamente e de forma adaptável através de retropropagação. Ainda segundo os autores, ela se diferencia de outros métodos empregados na área pois não requer a extração de características de modo artesanal e, ao mesmo tempo, por necessitar de muito mais dados, devido aos seus milhões de parâmetros de aprendizagem.

Segundo Vinayakumar, Soman e Poornachandran (2017, p. 1224, tradução nossa), a CNN “é composta por uma camada *convolution 1D*, uma camada *pooling 1D*, uma camada *fully connected* e uma função não linear de ativação *ReLU*” e é uma extensão das tradicionais Feedforward Neural Networks (FNN). Na Figura 6 pode-se observar uma clássica arquitetura CNN.

Comentado [AS1]: Nomes de pacotes, classes, entidades, atributos, métodos ou diálogos de interface devem ser escritos em fonte courier (tem estilo). Corrija os demais.

Figura 6 - Arquitetura CNN



Fonte: Chatterjee (2019).

A partir da Figura 6 pode observar que uma CNN é composta pelas seguintes camadas: (a) *input*, corresponde à imagem de entrada; (b) *convolution*, é uma camada composta por uma série de filtros os quais são chamados de *kernel* e representam uma característica cada. Caso o filtro passe pela imagem e encontre algo que corresponda ao que está procurando, a operação *convolucional* gerará um grande número, ativando assim o filtro para tal característica. Caso contrário, o filtro não é ativado; (c) *relu*, que é uma camada de ativação a qual está presente após a camada *convolucional* (item b) e que ajuda a rede com a aprendizagem das funções difíceis e também com a redução do *overfitting*; (d) *pooling*, é um vetor de transformação escalar, o qual, assim como as convoluções, opera em cada região da imagem. Krinski e Todt (2019) apontam que nesta camada um filtro passa sobre o dado de entrada (item a) e as operações *max* (máximo), *min* (mínimo) e *avg* (média) de *pooling* são aplicadas; (e) *flatten*, essa camada costuma ser usada na divisão das duas partes da CNN: *Hidden layer* e *Classification*. Segundo Wang *et al.* (2020), é uma camada de nivelamento muitas vezes necessária antes da classificação para que a camada *fully connected* (item f) possa realizar as classificações; (f) *fully connected* é uma *Perceptron* multicamada composta por três outras camadas, sendo elas: (i) *input*: camada para qual a CNN manda as características geradas; (ii) *hidden*: é uma sequência de neurônios que aprenderão durante o treino da CNN. Pode haver mais de uma camada *hidden* em uma *perceptron* multicamadas; (iii) *output*: é também uma sequência de neurônios, porém com ativação diferente; (g) a função *softmax* costuma ser usada em um problema para gerar para cada categoria as suas probabilidades.

De acordo com Shrestha e Mahmood (2019, p. 53040, tradução nossa), a implementação de uma rede neural é constituída por “(1) obter o conjunto de dados de treino e de teste; (2) treinar a rede; (3) fazer a predição com o dado de teste”. Quanto as arquiteturas da CNN, Ingargiola (2019) aponta que elas têm uma vaga inspiração no córtex visual. Ainda segundo o autor, após ganhar um concurso com grande margem, a arquitetura AlexNet deu início à uma onda de interesse em *Deep Learning*.

De acordo com Yuan e Zhang (2016 apud Jiang *et al.*, 2019, p. 4), a AlexNet é uma rede CNN de estrutura pouco profunda, sendo capaz de extrair muitas características da imagem. Shin *et al.* (2016) destacam outras arquiteturas diferentes da AlexNet, entre elas a GoogLeNet-CNN, segundo Alaskar *et al.* (2019), utilizada para a extração e classificação de características e, a ImageNet, que segundo Kornblith e Shlens (2019), é uma base de dados utilizada por outras arquiteturas de rede para reconhecimento de objetos.

REFERÊNCIAS

- ALASKAR, Haya *et al.* Application of Convolutional Neural Networks for Automated Ulcer Detection in Wireless Capsule Endoscopy Images. *Sensors*, [S.l.], v. 19, n. 6, p. 1265-1281, mar. 2019.
- ALMEIDA, Maria F. S. de. *Análise Temporal da Relação entre o Tremor Fisiológico Cinético e o Envelhecimento com Base em Desenhos Digitalizados da Espiral de Arquimedes*. 2011. 145 f. Tese (Doutorado) - Curso de Engenharia Elétrica, Universidade Federal de Uberlândia, Uberlândia.
- BARBOSA, Egberto Reis; SALLEM, Flávio Augusto Sekeff. Doença de Parkinson. *Revista Neurociências*, [S.l.], v. 13, n. 3, p. 158-165, jan. 2019.
- BERARDELLI, Alfredo *et al.* Mark. Pathophysiology of bradykinesia in Parkinson's disease. *Brain*, [S.l.], v. 124, n. 11, p. 2131-2146, nov. 2001.
- BIBLIOTECA VIRTUAL EM SAÚDE. *Doença de Parkinson*. [S.l.], [2015]. Disponível em: <<https://bvsm.sau.de.gov.br/dicas-em-sau-de/2059-doenca-de-parkinson>>. Acesso em: 02 set. 2020.
- BROWNLEE, Jason. **When to use MLP, CNN, and RNN neural networks**: What neural network is appropriate for your predictive modeling problem?. [S.l.], [2019]. Disponível em: <<https://machinelearningmastery.com/when-to-use-mlp-cnn-and-rnn-neural-networks/>>. Acesso em: 10 out. 2020.

CAMPOS, Maene *et al.* Confiabilidade do Teste dos Cinco Dígitos em adultos brasileiros. **Jornal Brasileiro de Psiquiatria**, [S.l.], v. 65, n. 2, p. 135-139, jun. 2016.

CHAKRABORTY, Sabyasachi *et al.* Parkinson's Disease Detection from Spiral and Wave Drawings using Convolutional Neural Networks: a multistage classifier approach. In: 22ND INTERNATIONAL CONFERENCE ON ADVANCED COMMUNICATION TECHNOLOGY (ICACT), 2020, PyeongChang. **Proceedings Of The Ieee**, PyeongChang: IEEE, 2020, p. 298-303.

CHATTERJEE, Chandra C. **Basics of the Classic CNN**: how a classic cnn (convolutional neural network) work?. [S.l.], [2019]. Disponível em: <<https://towardsdatascience.com/basics-of-the-classic-cnn-a3dce1225add>>. Acesso em: 10 nov. 2020.

CHEN, Chun; TURNBULL, Doug M.; REEVE, Amy K.. Mitochondrial Dysfunction in Parkinson's Disease—Cause or Consequence? **Biology**, [S.l.], v. 8, n. 2, p. 38-64, 11 maio 2019.

DUKER, Andrew P.; ESPAY, Alberto J.. Surgical Treatment of Parkinson Disease. **Neurologic Clinics**, [S.l.], v. 31, n. 3, p. 799-808, ago. 2013.

EARLS, Rachael H.; LEE, Jae-Kyung. The role of natural killer cells in Parkinson's disease. **Experimental & Molecular Medicine**, [S.l.], p. 1517-1525, set. 2020.

FONOFF, Erich. **A doença de Parkinson tem cura?** [S.l.], [2019a] Disponível em: <<https://www.erichfonoff.com.br/parkinson-tem-cura/>>. Acesso em: 10 out. 2020.

FONOFF, Erich. **Doença de Parkinson**. [S.l.], [2019b] Disponível em: <<https://www.erichfonoff.com.br/doenca-de-parkinson/>>. Acesso em: 09 out. 2020.

GOULART, Fátima; PEREIRA, Luciana X. Uso de escalas para avaliação da doença de Parkinson em fisioterapia. **Fisioterapia e Pesquisa**, [S.l.], v. 11, n. 1, p. 49-56, abr. 2005.

HAASE, Deisy C. B *et al.* Atuação da fisioterapia no paciente com Doença de Parkinson. **Fisioterapia em Movimento**, [S.l.], v. 21, n. 1, set. 2017.

HASSANEIN, Allam S. *et al.* A Survey on Hough Transform, Theory, Techniques and Applications. **IJCSI International Journal of Computer Science Issues**, [S.l.], v. 12, n. 2, p. 139-156, jan. 2015.

INGARGIOLA, Antonino. **Deep-dive into Convolutional Networks**: from the building-blocks to the most advanced architectures, touching on interpretability, and bias. [S.l.], [2019]. Disponível em: <<https://towardsdatascience.com/deep-dive-into-convolutional-networks-48db75969fdf>>. Acesso em: 19 nov. 2020.

JACINTHO, Juan Carlos. **Protótipo de baixo custo para quantizar tremores na doença de Parkinson**. 2019. 6 f. TCC (Graduação) - Curso de Ciência da Computação, Furb - Universidade Regional de Blumenau, Blumenau.

JIANG, Bo *et al.* Fusion of machine vision technology and AlexNet-CNNs deep learning network for the detection of postharvest apple pesticide residues. **Artificial Intelligence in Agriculture**, [S.l.], v. 1, p. 1-8, mar. 2019.

KASZUBSKA, Gosia. **Screening tech advances early detection of Parkinson's disease**: Screening technology to catch Parkinson's disease in its earliest stages could be available within three years, following an agreement between RMIT University and start-up company Jesse Medical. [S.l.], [2019]. Disponível em: <https://www.rmit.edu.au/news/all-news/2019/nov/screening-tech-detection-parkinsons>. Acesso em: 06 set. 2020.

KORNBLITH, Simon; SHLENS, Jonathon. Do Better ImageNet Models Transfer Better?. In: CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2019, [S.l.]. **Proceedings Of The Ieee**, [S.l.]: IEEE, 2019, p. 2661-2671.

KRINSKI, Bruno Alexandre; TODT, Eduardo. Convolutional neural network. [S.l.], 30 nov. 2019. Disponível em: http://www.inf.ufpr.br/todt/IAaplicada/CNN_Presentation.pdf. Acesso em: 26 nov. 2020.

KUOSMANEN, Elina *et al.* Measuring Parkinson's disease motor symptoms with smartphone-based drawing tasks. In: THE 2019 ACM INTERNATIONAL JOINT CONFERENCE ON PERSASIVE AND UBIQUITOUS COMPUTING, 2019, New York. **Proceedings Of The 2019 Acm International Joint Conference On Pervasive And Ubiquitous Computing And Proceedings Of The 2019 Acm International Symposium On Wearable Computers - Ubicomp/ISWC '19**, Londres: Association for Computing Machinery, 2019, p. 1182-1185.

LEGRAND, André Pierre *et al.* New insight in spiral drawing analysis methods – Application to action tremor quantification. **Clinical Neurophysiology**, [S.l.], v. 128, n. 10, p. 1823-1834, out. 2017.

LEITE, Marco A. A. Tremor essencial. **Revista Hospital Universitário Pedro Ernesto**. Rio de Janeiro, v. 9, n. 1, p. 20-29, jan/jun. 2010.

MAINARDI, Francesco. **Fractional calculus and waves in linear viscoelasticity**: an introduction to mathematical models. [S.l.]: Imperial College Press, 2010.

MELLO, Marcella P. B. de; BOTELHO, Ana C. G. Correlação das escalas de avaliação utilizadas na doença de Parkinson com aplicabilidade na fisioterapia. **Fisioterapia em Movimento**, [S.l.], v. 23, n. 1, p. 121-127, mar. 2010.

Comentado [AS2]: Não está de acordo com a norma.

Comentado [AS3]: Não está de acordo com a norma.

MOREIRA, Camilla S. *et al.* Doença de Parkinson: como diagnosticar e tratar. **Revista Científica da Faculdade de Medicina de Campos**, [S.l.], v. 2, n. 2, p. 19-29, dez. 2007.

MUCHA, Jan *et al.* Identification and Monitoring of Parkinson's Disease Dysgraphia Based on Fractional-Order Derivatives of Online Handwriting. **Applied Sciences**, [S.l.], v. 8, n. 12, p. 2566-2583, 11 dez. 2018.

NUTT, John G.; WOOTEN, G. Frederick. Diagnosis and Initial Management of Parkinson's Disease. **New England Journal of Medicine**, [S.l.], v. 353, n. 10, p. 1021-1027, 8 set. 2005.

POEWE, Werner *et al.* Parkinson disease. **Nature Reviews Disease Primers**, [S.l.], v. 3, n. 49-55, p. 1, mar. 2017.

PONTES, Antonio Carlos Fonseca. **Obtenção dos níveis de significância para os testes de Kruskal-Wallis, Friedman e comparações múltiplas não-paramétricas**. 2000. 142 f. Dissertação (Mestrado) - Curso de Agronomia, Escola Superior de Agricultura Luiz de Queiroz, Piracicaba.

RODRIGUES, Sônia das D.; CASTRO, Maria J. M. G. de; CIASCA, Sylvia M. Relação entre indícios de disgrafia funcional e desempenho acadêmico. **Revista Cefac**, [S.l.], v. 11, n. 2, p. 221-227, dez. 2008.

SAVITT, Joseph. M.; DAWSON, Valina L.; DAWSON, Ted M. Diagnosis and treatment of Parkinson disease: molecules to medicine. **Journal of Clinical Investigation**, [S.l.], v. 116, n. 7, p. 1744-1754, jul. 2006.

SCHMIDHUBER, Jürgen. Deep learning in neural networks: an overview. **Neural Networks**, [S.l.], v. 61, p. 85-117, jan. 2015.

SHIN, Hoo-Chang *et al.* Deep Convolutional Neural Networks for Computer-Aided Detection: cnn architectures, dataset characteristics and transfer learning. **IEEE Transactions on Medical Imaging**, [S.l.], v. 35, n. 5, p. 1285-1298, maio 2016.

SHRESTHA, Ajay; MAHMOOD, Ausif. Review of Deep Learning Algorithms and Architectures. **IEEE Access**, [S.l.], v. 7, p. 53040-53065, abr. 2019.

SIMONET, Claire *et al.* The motor prodromes of parkinson's disease: from bedside observation to large-scale application. **Journal of Neurology**, [S.l.], p. 1-1, dez. 2019.

SPAGNOL, Giovanna Pereira *et al.* Tratamentos Farmacológicos e Cirúrgicos da Doença de Parkinson: uma revisão da literatura. **Diário da Teoria e Prática na Enfermagem** 3, [S.l.], p. 128-136, fev. 2020.

SMITS, Esther J *et al.* Standardized Handwriting to Assess Bradykinesia, Micrographia and Tremor in Parkinson's Disease. **Plos One**, [S.l.], v. 9, n. 5, p. 1, 22 maio 2014.

SURANGSRIRAT, Decho; THANAWATTANO, Chusak. Android application for spiral analysis in Parkinson's Disease. In: 2012 PROCEEDINGS OF IEEE SOUTHEASTCON, 2012, Orlando. **2012 Proceedings of IEEE-IEEE Southeastcon**, Orlando: IEEE, 2012, p. 1-6, mar.

TARSHA-KURDI, Fayez; LANDES, Tania; GRUSSENMEYER, Pierre. Hough-Transform and Extended RANSAC Algorithms for Automatic Detection of 3D Building Roof Planes from Lidar Data. In: ISPRS WORKSHOP ON LASER SCANNING 2007 AND SILVILASER 2007, 2007, Espoo. **Proceedings...** Espoo: HAL, 2007, p.407-412.

UNIYAL, Deepak; RAYCHOUDHURY, Vaskar. Pervasive Healthcare: A Comprehensive Survey of Tools and Techniques. **Arxiv**, [S.l.], p. 1-48. 7 nov. 2014.

VINAYAKUMAR, Ravi; SOMAN, Kotti. P.; POORNACHANDRAN, Prabakaran. Applying convolutional neural network for network intrusion detection. In: 2017 INTERNATIONAL CONFERENCE ON ADVANCES IN COMPUTING, COMMUNICATIONS AND INFORMATICS (ICACCI), 2017, [S.l.]. **Proceedings of The IEEE**, [S.l.]: IEEE, 2017, p. 1222-1228.

WANG, Zijie J *et al.* CNN EXPLAINER: learning convolutional neural networks with interactive visualization. In: IEEE TRANSACTIONS ON VISUALIZATION AND COMPUTER GRAPHICS, 2020, [S.l.]. **Proceedings of The IEEE**, [S.l.]: IEEE, 2020, p. 1-11.

WATASE, Gabriela Sayuri. **Desenvolvimento de um software para a classificação de tremor de membro superior a partir de movimentos de escrita**. 2019. 35 f. TCC (Graduação) - Curso de Engenharia Biomédica, Universidade Federal do Abc, São Bernardo do Campo.

YAMASHITA, Rikiya *et al.* Convolutional neural networks: an overview and application in radiology. **Insights Into Imaging**, [S.l.], v. 9, n. 4, p. 611-629, jun. 2018.

ZHAM, Poonam *et al.* Distinguishing Different Stages of Parkinson's Disease Using Composite Index of Speed and Pen-Pressure of Sketching a Spiral. **Frontiers in Neurology**, [S.l.], v. 8, p. 1-7, set. 2017.

Formatado: Português (Brasil)

Comentado [AS4]: Não está de acordo com a norma.

Comentado [AS5]: Não está de acordo com a norma.

ASSINATURAS

(Atenção: todas as folhas devem estar rubricadas)

Assinatura do(a) Aluno(a): _____

Assinatura do(a) Orientador(a): _____

Assinatura do(a) Coorientador(a) (se houver): _____

Observações do orientador em relação a itens não atendidos do pré-projeto (se houver):

FORMULÁRIO DE AVALIAÇÃO – PROFESSOR TCC I

Acadêmico(a): Sidnei Lanser _____

Avaliador(a): Andreza Sartori _____

ASPECTOS AVALIADOS ¹		atende	atende parcialmente	não atende
ASPECTOS TÉCNICOS	1. INTRODUÇÃO O tema de pesquisa está devidamente contextualizado/delimitado?	X		
	O problema está claramente formulado?	X		
	2. OBJETIVOS O objetivo principal está claramente definido e é passível de ser alcançado?	X		
	Os objetivos específicos são coerentes com o objetivo principal?	X		
	3. JUSTIFICATIVA São apresentados argumentos científicos, técnicos ou metodológicos que justificam a proposta?	X		
	São apresentadas as contribuições teóricas, práticas ou sociais que justificam a proposta?	X		
ASPECTOS METODOLÓGICOS	4. METODOLOGIA Foram relacionadas todas as etapas necessárias para o desenvolvimento do TCC?	X		
	Os métodos, recursos e o cronograma estão devidamente apresentados?	X		
	5. REVISÃO BIBLIOGRÁFICA (atenção para a diferença de conteúdo entre projeto e pré-projeto) Os assuntos apresentados são suficientes e têm relação com o tema do TCC?	X		
	6. LINGUAGEM USADA (redação) O texto completo é coerente e redigido corretamente em língua portuguesa, usando linguagem formal/científica?	X		
	A exposição do assunto é ordenada (as ideias estão bem encadeadas e a linguagem utilizada é clara)?	X		
	7. ORGANIZAÇÃO E APRESENTAÇÃO GRÁFICA DO TEXTO A organização e apresentação dos capítulos, seções, subseções e parágrafos estão de acordo com o modelo estabelecido?	X		
	8. ILUSTRAÇÕES (figuras, quadros, tabelas) As ilustrações são legíveis e obedecem às normas da ABNT?	X		
	9. REFERÊNCIAS E CITAÇÕES As referências obedecem às normas da ABNT?	X		
	As citações obedecem às normas da ABNT?	X		
	Todos os documentos citados foram referenciados e vice-versa, isto é, as citações e referências são consistentes?	X		

PARECER – PROFESSOR DE TCC I OU COORDENADOR DE TCC (PREENCHER APENAS NO PROJETO):

O projeto de TCC será reprovado se:

- qualquer um dos itens tiver resposta NÃO ATENDE;
- pelo menos 4 (quatro) itens dos **ASPECTOS TÉCNICOS** tiverem resposta ATENDE PARCIALMENTE; ou
- pelo menos 4 (quatro) itens dos **ASPECTOS METODOLÓGICOS** tiverem resposta ATENDE PARCIALMENTE.

PARECER: (x) APROVADO () REPROVADO

Assinatura: _____ Data: 05/12/2020 _____

¹ Quando o avaliador marcar algum item como atende parcialmente ou não atende, deve obrigatoriamente indicar os motivos no texto, para que o aluno saiba o porquê da avaliação.